

Perbandingan Akurasi ChatGPT Menggunakan Chain-of-Thought dan Non-Chain-of-Thought pada IndoMMLU

Elvira Gladys Samsul¹, Muhammad Arhami^{2*}, Muhammad Rizka³

^{1,2,3} Jurusan Teknologi Informasi dan Komputer, Politeknik Negeri Lhokseumawe, Indonesia

*Penulis Korespondensi: muhammad.arhami@pnl.ac.id

This is an open access article under the [CC-BY-SA](#) license.



Abstrak

Perkembangan *Large Language Model* (LLM) seperti ChatGPT meningkatkan kemampuan pemahaman bahasa alami, namun kemampuannya dalam konteks bahasa dan budaya lokal Indonesia masih perlu dievaluasi karena sebagian besar pengujian dilakukan menggunakan dataset berbahasa Inggris. Penelitian ini mengukur akurasi jawaban GPT-4o mini pada soal *Multiple Choice Question* (MCQ) dataset IndoMMLU domain bahasa menggunakan algoritma *Levenshtein Distance*, serta membandingkan efektivitas metode *Chain-of-Thought* (CoT) dan *Non-Chain-of-Thought* (Non-CoT). Pengujian dilakukan melalui empat skenario terhadap sembilan domain bahasa daerah dengan total hingga 900 soal, mengukur nilai *similarity*, akurasi *exact match*, penggunaan token, dan waktu respons. Hasil menunjukkan pengujian per domain menghasilkan *similarity* rata-rata 67,66% (CoT) dan 66,65% (Non-CoT), dengan 483 dan 454 jawaban benar dari 900 soal. Pengujian gabungan skala besar menempatkan Non-CoT lebih stabil dengan *similarity* tertinggi 70,18% dibanding CoT 69,37%. Bahasa Indonesia mencapai *similarity* tertinggi (95,92%), sedangkan bahasa daerah lain berkisar 55,49%–77,23%. Metode CoT membutuhkan token sekitar 5,2 kali lebih besar dan waktu respons tiga hingga empat kali lebih lama dibanding Non-CoT. Temuan ini menunjukkan efektivitas *Chain-of-Thought* tidak konsisten meningkatkan kualitas jawaban GPT-4o mini, melainkan bergantung pada karakteristik domain bahasa dan skala pengujian.

Kata kunci: ChatGPT, *Chain-of-Thought*, IndoMMLU, *Levenshtein Distance*, *Large Language Model*.

1. Pendahuluan

Perkembangan teknologi *Artificial Intelligence* (AI) khususnya pada bidang *Natural Language Processing* (NLP) telah mengalami lompatan besar dengan diperkenalkannya *Large Language Model* (LLM) [1]. Peningkatan skala parameter dan cakupan data pelatihan membuat LLM mampu menyelesaikan beragam tugas bahasa, meskipun disertai keterbatasan berupa kebutuhan sumber daya komputasi yang besar serta tingkat akurasi yang bervariasi menurut konteks penggunaannya [2]. Salah satu implementasi LLM yang paling populer dan banyak digunakan di berbagai sektor adalah ChatGPT yang dikembangkan oleh OpenAI. Model ini disempurnakan melalui pendekatan *Reinforcement Learning from Human Feedback* (RLHF) sehingga mampu memahami instruksi pengguna, menghasilkan teks alami, serta melakukan penalaran logis dalam menjawab berbagai pertanyaan yang kompleks [3], [4].

LLM menunjukkan kinerja yang sangat baik dalam bahasa beresumber daya tinggi (*high-resource language*) seperti Bahasa Inggris dan Bahasa Indonesia formal, namun performa LLM dalam memahami ragam bahasa daerah di Indonesia masih menjadi tantangan yang terbuka [5]. Indonesia memiliki lebih dari 700 bahasa daerah dengan struktur sintaksis, kosakata, dan konteks sosio-kultural yang unik. Keterbatasan ketersediaan korpus digital untuk bahasa daerah (*low-resource regional languages*) menyebabkan LLM sering kali mengalami kesalahan pemahaman semantik maupun halusinasi ketika merespons pertanyaan berbasis bahasa daerah [4]. Kondisi serupa juga dilaporkan pada bahasa non-Inggris lainnya, yaitu keandalan jawaban model sangat dipengaruhi oleh struktur linguistik dan cakupan korpus pelatihan sehingga memerlukan strategi evaluasi yang spesifik [6].

Evaluasi kemampuan LLM umumnya dilakukan menggunakan soal pilihan ganda (*Multiple Choice Question*/MCQ) karena formatnya mudah distandarisasi dan memungkinkan penilaian objektif pada berbagai domain pengetahuan [7]. Namun, penilaian yang hanya bertumpu pada pencocokan huruf opsi belum sepenuhnya menggambarkan

kemampuan model karena mengabaikan narasi jawaban yang dihasilkan [8]. Untuk mengoptimalkan kemampuan penalaran LLM tanpa melakukan proses pelatihan ulang model (*fine-tuning*) yang memakan biaya komputasi tinggi, teknik rekayasa *prompt* (*prompt engineering*) menjadi solusi yang sangat efektif [9]. Dua pendekatan *prompting* utama yang sering digunakan adalah *Non-Chain-of-Thought* (Non-CoT) dan *Chain-of-Thought* (CoT). Non-CoT merupakan pendekatan konvensional yang meminta model memberikan jawaban akhir secara langsung (*direct answer*). Sebaliknya, pendekatan CoT mengarahkan model untuk menguraikan langkah-langkah pemikiran dan penalaran secara bertahap (*step-by-step reasoning*) sebelum sampai pada kesimpulan jawaban akhir [10], [11].


Penelitian terkini mengenai efektivitas CoT pada berbagai tugas penalaran menunjukkan hasil yang bervariasi. Sejumlah studi membuktikan bahwa CoT mampu meningkatkan kualitas penalaran dan akurasi model, misalnya pada penilaian otomatis jawaban siswa [12] serta pada ujian profesional dwibahasa [13]. Sebaliknya, studi lain melaporkan bahwa CoT tidak selalu memberikan peningkatan yang konsisten dan pada sebagian pertanyaan justru menghasilkan performa yang setara atau lebih rendah dibandingkan *prompting* standar [14], sehingga efektivitasnya sangat bergantung pada jenis tugas dan konteks bahasa yang digunakan [15]. Kualitas penalaran CoT juga rentan terhadap kesalahan berantai karena kekeliruan pada satu langkah penalaran dapat memengaruhi jawaban akhir [16]. Selain itu, pendekatan CoT menghasilkan teks penalaran yang panjang sehingga berdampak langsung pada lonjakan konsumsi token dan latensi komputasi API [2]. Efektivitas CoT pada domain bahasa daerah di Indonesia yang memiliki keragaman dialek dan struktur morfologi kompleks pun belum banyak dievaluasi secara komprehensif dan kuantitatif [5].

Pencocokan opsi jawaban secara eksak belum mengukur kesesuaian narasi jawaban model dengan jawaban referensi [17]. Pendekatan berbasis kemiripan teks (*text similarity*) digunakan untuk mengukur derajat kesamaan susunan teks jawaban model terhadap referensi secara langsung [18]. Oleh karena itu, penelitian ini bertujuan untuk menganalisis dan membandingkan akurasi jawaban ChatGPT (menggunakan model GPT-4o mini) dengan metode *Chain-of-Thought* dan *Non-Chain-of-Thought* pada *benchmark* dataset IndoMMLU [5]. Evaluasi dilakukan pada 9 domain bahasa (Bahasa Lampung, Bali, Makassar, Banjar, Madura, Indonesia, Dayak Ngaju, Sunda, dan Jawa) yang mencakup 4 skenario pengujian. Tingkat akurasi dan derajat kemiripan teks jawaban model terhadap kunci jawaban referensi diukur secara objektif menggunakan algoritma *Levenshtein Distance* [19], [20], serta dilengkapi dengan analisis efisiensi komputasi terhadap jumlah token dan waktu respons.

2. Metode

2.1 Arsitektur Sistem Evaluasi

Sistem evaluasi dirancang untuk menguji performa model GPT-4o mini secara otomatis dan terukur. Arsitektur sistem terdiri atas dua subsistem utama, yaitu tahap *preprocessing* dataset IndoMMLU dan tahap evaluasi akurasi jawaban menggunakan OpenAI API yang terintegrasi dengan algoritma pengukuran kemiripan teks *Levenshtein Distance*. Alur kerja sistem disajikan pada Gambar 1.



Gambar 1. Arsitektur Sistem Evaluasi

2.2 Dataset Penelitian dan Tahapan Preprocessing

Dataset penelitian bersumber dari *Indonesian Massive Multitask Language Understanding* (IndoMMLU) [5]. Penelitian ini memfokuskan pengujian pada 9 domain bahasa, yaitu Bahasa Lampung, Bahasa Bali, Bahasa Makassar, Bahasa Banjar, Bahasa Madura, Bahasa Indonesia, Bahasa Dayak Ngaju, Bahasa Sunda, dan Bahasa Jawa. Masing-masing domain bahasa terdiri atas 100 butir soal pilihan ganda (*multiple-choice questions*), sehingga total sampel data primer berjumlah 900 butir soal.

Dataset IndoMMLU mentah melewati empat tahapan *preprocessing* sebelum pengujian dijalankan:

1. Filtering Domain Bahasa, yaitu menyaring data soal agar hanya memuat 9 domain bahasa yang diteliti
2. Seleksi dan Penataan Kolom Data, yaitu memilih atribut penting (nomor, subject, soal, jawaban, dan kunci)

3. Pembentukan Narasi Jawaban Referensi (*jawaban_benar_teks*), yaitu mengekstrak teks murni pilihan jawaban benar secara otomatis berdasarkan kolom kunci tanpa huruf opsi (A/B/C/D/E) untuk evaluasi kemiripan teks;
4. Normalisasi Format Teks, yaitu menyeragamkan format UTF-8 dan pembersihan karakter spasi berlebih. Struktur master dataset hasil *preprocessing* disajikan pada Tabel 1.

Tabel 1: Struktur Kolom Dataset IndoMMLU Hasil Preprocessing

No	Nama Data	Sumber	Keterangan
1	nomor	IndoMMLU	Penanda urutan nomor soal
2	subject	IndoMMLU	Penanda domain bahasa soal
3	soal	IndoMMLU	Teks pertanyaan pilihan ganda
4	jawaban	IndoMMLU	Opsi pilihan jawaban pilihan ganda (A, B, C, D, E)
5	kunci	IndoMMLU	Penanda huruf jawaban benar dalam format A/B/C/D/E
6	jawaban_benar_teks	Preprocessing	Teks narasi jawaban benar hasil ekstraksi otomatis dari kolom kunci

2.3 Perancangan Prompt Pengujian (Non-CoT vs CoT)

Perancangan *prompt* bertujuan mengarahkan model menghasilkan format keluaran yang konsisten dan mudah dievaluasi secara otomatis [11]. Perbandingan struktur *prompt* Non-CoT dan CoT disajikan pada Gambar 2.

Prompt Non-CoT	Prompt Chain-of-Thought (CoT)
Instruksi: "Jawablah pertanyaan berikut. Berikan hanya jawaban akhir teks tanpa opsi (A/B/C/D/E)." Struktur Input: Soal: {soal} Pilihan: {pilihan jawaban} Karakteristik Output: • Memberikan jawaban teks langsung • Tanpa penalaran berbelit • Efisiensi token & latensi tinggi	Instruksi: "Jawablah pertanyaan berikut dengan berpikir langkah demi langkah untuk menyelesaikan soal ini secara logis." Struktur Input: Soal: {soal} Pilihan: {pilihan jawaban} Format Jawaban Akhir: "Setelah menjelaskan langkah penyelesaiannya, lalu di baris terakhir tulis format eksak: Jawaban akhir: [Teks jawaban tanpa huruf opsi]"

Gambar 2. Perancangan dan Perbandingan Format *Prompt Non-Chain-of-Thought (Non-CoT)* dan *Chain-of-Thought (CoT)*

Penjelasan kedua format *prompt* adalah sebagai berikut:

1. *Prompt Non-Chain-of-Thought (Non-CoT)*: Model diinstruksikan memberikan jawaban akhir secara langsung tanpa uraian langkah penalaran: "Jawablah pertanyaan berikut. Berikan hanya jawaban akhir teks tanpa opsi (A/B/C/D/E)". Format ini menghasilkan respons singkat dengan konsumsi token minimal.
2. *Prompt Chain-of-Thought (CoT)*: Model diinstruksikan melakukan penalaran bertahap sebelum menyimpulkan jawaban: "Jawablah pertanyaan berikut dengan berpikir langkah demi langkah... lalu di baris terakhir tulis format eksak: Jawaban akhir: [Teks jawaban tanpa huruf opsi]". Sistem mengekstrak baris jawaban akhir tersebut untuk dievaluasi.

2.4 Model LLM dan Konfigurasi Pengujian

Model LLM yang digunakan adalah GPT-4o mini (gpt-4o-mini-2024-07-18) yang diakses melalui OpenAI REST API. Model tersebut dipilih karena memiliki efisiensi komputasi tinggi, latensi rendah, serta kapabilitas penalaran yang unggul [21]. Seluruh pengujian dijalankan dengan parameter suhu (*temperature*) $T = 0,0$ guna memastikan determinisme keluaran respons model [22].

2.5 Skenario Pengujian

Evaluasi disusun ke dalam 4 skenario komprehensif:

1. Skenario 1 (Baseline Per Domain): Pengujian dilakukan pada masing-masing dari 9 domain bahasa secara terpisah dengan 100 butir soal per domain (total 900 butir soal).
2. Skenario 2 (Multi-Domain 225 Soal): Pengujian acak gabungan dari seluruh 9 domain bahasa dengan proporsi 25 soal per domain (total 225 butir soal).
3. Skenario 3 (Multi-Domain 450 Soal): Pengujian acak gabungan dari seluruh 9 domain bahasa dengan proporsi 50 soal per domain (total 450 butir soal).
4. Skenario 4 (Multi-Domain Skala Penuh 900 Soal): Pengujian acak gabungan seluruh 9 domain bahasa dengan proporsi 100 soal per domain (total 900 butir soal).

2.6 Rumus Matematis dan Metrik Pengukuran

Algoritma *Levenshtein Distance* digunakan untuk mengukur derajat kemiripan teks jawaban model terhadap jawaban referensi secara kuantitatif [23]. Pendekatan berbasis jarak edit tersebut terbukti andal memperkirakan kedekatan antar varian ujaran maupun antar teks pada kajian linguistik [24]. Penerapan algoritma yang sama terhadap teks berbahasa Indonesia juga efektif untuk mengukur kemiripan judul dan frasa secara otomatis [25].

2.6.1 Perhitungan Jarak Levenshtein

Diberikan dua string teks, yaitu string jawaban model s dengan panjang $m = \text{len}(s)$ dan string referensi t dengan panjang $n = \text{len}(t)$. Matriks jarak Levenshtein $\text{lev}(i, j)$ berukuran $(m + 1) \times (n + 1)$ dihitung melalui Persamaan (1):

$$\text{lev}(i, j) = \begin{cases} i, & \text{jika } j = 0 \\ j, & \text{jika } i = 0 \\ \text{lev}(i - 1, j - 1), & \text{jika } s[i] = t[j] \\ 1 + \min\{\text{lev}(i - 1, j), \text{lev}(i, j - 1), \text{lev}(i - 1, j - 1)\} & \text{jika } s[i] \neq t[j] \end{cases} \quad (1)$$

di mana $\text{lev}(m, n)$ menyatakan jumlah operasi edit minimum untuk mengubah string s menjadi string t .

2.6.2 Persentase Kemiripan Teks (*Similarity Score*)

Persentase kemiripan dihitung dari jarak Levenshtein $\text{lev}(m, n)$ menggunakan Persamaan (2):

$$\text{Similarity}(s, t) = 1 - \frac{\text{lev}(m, n)}{\max(m, n)} \quad (2)$$

2.6.3 Rata-rata Kemiripan Teks (*Average Similarity*)

Rata-rata persentase kemiripan untuk suatu skenario pengujian dengan N butir soal dihitung dengan Persamaan (3):

$$\text{Similarity}_{avg} = \frac{1}{N} \sum_{i=1}^N \text{similarity}_i \quad (3)$$

2.6.4 Akurasi Pencocokan Eksak (*Exact Match Accuracy*)

Butir soal bernilai benar (*Exact Match*) jika teks jawaban model identik dengan jawaban referensi ($\text{Similarity}_i = 100\%$). Akurasi keseluruhan dihitung melalui Persamaan (4) dan (5):

$$\text{Accuracy} = \frac{\sum_{i=1}^N \text{Correct}_i}{N} \quad (4)$$

$$\text{Correct}_i = \begin{cases} 1, & \text{Similarity}_i = 1 \\ 0, & \text{Similarity}_i < 1 \end{cases} \quad (5)$$

Proses evaluasi sistematis dirangkum pada Algoritma 1.

Algorithm 1 Prosedur Evaluasi Akurasi ChatGPT Menggunakan Levenshtein Distance

Require: Dataset IndoMMLU $D = \{(Q_k, O_k, R_k)\}_{k=1}^N$, Model GPT-4o mini M , Mode $\in \{\text{Non-CoT}, \text{CoT}\}$

Ensure: Metrik Akurasi (%) dan Rata-rata Similarity (%)

1: $\text{total_correct} \leftarrow 0$, $\text{sum_similarity} \leftarrow 0$

2: **for each** $(Q_k, O_k, R_k) \in D$ **do**

3: $\text{prompt}_k \leftarrow \text{GeneratePrompt}(\text{Mode}, Q_k, O_k)$

4: $\text{response}_k \leftarrow \text{CallOpenAI_API}(M, \text{prompt}_k, \text{temp} = 0.0)$

5: $\text{ans}_k \leftarrow \text{ExtractAnswer}(\text{Mode}, \text{response}_k)$

6: $m \leftarrow \text{len}(\text{ans}_k)$, $n \leftarrow \text{len}(R_k)$

7: $\text{dist}_k \leftarrow \text{ComputeLevenshtein}(\text{ans}_k, R_k, m, n)$

▷ Persamaan (1)

8: $\text{sim}_k \leftarrow (1 - \text{dist}_k / \max(m, n)) \times 100\%$

▷ Persamaan (2)

9: $\text{sum_similarity} \leftarrow \text{sum_similarity} + \text{sim}_k$

10: **if** $\text{sim}_k == 100\%$ **then**

11: $\text{total_correct} \leftarrow \text{total_correct} + 1$

12: **end if**

13: **end for**

14: $\text{Accuracy} \leftarrow (\text{total_correct} / N) \times 100\%$

15: $\text{Similarity}_{avg} \leftarrow \text{sum_similarity} / N$

return $\text{Accuracy}, \text{Similarity}_{avg}$

3. Hasil dan Pembahasan

3.1 Hasil Pengujian Per Domain Bahasa (Skenario 1)

Pengujian Skenario 1 dilakukan secara independen terhadap 9 domain bahasa IndoMMLU dengan 100 butir soal per domain (total 900 butir soal). Hasil perbandingan skor kemiripan (*similarity*) dan akurasi jumlah soal benar disajikan pada Tabel 2.

Tabel 2: Perbandingan Hasil Pengujian Skenario 1 Per Domain Bahasa

Domain Bahasa	Similarity Non-CoT	Similarity CoT	Soal Benar Non-CoT	Soal Benar CoT	Metode Unggul
Bahasa Lampung	61,60%	66,92%	46/100 (46%)	56/100 (56%)	CoT (+10)
Bahasa Bali	55,49%	62,14%	38/100 (38%)	49/100 (49%)	CoT (+11)
Bahasa Makassar	59,88%	59,39%	37/100 (37%)	37/100 (37%)	Setara
Bahasa Banjar	62,77%	61,03%	45/100 (45%)	45/100 (45%)	Setara
Bahasa Madura	59,36%	55,06%	40/100 (40%)	37/100 (37%)	Non-CoT (+3)
Bahasa Indonesia	93,86%	95,92%	90/100 (90%)	94/100 (94%)	CoT (+4)
Bahasa Dayak Ngaju	61,02%	57,88%	33/100 (33%)	33/100 (33%)	Setara
Bahasa Sunda	69,70%	73,39%	62/100 (62%)	66/100 (66%)	CoT (+4)
Bahasa Jawa	76,18%	77,23%	63/100 (63%)	66/100 (66%)	CoT (+3)
Rata-rata / Total	66,65%	67,66%	454/900 (50,44%)	483/900 (53,67%)	CoT Unggul (+29)

Tabel 2 memperlihatkan Bahasa Indonesia mencapai performa tertinggi dengan skor *similarity* 95,92% dan akurasi 94%, yang mengonfirmasi representasi korpus bahasa nasional sangat kuat pada model [5]. Rumpun bahasa daerah menempatkan Bahasa Jawa (77,23%, 66 benar) dan Bahasa Sunda (73,39%, 66 benar) pada posisi tertinggi. Bahasa daerah beresumber daya rendah seperti Bahasa Dayak Ngaju dan Bahasa Makassar hanya mencapai akurasi 33% dan 37%.

Metode CoT berhasil meningkatkan jumlah jawaban benar pada 5 domain (Lampung, Bali, Indonesia, Sunda, Jawa) dengan peningkatan terbesar pada Bahasa Bali (+11 soal) dan Bahasa Lampung (+10 soal). Tiga domain lain (Makassar, Banjar, Dayak Ngaju) menghasilkan akurasi identik untuk kedua metode. Bahasa Madura justru menempatkan Non-CoT lebih unggul (40 vs 37 soal), yang menandakan penalaran bertahap pada kosakata tertentu rentan memicu halusinasi leksikal (*reasoning error*). Rincian distribusi klasifikasi jawaban per butir soal disajikan pada Tabel 3.

Tabel 3: Rincian Distribusi Kebenaran Jawaban Per Butir Soal pada Skenario 1

Domain Bahasa	Kedua Metode Benar	Hanya Non-CoT Benar	Hanya CoT Benar	Kedua Metode Salah
Bahasa Lampung	36	10	20	34
Bahasa Bali	27	11	22	40
Bahasa Makassar	24	13	13	50
Bahasa Banjar	31	14	14	41
Bahasa Madura	20	20	17	43
Bahasa Indonesia	88	2	6	4
Bahasa Dayak Ngaju	20	13	13	54
Bahasa Sunda	54	8	12	26
Bahasa Jawa	55	8	11	26
Total Butir	355	99	128	318

3.2 Hasil Pengujian Multi-Domain (Skenario 2, 3, dan 4)


Evaluasi gabungan domain dilakukan untuk menguji stabilitas performa penalaran model saat menghadapi perpindahan konteks bahasa daerah secara acak dan simultan. Pengujian menggunakan sembilan domain bahasa dengan jumlah sampel yang berbeda, yaitu 25, 50, dan 100 soal untuk setiap domain. Variasi jumlah sampel tersebut memperlihatkan konsistensi performa model ketika jumlah data pengujian meningkat. Pengujian turut memperhatikan penggunaan token dan rata-rata latensi di samping nilai *similarity* dan akurasi untuk menilai efisiensi respons masing-masing metode. Hasil pengujian multi-domain dirangkum pada Tabel 4.

Tabel 4: Perbandingan Performa Pengujian Multi-Domain (Skenario 2, 3, dan 4)

Skenario Pengujian	Metode	Similarity (%)	Soal Benar / Akurasi	Total Token	Rata-rata Latensi (s)
Skenario 2 (Multi-Domain)	Non-CoT	68,60%	121 / 225 (53,78%)	16.307	1,77 s
(9 Bahasa × 25 Soal = 225)	CoT	68,27%	123 / 225 (54,67%)	88.819	5,16 s
Skenario 3 (Multi-Domain)	Non-CoT	70,18%	247 / 450 (54,89%)	34.068	1,42 s
(9 Bahasa × 50 Soal = 450)	CoT	69,37%	249 / 450 (55,33%)	180.602	5,00 s
Skenario 4 (Multi-Domain)	Non-CoT	67,30%	469 / 900 (52,11%)	71.908	1,46 s
(9 Bahasa × 100 Soal = 900)	CoT	65,55%	456 / 900 (50,67%)	372.965	5,48 s

3.3 Analisis Komparatif Gabungan 4 Skenario

Perbandingan akurasi *exact match* dan skor kemiripan pada seluruh skenario disajikan pada Gambar 3 sebagai gambaran visual dinamika performa kedua metode.



(a) Perbandingan Akurasi (Exact Match)

(b) Perbandingan Skor Kemiripan (Similarity)

Gambar 3. Grafik Perbandingan Komparatif Performa Metode Non-CoT dan CoT pada Seluruh Skenario Pengujian (Skenario 1–4)

Tabel 4 dan Gambar 3 memperlihatkan beberapa temuan empiris utama:

1. Metode CoT unggul pada akurasi *exact match* di Skenario 1–3 (+3,23% pada Skenario 1, +0,89% pada Skenario 2, dan +0,44% pada Skenario 3). Margin keunggulan tersebut menyempit seiring bertambahnya variasi domain dan jumlah data.
2. Non-CoT mencatat skor kemiripan lebih tinggi dibanding CoT pada Skenario 2 dan 3 (68,60% vs 68,27% dan 70,18% vs 69,37%). Respons CoT menyertakan narasi penalaran tambahan sehingga memperbesar jarak Levenshtein ketika teks jawaban akhir tidak terisolasi secara sempurna. Metrik berbasis kemiripan permukaan teks menilai kesamaan karakter, sehingga pengukuran berbasis makna dapat menjadi pelengkap pada evaluasi keluaran LLM [18].
3. Metode Non-CoT berbalik unggul mutlak atas CoT pada Skenario 4 (skala penuh 900 butir soal), baik dari sisi akurasi (52,11% vs 50,67%) maupun skor kemiripan (67,30% vs 65,55%). Volume data besar dengan pergantian bahasa daerah secara acak membuat model rentan mengalami disorientasi konteks semantik (*context drift*) selama proses penalaran langkah demi langkah. Temuan serupa dilaporkan pada evaluasi ChatGPT-4 yang menunjukkan metode standar mampu menyamai bahkan melampaui CoT untuk tipe pertanyaan tertentu [14].

3.4 Analisis Trade-Off Efisiensi Komputasi (Token dan Latensi)

Evaluasi aspek efisiensi komputasi menunjukkan bahwa metode *Chain-of-Thought* membutuhkan konsumsi sumber daya yang jauh lebih besar:

1. Penggunaan Token: Metode CoT mengonsumsi rata-rata $5,18\times$ hingga $5,44\times$ lipat lebih banyak token dibandingkan Non-CoT (contoh pada Skenario 4: 372.965 token CoT berbanding 71.908 token Non-CoT).
2. Waktu Respons (Latensi): Rata-rata waktu inferensi CoT berkisar antara 5,00–5,48 detik per soal, atau $3,5\times$ hingga $3,8\times$ lebih lambat dibandingkan Non-CoT yang hanya memerlukan 1,42–1,77 detik per soal.

Margin peningkatan akurasi CoT yang sangat tipis pada pengujian per domain (+3,23%) dan penurunan akurasi pada pengujian multi-domain skala besar (–1,44%) menjadikan penggunaan CoT untuk soal pilihan ganda bahasa daerah kurang efisien dari segi biaya operasional (*cost-inefficient*). Metode CoT tetap bernilai pada tugas yang menuntut uraian penalaran eksplisit kepada pengguna, sedangkan tugas klasifikasi jawaban singkat lebih diuntungkan oleh keluaran ringkas Non-CoT [2].

4. Kesimpulan

Hasil evaluasi dan pembahasan yang telah dilakukan menghasilkan beberapa kesimpulan berikut:

1. Metode *Chain-of-Thought* (CoT) terbukti efektif meningkatkan akurasi jawaban ChatGPT (GPT-4o mini) pada pengujian per domain bahasa (Skenario 1) dengan akurasi 53,67% (483/900 soal benar) dan *similarity* 67,66%, mengungguli Non-CoT yang mencatat akurasi 50,44% (454/900 soal benar) dan *similarity* 66,65%. Peningkatan signifikan terjadi pada Bahasa Bali (+11 soal) dan Bahasa Lampung (+10 soal).
2. Bahasa Indonesia mencatat performa tertinggi (akurasi 94%, *similarity* 95,92%), diikuti Bahasa Jawa (77,23%) dan Bahasa Sunda (73,39%). Bahasa daerah beresumber daya rendah seperti Bahasa Dayak Ngaju (33%) dan Bahasa Makassar (37%) memiliki akurasi terendah akibat keterbatasan data latih korpus bahasa daerah pada LLM.
3. Metode Non-CoT mencatat performa lebih unggul dibandingkan CoT pada pengujian *multi-domain* skala penuh (Skenario 4), baik dari sisi akurasi (52,11% vs 50,67%) maupun *similarity* (67,30% vs 65,55%), akibat kerentanan CoT terhadap disorientasi penalaran pada perpindahan bahasa yang dinamis.
4. Metode CoT membutuhkan konsumsi token $5,18\times$ – $5,44\times$ lebih besar dan latensi waktu $3,5\times$ – $3,8\times$ lebih lambat dibandingkan Non-CoT. Metode Non-CoT direkomendasikan sebagai pilihan yang jauh lebih efisien dan stabil untuk tugas klasifikasi pemahaman bahasa daerah berbasis pilihan ganda.

Saran untuk pengembangan penelitian selanjutnya antara lain:

1. Menerapkan teknik *Few-Shot* CoT dengan menyertakan contoh penalaran dalam bahasa daerah yang relevan untuk meminimalkan halusinasi semantik.
2. Melakukan pengujian perbandingan pada model LLM multibahasa sumber terbuka (*open-source*) seperti Llama 3 atau Mistral guna membandingkan ketahanan pemahaman bahasa daerah di luar ekosistem OpenAI.
3. Mengintegrasikan korpus kamus bahasa daerah melalui pendekatan *Retrieval-Augmented Generation* (RAG) guna memperkaya pengetahuan leksikal model secara dinamis.

REFERENSI

- [1] A. Mohammed and R. Kora, "A Comprehensive Overview and Analysis of Large Language Models: Trends and Challenges," 2025, *Institute of Electrical and Electronics Engineers Inc.* doi: 10.1109/ACCESS.2025.3573955.
- [2] A. Håkansson and G. Phillips-Wren, "Generative AI and Large Language Models - Benefits, Drawbacks, Future and Recommendations," in *Procedia Computer Science*, Elsevier B.V., 2024, pp. 5458–5468. doi: 10.1016/j.procs.2024.09.689.
- [3] L. Ouyang et al., "Training language models to follow instructions with human feedback," Mar. 2022, [Online]. Available: <http://arxiv.org/abs/2203.02155>
- [4] M. Alawida, S. Mejri, A. Mehmood, B. Chikhaoui, and O. Isaac Abiodun, "A Comprehensive Study of ChatGPT: Advancements, Limitations, and Ethical Considerations in Natural Language Processing and Cybersecurity," Aug. 01, 2023, *Multidisciplinary Digital Publishing Institute (MDPI)*. doi: 10.3390/info14080462.
- [5] F. Koto, N. Aisyah, H. Li, and T. Baldwin, "Large Language Models Only Pass Primary School Exams in Indonesia: A Comprehensive Test on IndoMMLU Department Natural Language Processing, MBZUAI," 1237. [Online]. Available: <https://github.com/>
- [6] G. Zhu, X. Zhang, and C. Chen, "Assessing and enhancing the reliability of Chinese large language models in dental implantology," *BMC Oral Health*, vol. 25, no. 1, Dec. 2025, doi: 10.1186/s12903-025-06648-1.
- [7] D. Hendrycks et al., "Measuring Massive Multitask Language Understanding," Jan. 2021, [Online]. Available: <http://arxiv.org/abs/2009.03300>
- [8] W. Li, L. Li, T. Xiang, X. Liu, W. Deng, and N. Garcia, "Can multiple-choice questions really be useful in detecting the abilities of LLMs?," May 2024, [Online]. Available: <http://arxiv.org/abs/2403.17752>
- [9] L. Reynolds and K. McDonnell, "Prompt Programming for Large Language Models: Beyond the Few-Shot Paradigm," Feb. 2021, [Online]. Available: <http://arxiv.org/abs/2102.07350>

- [10] J. Wei *et al.*, "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models," Jan. 2023, [Online]. Available: <http://arxiv.org/abs/2201.11903>
- [11] T. Kojima, S. S. Gu, M. Reid, Y. Matsuo, and Y. Iwasawa, "Large Language Models are Zero-Shot Reasoners," Jan. 2023, [Online]. Available: <http://arxiv.org/abs/2205.11916>
- [12] G. G. Lee, E. Latif, X. Wu, N. Liu, and X. Zhai, "Applying large language models and chain-of-thought for automatic scoring," *Computers and Education: Artificial Intelligence*, vol. 6, Jun. 2024, doi: 10.1016/j.caeai.2024.100213.
- [13] Y. T. Ting *et al.*, "Performance of ChatGPT incorporated chain-of-thought method in bilingual nuclear medicine physician board examinations," *Digit. Health*, vol. 10, Jan. 2024, doi: 10.1177/20552076231224074.
- [14] K. Ji, Z. Wu, J. Han, G. Zhai, and J. Liu, "Evaluating ChatGPT-4's performance on oral and maxillofacial queries: Chain of Thought and standard method," *Frontiers in Oral Health*, vol. 6, 2025, doi: 10.3389/froh.2025.1541976.
- [15] J. Chen, L. Chen, H. Huang, and T. Zhou, "When do you need Chain-of-Thought Prompting for ChatGPT?," Apr. 2023, [Online]. Available: <http://arxiv.org/abs/2304.03262>
- [16] Z. Jia, S. Geng, Y. Zhao, and H. Zhang, "Comprehensive Survey on Prompts Generating via Knowledge-Guided Chain-of-Thought," *International Journal of Crowd Science*, vol. 9, no. 4, pp. 251–261, Nov. 2025, doi: 10.26599/IJCS.2024.9100038.
- [17] J. Mugaanyi, L. Cai, S. Cheng, C. Lu, and J. Huang, "Evaluation of Large Language Model Performance and Reliability for Citations and References in Scholarly Writing: Cross-Disciplinary Study," *J. Med. Internet Res.*, vol. 26, no. 1, Jan. 2024, doi: 10.2196/52935.
- [18] S. Xu *et al.*, "Reasoning before Comparison: LLM-Enhanced Semantic Similarity Metrics for Domain Specialized Text Analysis," Feb. 2024, [Online]. Available: <http://arxiv.org/abs/2402.11398>
- [19] B. Berger, M. S. Waterman, and Y. W. Yu, "Levenshtein Distance, Sequence Comparison and Biological Database Search," *IEEE Trans. Inf. Theory*, vol. 67, no. 6, pp. 3287–3294, Jun. 2021, doi: 10.1109/TIT.2020.2996543.
- [20] T. Petty, J. Hannig, T. I. Huszar, and H. Iyer, "A New String Edit Distance and Applications," *Algorithms*, vol. 15, no. 7, Jul. 2022, doi: 10.3390/a15070242.
- [21] OpenAI, "GPT-4o mini: Advancing Cost-Efficient Intelligence," OpenAI. Accessed: Jul. 12, 2026. [Online]. Available: <https://openai.com/index/gpt-4o-mini-advancing-cost-efficient-intelligence/>
- [22] T. B. Brown *et al.*, "Language Models are Few-Shot Learners," Jul. 2020, [Online]. Available: <http://arxiv.org/abs/2005.14165>
- [23] J. Beernaerts, E. Debever, M. Lenoir, B. De Baets, and N. Van de Weghe, "A method based on the Levenshtein distance metric for the comparison of multiple movement patterns described by matrix sequences of different length," *Expert Syst. Appl.*, vol. 115, pp. 373–385, Jan. 2019, doi: 10.1016/j.eswa.2018.07.076.
- [24] H. C. Lind-Combs, T. Bent, R. F. Holt, C. G. Clopper, and E. Brown, "Comparing Levenshtein distance and dynamic time warping in predicting listeners' judgments of accent distance," *Speech Commun.*, vol. 155, Nov. 2023, doi: 10.1016/j.specom.2023.102987.
- [25] P. Sanda Mette, E. Arriyanti, S. Lailiyah, S. Widya Cipta Dharma, J. No, and K. Timur, "Penerapan Algoritma Levenshtein Distance Untuk Pengecekan Kemiripan Judul Skripsi di STMIK Widya Cipta Dharma," *Jurnal Nasional Komputasi dan Teknologi Informasi (JNKTI)*, vol. 8, no. 3, 2025.