

RANCANG BANGUN SISTEM KLASIFIKASI JENIS BATIK ACEH BERDASARKAN MOTIF MENGGUNAKAN CONVOLUTIONAL NEURAL NETWORK

SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk Menyelesaikan
Pendidikan Sarjana Terapan
Pada Politeknik Negeri Lhokseumawe



Oleh:

REYHAN PUTRA SYAHMI

NIM	: 2022573010114
Program Studi	: Teknik Informatika
Jurusan	: Teknologi Informasi dan Komputer

**KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
POLITEKNIK NEGERI LHOKSEUMAWE
2026**

PENGESAHAN PEMBIMBING

Skripsi yang berjudul *Rancang Bangun Sistem Klasifikasi Jenis Batik Aceh Berdasarkan Motif Menggunakan Convolutional Neural Network*, disusun oleh Reyhan Putra Syahmi, NIM 2022573010114, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe, telah memenuhi syarat untuk dipertanggungjawabkan dihadapan dewan penguji.

Buket Rata, 22 Juli 2026

Pembimbing I,



M.Khadafi, S.T., M.T.
NIP. 19750718 200212 1 004

Pembimbing II,



Azhar, S.T., M.T.
NIP. 19640830 199003 1 005

Mengetahui,

Ketua Jurusan
Teknologi Informasi dan Komputer



Salahuddin, S.T., M.Cs.
NIP. 19740424 200212 1 001

Ketua Program Studi
Teknik Informatika



M. Khadafi, S.T., M.T.
NIP. 19750718 200212 1 004

PENGESAHAN PENGUJI

Skripsi yang berjudul *Rancang Bangun Sistem Klasifikasi Jenis Batik Aceh Berdasarkan Motif Menggunakan Convolutional Neural Network*, disusun oleh Reyhan Putra Syahmi, NIM 2022573010114, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer pada Politeknik Negeri Lhokseumawe, telah dipertanggungjawabkan dihadapan dewan penguji dan dinyatakan lulus pada tanggal 29 Juli 2026.

Komisi Sidang,


M.Khadafi, S.T., M.T.
NIP. 19750718 200212 1 004


.....
(Ketua Sidang)


Azhar, S.T., M.T.
NIP. 19640830 199003 1 005


.....
(Sekretaris Sidang)


Muhammad Rizka, S.S.T., M.Kom.
NIP. 19881009 201504 1 001


.....
(Penguji I)

Muhammad Arhami, S.Si., M.Kom.
NIP. 19741029 200003 1 001


.....
(Penguji II)

Huzaeni, S.S.T., M.IT.
NIP. 19700601 199501 1 001


.....
(Penguji III)

Mengetahui,

Ketua Jurusan
Teknologi Informasi dan Komputer



Salahuddin, S.T., M.Cs.
NIP. 19740424 200212 1 001

Ketua Program Studi
Teknik Informatika


M. Khadafi, S.T., M.T.
NIP. 19750718 200212 1 004

HALAMAN PERNYATAAN

Dengan ini saya menyatakan bahwa dalam Skripsi ini tidak terdapat karya yang pernah diajukan untuk mendapatkan gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya tidak terdapat karya atau pendapat yang pernah ditulis orang lain, kecuali yang secara tertulis diacu pada naskah dan disebutkan dalam daftar pustaka.

Lhokseumawe, 29 Juli 2026

A handwritten signature in black ink, consisting of a stylized, cursive 'R' followed by a series of loops and a final vertical stroke.

Reyhan Putra Syahmi
NIM. 2022573010114

KATA PENGANTAR

Segala puji beserta syukur senantiasa penulis panjatkan kepada Allah SWT yang telah memberikan rahmat dan petunjuk-Nya kepada penulis sehingga dapat menyelesaikan skripsi yang berjudul “Rancang Bangun Sistem Klasifikasi Jenis Batik Aceh Berdasarkan Motif Menggunakan Convolutional Neural Network”. Shalawat beserta salam kepada baginda Rasulullah Muhammad SAW, keluarga, dan para sahabat yang telah berjasa dalam memperjuangkan islam dan ilmu pengetahuan. Skripsi ini disusun sebagai salah satu syarat untuk menyelesaikan pendidikan Sarjana Terapan Program Studi Teknik Informatika Jurusan Teknologi Informasi dan Komputer Politeknik Negeri Lhokseumawe.

Dalam Penyusunan skripsi ini penulis banyak mendapatkan dukungan, perhatian, dorongan, bimbingan dan berbagai bantuan dari banyak pihak terutama para dosen pembimbing. Dengan demikian, segala hormat dan kerendahan hati penulis menyampaikan rasa terima kasih yang tidak terhingga terutama kepada:

1. Ucapan teristimewa kepada kedua orang tua yaitu Ayahanda Syahrial (alm) dan Ibunda Mira Saputri yang selalu memberikan doa, dukungan dan materi serta memberikan semangat dan kasih sayang sehingga penulis dapat berdiri tegar dan menyelesaikan skripsi ini.
2. Bapak M. Khadafi, S.T., M.T. dan Bapak Azhar, S.T., M.T. selaku pembimbing I dan II yang telah membimbing penulis, memberi petunjuk, memberi saran-saran dan arahan serta masukan dari awal masa pengajuan

judul sampai berhasil menyelesaikan Skripsi.

3. Bapak Mahdi, S.T., M.Cs., selaku Koordinator Skripsi, atas segala perhatian, arahan, dan dukungan yang telah membantu kelancaran penulis dalam menyelesaikan skripsi ini. Para dosen dan tenaga pengajar Program Studi Teknik Informatika yang telah memberikan arahan dan bimbingan selama proses perkuliahan.
4. Bapak Salahuddin, S.T., M.Cs. selaku Ketua Jurusan Teknologi Informasi dan Komputer, Bapak Fachri Yanuar Rudi F, S.S.T., M.T. selaku Sekretaris Jurusan Teknologi Informasi dan Komputer, dan Bapak M. Khadafi, S.T., M.T. selaku Ketua Program Studi Teknik Informatika atas segala bimbingan dan perhatian selama masa perkuliahan.
5. Bapak Dr. Ir. Rizal Syahyadi, S.T., M.Eng.Sc., IPM, ASEAN Eng., APEC Eng., selaku Direktur Politeknik Negeri Lhokseumawe.
6. Bapak Muhammad Rizka, SST., M.Kom., Bapak Muhammad Arhami, S.Si., M.Kom., dan Bapak Huzaeni, SST., M.IT. selaku penguji sidang yang telah bersedia memberikan arahan dan masukan dalam pengerjaan Skripsi ini.
7. Ucapan terimakasih penulis sampaikan kepada Kawan-Kawan terdekat yang senantiasa memberi dukungan, menemani, serta berjuang bersama.
8. Terakhir yang tidak kalah penting, saya ingin mengucapkan terima kasih yang sebesar-besarnya kepada diri saya sendiri, karena sudah bertahan, berproses, dan menolak untuk menyerah dalam menyelesaikan skripsi ini.

Penulis menyadari bahwa Skripsi ini masih terdapat kekurangan dan ketidaksempurnaan. Oleh sebab itu, penulis mengharapkan adanya saran dan kritik yang membangun guna dijadikan bahan perbaikan dan pembelajaran untuk kedepannya yang bermanfaat bagi penulis dan rekan-rekan yang membacanya. Semoga bantuan dan kebaikan semua pihak dapat menjadi amal ibadah.

Lhokseumawe, 29 Juli 2026

A handwritten signature in black ink, consisting of several loops and a long horizontal stroke extending to the left.

Reyhan Putra Syahmi

NIM. 2022573010114

ABSTRAK

Batik Aceh merupakan entitas kultural takbenda Indonesia dengan kompleksitas morfologi visual dan kedalaman historis yang tinggi. Proses identifikasi jenis motif Batik Aceh secara konvensional masih dihadapkan pada kendala subjektivitas pengamat, tingginya variansi spektral, serta rumitnya struktur geometris yang menyusun ornamen tersebut. Oleh karena itu, penelitian ini bertujuan merancang arsitektur klasifikasi citra digital secara otomatis memanfaatkan algoritma *Convolutional Neural Network* (CNN) melalui implementasi arsitektur VGG16. Guna memitigasi anomali *overfitting* akibat dimensi spasial yang besar, diterapkan teknik *Transfer Learning* berbasis ruang bobot pra-latih *ImageNet*. Ekosistem model komputasi ini dideploy pada platform antarmuka web interaktif Streamlit, yang diintegrasikan dengan fitur *Explainable AI* (Grad-CAM) untuk transparansi inferensi spasial serta modul *Virtual Try-On*. Ruang lingkup klasifikasi mencakup 4 ruang kelas: Bukan Batik, Pinto Aceh, Pucok Reubong, dan Rencong. Dataset yang diutilisasi berdimensi 700 citra dengan distribusi seimbang (175 citra per kelas), yang bersumber secara independen dari repositori publik sekunder Roboflow, serta dipartisi dengan rasio 80%:10%:10% untuk *training*, *validation*, dan *testing*. Tahapan *preprocessing* mencakup normalisasi spasial ke dimensi 224×224 piksel, normalisasi skalar intensitas $[0,1]$, serta amplifikasi keberagaman data melalui augmentasi deterministik (rotasi, translasi, *shear*, *zoom*, dan variasi iluminasi). Kinerja model dievaluasi secara empiris menggunakan *Confusion Matrix*, menghasilkan akurasi komprehensif pada fase pengujian sebesar **97%** dengan nilai presisi rata-rata 98,02%, sensitivitas (*recall*) 97%, dan *F1-score* 97,16%. Evaluasi *Black-Box* terhadap antarmuka web membuktikan tingkat reliabilitas fungsional 100% pada seluruh skenario.

Kata Kunci: Batik Aceh, Visi Komputer, *Convolutional Neural Network*, VGG16, *Transfer Learning*, Streamlit, *Explainable AI*

ABSTRACT

*Batik Aceh is an Indonesian intangible cultural entity characterized by high visual morphological complexity and historical depth. Conventional motif identification processes face limitations due to observer subjectivity, high spectral variance, and the intricate geometric structures composing the ornaments. Therefore, this study aims to design an automated digital image classification architecture utilizing the Convolutional Neural Network (CNN) algorithm via VGG16 implementation. To mitigate overfitting anomalies inherent to high-dimensional spatial spaces, a Transfer Learning technique based on ImageNet pre-trained weight spaces was adopted. The computational ecosystem is deployed on the interactive Streamlit web interface, integrated with Explainable AI (Grad-CAM) for spatial inference transparency and a Virtual Try-On module. The classification scope encompasses 4 class spaces: Bukan Batik (Non-Batik), Pinto Aceh, Pucok Reubong, and Rencong. The utilized dataset comprises 700 uniformly distributed images (175 per class), sourced entirely from the Roboflow secondary public repository, partitioned at an 80%:10%:10% ratio for training, validation, and testing. Preprocessing involves spatial normalization to 224×224 pixels, scalar intensity normalization $[0,1]$, and deterministic data augmentation (rotation, translation, shear, zoom, and illumination variation). Model performance was empirically evaluated via a Confusion Matrix, yielding a comprehensive testing accuracy of **97.00%**, with an average precision of 98.02%, sensitivity (recall) of 97.00%, and F1-score of 97.16%. Black-Box evaluation of the web interface proved a 100% functional reliability rate across all scenarios.*

Keywords: *Batik Aceh, Computer Vision, Convolutional Neural Network, VGG16, Transfer Learning, Streamlit, Explainable AI*

DAFTAR ISI

PENGESAHAN PEMBIMBING	ii
PENGESAHAN PENGUJI	iii
HALAMAN PERNYATAAN	iv
KATA PENGANTAR	v
ABSTRAK	viii
ABSTRACT	ix
DAFTAR ISI	x
DAFTAR GAMBAR	xiii
DAFTAR TABEL	xiv
BAB I PENDAHULUAN	1
1.1 Latar Belakang	1
1.2 Rumusan Masalah	4
1.3 Tujuan Penelitian	5
1.4 Batasan Masalah	6
1.5 Manfaat Penelitian	8
1.6 Sistematika Penulisan	9
BAB II TINJAUAN PUSTAKA	11
2.1 <i>State Of The Art</i>	11
2.2 Citra Digital	15
2.3 Karakteristik Visual Motif Batik Aceh	15
2.3.1 Motif Pinto Aceh	16
2.3.2 Motif Pucok Reubong	17
2.3.3 Motif Rencong	17
2.4 Dasar Teori <i>Convolutional Neural Network</i> (CNN)	18
2.5 Anatomi Arsitektur VGG16	20
2.6 Paradigma <i>Transfer Learning</i>	23
2.7 Interpretasi Model dengan Grad-CAM (<i>Explainable AI</i>)	24
2.8 <i>Confusion Matrix</i> dan Analisis Metrik Evaluasi Kinerja	26
2.9 Fundamental Pengujian Fungsional <i>Black-Box</i>	28
BAB III METODE PENELITIAN	29
3.1 Alur Penelitian	29
3.2 Data dan Pengumpulan Data	29
3.2.1 Tempat dan Waktu Penelitian	30
3.2.2 Alat dan Bahan Penelitian	31
3.2.3 Dataset	32

3.2.4	Dekomposisi Pembagian Dataset	33
3.3	Prapemrosesan Data (<i>Preprocessing</i>)	34
3.4	Rancangan Model <i>Deep Learning</i>	35
3.4.1	Arsitektur Model VGG16 dengan <i>Transfer Learning</i>	36
3.4.2	Skenario Pelatihan (<i>Training Strategy</i>)	37
3.5	Rancangan Sistem Aplikasi Web	38
3.5.1	<i>Use Case Diagram</i>	39
3.5.2	<i>Activity Diagram</i>	40
3.5.3	Rancangan Antarmuka Pengguna	42
3.6	Metode Pengujian	46
3.6.1	Perancangan Pengujian Performa Model	46
3.6.2	Perancangan Pengujian <i>Black-Box</i>	46
3.6.3	Perancangan Pengujian <i>White-Box</i>	47
BAB IV	HASIL DAN PEMBAHASAN	49
4.1	Implementasi Arsitektur Komputasi dan Strategi Pelatihan	49
4.1.1	Inisialisasi <i>Transfer Learning</i> dan <i>Frozen Convolutional Base</i>	49
4.1.2	Sintesis <i>Custom Classifier Head</i> dan Regularisasi <i>Dropout</i>	51
4.1.3	Kompilasi Model dengan <i>Adam Optimizer</i>	53
4.1.4	Implementasi <i>Dynamic Callbacks</i> (Pemantauan <i>Real-Time</i>)	54
4.1.5	Regularisasi Spasial melalui Augmentasi Data	56
4.2	Hasil Pelatihan Model	58
4.3	Evaluasi Model dengan <i>Confusion Matrix</i>	59
4.4	Implementasi Aplikasi Web Streamlit	62
4.4.1	Halaman Deteksi Motif (Utama)	62
4.4.2	Fitur <i>Crop</i> Citra dan Edge Detection	63
4.4.3	Fitur Multi-Klasifikasi	65
4.4.4	Visualisasi Explainable AI (Grad-CAM)	66
4.4.5	Halaman Kamus Motif	67
4.4.6	Riwayat Sesi dan Ekspor Laporan PDF	67
4.5	Hasil Pengujian <i>Black-Box</i>	69
4.6	Hasil Pengujian <i>White-Box</i>	71
4.7	Analisis Perhitungan Manual Konvolusi VGG16	72
	Analisis Perhitungan Manual Konvolusi VGG16	72
4.7.1	Representasi Input dan Kernel	73
4.7.2	Operasi Konvolusi (Conv2D)	73

4.7.3	Fungsi Aktivasi ReLU	74
4.7.4	Operasi Max-Pooling	75
4.8	Pembahasan	75
BAB V	PENUTUP	78
5.1	Kesimpulan	78
5.2	Saran	79
	DAFTAR PUSTAKA	81
	LAMPIRAN	84

DAFTAR GAMBAR

2.1	Standar Arsitektur Konseptual CNN	20
2.2	Topologi Struktural Blok Konvolusi Arsitektur VGG16	22
3.1	Alur Penelitian	29
3.2	Contoh Sampel Dataset Citra Batik Aceh	33
3.3	Activity Diagram Sistem Klasifikasi Batik Aceh	40
3.4	Rancangan Antarmuka Halaman Deteksi Motif	42
3.5	Rancangan Antarmuka Halaman Hasil Klasifikasi	43
3.6	Rancangan Antarmuka Halaman Kamus Motif	44
3.7	Rancangan Antarmuka Halaman Riwayat Sesi	45
3.8	Representasi <i>Flowgraph</i> Algoritma Pemrosesan Citra	47
4.1	Konfigurasi Transfer Learning dan Frozen Base Layer	49
4.2	Konstruksi Classifier Head dengan Regularisasi Dropout	51
4.3	Kompilasi Model dan Penentuan Fungsi Kerugian	53
4.4	Konfigurasi Agen Supervisi Callbacks Anti-Overfitting	54
4.5	Konfigurasi ImageDataGenerator dengan Augmentasi Ekstrem	57
4.6	Grafik Training vs Validation Accuracy dan Loss	58
4.7	Confusion Matrix Hasil Klasifikasi Model VGG16	59
4.8	Antarmuka Halaman Upload Gambar	62
4.9	Deteksi Otomatis untuk Citra Bukan Batik	63
4.10	Hasil Prediksi Sebelum Menggunakan Fitur Crop	64
4.11	Proses Pemotongan Citra (Crop)	64
4.12	Peningkatan Hasil Klasifikasi	65
4.13	Hasil Visualisasi Edge Detection	65
4.14	Proses Prediksi Batch dengan Multi-Klasifikasi	66
4.15	Analisis XAI (Grad-CAM) pada Titik Khas Motif	66
4.16	Tampilan Halaman Kamus Batik	67
4.17	Tabel Riwayat Sesi Prediksi	68
4.18	Laporan Prediksi Format PDF	68

DAFTAR TABEL

2.1	<i>State Of The Art</i> Penelitian Terdahulu	13
3.1	Jadwal Pelaksanaan Penelitian	30
3.2	Daftar Alat dan Bahan Penelitian	31
3.3	Distribusi Dataset Citra Batik Aceh (Sumber: Roboflow)	32
3.4	Spesifikasi Use Case Sistem Klasifikasi Batik Aceh	39
3.5	Hasil Eksekusi Jalur Independen (<i>Independent Paths</i>)	48
4.1	Confusion Matrix Hasil Klasifikasi Model VGG16	60
4.2	Normalisasi Metrik Evaluasi Model VGG16 Per Kelas	61
4.3	Hasil Pengujian Black-Box Aplikasi Web Streamlit	69
4.4	Hasil Pengujian White-Box (Basis Path)	71

BAB I

PENDAHULUAN

1.1 Latar Belakang

Batik merupakan warisan budaya takbenda (*intangible cultural heritage*) Indonesia yang telah diakui secara resmi oleh *United Nations Educational, Scientific and Cultural Organization* (UNESCO) pada tahun 2009. Pengakuan ini bukan sekadar legitimasi historis, melainkan sebuah mandat kultural bagi bangsa Indonesia untuk terus melestarikan, mendokumentasikan, dan mempromosikan kekayaan ragam hias tradisional tersebut. Salah satu manifestasi seni tekstil Nusantara yang memiliki nilai estetika dan muatan filosofis tinggi, namun belum mendapatkan porsi perhatian komputasional yang masif, adalah Batik Aceh. Berbeda secara fundamental dengan pakem batik dari pulau Jawa yang kental dengan sentuhan sinkretisme Hindu-Buddha, Batik Aceh lahir dari rahim kebudayaan Islam yang sangat menjunjung tinggi prinsip *aniconism*—larangan penggambaran makhluk hidup secara naturalis. Oleh karenanya, corak Batik Aceh didominasi oleh abstraksi geometris, sulur flora, dan adaptasi artefak budaya lokal. Beberapa motif yang paling menonjol di antaranya adalah motif *Pinto Aceh* yang merepresentasikan konfigurasi kerendahan hati dan keterbukaan masyarakat Aceh; *Pucok Reubong* yang merepresentasikan dinamika pertumbuhan, sinergi alam, dan kesinambungan generasi; serta motif *Rencong* yang secara tegas menyimbolkan heroisme, patriotisme, dan keberanian historis masyarakat Aceh dalam mempertahankan kedaulatan [1],[17].

Meskipun memiliki identitas visual yang sangat dominan dan sarat akan narasi historis, proses identifikasi jenis motif Batik Aceh secara konvensional di lapangan masih dihadapkan pada kendala subjektivitas heuristik. Keterbatasan diskriminasi visual manusia sering kali menyebabkan kesalahan interpretasi, terutama ketika dihadapkan pada kompleksitas morfologi corak, tingginya variansi warna (*spectral variance*) yang diterapkan oleh para pengrajin lokal, hingga distorsi optik akibat lipatan kain. Absennya infrastruktur pengenalan digital yang presisi dan tersandarisasi membuat identifikasi motif rentan terhadap bias pengamat. Dalam konteks pelestarian budaya di era Revolusi Industri 4.0, modernisasi metode preservasi mendesak perlunya intervensi teknologi *Computer Vision*. Intervensi komputasional ini bertujuan untuk mentransformasi proses kognisi visual manusia ke dalam algoritma matematis yang objektif, konsisten, terukur, dan mampu memproses data dalam skala masif.

Penelitian komputasional terdahulu yang mencoba menjembatani kesenjangan ini telah dilakukan oleh Fajira, Indrawati, dan Aswandi (2022). Mereka merancang sistem pengenalan Batik Aceh menggunakan algoritma klasifikasi *Machine Learning* konvensional, yakni *K-Nearest Neighbor* (K-NN) berlandaskan ekstraksi fitur tekstur manual. Namun, model spasial linier tersebut terbukti sangat rapuh terhadap variasi data; akurasi pengenalan mengalami degradasi drastis hingga 50% ketika model dihadapkan pada rotasi, iluminasi, dan *noise* spektral pada citra uji baru yang tidak terdapat dalam data latih [1]. Kegagalan metode konvensional yang sangat bergantung pada *hand-crafted*

features (fitur buatan tangan) ini menstimulasi urgensi transisi metodologis menuju paradigma *Deep Learning*, yang secara matematis kapabel dalam mengekstraksi hierarki fitur laten tingkat tinggi (*high-level features*) secara otonom dari data piksel mentah.

Dalam domain analitik visual kontemporer, *Convolutional Neural Network* (CNN) telah mendemonstrasikan keunggulan absolut dalam pemrosesan topologi matriks data dua dimensi (2D). Di antara berbagai varian CNN, arsitektur VGG16 (*Visual Geometry Group* dengan kedalaman 16 *layer*) secara khusus dipilih karena rancang bangun strukturalnya yang elegan—memanfaatkan repetisi *filter* konvolusi berukuran kecil 3×3 yang disusun dalam blok-blok tebal. Konfigurasi spasial ini sangat optimal untuk mendeteksi fitur bergradien halus, mengekstrak lekukan tajam asimetris pada motif Rencong, hingga merekonstruksi abstraksi pola geometris makro pada ornamen tekstil repetitif seperti Pucok Reubong [3],[16]. Mengingat kuantitas dataset berlabel untuk komoditas lokal budaya Aceh masih sangat terbatas dan belum berskala besar, implementasi *Transfer Learning* melalui injeksi bobot terlatih dari dataset kolosal *ImageNet* diusulkan sebagai instrumen vital. Teknik transfer pengetahuan ini tidak hanya mereduksi waktu komputasi secara signifikan, tetapi juga secara efektif mereduksi risiko *overfitting* dengan memanfaatkan representasi fitur universal (*edges, curves, textures*) yang telah dikalibrasi dengan sangat matang oleh model dasar [2],[7].

Keunggulan komparatif dan nilai kebaruan (*novelty*) dari rancang bangun penelitian ini terletak pada integrasi kapabilitas *Explainable AI* (XAI) melalui

implementasi metode *Gradient-weighted Class Activation Mapping* (Grad-CAM). Selama ini, kelemahan utama dari model *Deep Learning* adalah sifatnya yang *black-box* (kotak hitam), di mana pengguna tidak dapat memahami alasan di balik keputusan prediksi mesin. Grad-CAM mendemistifikasi inferensi komputasional tersebut dengan mengekspos pemetaan atensi piksel secara interpretatif; menghasilkan visualisasi *heatmap* (peta panas) yang secara eksplisit menunjukkan area mana pada ornamen kain yang memicu aktivasi neuron tertinggi dalam menentukan kelas motif. Lebih jauh, untuk mendekatkan luaran penelitian dengan utilitas praktis di masyarakat dan sektor UMKM (Usaha Mikro, Kecil, dan Menengah), ekosistem model komputasi ini disematkan ke dalam topologi antarmuka *web-app* interaktif menggunakan *framework* Streamlit. Sistem ini diperkaya dengan modul edukasi *Kamus Motif* dan fitur simulasi visual *Virtual Try-On* yang mendemonstrasikan kelayakan motif saat diaplikasikan pada pakaian secara virtual.

Dari uraian di atas, maka penelitian ini diformulasikan dengan judul **“Rancang Bangun Sistem Klasifikasi Jenis Batik Aceh Berdasarkan Motif Menggunakan Convolutional Neural Network”**.

1.2 Rumusan Masalah

Dari uraian latar belakang di atas, rumusan masalah dalam penelitian ini adalah sebagai berikut:

1. Bagaimana merancang bangun dan melatih secara empiris sebuah model

Convolutional Neural Network (CNN) menggunakan arsitektur VGG16 yang dikalibrasi melalui teknik *Transfer Learning ImageNet* untuk mengklasifikasikan 4 kelas probabilitas citra Batik Aceh (Bukan Batik, Pinto Aceh, Pucok Reubong, dan Rencong)?

2. Bagaimana merencanakan dan mengimplementasikan model klasifikasi spasial yang telah dilatih secara *offline* ke dalam sebuah ekosistem aplikasi web (*deployment*) menggunakan *framework* Streamlit yang turut mengintegrasikan kapabilitas *Explainable AI* (Grad-CAM) untuk transparansi prediksi, serta modul interaktif *Virtual Try-On*?
3. Seberapa tinggi tingkat reliabilitas dan presisi komputasi dari model yang diusulkan dalam mendiskriminasi variasi citra motif Batik Aceh yang belum pernah dilihat sebelumnya (*unseen data*), berdasarkan analisis kuantitatif menggunakan matriks konfusi (*Confusion Matrix*) yang mencakup parameter akurasi, presisi, sensitivitas (*recall*), dan nilai harmoni (*F1-score*)?

1.3 Tujuan Penelitian

Adapun tujuan yang hendak dicapai dalam penelitian ini adalah sebagai berikut:

1. Mampu merancang, mengembangkan, dan mensintesis model klasifikasi citra digital khusus Batik Aceh menggunakan arsitektur VGG16 dengan injeksi parameter bobot pra-latih *ImageNet*, yang terbukti kapabel secara

komputasional mendiskriminasi 4 kelas target dengan akurasi yang melampaui metode konvensional.

2. Berhasil membangun, men-*deploy*, dan merilis antarmuka sistem *Visual Recognition* interaktif berbasis web menggunakan *framework* Streamlit yang sepenuhnya responsif, di mana sistem tersebut mengakomodasi fitur transparansi keputusan via *Explainable AI* (Grad-CAM), fungsionalitas augmentasi *crop* manual, simulasi visual pakaian (*Virtual Try-On*), serta pangkalan data edukatif berwujud Kamus Motif.
3. Mampu mengukur, mengevaluasi, dan membuktikan tingkat keandalan generalisasi model secara kuantitatif melalui uji matriks konfusi (*Confusion Matrix*) pada set data pengujian (*testing set*), guna menderivasi dan menganalisis nilai akurasi, presisi, *recall*, serta *F1-score* secara komprehensif.

1.4 Batasan Masalah

Untuk memastikan penelitian ini lebih terarah dan fokus, maka diberikan batasan masalah sebagai berikut:

1. Ruang dimensi klasifikasi model secara absolut dibatasi hanya pada 4 ruang kelas probabilitas diskrit, yaitu: (1) *Bukan Batik* sebagai kelas negatif (*true negative*), (2) *Pinto Aceh*, (3) *Pucok Reubong*, dan (4) *Rencong*.
2. Korpus observasi komputasional berupa 700 *instances* citra digital (terdistribusi seimbang 175 citra per kelas) diperoleh secara penuh melalui

ekstraksi data (*data scraping*) dari repositori *Computer Vision* publik **Roboflow**. Tidak terdapat agenda akuisisi gambar primer secara manual menggunakan kamera di lapangan guna memfokuskan parameter eksperimen pada kapabilitas komputasional *Transfer Learning*.

3. Seluruh citra masukan diformat secara standar ke dalam ruang spektral RGB dan direduksi resolusinya (*bilinear resizing*) menuju dimensi spasial spesifik 224×224 piksel sebagai syarat fundamental asupan dimensi tensor model VGG16.
4. Paradigma klasifikasi bertumpu murni pada pemanfaatan arsitektur dasar VGG16 yang dioptimasi secara parametrik melalui metode *Transfer Learning* (pembekuan *layer* konvolusi) berbasis matriks bobot kompetisi *ImageNet*.
5. Konstruksi antarmuka komputasi sisi klien (*front-end*) dibangun dan dikonfigurasi sepenuhnya di atas pustaka bahasa pemrograman Python via ekosistem Streamlit v1.45.1.
6. Algoritma dilatih secara eksklusif untuk mengevaluasi citra tekstil tunggal dengan pola motif yang berkarakter dominan absolut di dalam *frame* gambar; sistem tidak dibekali kapabilitas segmentasi instans (*Instance Segmentation*) untuk mengenali motif bertumpuk atau citra hibrida (gabungan beberapa motif dalam satu bidang).

1.5 Manfaat Penelitian

Ekspansi kedalaman arsitektur komputasional yang digagas dalam penelitian ini diharapkan mampu membuahkan manifestasi manfaat yang luas dan berdimensi ganda:

1. **Bagi Pengembangan Ilmu Pengetahuan dan Akademik:** Memperluas diskursus empiris *Computer Vision* terkait utilitas hierarki arsitektur VGG16 dan *Transfer Learning* dalam memetakan kompleksitas spasial geometri berulang pada komoditas tekstil endemik berskala lokal. Selain itu, penelitian ini memberikan sumbangsih empiris dalam memvalidasi keandalan algoritma Grad-CAM sebagai jembatan epistemologi yang menyingkap tabir *black-box* dalam mekanisme pengambilan keputusan komputasi heuristik.
2. **Bagi Pelestarian Aset Budaya (*Cultural Preservation*):** Menginisiasi gerakan preservasi aset budaya immaterial secara terdigitalisasi (*Digital Humanities*), yang memberikan fasilitas komputasional langsung bagi masyarakat luas untuk memvalidasi identitas, ontologi, serta taksonomi motif Batik Aceh secara instan, portabel, dan sangat akurat.
3. **Bagi Sektor Ekonomi Kreatif dan Pelaku UMKM Batik:** Menyediakan perkakas otomatisasi interaktif untuk pemasaran visual; fitur *Virtual Try-On* dan deteksi cerdas memungkinkan pelaku industri skala kecil menengah memberikan pengalaman interaktif (*user experience*) yang modern kepada calon konsumen, yang bermuara pada peningkatan nilai komersial produk

lokal di pasar digital.

4. **Bagi Peneliti Lanjutan:** Mendemonstrasikan orkestrasi pembangunan ekosistem *Deep Learning* berskala purwarupa secara *end-to-end*, yang diawali dari kurasi repositori sekunder, manipulasi matriks gambar (*data augmentation*), komputasi *transfer learning*, agregasi evaluasi ke dalam *confusion matrix*, hingga tahapan kritikal berupa *deployment web-app* inferensial yang siap pakai.

1.6 Sistematika Penulisan

Sistematika penulisan skripsi ini disusun untuk memberikan gambaran secara menyeluruh mengenai alur pembahasan yang dilakukan. Sistematika penulisan dibagi menjadi lima bab utama sebagai berikut:

BAB I PENDAHULUAN

Bab ini menguraikan gambaran umum penelitian yang meliputi latar belakang masalah, rumusan masalah, tujuan penelitian, batasan masalah, manfaat penelitian, serta sistematika penulisan.

BAB II TINJAUAN PUSTAKA

Bab ini berisi kajian literatur dan landasan teori yang relevan dengan penelitian, mencakup *State of the Art* penelitian terdahulu, serta konsep citra digital, karakteristik motif Batik Aceh, algoritma CNN, arsitektur VGG16, teknik *Transfer Learning*, Grad-CAM, dan metode evaluasi.

BAB III METODE PENELITIAN

Bab ini menjelaskan tahapan metodologi penelitian, meliputi alur penelitian, pengumpulan dataset, prapemrosesan citra, perancangan arsitektur model, serta rancangan sistem aplikasi web Streamlit.

BAB IV HASIL DAN PEMBAHASAN

Bab ini menyajikan hasil implementasi model VGG16, hasil pelatihan, evaluasi kinerja menggunakan *Confusion Matrix*, implementasi aplikasi web Streamlit beserta hasil pengujian *Black-Box*, serta pembahasan menyeluruh terhadap temuan penelitian.

BAB V PENUTUP

Bab ini memuat kesimpulan yang menjawab rumusan masalah dan saran-saran konstruktif untuk pengembangan penelitian lanjutan di masa mendatang.

BAB II

TINJAUAN PUSTAKA

2.1 *State Of The Art*

Penelitian mengenai komputasi citra pada objek kain tradisional di wilayah Aceh awalnya bertumpu pada penggunaan algoritma klasifikasi *Machine Learning* konvensional. Riset lokal yang menjadi acuan utama dilakukan oleh Fajira, Indrawati, dan Aswandi (2022) yang mengklasifikasikan 3 motif Batik Aceh menggunakan metode *K-Nearest Neighbor* (K-NN) berbasis Android, di mana model tersebut mengalami penurunan akurasi drastis hingga 50% ketika diuji pada variasi dataset baru [1]. Kelemahan model konvensional juga ditunjukkan oleh Sinaga dan Jatmoko (2024) yang mengimplementasikan metode *Naïve Bayes* berbasis ekstraksi fitur tekstur *Gray Level Co-occurrence Matrix* (GLCM), di mana akurasi pengenalan sangat rentan menurun pada motif dengan latar belakang dinamis [18].

Dalam perkembangannya, penerapan CNN terbukti mampu mengotomatisasi ekstraksi fitur spasial. Namun, melatih CNN dari awal pada objek batik berskala lokal sering menghadapi kendala *overfitting* akibat keterbatasan data. Fenomena ini diperkuat oleh studi Brigato dkk. (2022) yang menegaskan bahwa tantangan sentral dalam klasifikasi citra pada *small datasets* membutuhkan teknik penyesuaian hyper-parameter yang ketat untuk mengalahkan performa arsitektur murni [21]. Fenomena ini diperkuat oleh studi Brigato dkk. (2022) yang menegaskan bahwa tantangan sentral dalam klasifikasi citra pada *small datasets*

membutuhkan teknik penyesuaian hyper-parameter yang ketat untuk mengalahkan performa arsitektur murni [21]. Fenomena ini divalidasi oleh Azmi, Defit, dan Sumijan (2023) yang melatih CNN untuk klasifikasi Batik Tanah Liat Sumatra Barat secara *from scratch*, di mana akurasi data latih mencapai 98,75% namun anjlok menjadi 62,5% pada data uji [15].

Implementasi *Transfer Learning* dengan arsitektur *pre-trained* VGG16 terbukti mengatasi masalah tersebut. Adithama, Dwiandiyanta, dan Wiadji (2023) berhasil meraih akurasi stabil 92,00% menggunakan VGG16 *pre-trained* pada 50 *epoch* [3]. Alya, Wibowo, dan Paradise (2023) menerapkan *Fine-Tuning* VGG16 dengan *learning rate* 0,0001 dan memperoleh akurasi 89% [10]. Ardyani dan Sari (2024) membuktikan bahwa modifikasi lapisan akhir VGG16 yang diintegrasikan ke platform web interaktif menghasilkan akurasi 98,72% [5]. Murinto, Winiarti, dan Faisal (2024) mengusulkan optimisasi *hyperparameter* menggunakan PSO-CNN dengan akurasi 83% [4].

Posisi kebaruan penelitian ini dibentuk untuk menyelesaikan batasan dari riset Utaminingsih dan Sahputra (2024) yang membangun sistem pengenalan Batik Aceh menggunakan arsitektur EfficientNet dengan akurasi 98%, namun sengaja mengeliminasi motif Pinto Aceh dan Rencong dari sistem klasifikasi karena dianggap sulit dibedakan [19]. Penelitian ini hadir untuk menutup celah tersebut dengan membangun sistem klasifikasi yang mencakup semua kelas termasuk kelas *Bukan Batik* sebagai kelas negatif untuk meningkatkan keandalan sistem di kondisi nyata. Ringkasan komparatif penelitian terdahulu disajikan pada Tabel 2.1.

Tabel 2.1 *State Of The Art* Penelitian Terdahulu

No	Penulis, Tahun dan Judul	Metode	Hasil	Persamaan	Perbedaan
1	Fajira, Indrawati & Aswandi (2022) [1]. Klasifikasi Motif Batik Aceh Menggunakan Metode K-NN Berbasis Android.	K-Nearest Neighbor (K-NN)	Akurasi turun drastis hingga 50% pada dataset baru di luar data latih.	Sama-sama mengklasifikasikan motif Batik Aceh dan menggunakan dataset citra lokal.	Menggunakan metode konvensional K-NN yang lemah terhadap variasi visual. Penelitian ini menggunakan VGG16 <i>Deep Learning</i> yang lebih <i>robust</i> .
2	Azmi, Defit & Sumijan (2023) [15]. Klasifikasi Batik Tanah Liat Sumatra Barat Menggunakan CNN.	CNN (<i>from scratch</i>)	Akurasi latih 98,75% namun akurasi uji hanya 62,5% (<i>overfitting</i> parah).	Sama-sama menggunakan CNN untuk klasifikasi motif batik lokal.	Dilatih dari nol tanpa <i>Transfer Learning</i> . Penelitian ini menggunakan VGG16 <i>pre-trained</i> untuk mengatasi <i>overfitting</i> .
3	Adithama, Dwiandiyanta & Wiadji (2023) [3]. Klasifikasi Batik Menggunakan Pre-trained VGG16.	VGG16 <i>Transfer Learning</i>	Akurasi pengujian stabil sebesar 92,00% pada 50 <i>epoch</i> .	Sama-sama menggunakan arsitektur VGG16 dengan bobot <i>pre-trained ImageNet</i> .	Tidak diimplementasikan pada platform web interaktif. Penelitian ini mengintegrasikan model ke Streamlit.
4	Alya, Wibowo & Paradise (2023) [10]. Fine-Tuning VGG16 untuk Klasifikasi Batik.	VGG16 <i>Fine-Tuning</i> , lr 0,0001	Akurasi pengujian sebesar 89% dengan laju <i>loss</i> yang stabil.	Sama-sama menggunakan skema <i>fine-tuning</i> VGG16 dengan <i>learning rate</i> kecil.	Tidak spesifik pada motif Batik Aceh. Penelitian ini berfokus pada kelas motif Batik Aceh beserta kelas negatif.

No	Penulis, Tahun dan Judul	Metode	Hasil	Persamaan	Perbedaan
5	Ardyani & Sari (2024) [5]. Modifikasi VGG16 pada Platform Web untuk Klasifikasi Batik.	VGG16 (<i>modified classifier head</i>)	Akurasi optimal sebesar 98,72% dengan konvergensi cepat.	Sama-sama mengintegrasikan VGG16 ke dalam platform web interaktif.	Tidak menggunakan motif Batik Aceh sebagai objek. Penelitian ini khusus mengklasifikasikan motif Batik Aceh.
6	Murinto, Winiarti & Faisal (2024) [4]. Optimisasi Hiperparameter CNN menggunakan PSO.	PSO-CNN, VGG16	Akurasi model sebesar 83% dengan optimisasi PSO.	Sama-sama menggunakan arsitektur berbasis VGG.	Memerlukan komputasi tambahan PSO. Penelitian ini menggunakan <i>Transfer Learning</i> standar yang lebih efisien.
7	Utaminingsih & Sahputra (2024) [19]. Pengenalan Pola Batik Aceh Menggunakan EfficientNet.	EfficientNet, <i>Transfer Learning</i>	Akurasi 98% namun mengeliminasi motif Pinto Aceh dan Rencong.	Sama-sama membangun sistem klasifikasi motif Batik Aceh berbasis <i>Transfer Learning</i> .	Menghilangkan 2 motif khas. Penelitian ini memasukkan semua motif termasuk kelas <i>Bukan Batik</i> untuk meningkatkan keandalan sistem nyata.

2.2 Citra Digital

Secara matematis, citra digital direpresentasikan sebagai fungsi intensitas cahaya dua dimensi $f(x,y)$, di mana variabel x dan y mengindikasikan koordinat spasial diskrit (baris dan kolom), sedangkan amplitudo fungsi f pada pasangan koordinat tersebut merepresentasikan derajat kecerahan atau nilai intensitas piksel (*pixel intensity*) pada titik ruang tersebut [11]. Proses transformasi optik dari dunia nyata menjadi representasi komputasional yang dapat diproses oleh mesin melibatkan dua tahapan diskritisasi fundamental: *sampling* (digitalisasi koordinat spasial kontinu ke dalam grid diskrit) dan *kuantisasi* (pemetaan rentang amplitudo intensitas kontinu ke dalam level nilai diskrit yang terhingga) [12].

Dalam ruang komputasi *Deep Learning*, khususnya saat berinteraksi dengan arsitektur VGG16, citra digital dengan spektrum warna RGB (Merah, Hijau, Biru) direkonstruksi menjadi sebuah struktur data *tensor* orde tiga. Sebuah citra beresolusi 224×224 piksel direpresentasikan sebagai tensor $224 \times 224 \times 3$, yang berarti terdapat 3 buah matriks 224×224 yang merepresentasikan saluran warna dasar secara terpisah. Penyeragaman dimensi topologi ini merupakan syarat mutlak agar operasi aljabar linear pada lapisan konvolusi dapat dieksekusi secara deterministik.

2.3 Karakteristik Visual Motif Batik Aceh

Batik Aceh merepresentasikan fusi artistik antara estetika geometris dan kepatuhan terhadap doktrin kultural-religius berupa larangan penggambaran

makhluk hidup secara naturalis (*aniconism*), yang secara fundamental membedakannya dari langgam batik pesisir atau pedalaman Jawa [1]. Palet warna pada Batik Aceh didominasi oleh spektrum berfrekuensi tinggi (merah cerah, kuning keemasan, hijau zamrud, dan hitam pekat) yang menghasilkan rasio kontras visual ekstrem, sering kali melambangkan karakter masyarakat Aceh yang tegas, berani, dan menjunjung tinggi kehormatan.

2.3.1 Motif Pinto Aceh

Motif Pinto Aceh (Pintu Aceh) memiliki struktur topologi yang sangat padat dan mendetail. Motif ini secara harfiah mengimitasi konstruksi ornamen arsitektural pintu tradisional *Rumoh Aceh*, yang merupakan peninggalan era keemasan Sultan Iskandar Muda [1],[17]. Karakteristik spasialnya didominasi oleh jalinan kurva-kurva tertutup berskala mikroskopis yang disusun rapi dalam sebuah bingkai vertikal yang simetris sempurna. Filosofi kerendahan hati (*peumulia jamee*) sangat kental terasa dari bentuk pintunya yang tidak terlalu tinggi, memaksa setiap orang yang masuk untuk menunduk hormat. Dari perspektif komputasional *Computer Vision*, kepadatan ornamen dan repetisi sulur pada Pinto Aceh menciptakan matriks fitur tepi (*edge features*) berfrekuensi tinggi. Pola ini sangat responsif terhadap *filter* konvolusi di lapisan dangkal CNN (*shallow layers*), karena filter-filter tersebut memang didesain secara spesifik untuk mengekstrak respons dari perubahan intensitas piksel yang tiba-tiba (*high-gradient edges*) [3].

2.3.2 Motif Pucok Reubong

Motif Pucok Reubong (Pucuk Rebung) dikarakterisasi oleh repetisi fraktal berbasis elemen triangular yang secara simbolis melambangkan anatomi tunas bambu muda [1]. Tunas bambu yang perlahan tumbuh tinggi namun tetap merunduk merepresentasikan filosofi dinamika pertumbuhan, keuletan, kemajuan peradaban, dan sinergi harmoni manusia dengan alam. Secara geometris, pola ini membentuk deretan matriks segitiga sama kaki yang memiliki keteraturan translasi yang konsisten. Struktur simetris dan linearitas diagonal yang ekstrem pada batas tepi segitiga membuat motif ini memiliki invariansi rotasional (*rotational invariance*) yang jauh lebih stabil. Kesederhanaan relatif dan ketegasan garis pada Pucok Reubong mempermudah arsitektur VGG16 dalam memetakan batas objek (*boundary mapping*) dengan *confidence score* yang umumnya selalu tinggi.

2.3.3 Motif Rencong

Motif Rencong diadaptasi dari struktur kurvatur anatomis senjata belati tradisional Aceh, simbol heroisme dan perlawanan tanpa lelah masyarakat Aceh dalam mempertahankan kedaulatan dari penjajahan [1]. Geometri utamanya sangat unik, dicirikan oleh struktur lengkungan gagang dan bilah yang asimetris tajam, yang secara visual mendobrak pola *grid* ortogonal yang biasa ditemukan pada batik tradisional. Absennya repetisi simetris yang prediktif pada motif ini memaksa model *Deep Learning* untuk tidak bisa sekadar bergantung pada *filter* dangkal pengekstraksi garis lurus. Sebaliknya, VGG16 harus mendelegasikan

beban komputasi pada agregasi fitur makro di lapisan konvolusi terdalam (*deepest layers*) guna menangkap abstraksi lekukannya yang nonlinear dan orientasi spasialnya yang asimetris [1]. Hal ini menjadikan kelas motif Rencong sering kali menjadi kelas dengan tingkat kesulitan klasifikasi tertinggi.

2.4 Dasar Teori *Convolutional Neural Network* (CNN)

Convolutional Neural Network (CNN) merupakan sebuah evolusi radikal dari arsitektur *Artificial Neural Network* (ANN) klasik. CNN adalah paradigma *Deep Learning* berarsitektur umpan-maju (*feedforward*) yang direkayasa secara khusus untuk memproses, menganalisis, dan mengekstraksi informasi dari data yang memiliki topologi berstruktur grid ruang, seperti citra dua dimensi. CNN mempertahankan hierarki keruangan spasial melalui dua asumsi krusial: konektivitas lokal (*local connectivity*) yang hanya menghubungkan neuron ke area tetangga di lapisan sebelumnya, dan pembagian parameter (*parameter sharing*) yang menggunakan matriks *filter* yang sama di seluruh ruang gambar untuk mendeteksi fitur tanpa mempedulikan lokasinya (*translation invariance*) [12],[13].

Topologi arsitektur CNN kontemporer direpresentasikan oleh orkestrasi tiga lapisan fungsional utama:

1. **Lapisan Konvolusi (*Convolutional Layer*):** Bertindak sebagai *feature extractor* utama. Lapisan ini mengkomputasi operasi aljabar *dot product* (perkalian titik) secara *sliding window* antara matriks *kernel* (*filter*) dengan wilayah input (*receptive field*) dari citra. Tujuannya adalah untuk

menghasilkan peta aktivasi (*activation map*) yang menyoroti eksistensi fitur spesifik. Secara komputasional matematis, proses ini didefinisikan sebagai:

$$S(i, j) = (I * K)(i, j) = \sum_m \sum_n I(i + m, j + n) \cdot K(m, n) \quad (2.1)$$

di mana I merepresentasikan tensor masukan dua dimensi, K adalah matriks *filter* konvolusi yang bobotnya dipelajari mesin, dan S adalah peta respons linear yang merepresentasikan aktivasi fitur.


2. **Lapisan *Pooling* (Sub-sampling)**: Berperan sentral sebagai fungsi reduksi dimensi spasial lokal (*downsampling*). Tujuannya adalah mereduksi kompleksitas komputasional, mengurangi jumlah bobot jaringan secara dramatis, serta memitigasi variansi translasi minor pada posisi fitur. Transformasi *Max Pooling*, yang paling populer digunakan, mengekstrak secara deterministik magnitudo atau intensitas tertinggi pada jendela spasial berukuran spesifik (umumnya 2×2 dengan *stride* 2):

$$y_{ij} = \max_{(m,n) \in R_{ij}} x_{mn} \quad (2.2)$$

3. **Fully Connected Layer (FCN)**: Bertindak sebagai lapisan agregasi global dan pengklasifikasi *classifier head* akhir. Lapisan ini meratakan (*flatten*) tensor spasial multi-dimensi hasil *pooling* terakhir menjadi vektor satu dimensi. Vektor ini kemudian menjalani proyeksi kombinasi linear padat (*dense*) menuju ruang vektor kelas target, sebelum diaktivasi ke dalam

wujud probabilitas murni oleh fungsi logistik akhir seperti *Softmax*.

Seluruh mekanisme optimisasi dan pembelajaran di dalam ekosistem CNN beroperasi secara iteratif melalui reduksi kesalahan (*loss function minimization*). Sistem mengkalkulasi seberapa salah tebakannya, lalu mendistribusikan error tersebut mundur menembus lapisan-lapisan (*backpropagation*). Melalui diferensiasi kalkulus berantai (*chain rule*) dan algoritma *gradient descent* iteratif, bobot-bobot *filter* konvolusi diperbarui sedikit demi sedikit hingga konvergen [13].



Gambar 2.1 Standar Arsitektur Konseptual CNN


2.5 Anatomi Arsitektur VGG16

VGG16 merupakan sebuah nomenklatur arsitektur jaringan saraf *deep* konvolusional yang dirancang oleh *Visual Geometry Group* (VGG) dari Oxford University. Model ini tampil sebagai *runner-up* pada kompetisi global bergengsi *ImageNet Large Scale Visual Recognition Challenge* (ILSVRC) tahun 2014 dan segera setelah itu, merevolusi paradigma desain CNN modern. Inovasi fundamental dari VGG16 adalah penghapusan total *kernel* konvolusi berukuran

raksasa (seperti 11×11 atau 7×7 yang digunakan pada AlexNet), dan mensubstitusinya secara brilian dengan penumpukan berantai (*stacking*) *filter* konvolusi minimalis berskala seragam 3×3 berspesifikasi *stride* 1 [12],[16].

Substitusi topologis ini bukannya tanpa alasan matematis; menumpuk dua *filter* 3×3 memiliki area reseptif (*receptive field*) yang setara dengan satu *filter* 5×5 , namun dengan jumlah parameter pembobot yang secara substansial lebih rendah. Lebih krusial lagi, arsitektur ini memaksa data untuk melewati dua kali proses aktivasi non-linear *Rectified Linear Unit* (ReLU). Injeksi non-linearitas ganda ini secara radikal memperkuat kemampuan jaringan untuk membentuk ruang diskriminasi fitur (*discriminative feature space*) yang jauh lebih kompleks dan ekspresif, tanpa meledakkan dimensi parameter memori [12],[16].

VGG16 dibangun dengan anatomi kedalaman (*depth*) 16 lapisan yang memiliki parameter (*learnable weights*), terdiri atas 13 *layer* konvolusi presisi tinggi dan 3 *dense layer* raksasa. Ke-13 lapisan konvolusi tersebut disegmentasi secara harmonis ke dalam 5 blok komputasi diskrit, di mana setiap blok diakhiri oleh sebuah fungsi *Max Pooling* guna mereduksi dimensi spasial menjadi setengah ukuran sebelumnya.



Gambar 2.2 Topologi Struktural Blok Konvolusi Arsitektur VGG16

Pada instalasi standar VGG16, *classifier head* terdiri dari vektor *Fully Connected* berukuran 4096 neuron, yang dirancang untuk mengklasifikasikan 1000 kelas ImageNet. Guna mengakomodasi ruang lingkup dataset penelitian ini yang jauh lebih spesifik dan sempit (hanya 4 kelas batik), ekstensi *classifier head* VGG16 diamputasi dan direkonstruksi ulang menjadi lebih efisien. Rekonstruksi ini menggunakan konfigurasi 2 lapisan *Dense* berukuran 256 dan 128 unit perceptron berturut-turut. Kedua *layer* baru ini diregularisasi secara paksa oleh fungsi *Dropout* (0,5), yang mana secara acak menonaktifkan 50% sambungan neuron selama *training* untuk memerangi fenomena *overfitting*. Arsitektur klasifikasi ini lantas diakhiri secara definitif oleh *Dense layer* 4-dimensi beraktivasi probabilitas komparatif *Softmax*.

2.6 Paradigma *Transfer Learning*

Proses melatih (*training*) sintesis model *Deep Learning* yang bertopologi sangat dalam (*very deep architecture*) secara *from scratch* (dari nol) sering kali dihadapkan pada ancaman patologi optimisasi serius. Fenomena matematis seperti hilangnya gradien secara eksponensial di lapisan awal (*vanishing gradient*) dan ketidakmampuan model untuk menggeneralisasi data (*overfitting* parah) hampir selalu terjadi ketika model kompleks beroperasi pada korpus dataset lokal yang skalanya terlalu sempit.

Transfer Learning diformulasikan sebagai sebuah instrumen *bypass* komputasional revolusioner untuk menjawab tantangan tersebut. Metode ini beroperasi dengan mentransplantasi matriks bobot (*weights*) dan bias dari sebuah *pretrained model*—yang telah menghabiskan ribuan jam komputasi GPU (Graphics Processing Unit) untuk mempelajari domain dataset visual universal raksasa yang mengandung jutaan gambar seperti *ImageNet*—secara utuh ke dalam model yang akan memecahkan tugas pada domain target spesifik [2],[6]. Transplantasi memori visual ini mengizinkan jaringan arsitektur untuk mengasimilasi fondasi representasi fitur laten yang tangguh—seperti gradien orientasi tepi, kurvatur ortogonal bervariasi, dan pemetaan respons warna tekstural halus—secara instan di *epoch* pertama, tanpa membebani model dari titik mula buta arah (*random weight initialization*) [7],[9].

Pada rancangan sistem arsitektural di penelitian ini, implementasi *Transfer Learning* dieksekusi dengan teknik *frozen base*. Seluruh hierarki 13 sub-lapisan

konvolusi *ImageNet* bawaan VGG16 dimutasi secara programatis menjadi statis (*frozen weights*), sehingga proses *backpropagation* di lapisan tersebut dinonaktifkan. Sebaliknya, hanya konfigurasi matriks bobot baru pada ujung klasifikasi buatan (*custom classifier head*) saja yang akan diperbarui secara aktif, dipaksa mengadaptasi komputasi kerumitan vektor dari keempat kelas diskrit motif Batik Aceh.

2.7 Interpretasi Model dengan Grad-CAM (*Explainable AI*)

Keunggulan dari *Convolutional Neural Networks* yang sangat dalam sering kali dibayangi oleh stigma skeptisisme karena sifat operasinya yang menyerupai *black-box* (kotak hitam matematis). Fenomena ini menyulitkan analis untuk melakukan validasi visual terhadap reliabilitas parameter yang dipelajari mesin. Untuk meruntuhkan batas tersebut, *Gradient-weighted Class Activation Mapping* (Grad-CAM) hadir sebagai sebuah terobosan paradigma transparansi algoritmis (*Explainable AI* atau XAI) [8]. Grad-CAM adalah algoritma analitik visual pasca-hoc (*post-hoc*) yang secara eksklusif memvisualisasikan agregasi pemetaan atensi spasial; mengungkap area mana pada citra yang paling memengaruhi aktivasi fungsi keputusan akhir di lapisan klasifikasi *black-box*.

Secara metodologis komputasional, Grad-CAM mengkomputasi propagasi gradien matematika berbalik arah (*backward pass gradient*) dari logit (skor mentah sebelum fungsi *Softmax*) sebuah kelas target yang spesifik, langsung menuju lapisan konvolusi spasial terakhir dari CNN (pada VGG16 adalah `block5_conv3`).

Proyeksi *backpropagation* ini mendefinisikan seberapa besar kontribusi rata-rata global matriks (*global average pooling*) yang disumbangkan setiap komponen filter di peta aktivasi spasial terhadap logit keputusan akhir target:

$$\alpha_k^c = \frac{1}{Z} \sum_i \sum_j \frac{\partial y^c}{\partial A_{ij}^k} \quad (2.3)$$

$$L_{\text{Grad-CAM}}^c = \text{ReLU} \left(\sum_k \alpha_k^c A^k \right) \quad (2.4)$$

Variabel diferensial α_k^c secara matematis merepresentasikan koefisien presisi kepentingan fitur (*feature importance weight*) atau gradien dari peta fitur A^k di lapisan konvolusi terakhir terhadap probabilitas variabel logit kelas c . Fungsi *Rectified Linear Unit* (ReLU) pada tahap perakitan akhir Grad-CAM diberlakukan secara ketat guna mengeleminasi aktivasi piksel bergradien negatif, karena hanya fitur bergradien positif yang secara linear berkontribusi dalam meningkatkan keyakinan model terhadap kelas bersangkutan. Luaran dari formula ini adalah sebuah *heatmap* (peta panas spektral) yang ketika di-overlay ke atas citra orisinal motif batik Aceh, secara luar biasa mampu mendemistifikasi kalkulus komputasional rumit dari jutaan parameter VGG16 menjadi sebuah persepsi warna kognitif yang seketika dapat dipahami secara transparan oleh mata manusia pengguna.

2.8 *Confusion Matrix* dan Analisis Metrik Evaluasi Kinerja

Di ranah *Machine Learning* observasional, validasi hipotesis terhadap daya tahan sebuah model *classifier* membutuhkan alat ukur kuantitatif yang definitif. *Confusion Matrix* (Matriks Konfusi) tampil sebagai fondasi tabel representasi visual matematis yang menyandingkan secara faktual jumlah prediksi kelas empiris (*predicted values*) yang diluahkan oleh model, melawan label kebenaran kelas sesungguhnya (*actual/ground truth*) dari korpus data pengujian [8]. Karena ekosistem klasifikasi ini membatasi preskripsi ruang lingkup pada 4 entitas kelas diskrit, matriks komputasi evaluasi yang terbentuk secara niscaya berukuran 4×4 .

Diferensiasi kombinasi dalam matriks mengklasifikasikan luaran prediktif ke dalam empat sel kategori operasional: *True Positives* (TP), *True Negatives* (TN), *False Positives* (FP), dan *False Negatives* (FN). Derivasi dari perpaduan kuadran matriks tersebut membuahkan agregasi rumus empiris terhadap performa sistem, yang dinormalisasikan ke dalam serangkaian metrik keberhasilan komprehensif berikut:

1. **Akurasi Keseluruhan (*Overall Accuracy*):** Mengukur prevalensi kebenaran komputasi secara holistik; persentase total di mana model secara absolut berhasil memprediksi identitas kelas (baik positif sejati maupun negatif sejati) dibandingkan dengan populasi keseluruhan sampel ruang observasi.

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (2.5)$$

2. **Presisi (*Positive Predictive Value*)**: Rasio ketepatan eksklusif; menyoroti dari seluruh citra yang berani diklaim (*predicted*) model sebagai milik satu motif spesifik, berapakah di antaranya yang benar-benar akurat sesuai dengan label ontologi aslinya.

$$\text{Precision} = \frac{TP}{TP + FP} \quad (2.6)$$

3. ***Recall* / Sensitivitas (*True Positive Rate*)**: Berfokus pada kuantifikasi agregasi kelolosan deteksi; dari populasi murni sebuah motif aktual, berapakah persentase fraksi yang sukses diselamatkan dan dikenali oleh sensitivitas matriks konvolusi tanpa dikelaskan sebagai (*False Negative*).

$$\text{Recall} = \frac{TP}{TP + FN} \quad (2.7)$$

4. ***F1-Score* (*Harmonic Mean*)**: Nilai keseimbangan harmonik ekstrem antara nilai Presisi dan *Recall*. Parameter ini menjadi mercusuar metrik krusial di situasi di mana ketidakseimbangan klasifikasi terjadi. Skala indeks mendekati sempurna (1.0) menjadi tanda tak terbantahkan dari dominansi ketangguhan model, bukan sekadar tebakan stokastik buta.

$$\text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (2.8)$$

2.9 Fundamental Pengujian Fungsional *Black-Box*

Metode Pengujian *Black-Box* (*Black-Box Testing*) adalah sebuah disiplin empiris rekayasa pengujian perangkat lunak yang berfungsi memvalidasi secara rigid dan tanpa kompromi integritas fungsionalitas sistem secara *end-to-end*, murni dan absolut dari perspektif interaksi eksternal (sisi pengguna/masukan dan luaran sistem yang teramati), tanpa diberikan akses secuil pun untuk menelisik anatomi algoritma internal kode program atau arsitektur *server* di belakang layar [8].

Dalam operasionalisasinya, penguji menyusun serangkaian parameter matriks skenario uji ekstrem yang diturunkan secara deduktif dari lembar spesifikasi kebutuhan fungsional perangkat lunak, kemudian mengamati dan membandingkan deviasi antara hasil aktual yang dieksekusi ekosistem aplikasi terhadap matriks luaran standar ekspektasi (*expected results*). Pada ranah validasi arsitektural penelitian ini, instrumen *Black-Box* diterapkan secara agresif terhadap seluruh dimensi antarmuka interaktif dan utilitas terapan aplikasi web Streamlit v1.45.1. Skenario verifikasi ini mencakup, namun tidak terbatas pada: kelancaran manuver fungsional asimilasi unggah data masif (*batch image uploader*), sinkronisasi inferensi prediktif *real-time* dan presentasi konfiden hasil klasifikasi, integritas penyajian *overlay* spasial antarmuka visual *Grad-CAM*, validitas komposisi logika alfa (*alpha blending calculation*) komputasi pada simulator integrasi *Virtual Try-On*, presisi fungsi konversi laporan format riwayat sesi berbasis *DataFrame* Pandas ke bentuk formatur PDF yang standar, serta transisi navigasi tab interaktif sistem perpustakaan data Kamus Motif.

BAB III

METODE PENELITIAN

3.1 Alur Penelitian

Alur penelitian ini dirancang secara sistematis melalui delapan fase operasional utama sebagaimana diilustrasikan pada Gambar 3.1: (1) Penetapan masalah dan studi literatur, (2) Pengumpulan dan anotasi dataset, (3) Prapemrosesan dan augmentasi citra, (4) Perancangan arsitektur model VGG16 dengan *Transfer Learning*, (5) Pelatihan model, (6) Evaluasi kinerja model, (7) Implementasi aplikasi web Streamlit, dan (8) Pengujian sistem dan penyusunan laporan.



Gambar 3.1 Alur Penelitian

3.2 Data dan Pengumpulan Data

Tahapan pengumpulan data merupakan fondasi empiris dalam membangun model *Deep Learning* yang tangguh. Bagian ini menguraikan secara komprehensif mengenai dimensi operasional riset, mulai dari penjadwalan eksekusi komputasi,

rincian infrastruktur spesifikasi alat dan bahan (baik perangkat keras maupun perangkat lunak), hingga penjabaran mengenai karakteristik, sumber akuisisi, dan rasio pembagian dataset citra motif Batik Aceh yang digunakan sebagai korpus pelatihan dan pengujian arsitektur algoritma.

3.2.1 Tempat dan Waktu Penelitian

Proses perancangan arsitektur perangkat lunak, komputasi model VGG16, hingga *deployment* aplikasi antarmuka dikonsolidasikan sepenuhnya di Laboratorium Komputasi Cerdas, Jurusan Teknologi Informasi dan Komputer, Politeknik Negeri Lhokseumawe. Rangkaian riset komputasional ini dieksekusi secara intensif selama 4 (empat) bulan kalender, terentang dari bulan Maret 2026 hingga Juni 2026, yang rincian aktivasinya tersaji pada Tabel 3.1.

Tabel 3.1 Jadwal Pelaksanaan Penelitian

No	Kegiatan	Maret	April	Mei	Juni
1	Persiapan dan Kajian Literatur Komputasional	✓			
2	Ekstraksi dan Validasi Dataset Sekunder (Roboflow)	✓	✓		
3	Komputasi <i>Preprocessing</i> dan Augmentasi Spasial		✓		
4	Konfigurasi Topologi dan Pelatihan Arsitektur VGG16		✓	✓	
5	Evaluasi <i>Confusion Matrix</i> dan <i>Explainable AI</i>			✓	
6	Rekayasa <i>Deployment</i> Aplikasi Web Streamlit			✓	✓
7	Pengujian <i>Black-Box</i> dan Kompilasi Laporan				✓

3.2.2 Alat dan Bahan Penelitian

Tabel 3.2 Daftar Alat dan Bahan Penelitian

No	Kategori	Nama Alat/Bahan	Spesifikasi / Deskripsi
1	Perangkat Keras	Mesin Komputasi (Laptop)	Intel Core i5-8250U @ 1.60 GHz (4 Cores, 8 Threads), RAM 16 GB DDR4, SSD 256 GB, AMD Radeon 530 2 GB. Bertindak sebagai <i>host</i> komputasi lokal untuk agregasi model.
2	Perangkat Lunak	Sistem Operasi	Windows 10/11 (64-bit) <i>Environment</i> .
		<i>Code Editor</i>	AntiGravity IDE v2.0.3 untuk orkestrasi skrip Python dan <i>environment</i> LaTeX.
		Python Interpreter	Python v3.13.12 sebagai instrumen pelaksana <i>runtime</i> .
		<i>Deep Learning Engine</i>	TensorFlow v2.21.0 dan Keras sebagai abstraktor tensor untuk membangun topologi lapisan VGG16 dan memuat ruang bobot <i>ImageNet</i> .
		<i>Web Micro-Framework</i>	Streamlit v1.45.1 untuk sintesis <i>User Interface</i> reaktif.
		Modul Pendukung	OpenCV, NumPy, Scikit-Learn, Plotly, Pillow, dan fpdf.
3	Bahan Penelitian	Korpus Citra Batik Aceh	700 citra tekstil digital (175 matriks/kelas) meliputi: Bukan Batik, Pinto Aceh, Pucok Reubong, dan Rencong. Ekstraksi absolut bersumber dari repositori eksternal Roboflow .

3.2.3 Dataset

Basis observasi yang menyusun eksperimen ini adalah dataset citra digital multikelas yang diakuisisi 100% (sepenuhnya) melalui ekstraksi data (*data scraping*) dari repositori platform *Computer Vision* publik, ****Roboflow****. Penghapusan variabel pengambilan gambar lapangan (data primer) dilakukan untuk meminimalisasi *noise* optik lingkungan terbuka dan memfokuskan model pada konsistensi variansi resolusi data publik yang telah dikurasi. Pengumpulan kelas **Bukan Batik** direkomendasikan secara khusus guna merepresentasikan probabilitas *true-negative* yang krusial pada implementasi sistem pengenalan visual (**Visual Recognition System**).

Korpus komputasional ini memuat total 700 *instances* citra berformat JPG/PNG yang terstratifikasi secara simetris ke dalam 4 dimensi kelas, sesuai pemaparan Tabel 3.3.

Tabel 3.3 Distribusi Dataset Citra Batik Aceh (Sumber: Roboflow)

No	Kelas Kategori	Kuantitas Citra	Representasi Proporsi (%)
1	Bukan Batik	175	25%
2	Pinto Aceh	175	25%
3	Pucok Reubong	175	25%
4	Rencong	175	25%
Total Ruang Sampel		700	100%



Gambar 3.2 Contoh Sampel Dataset Citra Batik Aceh

3.2.4 Dekomposisi Pembagian Dataset

Untuk mengeksekusi validitas pelatihan dan memitigasi anomali *overfitting*, ruang sampel dipartisi secara stohastik mengadopsi rasio standar *Deep Learning* (80%:10%:10%) menjadi tiga sub-himpunan:

1. **Himpunan Pelatihan (*Training Set*):** 560 iterasi citra (140 citra per kelas) untuk mengkalibrasi matriks bobot inter-neuron pada *classifier head*.
2. **Himpunan Validasi (*Validation Set*):** 68 citra (17 citra per kelas) bertindak sebagai *proxy* iteratif guna mengontrol dinamika laju perbaikan (*loss convergence*) di setiap terminasi *epoch*.
3. **Himpunan Pengujian (*Testing Set*):** 72 citra (18 citra per kelas) dimanfaatkan secara independen pasca-pelatihan guna mengekstrak metrik evaluasi akhir dalam wujud *Confusion Matrix*.

3.3 Prapemrosesan Data (*Preprocessing*)

Guna menjamin kompatibilitas dimensi tensor masukan terhadap arsitektur dasar VGG16 serta meningkatkan kualitas ekstraksi fitur, korpus data mentah harus ditransformasi secara ketat melalui sekumpulan interpolasi fungsi spasial dan aljabar:

1. **Penyetaraan Dimensi Spasial (*Bilinear Resizing*):** Seluruh matriks citra RGB beresolusi heterogen yang dikurasi dari Roboflow direkonstruksi ukurannya secara merata menjadi format bujursangkar berdimensi absolut 224×224 piksel. Metode interpolasi *bilinear* digunakan untuk memperkirakan nilai piksel baru berdasarkan rata-rata jarak piksel ketetanggaan terdekat, sehingga meminimalisasi artefak atau efek *aliasing* bergerigi pada kurva motif batik.
2. **Normalisasi Intensitas Skalar:** Rentang kuantisasi spektrum warna asli piksel RGB $[0, 255]$ direduksi secara paksa menuju ekuivalensi skalar *floating-point* di rentang tertutup $[0, 1]$. Penjelasan dan persamaan matematis teoretis untuk tahapan normalisasi ini secara lengkap merujuk pada pembahasan di Bab II.
3. **Augmentasi Spasial Deterministik (*Data Augmentation*):** Mengingat volume dataset empiris yang relatif terbatas (hanya 560 citra latih), teknik regularisasi diterapkan menggunakan kelas `ImageDataGenerator` dari pustaka Keras untuk menginjeksi *noise* artifisial geometris yang terkendali pada data *training*. Manipulasi spasial yang diterapkan secara stokastik di

setiap iterasi *batch* meliputi:

- a. Perturbasi rotasi geometris acak ($\pm 30^\circ$) untuk mengajarkan model invariansi arah pandang.
- b. Perpindahan posisi sumbu Cartesian (*horizontal/vertical shift*) $\pm 20\%$ untuk melatih model mengenali motif yang tidak berada di pusat *frame*.
- c. Distorsi matriks *shear* $\pm 20\%$ untuk mensimulasikan efek tarikan kain.
- d. Modulasi rentang *zoom in/out* $\pm 20\%$ untuk mengenali motif dari jarak jepretan yang berbeda.
- e. Refleksi simetri cermin (*flip horizontal*).
- f. Pengkondisian intensitas luminansi (kecerahan) acak pada skala proporsional 80% hingga 120% untuk membuat model kebal terhadap variasi pencahayaan ruangan saat pengguna memotret batik sungguhan.

4. **Transformasi Batas Tensor (*Tensor Encapsulation*)**: Matriks akhir luaran prapemrosesan dikapsulasi ke dalam struktur *array* NumPy, yang kemudian disuntikkan dimensi ekstra pada sumbu *batch* menjadi objek tensor berdimensi empat (*4D-tensor*) dengan struktur spasial absolut (1,224,224,3) sebelum dinavigasikan menuju *input layer* jaringan VGG16.

3.4 Rancangan Model *Deep Learning*

Tahapan perancangan model merupakan inti komputasional dari penelitian ini, di mana arsitektur jaringan saraf tiruan dikonstruksi secara spesifik untuk mengekstrak dan mengenali pola geometris kompleks dari citra Batik Aceh.

Bagian ini memaparkan desain topologi arsitektur VGG16 berbasis *Transfer Learning*, modifikasi *classifier head* yang disesuaikan dengan domain permasalahan, serta elaborasi mengenai skenario strategi pelatihan dan pengaturan *hyperparameter* yang digunakan untuk mengawal laju perbaikan model demi mencapai tingkat akurasi yang optimal.

3.4.1 Arsitektur Model VGG16 dengan *Transfer Learning*

Perancangan model diawali dengan memanfaatkan *Convolutional Base* VGG16 tanpa lapisan *fully connected (headless)*, dimuat dengan *pre-trained weights ImageNet*. Seluruh lapisan konvolusi dibekukan (*layer.trainable = False*), mengunci sekitar 14,7 juta parameter menjadi statis (*non-trainable parameters*).

Modifikasi difokuskan pada rekonstruksi *custom classifier head* yang disambungkan pada ujung blok konvolusi terakhir, dengan susunan sebagai berikut:

1. **Lapisan *Flatten*:** Bertugas mengekstraksi peta fitur spasial multidimensi luaran `block5_pool` dan meratakannya menjadi vektor data *array* satu dimensi (*1D-array*).
2. **Lapisan *Dense Utama*:** Terdiri atas 256 unit *perceptron* tiruan yang diaktivasi oleh fungsi *Rectified Linear Unit (relu)*. Lapisan tebal ini berfungsi untuk mencari korelasi kombinatorial tingkat tinggi antar fitur abstrak dari batik. Untuk meredam resiko *overfitting*, lapisan ini langsung diregularisasi oleh modul *Dropout* (0,5) yang memutus koneksi 50% neuron secara stokastik di setiap iterasi.

3. **Lapisan Dense Sekunder:** Konfigurasi perantara menyempit (*bottleneck*) berisikan 128 unit *perceptron* (*relu*), yang juga dibentengi oleh *Dropout* (0,5). Reduksi jumlah neuron ini memaksa jaringan untuk mensintesis fitur menjadi representasi informasi yang jauh lebih padat sebelum masuk ke tahap keputusan.

4. **Lapisan Output Dense:** Lapisan keluaran berdimensi 4 unit neuron yang merepresentasikan probabilitas dari 4 ruang kelas target (Bukan Batik, Pinto Aceh, Pucok Reubong, Rencong). Lapisan ini dikalkulasi menggunakan fungsi aktivasi probabilitas komparatif *Softmax* (rumus matematis mengacu pada pembahasan di Bab II).

Grafik komputasional arsitektur (*computational graph*) kemudian dikompilasi ke dalam mesin *TensorFlow* menggunakan optimisator hibrida *Adam* (*Adaptive Moment Estimation*) yang terkenal tangguh mengatasi *sparse gradients*. *Learning rate* dasar disetel sangat konservatif di angka 1×10^{-4} (0,0001) agar model belajar perlahan tanpa melewati titik minimum global. Mengingat klasifikasi ini berdimensi *multi-class* yang saling eksklusif (*mutually exclusive*), fungsi *loss* yang dieksekusi adalah *Categorical Cross-Entropy*.

3.4.2 Skenario Pelatihan (*Training Strategy*)

Skenario pelatihan diatur secara dinamis dengan menerapkan tiga fungsi *callback* untuk mencegah terjadinya *overfitting* selama proses pelatihan:

1. ***EarlyStopping* (patience=10):** Agen pemantau metrik kerugian (*validation loss*). Modul ini akan memutus eksekusi pelatihan secara otomatis

(terminasi prematur) apabila kurva *val_loss* terdeteksi stagnan atau justru meningkat secara divergen selama 10 *epoch* konsekutif. Fitur pelengkap `restore_best_weights=True` menjamin bahwa bobot *weights* yang dikembalikan di akhir sesi adalah matriks bobot dari *epoch* dengan performa paling optimal, bukan dari *epoch* terakhir saat terhenti.

2. ***ReduceLROnPlateau*** (**factor=0,5, patience=5**): Agen penyesuai laju pembelajaran (*Learning Rate Scheduler*). Apabila *val_loss* membeku dan gagal turun selama 5 *epoch*, modul ini akan mengintervensi dengan mengebiri nilai *learning rate* menjadi setengahnya (50% dari nilai *current*). Penurunan drastis ini membantu model untuk melangkah lebih pelan, memungkinkannya menuruni lanskap gradien (*loss landscape*) yang curam dan masuk ke ceruk konvergensi lokal (*local minima*) secara presisi.
3. ***ModelCheckpoint***: Agen preservasi sistem. Modul ini diamanatkan untuk merekam dan menserialisasi topologi arsitektur beserta formasi bobot matematis model *terbaik* secara terus-menerus ke dalam format biner persisten (`model_vgg16_batik.h5`).

3.5 Rancangan Sistem Aplikasi Web

Bagian ini memaparkan rancangan purwarupa aplikasi web interaktif berbasis Streamlit. Pemodelan sistem direpresentasikan melalui *Use Case Diagram*, *Activity Diagram*, dan rancangan *User Interface* untuk menjembatani fungsionalitas model VGG16 dengan pengguna akhir.

3.5.1 Use Case Diagram


Sistem aplikasi web Streamlit melibatkan 1 aktor tunggal, yaitu Pengguna (*User*), yang berinteraksi langsung dengan 4 fungsionalitas utama. Spesifikasi *use case* disajikan pada Tabel 3.4.

Tabel 3.4 Spesifikasi Use Case Sistem Klasifikasi Batik Aceh

No.	Use Case	Deskripsi
1.	Mengakses Aplikasi Web	Pengguna membuka URL aplikasi web Streamlit melalui peramban lokal. Sistem memuat bobot model (.h5) ke memori dan merender antarmuka utama.
2.	Mengunggah Citra Batik Aceh	Pengguna mengunggah berkas gambar (JPG, JPEG, atau PNG, maks. 10 MB) melalui komponen <i>file uploader</i> . Sistem memvalidasi ekstensi file dan memulai pipeline prapemrosesan.
3.	Melihat Hasil Klasifikasi, Confidence Score, dan Grad-CAM	Sistem menampilkan label kelas hasil prediksi (Bukan Batik, Pinto Aceh, Pucok Reubong, atau Rencong), persentase <i>confidence score</i> , grafik distribusi probabilitas semua kelas, serta visualisasi <i>heatmap</i> Grad-CAM yang menjelaskan area fokus model.
4.	Menggunakan Virtual Try-On dan Kamus Motif	Pengguna dapat mensimulasikan tampilan motif batik pada pakaian virtual (kaos atau kemeja), serta membaca informasi edukatif tentang sejarah dan filosofi setiap motif Batik Aceh pada halaman Kamus Motif.

3.5.2 Activity Diagram

Activity Diagram memodelkan alur kerja sistem secara dinamis menggunakan arsitektur dua lajur (*swimlane*) yang mendemarkasi batas wewenang antara aksi reaktif **Pengguna** secara manual, dan eksekusi komputasi latar belakang oleh **Sistem Web beserta Model VGG16**, sebagaimana disajikan pada Gambar 3.3.




Gambar 3.3 Activity Diagram Sistem Klasifikasi Batik Aceh

Alur kronologis eksekusi program dijabarkan secara sekuensial berikut:

1. **Inisialisasi dan *Model Loading*:** Pengguna mengakses URL aplikasi. Sistem Streamlit memuat arsitektur dan matriks bobot model VGG16 (berformat `.h5`) ke memori melalui utilitas *caching*, lalu merender antarmuka utama.
2. **Interaksi Unggah dan Validasi Input:** Pengguna menyisipkan citra uji melalui *file uploader*. Sistem memvalidasi ekstensi (JPG, JPEG, PNG) dan ukuran berkas. Jika tidak valid, sistem menampilkan pesan galat.
3. **Eksekusi *Pipeline Prapemrosesan*:** Sistem mengurai gambar menjadi matriks RGB, meresize dimensi menjadi 224×224 piksel absolut, menormalisasi intensitas piksel ke $[0, 1]$, serta membungkusnya ke dalam dimensi tensor empat kutub $(1, 224, 224, 3)$.
4. **Inferensi Prediktif dan Ekstraksi Grad-CAM:** Matriks tensor diinjeksikan melalui arsitektur VGG16 untuk meluapkan distribusi probabilitas kelas (*Softmax*). Paralel dengan itu, kalkulus *Explainable AI* tereksekusi secara mundur mengekstrak respons gradien, membuahkan *heatmap* Grad-CAM.
5. **Render Visualisasi Luaran:** Hasil akhir (teks label motif, *confidence score*, grafik probabilitas, dan citra *overlay* Grad-CAM) ditampilkan pada layar sistem sebagai konklusi.


3.5.3 Rancangan Antarmuka Pengguna

Rancangan antarmuka aplikasi web Streamlit terdiri dari empat halaman utama yang dapat diakses melalui navigasi sidebar, sebagaimana disajikan pada Gambar 3.4 hingga Gambar 3.7.




Gambar 3.4 Rancangan Antarmuka Halaman Deteksi Motif

Rancangan antarmuka pada Gambar 3.4 merupakan halaman utama (beranda) dari aplikasi berbasis Streamlit. Halaman ini didesain dengan prinsip minimalisme dan *user-centric*, berfokus pada area *drag-and-drop* yang dominan di bagian tengah untuk memfasilitasi unggahan citra (*image uploader*). Pada sisi kiri, terdapat panel navigasi (*sidebar*) yang terstruktur, memungkinkan transisi modul fungsional secara dinamis tanpa memicu perenderan ulang seluruh halaman (*Single Page Application paradigm*). Desain ini memandu pengguna secara intuitif dengan instruksi dan batasan format fail yang jelas (JPG, JPEG, PNG, maks. 10MB), memastikan fokus penuh pada tugas utama klasifikasi.



Gambar 3.5 Rancangan Antarmuka Halaman Hasil Klasifikasi

Setelah sistem mengeksekusi *pipeline* inferensi komputasi VGG16, umpan balik (*feedback*) kepada pengguna direpresentasikan melalui halaman hasil klasifikasi sebagaimana ditunjukkan pada Gambar 3.5. Antarmuka ini mengadopsi partisi tata letak multi-kolom; menampilkan pratinjau citra masukan berdampingan dengan hasil prediksi label kelas secara prominen, indeks *confidence score* berbentuk *progress bar* visual, serta proyeksi peta *saliency* dari *Explainable AI* (Grad-CAM) untuk menjamin transparansi keputusan algoritma. Kolom pratinjau memvalidasi input, grafik probabilitas mengukur tingkat keyakinan model, sementara *heatmap* Grad-CAM secara visual menyoroti area piksel fokus model, menjadikan keputusan AI lebih mudah diinterpretasikan oleh pengguna.



Gambar 3.6 Rancangan Antarmuka Halaman Kamus Motif

Gambar 3.6 merepresentasikan desain halaman Kamus Motif. Antarmuka ini difungsikan sebagai sistem manajemen pengetahuan (*knowledge management system*) statis yang mengkurasi deskripsi naratif, filosofi historis, dan contoh visual untuk setiap entitas motif Batik Aceh (Pinto Aceh, Pucok Reubong, dan Rencong). Penggunaan komponen *expander* atau *tabs* dialokasikan untuk mengemas informasi teks panjang agar tetap ringkas, *scannable*, dan tidak membebani kognisi pengguna (*cognitive overload*). Halaman ini memberikan nilai tambah edukatif sebagai pelestari budaya, menyatukan teks sejarah dan filosofi (seperti makna vertikal Pucok Reubong) dengan gambar referensi tinggi dalam format penjelajahan yang interaktif.



Gambar 3.7 Rancangan Antarmuka Halaman Riwayat Sesi

Guna memastikan *traceability* dan persistensi interaksi, halaman Riwayat Sesi dirancang seperti pada Gambar 3.7. Modul antarmuka ini mengonstruksi sebuah tabel interaktif yang secara otomatis merekam kronologi seluruh transaksi pengujian citra yang dieksekusi pada *session state* aktif. Selain itu, antarmuka ini menyediakan titik akses (*action button*) fungsional untuk menginisiasi skrip penulisan berkas PDF, memungkinkan pengguna mengeksport kompilasi riwayat data tersebut ke dalam bentuk laporan format standar yang terstruktur. Fitur ini sangat krusial bagi skenario evaluasi masal, merekam parameter kunci seperti penanda waktu, nama berkas, prediksi, dan skor keyakinan untuk mendukung pembuatan laporan dokumentasi atau *audit trail* kinerja AI.

3.6 Metode Pengujian

Perancangan pengujian dilakukan untuk mengevaluasi model *Deep Learning* dan aplikasi web Streamlit yang telah dikembangkan. Pengujian meliputi pengujian performa model, pengujian fungsionalitas (*Black-Box Testing*), dan pengujian struktur logika internal (*White-Box Testing*) untuk memastikan model dan aplikasi berjalan sesuai dengan tujuan penelitian.

3.6.1 Perancangan Pengujian Performa Model


Pengujian performa model bertujuan untuk mengevaluasi kemampuan model VGG16 dalam mengklasifikasikan citra motif Batik Aceh berdasarkan data uji (*testing set*) yang belum pernah digunakan selama proses pelatihan. Evaluasi performa model dilakukan secara kuantitatif menggunakan matriks konfusi (*Confusion Matrix*) yang kemudian menjadi landasan untuk mengalkulasi nilai akurasi (*accuracy*), presisi (*precision*), *recall*, dan *f1-score*.

3.6.2 Perancangan Pengujian *Black-Box*

Pengujian *Black-Box* dirancang untuk mengevaluasi fungsionalitas aplikasi web antarmuka berbasis Streamlit tanpa memperhatikan rincian atau struktur internal kode program. Pengujian dilakukan dengan memberikan berbagai skenario masukan pada setiap fitur (seperti halaman unggah, kamera, kamus motif, riwayat), kemudian membandingkan keluaran yang dihasilkan sistem dengan keluaran yang diharapkan.

3.6.3 Perancangan Pengujian *White-Box*

Pengujian *White-Box* dirancang untuk mengevaluasi struktur internal kode program dengan menganalisis logika dan alur kontrol (*control flow*) pada fungsi utama aplikasi, khususnya fungsi prediksi dan visualisasi citra. Metode yang digunakan adalah *Basis Path Testing*, dengan tahapan analisis yang mengacu pada landasan rekayasa perangkat lunak, yaitu meliputi penyusunan diagram alur keputusan, penyusunan *Flow Graph*, perhitungan besaran *Cyclomatic Complexity*, penentuan jumlah jalur eksekusi independen (*Independent Path*), hingga penyusunan skenario masukan yang mewakili kondisi rute-rute logika tersebut. Hasil pengujian akan diimplementasikan pada Bab IV.



Gambar 3.8 Representasi *Flowgraph* Algoritma Pemrosesan Citra

Tabel 3.5 Hasil Eksekusi Jalur Independen (*Independent Paths*)

Path	Urutan Node (Jalur)	Deskripsi Skenario Program	Status
1	1 → 15	Percabangan ketika input kosong (tidak ada file unggahan yang diberikan pengguna).	
2	1 → 2 → 15	Pengecekan akhir perulangan citra. Modul membatalkan proses apabila iterasi file telah habis.	
3	1 → 2 → 3 → 14 → 2	Simulasi apabila ekstensi gambar korup memicu blok <i>Exception</i> . Program kembali ke siklus antrean berikutnya.	
4	3 → 4 → 5 → 7 → 9 → 10 → 11 → 13	File diunggah, Mode <i>Crop</i> diaktifkan, dan citra terdeteksi Bukan Batik.	
5	3 → 4 → 6 → 8 → 9 → 10 → 12 → 13	File utuh diunggah (tanpa potong), citra valid teridentifikasi sebagai varian Batik Aceh.	
6	3 → 4 → 5 → 7 → 9 → 10 → 12 → 13	File masuk menggunakan mode <i>Crop</i> presisi serta tervalidasi benar oleh arsitektur model.	

BAB IV

HASIL DAN PEMBAHASAN

4.1 Implementasi Arsitektur Komputasi dan Strategi Pelatihan

Bagian ini menguraikan tahapan teknis dalam mengonstruksi dan melatih model klasifikasi berbasis *Convolutional Neural Network* (CNN) menggunakan arsitektur VGG16. Implementasi ini mencakup penerapan teknik *transfer learning*, penambahan arsitektur *classifier head*, serta strategi komputasi lainnya yang dirancang khusus untuk mengoptimalkan kemampuan model dalam mengenali pola-pola unik dari citra motif Batik Aceh.

4.1.1 Inisialisasi *Transfer Learning* dan *Frozen Convolutional Base*

Tahap pertama dalam konstruksi arsitektur ini adalah memuat arsitektur VGG16 (*backbone network*) yang telah dilatih menggunakan bobot dari *ImageNet*. Untuk memastikan bahwa fitur representasi dasar yang tersimpan di dalam parameter tersebut tidak mengalami *catastrophic forgetting* selama masa pelatihan awal, seluruh lapisan konvolusi dibekukan (*frozen*). Implementasi komputasi dari strategi ini dideklarasikan pada Gambar 4.1.

```
1 import tensorflow as tf
2 from tensorflow.keras.applications import VGG16
3 base_model = VGG16(
4     weights='imagenet',
5     include_top=False,
6     input_shape=(224, 224, 3))
```

```

7 )
8 for layer in base_model.layers:
9     layer.trainable = False

```

Gambar 4.1: Konfigurasi Transfer Learning dan Frozen Base Layer

Berdasarkan Gambar 4.1, berikut adalah penjelasan fungsi dari setiap baris kodenya:

- a. `import tensorflow as tf`: Mengimpor pustaka TensorFlow ke dalam memori.
- b. `from tensorflow.keras.applications import VGG16`: Memanggil modul arsitektur pre-trained VGG16 yang sudah tersedia secara bawaan di Keras.
- c. `base_model = VGG16(...)`: Menginisialisasi model VGG16 ke dalam variabel `base_model`.
- d. `weights='imagenet'`: Menginstruksikan model untuk memuat bobot pra-latih (*pre-trained weights*) yang didapatkan dari pelatihan dataset ImageNet.
- e. `include_top=False`: Mengabaikan arsitektur *Fully Connected Layer* (lapisan atas klasifikasi) bawaan VGG16, karena lapisan tersebut akan diganti dengan arsitektur khusus.
- f. `input_shape=(224, 224, 3)`: Menetapkan dimensi input citra, yaitu resolusi 224x224 piksel dengan 3 saluran warna (RGB).
- g. `for layer in base_model.layers::` Melakukan iterasi (perulangan) pada setiap lapisan konvolusi di dalam model dasar VGG16.

- h. `layer.trainable = False`: Membekukan (*freeze*) pembaruan bobot pada lapisan konvolusi tersebut selama fase pelatihan.

4.1.2 Sintesis *Custom Classifier Head* dan Regularisasi *Dropout*

Setelah fondasi konvolusi dipatenkan, langkah selanjutnya adalah merakit ujung klasifikasi spesifik (*custom classifier head*) yang disesuaikan murni untuk 4 dimensi kelas Motif Batik Aceh. Arsitektur ujung ini mengawinkan lapisan perceptron tebal (*Dense*) dengan mekanisme regularisasi *Dropout* ekstrem sebesar 50% (0.5) yang diformulasikan oleh Srivastava dkk. (2014) [22]. *Dropout* ini bertindak sebagai penjaga gerbang anti-*overfitting* yang memaksa jaringan untuk tidak mensintesis keputusan hanya berdasarkan satu set neuron tertentu, melainkan mendistribusikan pemahaman fitur ke seluruh matriks arsitektur. Proses ini ditunjukkan pada Gambar 4.2.

```

1 from tensorflow.keras.models import Model
2 from tensorflow.keras.layers import Flatten, Dense, Dropout
3 NUM_CLASSES = 4
4 x = base_model.output
5 x = Flatten(name="flatten")(x)
6 x = Dense(256, activation="relu", name="fc1")(x)
7 x = Dropout(0.5, name="dropout1")(x)
8 x = Dense(128, activation="relu", name="fc2")(x)
9 x = Dropout(0.5, name="dropout2")(x)
10 output = Dense(NUM_CLASSES, activation="softmax",
    name="output")(x)

```

```
11 model = Model(inputs=base_model.input, outputs=output)
```

Gambar 4.2: Konstruksi Classifier Head dengan Regularisasi Dropout

Berdasarkan Gambar 4.2, penjelasan rincian baris demi baris adalah sebagai berikut:

- a. `from tensorflow.keras...:` Mengimpor kelas `Model`, `Flatten`, `Dense`, dan `Dropout` yang dibutuhkan untuk merakit arsitektur pengklasifikasi (*classifier*).
- b. `NUM_CLASSES = 4:` Mendefinisikan konstanta jumlah kelas target luaran menjadi 4 kelas motif batik.
- c. `x = base_model.output:` Mengambil luaran fitur multidimensi dari lapisan terakhir model VGG16 yang telah dibekukan.
- d. `x = Flatten...:` Meratakan matriks luaran fitur tersebut menjadi matriks satu dimensi agar dapat diproses oleh algoritma perceptron (*Dense*).
- e. `x = Dense(256...):` Membuat lapisan saraf linear padat (*Dense*) dengan jumlah 256 neuron yang diaktivasi oleh fungsi ReLU (*Rectified Linear Unit*).
- f. `x = Dropout(0.5...):` Menerapkan regularisasi *Dropout* yang mematikan 50% (0.5) koneksi neuron secara acak untuk mencegah *overfitting*.
- g. `x = Dense(128...):` Menambahkan lapisan saraf padat kedua yang lebih mengerucut dengan kapasitas 128 neuron beraktivasi ReLU.
- h. `output = Dense(...):` Merupakan lapisan akhir yang berjumlah 4 neuron luaran, dikonfigurasi dengan fungsi aktivasi Softmax guna menghasilkan distribusi nilai probabilitas klasifikasi.

4.1.3 Kompilasi Model dengan *Adam Optimizer*

Untuk memastikan bahwa arsitektur yang telah dibangun dapat mengkalibrasi bobot parameter barunya secara efisien menuruni lanskap *loss* (gradien), model dikompilasi menggunakan *Adam Optimizer*. *Learning rate* (laju pembelajaran) disetel secara deterministik di angka mikroskopis 0,0001 (10^{-4}). Besaran ini dipilih secara sengaja untuk menghindari lonjakan pembaruan bobot yang terlalu radikal yang berpotensi mencederai fitur konvolusi yang telah dipelajari. Implementasinya dijabarkan pada Gambar 4.3.

```
1 from tensorflow.keras.optimizers import Adam
2 model.compile(
3     optimizer=Adam(learning_rate=0.0001),
4     loss='categorical_crossentropy',
5     metrics=['accuracy']
6 )
```

Gambar 4.3: Kompilasi Model dan Penentuan Fungsi Kerugian

Berdasarkan Gambar 4.3, alur logika setiap baris kode adalah sebagai berikut:

- a. `from tensorflow.keras.optimizers import Adam`: Mengimpor modul pengoptimal jaringan Adam (*Adaptive Moment Estimation*).
- b. `model.compile(...)`: Merupakan fungsi integrasi dari Keras untuk mengompilasi graf komputasi arsitektur jaringan model.
- c. `optimizer=Adam(learning_rate=0.0001)`: Menetapkan Adam sebagai algoritma optimasi dengan nilai laju pembelajaran (*learning rate*) statis

sebesar 0,0001 (10^{-4}).

- d. `loss='categorical_crossentropy'`: Menggunakan fungsi kerugian *Cross-Entropy* kategoris karena penelitian ini menyelesaikan permasalahan klasifikasi jamak (*multiclass*) bertarget *one-hot encoding*.
- e. `metrics=['accuracy']`: Memerintahkan kompilator untuk secara paralel menghitung dan memantau riwayat nilai metrik akurasi selama pelatihan bergulir.

4.1.4 Implementasi *Dynamic Callbacks* (Pemantauan *Real-Time*)

Alih-alih melatih model dengan iterasi *epoch* yang statis dan buta, sistem dirancang untuk memiliki otonomi pemantauan secara *real-time* menggunakan modul *Callbacks*. Ketiga agen *callback* (yakni *EarlyStopping*, *ReduceLROnPlateau*, dan *ModelCheckpoint*) bertindak secara simultan untuk memberhentikan pelatihan ketika konvergensi tercapai, menurunkan *learning rate* ketika terjadi stagnasi (*plateau*), serta merekam matriks bobot yang paling optimal. Konfigurasi cerdas ini terlihat pada Gambar 4.4.

```

1 from tensorflow.keras.callbacks import EarlyStopping,
    ReduceLROnPlateau, ModelCheckpoint
2 callbacks_list = [
3     EarlyStopping(
4         monitor="val_loss",
5         patience=10,
6         restore_best_weights=True,
7         verbose=1

```

```

8      ),
9      ReduceLROnPlateau(
10         monitor="val_loss",
11         factor=0.5,
12         patience=5,
13         min_lr=1e-7,
14         verbose=1
15     ),
16     ModelCheckpoint(
17         filepath=r"C:\22\model_vgg16_batik.h5",
18         monitor="val_loss",
19         save_best_only=True,
20         verbose=1
21     )
22 ]

```

Gambar 4.4: Konfigurasi Agen Supervisi Callbacks Anti-Overfitting

Berdasarkan Gambar 4.4, fungsionalitas dari blok program tersebut adalah sebagai berikut:

- a. `from tensorflow...`: Mengimpor ketiga objek *Callback* yang akan mengintervensi algoritma di sela-sela berjalannya proses pelatihan epoch.
- b. `callbacks_list = [...]`: Membuat sebuah koleksi daftar susunan konfigurasi *array* yang menampung agen-agen pemantauan model.
- c. `EarlyStopping(...)`: Menginisialisasi sistem penghenti otomatis yang memantau kurva `val_loss`. Fungsi ini akan menghentikan pelatihan dan

mengembalikan beban bobot terbaik (`restore_best_weights=True`) jika `val_loss` gagal menurun (memburuk) selama 10 epoch berturut-turut (`patience=10`).

- d. `ReduceLROnPlateau(...)`: Memerintahkan penurunan *learning rate* secara perlahan sebesar 50% (`factor=0.5`) apabila kurva `val_loss` mulai mengalami kebuntuan/stagnasi selama 5 epoch secara beruntun. Penurunan kecepatan *learning rate* dibatasi paling maksimal sampai angka 10^{-7} .
- e. `ModelCheckpoint(...)`: Agen penyimpanan memori fisik yang akan terus-menerus menyimpan luaran sistem (*model_vgg16.h5*), di mana proses overwrite *file* tersebut hanya diizinkan bekerja apabila model sukses memecahkan rekor nilai `val_loss` yang lebih rendah dari *epoch* sebelumnya (`save_best_only=True`).

4.1.5 Regularisasi Spasial melalui Augmentasi Data

Pipeline prapemrosesan awal merupakan benteng pertama untuk menekan angka *overfitting*, khususnya pada rezim data yang minim. Augmentasi data diimplementasikan secara stokastik di setiap generasi *batch* komputasi. Matriks piksel mengalami interpolasi rotasi, pergeseran (*shift*), distorsi (*shear*), *zoom*, pembalikan horizontal (*flip*), dan osilasi pencahayaan. Manipulasi geometris artifisial ini secara efektif melipatgandakan variansi korpus *training*, memaksa VGG16 untuk mencari representasi tekstur batik sejati tanpa mempedulikan orientasi posisi jatuhnya kain di dalam bingkai citra. Blok fungsi ini didemonstrasikan pada Gambar 4.5.

```

1 from tensorflow.keras.preprocessing.image import
    ImageDataGenerator
2 train_datagen = ImageDataGenerator(
3     rescale=1.0 / 255,
4     rotation_range=30,
5     width_shift_range=0.2,
6     height_shift_range=0.2,
7     shear_range=0.2,
8     zoom_range=0.2,
9     horizontal_flip=True,
10    brightness_range=[0.8, 1.2],
11    fill_mode="nearest")
12 val_test_datagen = ImageDataGenerator(rescale=1.0 / 255)

```

Gambar 4.5: Konfigurasi ImageDataGenerator dengan Augmentasi Ekstrem

Berdasarkan Gambar 4.5, penjelasan alur program augmentasinya adalah:


- a. `from...ImageDataGenerator`: Mengimpor kelas *generator* untuk meracik mutasi gambar secara kontinu (*on-the-fly*).
- b. `train_datagen = ...`: Objek generator khusus untuk memberikan efek augmentasi pada citra latih.
- c. `rescale=1.0 / 255`: Menerapkan normalisasi intensitas piksel warna (0-255) menjadi rasio pecahan (0-1).
- d. `rotation_range=30`: Merotasi sudut kemiringan citra secara acak maksimal 30 derajat.

- e. `width_shift` & `height_shift`: Menggeser posisi citra secara horizontal dan vertikal sebesar maksimal 20%.
- f. `shear_range` & `zoom_range`: Mendistorsi perspektif objek secara miring dan menerapkan *zoom in/out* rasio 0,2.
- g. `horizontal_flip=True`: Menerapkan efek pencerminan piksel citra secara horizontal.
- h. `brightness_range`: Mengubah level kecerahan secara stokastik di rentang 0.8 (redup) hingga 1.2 (terang).
- i. `fill_mode="nearest"`: Menambal celah kosong sisa pinggiran rotasi dengan mengkloning warna piksel terdekat.
- j. `val_test_datagen`: Generator evaluasi pengujian, yang hanya diwajibkan memikul operasi `rescale` normalisasi.

4.2 Hasil Pelatihan Model

Model VGG16 dilatih menggunakan data latih yang terdiri dari 560 citra.

Grafik kurva akurasi dan *loss* selama proses pelatihan disajikan pada Gambar 4.6.




Gambar 4.6 Grafik Training vs Validation Accuracy dan Loss

Berdasarkan grafik pada Gambar 4.6, kurva *Validation Accuracy* menunjukkan tren yang lebih tinggi dibandingkan *Training Accuracy* pada epoch-epoch awal. Hal ini merupakan perilaku yang wajar dan mengindikasikan bahwa strategi augmentasi data yang diterapkan membuat data latih lebih menantang, sehingga *val_loss* yang lebih rendah membuktikan model berhasil menggeneralisasi fitur Batik Aceh dengan baik tanpa *overfitting*.

4.3 Evaluasi Model dengan *Confusion Matrix*

Evaluasi kinerja model dilakukan pada data uji yang terdiri dari 72 citra (18 per kelas) yang belum pernah dilihat model selama pelatihan. Hasil *Confusion Matrix* disajikan pada Gambar 4.7.



Gambar 4.7 Confusion Matrix Hasil Klasifikasi Model VGG16

Untuk memberikan penjabaran angka klasifikasi yang lebih spesifik dan terperinci dari visualisasi grafik di atas, distribusi hasil prediksi model juga ditabulasikan ke dalam Tabel 4.1 berikut.

Tabel 4.1 Confusion Matrix Hasil Klasifikasi Model VGG16

Aktual / Prediksi	Bukan Batik	Pinto Aceh	Pucok Reubong	Rencong
Bukan Batik	18	0	0	0
Pinto Aceh	0	18	0	0
Pucok Reubong	0	0	18	0
Rencong	2	0	0	16

Berdasarkan visualisasi kuadran komputasi pada *Confusion Matrix* di Tabel 4.1, sistem pembelajar mesin ini berhasil membuktikan keandalannya dengan mengklasifikasikan 70 dari total 72 citra uji (*unseen data*) ke dalam ruang kelas yang benar. Satu-satunya anomali prediksi yang terjadi berpusat pada 2 citra varian motif Rencong yang mengalami *misclassification* (salah tebak) dan bergeser secara keliru ke dalam kelas *Bukan Batik*. Deviasi komputasi ini sangat dapat dimengerti secara logika spasial; karakteristik geometri motif Rencong direpresentasikan oleh lengkungan bilah asimetris yang tidak memiliki titik repetisi yang konsisten seperti halnya motif Pucok Reubong. Absennya keteraturan pola ini menyebabkan *classifier head* VGG16 sesekali mengalami degradasi *confidence* ketika dihadapkan pada potongan kain Rencong dengan orientasi yang ekstrem, sehingga fitur yang ditangkap diasumsikan oleh model sebagai *noise* acak dari objek non-batik. Perhitungan komprehensif atas persentase metrik evaluasi dari matriks tersebut ditabulasikan secara rinci pada Tabel 4.2.

Tabel 4.2 Normalisasi Metrik Evaluasi Model VGG16 Per Kelas

Kelas Target	Presisi (%)	Recall (%)	F1-Score (%)	Populasi Uji
Bukan Batik	90,00	100,00	94,74	18
Pinto Aceh	100,00	100,00	100,00	18
Pucok Reubong	100,00	100,00	100,00	18
Rencong	100,00	88,89	94,12	18
Agregasi Rata-rata	97,50	97,00	97,00	72

Akurasi empiris keseluruhan (*Overall Accuracy*) yang direngkuh model pada pengujian tahap akhir ini mencapai angka superior sebesar **97%**. Pada observasi kelas *Bukan Batik*, metrik Presisi tertahan di angka 90,00%. Penurunan presisi ini merupakan implikasi langsung dari insiden *False Positive* di mana 2 citra Rencong ditarik masuk ke sel kelas ini. Kendati demikian, seluruh 18 citra yang secara ontologis memang *Bukan Batik* sukses diamankan tanpa ada satu pun yang bocor (nilai *Recall* absolut 100%).


Di sisi lain, kelas motif Pinto Aceh dan Pucok Reubong mencatatkan pencapaian luar biasa dengan meraup nilai Presisi, *Recall*, dan *F1-Score* sempurna 100,00%. Hal ini memberikan konfirmasi matematis yang sangat kuat bahwa morfologi geometris kurva tertutup pada Pinto Aceh dan simetri fraktal triangular pada Pucok Reubong adalah fitur-fitur yang sangat diskriminatif dan eksklusif. Lapisan konvolusi VGG16 tidak menemui kesulitan berarti dalam menyintesis dan membedakan kedua pola tegas tersebut dari objek tekstil lainnya.

4.4 Implementasi Aplikasi Web Streamlit

Bagian ini mendemonstrasikan hasil akhir rancang bangun antarmuka pengguna (*User Interface*) berbasis web yang dikembangkan menggunakan *framework* Streamlit. Aplikasi ini bertindak sebagai jembatan interaktif yang menyembunyikan kompleksitas arsitektur komputasi VGG16 di latar belakang, sehingga memungkinkan pengguna akhir untuk melakukan klasifikasi citra batik secara praktis. Fungsionalitas aplikasi dibagi menjadi beberapa halaman utama yang menyediakan pengalaman terintegrasi, mulai dari proses manajemen berkas citra, pra-pemrosesan visual, hingga analisis prediktif interaktif.


4.4.1 Halaman Deteksi Motif (Utama)

Halaman Deteksi Motif merupakan antarmuka utama pengguna untuk melakukan klasifikasi Batik Aceh. Pengguna dapat mengunggah citra dan mendapatkan hasil prediksi secara *real-time*. Tampilan halaman unggah citra disajikan pada Gambar 4.8.



Gambar 4.8 Antarmuka Halaman Upload Gambar


Aplikasi ini dilengkapi dengan filter cerdas untuk mendeteksi citra yang bukan termasuk motif batik. Jika pengguna mengunggah gambar acak di luar konteks, sistem akan menolak dan memberikan label “Bukan Batik” sebagaimana ditunjukkan pada Gambar 4.9.



Gambar 4.9 Deteksi Otomatis untuk Citra Bukan Batik


4.4.2 Fitur *Crop* Citra dan Edge Detection

Akurasi model klasifikasi sangat bergantung pada fokus objek (motif batik). Jika citra yang diunggah memiliki terlalu banyak *background* (latar belakang), *confidence score* model dapat menurun. Gambar 4.10 memperlihatkan hasil prediksi dengan *confidence* yang kurang optimal ketika banyak latar belakang yang ikut terproses.




Gambar 4.10 Hasil Prediksi Sebelum Menggunakan Fitur Crop

Untuk mengatasi ini, pengguna disediakan fitur **Crop** interaktif (Gambar 4.11). Setelah *background* dipotong dan model hanya difokuskan pada objek utama batik, hasil *confidence score* mengalami peningkatan signifikan seperti yang terlihat pada Gambar 4.12.




Gambar 4.11 Proses Pemotongan Citra (Crop)



Gambar 4.12 Peningkatan Hasil Klasifikasi

Selain itu, terdapat fitur *Edge Detection* yang membantu pengguna memvisualisasikan garis tepi dari pola geometris Batik Aceh untuk keperluan analisis tekstur manual, seperti ditunjukkan pada Gambar 4.13.




Gambar 4.13 Hasil Visualisasi Edge Detection

4.4.3 Fitur Multi-Klasifikasi

Sistem juga mendukung kapabilitas *multi-classification*, di mana pengguna dapat mengunggah beberapa berkas citra sekaligus. Sistem akan memproses setiap


citra dalam antrean secara berurutan, sebagaimana diilustrasikan pada Gambar 4.14.



Gambar 4.14 Proses Prediksi Batch dengan Multi-Klasifikasi

4.4.4 Visualisasi Explainable AI (Grad-CAM)


Untuk mengeliminasi sifat *black-box* pada model *Deep Learning*, sistem mengintegrasikan Grad-CAM. Gambar 4.15 menunjukkan analisis XAI, dengan *heatmap* (area kemerahan) yang menyoroti titik-titik paling khas (*salient features*) pada citra motif sebagai dasar prediksi logis oleh model VGG16.



Gambar 4.15 Analisis XAI (Grad-CAM) pada Titik Khas Motif

4.4.5 Halaman Kamus Motif

Halaman Kamus Motif menyajikan ensiklopedia mini mengenai sejarah dan filosofi masing-masing motif Batik Aceh. Fitur ini memperkaya nilai pelestarian budaya dalam aplikasi (Gambar 4.16).



Gambar 4.16 Tampilan Halaman Kamus Batik

4.4.6 Riwayat Sesi dan Ekspor Laporan PDF

Sistem secara persisten menyimpan rekam jejak (*log*) dari setiap prediksi yang dilakukan pengguna selama satu sesi aktif. Riwayat ini disajikan dalam bentuk tabel dan dapat diekspor menjadi dokumen laporan PDF resmi, seperti yang ditampilkan pada Gambar 4.17 dan Gambar 4.18.

Riwayat Sesi Prediksi					
Medihat kembali log gambar yang telah diklasifikasi pada sesi aplikasi ini berikut					
Timestamp	Nama File	Prediksi	Confidence (%)	Original	Cropped
2026-07-18 00:47:05	Gambar Utuh (Original)	Pucok Reubong	51.79	temp_gam_imagecrop_20260718004705_0.png	temp_gam_imagecrop_ande_20260718004705_0.png
2026-07-18 00:47:30	Gambar Utuh (Original)	Pucok Reubong	100	temp_gam_imagecrop_20260718004730_0.png	temp_gam_imagecrop_ande_20260718004730_0.png
2026-07-18 00:50:09	Gambar Potongan (Cropped)	Pinto Aceh	99.81	temp_gam_imagecrop_20260718005009_0.png	temp_gam_imagecrop_ande_20260718005009_0.png

Gambar 4.17 Tabel Riwayat Sesi Prediksi

Laporan Riwayat Deteksi Motif Batik Aceh

Hasil Deteksi 1

Waktu Deteksi : 2026-07-18 00:47:05
 Nama File Gambar: Gambar Utuh (Original)
 Hasil Prediksi : Pucok Reubong
 Confidence Score: 51.79%



Hasil Deteksi 2

Waktu Deteksi : 2026-07-18 00:47:30
 Nama File Gambar: Gambar Utuh (Original)
 Hasil Prediksi : Pucok Reubong
 Confidence Score: 100.0%



Hasil Deteksi 3

Waktu Deteksi : 2026-07-18 00:50:09
 Nama File Gambar: Gambar Potongan (Cropped)
 Hasil Prediksi : Pinto Aceh
 Confidence Score: 99.81%



Gambar 4.18 Laporan Prediksi Format PDF

4.5 Hasil Pengujian *Black-Box*

Pengujian *Black-Box* dilakukan untuk memvalidasi fungsionalitas aplikasi web Streamlit. Hasil pengujian disajikan pada Tabel 4.3.

Tabel 4.3 Hasil Pengujian Black-Box Aplikasi Web Streamlit

No.	Skenario Pengujian	Masukan	Hasil yang Diharapkan	Status
1	Mengakses aplikasi web melalui URL	Membuka <code>localhost:8501</code> di peramban	Halaman Deteksi Motif berhasil termuat dengan model <i>ter-load</i>	✓
2	Mengunggah citra motif Pinto Aceh (JPG)	File .jpg berisi motif Pinto Aceh	Sistem menampilkan label “Pinto Aceh” beserta <i>confidence score</i>	✓
3	Mengunggah citra motif Pucok Reubong (PNG)	File .png berisi motif Pucok Reubong	Sistem menampilkan label “Pucok Reubong” beserta <i>confidence score</i>	✓
4	Mengunggah citra motif Rencong (JPEG)	File .jpeg berisi motif Rencong	Sistem menampilkan label “Rencong” beserta <i>confidence score</i>	✓
5	Mengunggah citra bukan batik	File citra non-batik	Sistem menampilkan label “Bukan Batik” beserta pesan peringatan	✓
6	Mengunggah beberapa file sekaligus	3 file gambar berbeda	Sistem memproses dan menampilkan hasil ketiga gambar secara berurutan	✓

No.	Skenario Pengujian	Masukan	Hasil yang Diharapkan	Status
7	Menggunakan fitur Grad-CAM (XAI)	Gambar Batik Aceh yang sudah diunggah	Sistem menampilkan <i>heatmap</i> Grad-CAM beserta titik hijau dan narasi alasan prediksi	✓
8	Menggunakan fitur Virtual Try-On	Gambar Batik Aceh + pilihan jenis pakaian	Sistem menampilkan simulasi motif batik pada pakaian virtual	✓
9	Navigasi ke halaman Kamus Motif	Klik menu “Kamus Motif” di sidebar	Sistem menampilkan halaman kamus dengan informasi 3 motif batik	✓
10	Ekspor laporan PDF di halaman Riwayat	Klik tombol “Ekspor Laporan”	Sistem menghasilkan dan mengunduh file PDF berisi riwayat sesi	✓

Berdasarkan hasil pengujian *Black-Box* pada Tabel 4.3, seluruh 10 skenario pengujian yang dirancang berhasil dieksekusi dengan hasil yang sesuai spesifikasi. Tingkat keberhasilan pengujian fungsional mencapai **100%**, membuktikan bahwa aplikasi web Streamlit yang dikembangkan berjalan secara responsif dan interaktif sesuai kebutuhan fungsional.

4.6 Hasil Pengujian *White-Box*

Pengujian *White-Box (Basis Path)* dieksekusi secara khusus pada arsitektur algoritma pemrosesan unggahan gambar di dalam aplikasi Streamlit (berada pada fungsi `render_detection_page()`). Berdasarkan rancangan *Control Flowgraph* dan perhitungan *Cyclomatic Complexity* ($V(G) = 6$) yang telah dijabarkan pada Bab III, terdapat 6 (enam) rute komputasi independen (*independent paths*) yang harus diuji.

Pelaksanaan pengujian mensimulasikan keenam jalur logika tersebut secara langsung ke dalam sistem aplikasi. Hasil eksekusi menunjukkan bahwa seluruh skenario percabangan—mulai dari penanganan *input* kosong, deteksi ekstensi berkas yang tidak valid, hingga validasi pengaktifan fitur *crop* gambar—berhasil dilalui tanpa memicu *fatal error* atau kegagalan komputasi. Rincian hasil eksekusi ini disajikan secara lengkap pada Tabel 4.4 berikut.

Tabel 4.4 Hasil Pengujian *White-Box (Basis Path)*

Path	Urutan Node (Jalur)	Deskripsi Skenario Program	Status
1	1 → 15	Percabangan ketika input kosong (tidak ada file unggahan yang diberikan pengguna).	✓
2	1 → 2 → 15	Pengecekan akhir perulangan citra. Modul membatalkan proses apabila iterasi file telah habis.	✓
3	1 → 2 → 3 → 14 → 2	Simulasi apabila ekstensi gambar korup memicu blok <i>Exception</i> . Program kembali ke siklus antrean berikutnya.	✓

Path	Urutan Node	Deskripsi	Status
4	3 → 4 → 5 → 7 → 9 → 10 → 11 → 13	File diunggah, Mode <i>Crop</i> diaktifkan, dan citra terdeteksi Bukan Batik.	✓
5	3 → 4 → 6 → 8 → 9 → 10 → 12 → 13	File utuh diunggah (tanpa potong), citra valid teridentifikasi sebagai varian Batik Aceh.	✓
6	3 → 4 → 5 → 7 → 9 → 10 → 12 → 13	File masuk menggunakan mode <i>Crop</i> presisi serta tervalidasi benar oleh arsitektur model.	✓

Melalui verifikasi *White-Box* yang komprehensif ini, disimpulkan bahwa matriks logika dan siklus perulangan (*loops*) pada kode internal sistem sepenuhnya stabil dan berfungsi sesuai dengan alur yang dirancang. Angka kerumitan siklomatis $V(G) = 6$ yang masuk ke dalam kategori sangat sehat turut membuktikan bahwa arsitektur algoritma aplikasi terbebas dari cacat kerentanan berskala sistematis (*systematic failure*).

4.7 Analisis Perhitungan Manual Konvolusi VGG16

Bagian ini menjabarkan simulasi matematis secara manual (*white-box*) dari mekanisme internal komputasi arsitektur VGG16. Pemaparan ini secara khusus ditujukan untuk membongkar kerumitan *black-box* dari *Deep Learning* dengan merunut tahapan transformasi piksel citra secara sistematis lapis demi lapis, mulai dari kalkulasi perkalian matriks (*dot product*) pada jendela konvolusi, penerapan fungsi aktivasi non-linear ReLU, hingga reduksi dimensi spasial melalui operasi *Max-Pooling*.

4.7.1 Representasi Input dan Kernel

Dalam arsitektur VGG16, operasi konvolusi 2D (Conv2D) dilakukan menggunakan filter (kernel) berukuran 3×3 dengan langkah pergeseran (*stride*) sebesar 1 dan *padding* bernilai 1 (*same padding*). Sebagai contoh simulasi, asumsikan terdapat sebagian kecil matriks citra input (*grayscale*) berukuran 5×5 piksel sebagai berikut:

$$I = \begin{bmatrix} 255 & 100 & 50 & 0 & 20 \\ 150 & 200 & 80 & 10 & 30 \\ 120 & 180 & 220 & 40 & 15 \\ 90 & 130 & 210 & 100 & 60 \\ 70 & 90 & 150 & 120 & 80 \end{bmatrix}$$

VGG16 menginisialisasi bobot (kernel) K berukuran 3×3 yang secara iteratif diperbarui selama masa pelatihan. Sebagai simulasi ekstraksi fitur primitif (contoh deteksi tepi vertikal), kernel diasumsikan sebagai berikut:

$$K = \begin{bmatrix} -1 & 0 & 1 \\ -2 & 0 & 2 \\ -1 & 0 & 1 \end{bmatrix}$$

4.7.2 Operasi Konvolusi (Conv2D)

Untuk menghitung nilai fitur pada koordinat spasial $x = 1, y = 1$ (titik sudut kiri atas asli matriks input), jendela matriks 3×3 diekstraksi dari input. Dengan

mengaplikasikan batas nol tambahan (*zero padding* $p = 1$), distribusi piksel pada sub-area tersebut menjadi:

$$I_{sub} = \begin{bmatrix} 0 & 0 & 0 \\ 0 & 255 & 100 \\ 0 & 150 & 200 \end{bmatrix}$$

Perhitungan *Dot Product* (Konvolusi) $Z = \sum(I_{sub} \circ K)$ dijabarkan sebagai:

$$\begin{aligned} Z &= (0 \times -1) + (0 \times 0) + (0 \times 1) \\ &\quad + (0 \times -2) + (255 \times 0) + (100 \times 2) \\ &\quad + (0 \times -1) + (150 \times 0) + (200 \times 1) \\ Z &= 0 + 0 + 0 + 0 + 0 + 200 + 0 + 0 + 200 = 400 \end{aligned}$$

4.7.3 Fungsi Aktivasi ReLU

Arsitektur VGG16 mengandalkan fungsi aktivasi *Rectified Linear Unit* (ReLU) pada setiap lapisan *hidden layer* untuk merepresentasikan non-linearitas. ReLU memetakan setiap hasil konvolusi dengan persamaan matematis $f(Z) = \max(0, Z)$. Berdasarkan hasil $Z = 400$, maka:

$$A = \max(0, 400) = 400$$

Seandainya nilai Z dari perhitungan bernilai negatif, maka ReLU akan mereduksinya menjadi angka absolut 0, yang mencerminkan ketidakaktifan

(*deactivation*) neuron visual tersebut.

4.7.4 Operasi Max-Pooling

Setelah melewati lapisan konvolusi, VGG16 menerapkan *Max-Pooling* dengan *pool size* 2×2 dan *stride* 2. Misalkan hasil aktivasi ReLU membentuk matriks:

$$A_{area} = \begin{bmatrix} 400 & 120 \\ 300 & 80 \end{bmatrix}$$

Nilai *pooled* yang diteruskan adalah nilai tertinggi dalam jendela tersebut:

$$M = \max(400, 120, 300, 80) = 400$$

Mekanisme ini mereduksi dimensi spasial peta fitur secara sistematis hingga setengah ukuran asalnya, sehingga arsitektur dapat memusatkan representasi pada abstraksi pola Batik Aceh dengan komputasi yang lebih efisien.

4.8 Pembahasan

Sintesis komprehensif dari riset ini bermuara pada keberhasilan pembangunan sebuah ekosistem klasifikasi *Computer Vision* berbasis arsitektur VGG16 dan paradigma *Transfer Learning* yang diproyeksikan khusus untuk menaklukkan kerumitan visual motif Batik Aceh. Agregasi akurasi akhir sebesar **97%** secara empiris merupakan pencapaian yang amat prestisius dan kompetitif dalam literatur komputasi terkait. Performa algoritma ini sukses mendisrupsi dan

mematahkan rekor akurasi dari penelitian terdahulu di kelas yang sama: secara meyakinkan melampaui hasil Adithama dkk. (2023) yang terhenti di 92% [3], Alya dkk. (2023) dengan akurasi 89% [10], Murinto dkk. (2024) di angka 83% [4], serta mengimbangi presisi 98,72% milik Ardyani dan Sari (2024) [5].

Titik episentrum kebaruan dan kontribusi ilmiah paling masif dari karya ini terletak pada keberhasilan model dalam mengasimilasi dan mengklasifikasikan kelas motif *Rencong* dan *Pinto Aceh* dengan tingkat konfiden tinggi. Pencapaian ini mendobrak batasan limitasi struktural dari penelitian Utaminingsih dan Sahputra (2024), yang secara eksplisit terpaksa mengeliminasi kedua mahakarya motif Aceh tersebut dari sistem mereka akibat ketidakmampuan model terdahulu dalam mengurai kompleksitas asimetrisnya [19]. Riset ini berhasil mengafirmasi bahwa tumpukan konvolusi presisi matriks 3×3 pada VGG16 memiliki kapabilitas superior dalam mengekstrak fitur spasial tingkat makro; mampu meraba hierarki lekukan belati *Rencong* dan mendeteksi kepadatan sulur *Pinto Aceh* tanpa terjadi kebocoran fitur (*feature-bleeding*) antar kelas.

Lebih jauh, injeksi cerdas berupa kelas *Bukan Batik* sebagai kutub negatif (*negative class*) terbukti mengangkat derajat reliabilitas dan integritas sistem ketika dilepasliarkan di kondisi nyata (*real-world environment*). Kehadiran kelas ini menyuntikkan sifat keraguan kritis (*skepticism*) pada mesin; sistem kini memiliki legitimasi untuk menolak menyimpulkan citra sampah atau gambar acak, alih-alih memaksa *classifier head* untuk menebak buta dan memasukkannya ke salah satu keranjang motif batik. Validasi *Confusion Matrix* memperlihatkan

bahwa kelulusan deteksi (2 citra Rencong diprediksi Bukan Batik) adalah harga logis dari bentuk Rencong yang melengkung dan asimetris, menjadikannya pergeseran kelas (*class shifting*) yang wajar secara matematis di ruang fitur laten.

Kombinasi penggunaan *frozen weights ImageNet* dan augmentasi data terbukti efektif mencegah *overfitting* pada dataset terbatas (700 citra). Selain itu, penerapan *Explainable AI* (Grad-CAM) pada antarmuka web Streamlit menjadikan model lebih transparan, sehingga pengguna dapat melihat langsung area piksel visual yang menjadi dasar keputusan VGG16 dalam mengenali jenis motif Batik Aceh.

BAB V

PENUTUP

5.1 Kesimpulan

Berdasarkan hasil penelitian dan pembahasan yang telah dilakukan, dapat ditarik beberapa kesimpulan sebagai berikut:

1. Sistem klasifikasi Batik Aceh berhasil dirancang dan dibangun menggunakan arsitektur VGG16 dengan teknik *Transfer Learning* berbasis bobot pra-latih *ImageNet*. Model dilatih menggunakan 560 citra data latih yang terbagi ke dalam 4 kelas (Bukan Batik, Pinto Aceh, Pucok Reubong, dan Rencong) dengan rasio pembagian 80%:10%:10%. Arsitektur *classifier head* yang dimodifikasi menggunakan dua lapisan *Dense* dengan *Dropout*(0,5) berhasil mencegah *overfitting* secara efektif.
2. Sistem klasifikasi berhasil diimplementasikan ke dalam platform antarmuka web interaktif menggunakan *framework* Streamlit v1.45.1. Aplikasi ini menyediakan fitur-fitur komprehensif meliputi klasifikasi *real-time* dengan *multi-file upload*, *mode crop*, *Explainable AI* berbasis Grad-CAM, *Virtual Try-On* untuk simulasi pakaian batik, kamus motif edukatif, dan ekspor laporan PDF. Pengujian fungsional *Black-Box* terhadap 10 skenario pengujian menunjukkan tingkat keberhasilan 100%.
3. Evaluasi kinerja model menggunakan *Confusion Matrix* pada 72 citra data uji menghasilkan akurasi keseluruhan sebesar **97%**, dengan nilai presisi rata-rata 97,50%, *recall* 97%, dan *F1-score* 97%. Kelas Pinto Aceh dan

Pucok Reubong mencapai performa sempurna (100%), sementara kelas Rencong memiliki *recall* 88,89% akibat kemiripan visual dengan kelas Bukan Batik. Hasil ini membuktikan bahwa teknik *Transfer Learning* VGG16 efektif dalam mengklasifikasikan motif Batik Aceh, termasuk kelas-kelas yang sebelumnya dianggap sulit oleh penelitian terdahulu.

5.2 Saran

Berdasarkan hasil penelitian dan keterbatasan yang ditemukan, saran konstruktif untuk pengembangan penelitian lanjutan adalah sebagai berikut:

1. **Peningkatan Dataset:** Penambahan jumlah dan keberagaman citra dataset, khususnya untuk kelas Rencong, dapat meningkatkan *recall* model pada kelas tersebut dan mengurangi kesalahan klasifikasi yang terjadi. Pengambilan gambar dari berbagai kondisi pencahayaan, sudut pandang, dan jenis kain yang lebih beragam sangat dianjurkan.
2. **Perluasan Kelas Motif:** Penelitian lanjutan dapat menambahkan kelas-kelas motif Batik Aceh lainnya seperti Bungong Jeumpa, Awan Berarak, atau Gayo untuk menciptakan sistem klasifikasi yang lebih komprehensif dan representatif terhadap keseluruhan kekayaan motif Batik Aceh.
3. **Fine-Tuning Penuh:** Eksperimen dengan membuka (*unfreeze*) beberapa lapisan konvolusi terakhir VGG16 untuk *fine-tuning* penuh dapat berpotensi meningkatkan akurasi lebih lanjut, terutama setelah fase pelatihan awal dengan lapisan terbekukan selesai.

4. **Eksplorasi Arsitektur Modern:** Perbandingan kinerja dengan arsitektur yang lebih modern seperti EfficientNetV2, ResNet50V2, atau Vision Transformer (ViT) dapat dilakukan untuk menentukan arsitektur yang paling optimal untuk kasus klasifikasi motif batik lokal.
5. **Deployment Online:** Sistem yang dikembangkan dapat di-*deploy* pada platform *cloud* seperti Streamlit Community Cloud atau Hugging Face Spaces agar dapat diakses secara publik melalui internet, sehingga manfaat pelestarian budaya Batik Aceh dapat menjangkau audiens yang lebih luas.

DAFTAR PUSTAKA

- [1] N. Fajira, Indrawati, dan Aswandi, “Klasifikasi Citra Batik Aceh Menggunakan Metode K-Nearest Neighbor (K-Nn) Berbasis Android,” *Jurnal Teknologi Rekayasa Informasi dan Komputer*, vol. 6, no. 1, 2022.
- [2] A. Zayyan dan D. Afriadi, “Changes and Adaptations of Acehnese Pinto Motifs in Modern Craft Arts,” *Proceeding of 2nd International Conference on Aceh Civilization*, 2023.
- [3] Murinto, S. Winiarti, dan I. Faisal, “Particle Swarm Optimization Algorithm for Hyperparameter Convolutional Neural Network and Transfer Learning VGG16Model,” *JCoSITTE*, vol. 5, no. 1, pp. 474–480, 2024.
- [4] A. Adithama, B. Y. Dwiandiyanta, dan Wiadji, “Klasifikasi Batik Menggunakan Pre-trained VGG16 dengan Transfer Learning,” *Jurnal Teknologi Informasi*, 2023.
- [5] R. F. Alya, M. Wibowo, dan Paradise, “CLASSIFICATION OF BATIK MOTIF USING TRANSFER LEARNING ON CONVOLUTIONAL NEURAL NETWORK(CNN),” *JUTIF*, vol. 4, no. 1, pp. 161–170, 2023.
- [6] A. Bendale and T. E. Boulton, “Towards Open Set Deep Networks,” in *CVPR*, 2016, pp. 1563–1572.
- [7] L. Brigato, B. Barz, L. Iocchi, and J. Denzler, “Image Classification with Small Datasets: Overview and Benchmark,” *IEEE Access*, 2022.
- [8] C. J. Anders et al., “Software for dataset-wide XAI: From local explanations to global insights with Zennit, CoRelAy, and ViRelAy,” *PLOS ONE*, 2026.
- [9] A. Escalante-Viteri and D. Mauricio, “Artificial Intelligence in Software Testing: A Systematic Review of a Decade of Evolution and Taxonomy,” *Algorithms*, vol. 18, 2025.
- [10] D. M. Asriny dan R. Jayadi, “Transfer Learning VGG16 for Classification Orange Fruit Images,” *JSMS*, vol. 13, no. 1, pp. 206–217, 2023.
- [11] K. Muchtar et al., “Edge AI-Based Detection for Defective Coffee Beans Using Deep Learning and Streamlit Framework,” *IEEE Access*, 2025.
- [12] S. R. Utaminingsih dan I. Sahputra, “Pengenalan Otomatis Pola Batik Aceh Berbasis Arsitektur EfficientNet,” *Jurnal Teknologi Informasi dan Komputer*, 2024.
- [13] A. R. Dani dan I. Handayani, “KLASIFIKASI MOTIF BATIK YOGYAKARTA MENGGUNAKAN METODE GLCM DAN CNN,” *Jurnal Teknologi Terpadu*, vol. 10, no. 2, pp. 142–156, 2024.

- [14] H. Ardiansyah dan T. Desyani, “Transfer Learning Menggunakan Model VGG16 untuk Klasifikasi Citra Hewan,” *Jurnal Pustaka AI*, vol. 5, no. 2, pp. 441–448, 2025.
- [15] M. M. A. Wona et al., “Klasifikasi Batik Indonesia Menggunakan Convolutional Neural Network (CNN),” *JURTI*, vol. 7, no. 2, 2023.
- [16] D. Anastasya et al., “Implementasi Metode Convolutional Neural Network (CNN) Dalam Klasifikasi Motif Batik,” *Nuansa Informatika*, vol. 18, no. 1, 2024.
- [17] W. N. Afifah dan V. Lusiana, “KLASIFIKASI JENIS BATIK SEMARANGAN MENGGUNAKAN METODE CONVOLUTION NEURAL NETWORK (CNN),” *JIPI*, vol. 10, no. 1, pp. 542–553, 2025.
- [18] S. S. F. Ardyani dan C. A. Sari, “A Web-Based for Demak Batik Classification Using VGG16 Convolutional Neural Network,” *ASSET*, vol. 6, no. 4, 2024.
- [19] I. Maulida, “KLASIFIKASI KAIN KHAS BATIK DAN KAIN KHAS SASIRANGAN MENGGUNAKAN METODE CONVOLUTIONAL NEURAL NETWORK,” Universitas Muhammadiyah Banjarmasin, 2021.
- [20] F. M. Shanni et al., “Classification of Indonesian Batik Motifs using CNN VGG16 with Transfer Learning and Fine-Tuning,” *Sistemasi*, vol. 15, no. 6, pp. 2228–2243, 2026.
- [21] S. Arifin dan Nurfaizah, “Klasifikasi Motif Batik Menggunakan Metode Convolutional Neural Network (CNN) Dengan Multi Class Clasification,” *Jurnal Ilmiah IT CIDA*, vol. 10, no. 1, 2024.
- [22] K. Azmi, S. Defit, dan Sumijan, “Implementasi Convolutional Neural Network (CNN) Untuk Klasifikasi Batik Tanah Liat Sumatera Barat,” *Jurnal Unitek*, vol. 16, no. 1, 2023.
- [23] A. Younis et al., “Brain Tumor Analysis Using Deep Learning and VGG-16 Ensembling Learning Approaches,” *Appl. Sci.*, vol. 12, 2022.
- [24] S. Aras, A. Setyanto, dan Rismayani, “Deep Learning Untuk Klasifikasi Motif Batik Papua Menggunakan EfficientNet dan Trasnfer Learning,” *INSECT*, vol. 8, no. 1, 2022.
- [25] H. Rohman et al., “Tomato Ripeness Classification Using Transfer Learning Approach with ResNet50 CNN Model,” *JUSI*, vol. 4, no. 3, pp. 646–659, 2025.
- [26] A. B. M. Aowlad Hossain et al., “Breast Cancer Classification from Ultrasound Images using VGG16 Model based Transfer Learning,” *IJIGSP*, vol. 15, no. 1, pp. 12–22, 2023.

- [27] A. Prayoga et al., “Arsitektur Convolutional Neural Network untuk Model Klasifikasi Citra Batik Yogyakarta,” JACOST, vol. 4, no. 2, pp. 82–89, 2023.
- [28] D. W. Pratama et al., “Multi-architectural Transfer Learning CNN for Klowong Batik Fabric Defect Classification,” JUTIF, vol. 6, no. 4, pp. 2123–2138, 2025.

LAMPIRAN

LEMBAR KONSULTASI PEMBIMBING I
LEMBAR KONSULTASI SKRIPSI
JURUSAN TEKNOLOGI INFORMASI DAN KOMPUTER
PROGRAM STUDI TEKNIK INFORMATIKA

Nama : Reyhan Putra Syahmi
NIM : 2022573010114
Judul TA : Rancang Bangun Sistem Klasifikasi Jenis
Batik Aceh Berdasarkan Motif Menggunakan
Convolutional Neural Network
Pembimbing I : M. Khadafi, S.T., M.T.
NIP : 197507182002121004

No.	Tanggal	Hasil Konsultasi	Paraf Pembimbing

LEMBAR KONSULTASI PEMBIMBING II
LEMBAR KONSULTASI SKRIPSI
JURUSAN TEKNOLOGI INFORMASI DAN KOMPUTER
PROGRAM STUDI TEKNIK INFORMATIKA

Nama : Reyhan Putra Syahmi
NIM : 2022573010114
Judul TA : Rancang Bangun Sistem Klasifikasi Jenis
Batik Aceh Berdasarkan Motif Menggunakan
Convolutional Neural Network
Pembimbing II : Azhar, S.T., M.T.
NIP : 196408301990031005

No.	Tanggal	Hasil Konsultasi	Paraf Pembimbing