

**RANCANG BANGUN SISTEM PREDIKSI *RETURN* SAHAM
MENGUNAKAN METODE *EXTREMELY RANDOMIZED
TREES* DAN *GRADIENT BOOSTING***

SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk Menyelesaikan Pendidikan

Jenjang Sarjana Terapan Pada Politeknik Negeri Lhokseumawe



OLEH:

ANDRIAN FAKHRUZA

NIM : 2022573010060

Program Studi : Teknik Informatika

Jurusan : Teknologi Informasi dan Komputer

**KEMENTERIAN PENDIDIKAN TINGGI, SAINS, DAN TEKNOLOGI
POLITEKNIK NEGERI LHOKSEUMAWE**

2026

PENGAJUAN SKRIPSI

**RANCANG BANGUN SISTEM PREDIKSI *RETURN* SAHAM
MENGUNAKAN METODE *EXTREMELY RANDOMIZED TREES* DAN
*GRADIENT BOOSTING***



Oleh

Andrian Fakhruza

NIM. 2022573010060

SKRIPSI

Diajukan Sebagai Salah Satu Syarat Untuk Menyelesaikan Pendidikan Jenjang
Sarjana Terapan Pada Politeknik Negeri Lhokseumawe

**PROGRAM STUDI TEKNIK INFORMATIKA
JURUSAN TEKNOLOGI INFORMASI DAN KOMPUTER
POLITEKNIK NEGERI LHOKSEUMAWE**

2026

PENGESAHAN PEMBIMBING

Skripsi yang berjudul *Rancang Bangun Sistem Prediksi Return Saham Menggunakan Metode Extremely Randomized Trees dan Gradient Boosting* Program Studi Sarjana Terapan Teknik Informatika , Jurusan Teknologi Informasi dan Komputer Pada Politeknik Negeri Lhokseumawe, telah disetujui dan memenuhi syarat untuk dipertanggungjawabkan dihadapan dewan penguji.

Buket Rata, 04 Agustus 2026

Pembimbing I,

Pembimbing II,

M. Khadafi, S.T., M.T.

NIP. 19750718 200212 1 004

Muhammad Reza Zulman, S.S.T., M.Sc.

NIP. 19920501 202203 1 005

Mengetahui

Ketua Jurusan

Teknologi Informasi dan Komputer,

Ketua Program Studi

Teknik Informatika,

Salahuddin, S.T., M.Cs.

NIP. 19740424 200212 1 001

M. Khadafi, S.T., M.T.

NIP. 19750718 200212 1 004

PENGESAHAN PENGUJI

Skripsi yang berjudul *Rancang Bangun Sistem Prediksi Return Saham Menggunakan Metode Extremely Randomized Trees dan Gradient Boosting* disusun oleh Andrian Fakhruza, NIM 2022573010060, Program Studi Teknik Informatika, Jurusan Teknologi Informasi dan Komputer Pada Politeknik Negeri Lhokseumawe, telah dipertanggungjawabkan didepan dewan penguji dan dinyatakan lulus pada tanggal 12 Agustus 2026.

Komisi Sidang,

M. Khadafi, S.T., M.T. NIP. 19750718 200212 1 004	 (Ketua Sidang)
---	-------------------------

Muhammad Reza Zulman, S.S.T., M.Sc. NIP. 19920501 202203 1 005	 (Sekretaris Sidang)
--	------------------------------

Muhammad Arhami, S.Si., M.Kom. NIP. 19741029 200003 1 001	 (Penguji I)
---	----------------------

Musta'inul Abdi, S.S.T., M.Kom. NIP. 19911030 201903 1 015	 (Penguji II)
--	-----------------------

Radhiyatammardhiyyah, SST, M.Sc. NIP. 19920826 202203 2 011	 (Penguji III)
---	------------------------

Mengetahui

Ketua Jurusan
Teknologi Informasi dan Komputer,

Ketua Program Studi
Teknik Informatika,

Salahuddin, S.T., M.Cs.
NIP. 19740424 200212 1 001

M. Khadafi, S.T., M.T.
NIP. 19750718 200212 1 004

HALAMAN PERNYATAAN

Dengan ini saya menyatakan bahwa dalam Skripsi ini tidak terdapat karya yang pernah diajukan untuk mendapatkan gelar kesarjanaan di suatu Perguruan Tinggi, dan sepanjang pengetahuan saya juga tidak terdapat karya atau pendapat yang pernah ditulis orang lain, kecuali yang secara tertulis diacu dalam naskah dan disebut dalam daftar pustaka

Buket Rata, 12 Agustus 2026

Andrian Fakhruza

NIM. 2022573010060

KATA PENGANTAR

Puji syukur penulis panjatkan kehadirat Allah SWT, karena atas rahmat dan hidayah-Nya, penulis dapat menyelesaikan skripsi ini dengan judul Rancang Bangun Sistem Prediksi *Return* Saham Menggunakan Metode *Extremely Randomized Trees* dan *Gradient Boosting*. Skripsi ini disusun sebagai salah satu syarat untuk memperoleh gelar Sarjana Terapan pada Program Studi Teknik Informatika Politeknik Negeri Lhokseumawe. Penulis menyadari bahwa skripsi ini masih jauh dari sempurna. Oleh karena itu, penulis mengharapkan kritik dan saran yang bersifat membangun dari semua pihak.

Dalam penulisan Skripsi ini penulis dapat melaksanakannya dengan baik berkat dukungan, bimbingan, dan bantuan dari berbagai pihak. Oleh karena itu, penulis ingin mengucapkan terima kasih yang sebesar-besarnya kepada:

1. Allah Swt. Atas segala rahmat, karunia dan kekuatan yang diberikan kepada penulis.
2. Keluarga tercinta terutama kedua orang tua tercinta, Ayahanda SURYA DARMA dan Ibunda ELYZAR yang telah memberikan dukungan moral dan material serta doa untuk penulis.
3. Kakak penulis yaitu Triana Ulvia dan Sagita Rahmadhani yang telah memberikan dukungan serta doa untuk penulis.
4. Bapak Dr. Ir. Rizal Syahyadi, ST., M.Eng.Sc., IPM., ASEAN Eng., APEC Eng. selaku Direktur Politeknik Negeri Lhokseumawe.
5. Bapak Salahuddin, S.T., M.Cs. selaku Ketua Jurusan Teknologi Informasi dan Komputer, Bapak Fachri Yanuar Rudi F, S.S.T., M.T. selaku Sekretaris

Jurusan Teknologi Informasi dan Komputer, dan Bapak M.Khadafi, S.T., M.T. selaku Ketua Program Studi Teknik Informatika atas segala bimbingan dan perhatian selama masa perkuliahan.

6. Bapak M.Khadafi, S.T., M.T. selaku Pembimbing utama dan Bapak Muhammad Reza Zulman, S.S.T., M.Sc. selaku pembimbing pendamping yang telah membantu, membimbing, dan mengarahkan penulis dalam proses penyelesaian Skripsi ini.
7. Bapak Muhammad Arhami, S.Si., M.Kom., Bapak Musta'inul Abdi, S.S.T., M.Kom., dan Ibu Radhiyatammardhiyyah, SST, M.Sc. selaku penguji yang telah bersedia memberikan arahan dan masukan dalam pengerjaan Skripsi ini.
8. Seluruh Dosen Pengajar Program Studi Teknik Informatika yang telah memberikan ilmu dan motivasi kepada penulis selama masa perkuliahan.
9. Sahabat-sahabat penulis yaitu yang telah kebersamai dan membantu penulis selama masa perkuliahan dan proses penyusunan Skripsi ini.
10. Teman-teman penulis yang telah telah mewarnai perjalanan perkuliahan dengan canda, tawa, serta diskusi penuh makna.
11. Teman-teman Program Studi Teknik Informatika Angkatan 2022 terkhusus TI kelas D yang telah kebersamai penulis selama masa perkuliahan.
12. Pihak-pihak lain yang tidak dapat penulis sebutkan satu persatu yang telah membantu penulis dalam penyusunan Skripsi ini.

Penulis menyadari bahwa Skripsi ini masih terdapat kekurangan dan ketidaksempurnaan. Oleh sebab itu, penulis mengharap adanya saran dan kritikan

yang membangun guna dijadikan bahan perbaikan dan pembelajaran untuk kedepan yang bermanfaat bagi penulis dan rekan-rekan yang membacanya. semoga bantuan dan kebaikan semua pihak dapat menjadi amal ibadah

Buket Rata, 12 Agustus 2026

Andrian Fakhruza
NIM. 2022573010060

ABSTRAK

Tingginya fluktuasi harga saham berkapitalisasi besar pada indeks IDX30 membuat investor memerlukan alat bantu analisis berbasis data untuk mengurangi ketergantungan pada intuisi dalam pengambilan keputusan investasi. Penelitian ini merancang sistem prediksi *return* saham IDX30 (SmartSaham) menggunakan pendekatan *Machine Learning* dan membandingkan performa algoritma *Extremely Randomized Trees* (ExtraTrees) dengan *Gradient Boosting*. Data historis diperoleh melalui *Yahoo Finance API*, meliputi indikator teknikal (seperti *Moving Average*, *RSI*, *MACD*) dan variabel makroekonomi (inflasi, BI Rate), dengan target prediksi berupa *return* kumulatif 5 hari bursa ke depan. Data dibagi secara *time-based split* untuk mencegah kebocoran data (*data leakage*), dan model dievaluasi menggunakan RMSE, MAE, dan R^2 . Hasil pengujian pada data uji menunjukkan model ExtraTrees memberikan performa terbaik dengan RMSE 0,068468, MAE 0,047930, dan R^2 -0,0139, serta mencatatkan efisiensi waktu pelatihan yang jauh lebih singkat dibandingkan *Gradient Boosting*. Nilai R^2 yang negatif mengindikasikan bahwa pergerakan *return* saham IDX30 dalam jangka pendek sulit dijelaskan hanya dengan indikator teknikal dan data makroekonomi, sejalan dengan efisiensi pasar jangka pendek (*short-term market efficiency*) setelah eliminasi *look-ahead bias*.

Kata Kunci: Prediksi *Return* Saham, IDX30, *Machine Learning*, *Extremely Randomized Trees*, *Gradient Boosting*, Indikator Teknikal, Makroekonomi, *Ensemble Learning*, SmartSaham, Bursa Efek Indonesia.

ABSTRACT

The high volatility of large-capitalization stock prices in the IDX30 index makes data-driven analytical tools essential for investors to reduce reliance on intuition in investment decision-making. This study designs a return prediction system for IDX30 stocks (SmartSaham) using a Machine Learning approach and compares the performance of the Extremely Randomized Trees (ExtraTrees) algorithm with Gradient Boosting. Historical data were obtained through the Yahoo Finance API, comprising technical indicators (such as Moving Average, RSI, and MACD) and macroeconomic variables (inflation and the BI Rate), with the prediction target being the cumulative return over the next 5 trading days. The data were split using a time-based split to prevent data leakage, and the models were evaluated using RMSE, MAE, and R^2 . Testing results on the test set show that the ExtraTrees model achieved the best performance, with an RMSE of 0.068468, MAE of 0.047930, and R^2 of -0.0139, and also recorded a significantly shorter training time compared to Gradient Boosting. The negative R^2 value indicates that short-term movements in IDX30 stock returns are difficult to explain using only technical indicators and macroeconomic data, which is consistent with short-term market efficiency after the elimination of look-ahead bias.

Keywords: *Stock Return Prediction, IDX30, Machine Learning, Extremely Randomized Trees, Gradient Boosting, Technical Indicators, Macroeconomics, Ensemble Learning, SmartSaham, Indonesia Stock Exchange.*

DAFTAR ISI

PENGESAHAN PEMBIMBING	ii
PENGESAHAN PENGUJI	iii
HALAMAN PERNYATAAN.....	iv
KATA PENGANTAR.....	v
ABSTRAK	viii
<i>ABSTRACT</i>	ix
DAFTAR ISI.....	x
DAFTAR GAMBAR.....	xiii
DAFTAR TABEL.....	xv
BAB I PENDAHULUAN.....	1
1.1 Latar Belakang Masalah	1
1.2 Rumusan Masalah.....	3
1.3 Tujuan Penelitian	4
1.4 Batasan Masalah	4
1.5 Manfaat Penelitian	5
1.6 Sistematika Penulisan	5
BAB II TINJAUAN PUSTAKA.....	8
2.1 <i>State of the Art</i>	8
2.2 Tinjauan Teoritis.....	15
2.2.1 Pasar Saham dan Investasi Saham.....	15
2.2.2 <i>Return</i> Saham.....	17
2.2.3 Indeks IDX30.....	18
2.2.4 Data dan Variabel dalam Prediksi Saham	20
2.2.5 Konsep <i>Machine Learning</i> dalam Prediksi Saham.....	21
2.2.6 <i>Ensemble learning</i>	22
2.2.7 Algoritma <i>Extremely Randomized Trees</i>	23
2.2.8 Algoritma <i>Gradient Boosting</i>	25
2.2.9 Evaluasi Model Prediksi (R^2 , <i>RMSE</i> , <i>MAE</i>)	26
BAB III METODOLOGI PENELITIAN	29
3.1 Alur Penelitian	29

3.2 Analisa Kebutuhan Sistem.....	31
3.2.1 Analisa Kebutuhan Sistem.....	31
3.2.2 Analisa Kebutuhan Non Fungsional.....	33
3.3 Rancangan Sistem.....	36
3.3.1 Ilustrasi Sistem.....	37
3.3.2 <i>Use case diagram</i>	38
3.3.3 <i>Activity diagram</i>	41
3.3.4 Perancangan <i>Database</i>	50
3.3.5 Rancangan <i>Wireframe</i>	55
3.4 Data dan Pengumpulan Data	70
3.4.1 Sumber Data	71
3.4.2 Rekayasa Fitur (<i>Feature engineering</i>).....	74
3.4.3 Pembagian Data	77
3.5 Pra-pemrosesan Data	78
3.5.1 Pembersihan Data (<i>Data cleaning</i>).....	78
3.5.2 Penanganan <i>Outlier</i>	79
3.5.3 Standardisasi Fitur (<i>Feature scaling</i>)	79
3.6 Pengembangan Model (<i>Model development</i>).....	80
3.6.1 <i>Extremely Randomized Trees</i> (ExtraTrees)	80
3.6.2 <i>Gradient Boosting</i>	81
3.6.3 Skenario Pengujian <i>Tuning Hyperparameter</i>	82
3.6.4 Proses Pelatihan Model.....	84
3.7 Pengujian dan Evaluasi Model.....	84
3.7.1 Pengujian Model.....	84
3.7.2 Metrik Evaluasi.....	85
3.7.3 Perbandingan Performa Model	86
BAB IV HASIL DAN PEMBAHASAN.....	87
4.1 Hasil <i>User interface</i> Sistem Prediksi <i>Return Saham</i>	87
4.1.1 Hasil Halaman <i>Login</i>	87
4.1.2 Hasil Halaman <i>Register</i>	88
4.1.3 Hasil Halaman Beranda	89

4.1.4 Hasil Halaman <i>Screener</i> Saham	90
4.1.5 Hasil Halaman Riset Emiten.....	92
4.1.6 Hasil Halaman <i>Watchlist</i>	97
4.1.7 Hasil Halaman <i>Price alert</i>	98
4.1.8 Hasil Halaman Pengaturan	100
4.1.9 Hasil Halaman Kelola <i>User</i>	101
4.2 <i>Preprocessing</i> Data.....	104
4.2.1 Rekayasa Fitur Teknikal (<i>Feature engineering</i>).....	104
4.2.2 Penggabungan dan Pembersihan Data (<i>Data cleaning</i>)	106
4.2.3 Rekayasa <i>Target</i> , Split Data, dan Standardisasi	108
4.3 Pengujian Sistem	111
4.3.1 Pengujian <i>Black box</i>	111
4.3.2 Pengujian <i>White box</i>	122
4.4 Hasil Skenario Pengujian <i>Tuning</i>	126
4.4.1 Skenario A - <i>Grid search</i> (Sempit).....	127
4.4.2 Skenario B - <i>Grid search</i> (Lebar)	130
4.4.3 Skenario C - <i>Randomized Search</i> (Sempit)	134
4.4.4 Skenario D - <i>Randomized Search</i> (Lebar)	138
4.4.5 Ringkasan Perbandingan Seluruh Skenario	143
BAB V PENUTUP	144
5.1 Simpulan	144
5.2 Saran	146
DAFTAR PUSTAKA	148
BIODATA PENULIS.....	151

DAFTAR GAMBAR

Gambar 3. 1 Tahapan Alur Penelitian.....	29
Gambar 3. 2 Ilustrasi Sistem Prediksi Saham	37
Gambar 3. 3 Use Case <i>User</i> dan <i>Admin</i>	40
Gambar 3. 4 <i>Activity diagram</i> Autentikasi Pengguna	42
Gambar 3. 5 <i>Activity diagram</i> Riset Emiten & Prediksi Saham	44
Gambar 3. 6 <i>Activity diagram</i> Manajemen <i>Watchlist</i>	46
Gambar 3. 7 <i>Activity diagram</i> <i>Price alert</i> & Pemicu Notifikasi	47
Gambar 3. 8 <i>Activity diagram</i> Panel <i>Admin</i> & Pengunggahan Data Makro	49
Gambar 3. 9 Struktur <i>Database</i> Tabel <i>Users</i>	50
Gambar 3. 10 Rancangan Halaman <i>Login</i>	56
Gambar 3. 11 Rancangan Halaman <i>Register</i>	57
Gambar 3. 12 Rancangan Halaman Beranda	58
Gambar 3. 13 Rancangan Halaman <i>Screener</i> Saham.....	59
Gambar 3. 14 Rancangan Halaman Riset Emiten	60
Gambar 3. 15 Rancangan Halaman Riset Emiten - Key Stats	61
Gambar 3. 16 Rancangan Halaman Riset Emiten - Faktor Prediksi	62
Gambar 3. 17 Rancangan Halaman Riset Emiten - Rencana Investasi.....	63
Gambar 3. 18 Rancangan Halaman Riset Emiten - Profil Perusahaan	64
Gambar 3. 19 Rancangan Halaman <i>Watchlist</i>	65
Gambar 3. 20 Rancangan Halaman <i>Price alert</i>	66
Gambar 3. 21 Rancangan Halaman Pengaturan - Profil Pengguna.....	67
Gambar 3. 22 Rancangan Halaman Pengaturan - Keamanan dan Sandi	68
Gambar 3. 23 Rancangan Halaman Kelola <i>User</i> - Manajemen Pengguna	69
Gambar 3. 24 Rancangan Halaman Kelola <i>User</i> - <i>Upload</i> Data Makro.....	70
Gambar 4. 1 Hasil Halaman <i>Login</i>	87
Gambar 4. 2 Hasil Halaman <i>Register</i>	88
Gambar 4. 3 Hasil Halaman Beranda.....	89
Gambar 4. 4 Hasil Halaman <i>Screener</i> Saham	91
Gambar 4. 5 Hasil Halaman Riset Emiten	92
Gambar 4. 6 Hasil Halaman Riset Emiten - Key Stats.....	93

Gambar 4. 7 Hasil Halaman Riset Emiten - Faktor Prediksi	94
Gambar 4. 8 Hasil Halaman Riset Emiten - Rencana Investasi	95
Gambar 4. 9 Hasil Halaman Riset Emiten - Profil Perusahaan.....	96
Gambar 4. 10 Hasil Halaman <i>Watchlist</i>	97
Gambar 4. 11 Hasil Halaman <i>Price alert</i>	99
Gambar 4. 12 Hasil Halaman Pengaturan - Profil Pengguna	100
Gambar 4. 13 Hasil Halaman Pengaturan - Keamanan dan Sandi.....	101
Gambar 4. 14 Hasil Halaman Kelola <i>User</i> - Manajemen Pengguna.....	102
Gambar 4. 15 Hasil Halaman Kelola <i>User</i> - <i>Upload</i> Data Makro	103
Gambar 4. 16 Kode Rekayasa Fitur Teknikal	105
Gambar 4. 17 Kode Pembersihan Data (<i>Data cleaning</i>).....	107
Gambar 4. 18 Kode Rekayasa <i>Target</i> , Split Data, dan Standardisasi Fitur	110
Gambar 4. 19 <i>Flowgraph</i> Proses Prediksi.....	124
Gambar 4. 20 Perbandingan Metrik R^2 , <i>RMSE</i> , <i>MAE</i>	128
Gambar 4. 21 <i>Actual vs predicted</i>	129
Gambar 4. 22 <i>Feature importance</i>	130
Gambar 4. 23 Perbandingan Metrik R^2 , <i>RMSE</i> , <i>MAE</i>	132
Gambar 4. 24 <i>Actual vs predicted</i>	133
Gambar 4. 25 <i>Feature importance</i>	134
Gambar 4. 26 Perbandingan Metrik R^2 , <i>RMSE</i> , <i>MAE</i>	136
Gambar 4. 27 <i>Actual vs predicted</i>	137
Gambar 4. 28 <i>Feature importance</i>	138
Gambar 4. 29 Perbandingan Metrik R^2 , <i>RMSE</i> , <i>MAE</i>	140
Gambar 4. 30 <i>Actual vs predicted</i>	141
Gambar 4. 31 <i>Feature importance</i>	142

DAFTAR TABEL

Tabel 3. 1 <i>Software</i> yang Digunakan	34
Tabel 3. 2 <i>Hardware</i> yang digunakan.....	36
Tabel 3. 3 Penjelasan <i>Use case diagram</i>	41
Tabel 3. 4 Struktur Tabel <i>Users</i>	51
Tabel 3. 5 Struktur Tabel <i>Watchlist</i>	52
Tabel 3. 6 Struktur Tabel <i>Price_Alerts</i>	52
Tabel 3. 7 Struktur Tabel <i>Inflation_Data</i>	53
Tabel 3. 8 Struktur Tabel <i>BI_Rate_Data</i>	54
Tabel 3. 9 Daftar Saham IDX30 yang Digunakan	71
Tabel 3. 10 Ringkasan Sumber Data Penelitian.....	74
Tabel 3. 11 Fitur (Variabel Independen) yang Digunakan dalam Model	76
Tabel 3. 12 Pembagian Data (<i>Time-based split</i>)	78
Tabel 3. 13 Skenario Pengujian <i>Tuning Hyperparameter</i>	82
Tabel 3. 14 Rentang <i>Hyperparameter</i> Model ExtraTrees.....	82
Tabel 3. 15 Rentang <i>Hyperparameter</i> Model <i>Gradient Boosting</i>	83
Tabel 3. 16 Metrik Evaluasi Model Regresi	85
Tabel 4. 1 <i>Black box</i> Autentikasi	112
Tabel 4. 2 Pengujian Halaman Beranda & <i>Screener</i> Saham.....	114
Tabel 4. 3 Pengujian Halaman Riset Emiten & Prediksi AI	115
Tabel 4. 4 Pengujian Halaman <i>Watchlist & Price alert</i>	117
Tabel 4. 5 Pengujian Halaman Pengaturan	119
Tabel 4. 6 Pengujian Halaman Kelola <i>User & Data</i> Makro.....	121
Tabel 4. 7 Potongan Kode Proses Prediksi	123
Tabel 4. 8 Test Case Skenario Proses Prediksi	125
Tabel 4. 9 Kombinasi <i>Hyperparameter</i> Terbaik ExtraTrees.....	127
Tabel 4. 10 Kombinasi <i>Hyperparameter</i> Terbaik <i>Gradient Boosting</i>	127
Tabel 4. 11 Kombinasi <i>Hyperparameter</i> Terbaik ExtraTrees.....	131
Tabel 4. 12 Kombinasi <i>Hyperparameter</i> Terbaik <i>Gradient Boosting</i>	131
Tabel 4. 13 Kombinasi <i>Hyperparameter</i> Terbaik ExtraTrees.....	135
Tabel 4. 14 Kombinasi <i>Hyperparameter</i> Terbaik <i>Gradient Boosting</i>	135

Tabel 4. 15 Kombinasi <i>Hyperparameter</i> Terbaik ExtraTrees.....	139
Tabel 4. 16 Kombinasi <i>Hyperparameter</i> Terbaik <i>Gradient Boosting</i>	139
Tabel 4. 17 Ringkasan Perbandingan Seluruh Skenario - ExtraTrees	143
Tabel 4. 18 Ringkasan Perbandingan Seluruh Skenario - <i>Gradient Boosting</i>	143

BAB I

PENDAHULUAN

1.1 Latar Belakang Masalah

Investasi saham merupakan salah satu instrumen keuangan yang banyak diminati masyarakat karena potensi keuntungan yang relatif tinggi dibandingkan instrumen investasi lainnya. Seiring meningkatnya jumlah investor ritel di Indonesia, khususnya dari kalangan generasi muda, banyak investor pemula yang masuk ke pasar saham hanya karena mengikuti tren dan dorongan keuntungan jangka pendek tanpa pemahaman yang memadai mengenai mekanisme pasar dan risiko investasi. Sebagian besar investor pemula belum memahami proses analisis saham secara menyeluruh sehingga keputusan investasi sering dilakukan secara impulsif dan tidak berbasis data yang kuat [1].

Fenomena serupa juga menunjukkan bahwa investor pemula kerap tergoda keuntungan instan serta mengikuti rekomendasi dari pihak tertentu tanpa memahami analisis teknikal saham secara komprehensif. Kondisi ini menyebabkan investor rentan mengalami kerugian karena keputusan yang diambil lebih didasarkan pada emosi dan tren pasar dibandingkan pertimbangan objektif terhadap potensi *return* dan risiko saham [2].

Pengambilan keputusan investasi di pasar modal pada era ketidakpastian ekonomi banyak dipengaruhi oleh faktor psikologis dan tekanan informasi. Investor yang tidak memiliki kemampuan dalam mengolah data historis secara sistematis cenderung terjebak pada rumor pasar dan spekulasi, sehingga keputusan yang diambil menjadi tidak rasional dan berisiko tinggi [3].

Perilaku investor pasar saham Indonesia masih didominasi oleh bias emosional seperti *overconfidence* dan *herd behavior*. Kondisi ini mengakibatkan investor sering mengabaikan analisis berbasis data dan lebih mengandalkan intuisi atau rekomendasi lingkungan sekitar dalam menentukan keputusan investasi [4]. Faktor *behavioral finance* juga memiliki pengaruh signifikan terhadap peningkatan risiko kerugian investasi pada investor ritel, terutama ketika keputusan tidak didukung oleh analisis teknikal [5].

Indeks IDX30 dipilih karena terdiri dari 30 saham dengan tingkat likuiditas paling tinggi dan kapitalisasi pasar *free float* besar yang disaring secara selektif dari 45 konstituen LQ45. Tingginya fluktuasi harga saham berkapitalisasi besar pada indeks ini mendorong kebutuhan akan analisis berbasis data guna mengurangi ketergantungan investor pada intuisi dalam pengambilan keputusan. Selain itu, IDX30 merupakan indeks yang sangat populer digunakan sebagai aset dasar (*underlying product*) untuk Reksa Dana Indeks dan *Exchange-traded funds* (ETF) di Indonesia. Karakteristik likuiditas tinggi tersebut menjadikan IDX30 sebagai acuan yang paling representatif untuk memodelkan prediksi *return* saham secara objektif [6].

Algoritma *Extremely Randomized Trees* (*Extra Trees*) dan *Gradient Boosting* dibandingkan karena keduanya merupakan metode *ensemble* berbasis pohon keputusan yang memiliki pendekatan berbeda dalam memprediksi *return* saham. *Extra Trees* bekerja dengan melakukan pengacakan kuat pada penentuan atribut dan titik potong (*cut-point*) di setiap *node* pohon guna meminimalkan nilai *variance* (menjaga stabilitas model). Sebaliknya, *Gradient Boosting* melatih model

sekuensial secara iteratif untuk mengoreksi *residual error* dari model sebelumnya demi memperkecil nilai *bias* dan mengejar akurasi tinggi. Kedua metode ini diuji secara komparatif guna mengidentifikasi algoritma mana yang mampu menghasilkan keseimbangan *bias-variance tradeoff* paling optimal pada karakteristik data runtun waktu IDX30 [6].

1.2 Rumusan Masalah

Berdasarkan uraian latar belakang yang sudah di jelaskan pada bagian sebelumnya, maka penelitian ini difokuskan dengan rumusan masalah sebagai berikut.

1. Seberapa akurat algoritma *Extremely Randomized Trees* dan *Gradient Boosting* dalam memprediksi *return* saham IDX30 berdasarkan indikator teknikal dan data makroekonomi?
2. Bagaimana perbandingan performa antara algoritma *Extremely Randomized Trees* dan *Gradient Boosting* dalam memprediksi *return* saham IDX30 ditinjau dari nilai R^2 , *RMSE*, dan MA

1.3 Tujuan Penelitian

Berdasarkan rumusan masalah yang telah dijelaskan maka tujuan penelitian ini adalah sebagai berikut:

1. Mengukur tingkat akurasi algoritma *Extremely Randomized Trees* dan *Gradient Boosting* dalam memprediksi *return* saham IDX30 menggunakan indikator teknikal dan data makroekonomi berdasarkan metrik *MAE*, *RMSE*, dan R^2 .
2. Membandingkan performa algoritma *Extremely Randomized Trees* dan *Gradient Boosting* dalam memprediksi *return* saham IDX30 untuk menentukan metode yang lebih unggul berdasarkan metrik evaluasi *MAE*, *RMSE*, dan R^2 .

1.4 Batasan Masalah

Agar penelitian yang sedang dilakukan tidak melebar kemana mana, maka di perlukan batasan masalah sebagai berikut

1. Objek penelitian difokuskan pada seluruh saham yang tergabung dalam indeks IDX30.
2. Data yang digunakan berupa data historis harian saham IDX30 selama 3 tahun terakhir yang mencakup data harga saham, indikator teknikal dan data makroekonomi.
3. Evaluasi model dilakukan menggunakan metrik *Mean absolute error (MAE)*, *Root mean squared error (RMSE)*, dan koefisien determinasi (R^2).

4. Penelitian ini tidak membahas faktor eksternal di luar variabel yang telah ditentukan, seperti sentimen pasar, berita ekonomi, maupun faktor geopolitik.
5. Sistem yang dibangun hanya berfungsi sebagai alat bantu analisis untuk menampilkan prediksi *return* saham dan tidak memberikan rekomendasi beli atau jual secara langsung.
6. Kedua model yang digunakan bersifat statis dan tidak diperbarui secara otomatis. Pembaruan model dilakukan secara manual apabila terdapat perubahan signifikan pada kondisi pasar atau data yang digunakan.

1.5 Manfaat Penelitian

Penelitian ini diharapkan dapat memberikan manfaat dalam pengembangan sistem prediksi *return* saham melalui penerapan algoritma *Extremely Randomized Trees* yang dibandingkan dengan algoritma *Gradient Boosting* untuk memprediksi *return* saham IDX30. Secara praktis, sistem yang dirancang dapat membantu investor dalam memperkirakan potensi *return* saham, dengan menyajikan estimasi *return* secara otomatis berdasarkan indikator teknikal dan data makroekonomi. Selain itu, penerapan kombinasi ketiga jenis variabel tersebut diharapkan dapat meningkatkan akurasi prediksi karena setiap jenis variabel menangkap aspek pergerakan saham yang berbeda.

1.6 Sistematika Penulisan

Sistematika penulisan skripsi ini bertujuan untuk memberikan gambaran secara umum mengenai penelitian yang dilakukan. Adapun sistematika penulisan skripsi ini adalah sebagai berikut.

BAB I : PENDAHULUAN

Bab ini berisi latar belakang masalah, rumusan masalah, batasan masalah, tujuan penelitian, manfaat penelitian, serta sistematika penulisan.

BAB II : TINJAUAN PUSTAKA

Bab ini berisi *State of the Art* serta tinjauan teoritis yang mendukung penelitian, meliputi konsep pasar saham dan investasi, *return* saham, indeks IDX30, data dan variabel prediksi saham, konsep *Machine Learning*, *ensemble learning*, algoritma *Extremely Randomized Trees*, algoritma *Gradient Boosting*, serta metrik evaluasi model (R^2 , *RMSE*, *MAE*).

BAB III : METODOLOGI PENELITIAN

Bab menjelaskan tentang alur penelitian, analisa kebutuhan sistem (fungsional dan non-fungsional), perancangan sistem berbasis UML (*use case diagram* dan *activity diagram*), pengumpulan dan pemrosesan data, perancangan model *Machine Learning* (*ExtraTrees* dan *Gradient Boosting*), serta teknik pengujian sistem yang digunakan.

BAB IV : HASIL DAN PEMBAHASAN

Bab ini berisi hasil implementasi sistem *SmartSaham*, hasil pengumpulan dan *preprocessing* data, penerapan serta perbandingan model *Extremely Randomized Trees* dan *Gradient*

Boosting, hingga hasil evaluasi model dan pengujian sistem (*black box* dan *white box*).

BAB V : PENUTUP

Bab ini berisi simpulan yang diperoleh berdasarkan hasil rancangan, implementasi, dan pengujian model prediksi, serta saran yang dapat digunakan untuk pengembangan penelitian selanjutnya.

BAB II

TINJAUAN PUSTAKA

2.1 *State of the Art*

Analisis komparatif *Empirical Asset Pricing* menggunakan *Machine Learning* untuk pasar global (*developed*, *emerging*, dan *frontier markets*) dengan dataset 58.000 saham dari 56 negara menunjukkan bahwa *Machine Learning* secara konsisten mengungguli metode tradisional di semua wilayah, dengan *emerging* dan *frontier markets* menunjukkan *predictability* yang lebih tinggi daripada *developed markets*. Penelitian ini menjadi landasan penting bahwa *Machine Learning* dapat diterapkan di berbagai konteks pasar, termasuk *emerging market* seperti Indonesia. Namun, penelitian tersebut menggunakan konteks global *cross-country analysis* tanpa fokus spesifik pada perbandingan *Extremely Randomized Trees* vs *Gradient Boosting*, serta tidak memasukkan variabel makroekonomi spesifik Indonesia seperti *BI_Rate* atau *Inflation* [7].

Analisis *Empirical Asset Pricing* menggunakan *Machine Learning* untuk pasar saham Eropa dengan berbagai model (OLS, Lasso, Ridge, Random Forest, Gradient Boosting, Neural Networks) menunjukkan bahwa metode non-linear (terutama *Tree-based* dan *Neural Networks*) secara signifikan mengungguli metode linear tradisional dalam prediksi *Return Out-of-sample* di pasar Eropa, sehingga menjadi landasan penting bahwa ensemble *Tree-based* seperti Random Forest dan Gradient Boosting memiliki keunggulan untuk *Return prediction* di *developed market*. Namun, penelitian ini menggunakan konteks pasar Eropa (*developed market*) yang sangat berbeda dengan *emerging market* seperti Indonesia, serta tidak secara

spesifik membandingkan *Extremely Randomized Trees* dengan *Gradient Boosting* pada data IDX30 dengan fitur teknikal dan makroekonomi [8].

Tinjauan literatur sistematis tentang algoritma *Machine Learning* untuk prediksi harga saham dengan analisis berbagai metode (SVM, Random Forest, LSTM, CNN, dll.) menemukan bahwa Random Forest dan *ensemble methods* secara konsisten menunjukkan performa terbaik untuk prediksi pasar saham dibandingkan metode tunggal, sehingga menjadi landasan penting bahwa *Ensemble learning*, khususnya *Tree-based methods*, efektif untuk pemodelan data pasar saham. Namun, penelitian ini berbentuk studi literatur (bukan penelitian empiris) dengan fokus pada *price prediction*, bukan *Return prediction*, serta tidak secara spesifik membandingkan *Extremely Randomized Trees* dengan *Gradient Boosting* pada data IDX30 dengan integrasi teknikal dan makroekonomi [9].

Analisis komparatif metode *Machine Learning* untuk masalah kanonikal *Empirical Asset Pricing*, yaitu mengukur *risk premium* saham, menggunakan dataset hampir 30.000 saham AS dari 1957–2016 dengan 94 karakteristik *firm-level*, menemukan bahwa metode non-linear yang fleksibel—khususnya *gradient-boosted trees* dan *Neural Networks*—secara substansial mengungguli semua metode regresi linear tradisional dalam prediksi *Return Out-of-sample*, sehingga menjadi landasan penting bahwa metode *ensemble Tree-based* seperti *Gradient Boosting* dan *Extremely Randomized Trees* memiliki keunggulan teoretis untuk memodelkan interaksi non-linear antar prediktor dalam konteks *Return* saham. Namun, penelitian ini menggunakan konteks pasar AS yang sangat berbeda dengan pasar *emerging* seperti Indonesia, serta tidak secara spesifik membandingkan *Extremely*

Randomized Trees dengan *Gradient Boosting* pada data *Return* saham IDX30 dengan fitur teknikal dan makroekonomi [10].

Pengembangan sistem optimasi seleksi fitur prediksi saham menggunakan *Quantum Inspired Metaheuristic* (QIM) dan LightGBM untuk meningkatkan akurasi prediksi harga saham menemukan bahwa kombinasi QIM untuk *feature selection* dengan LightGBM menghasilkan akurasi prediksi yang lebih tinggi dibandingkan menggunakan LightGBM tanpa optimasi fitur, sehingga menjadi landasan penting bahwa *feature selection* dan optimasi *hyperparameter* dapat meningkatkan performa *ensemble Tree-based* untuk prediksi saham. Namun, penelitian ini fokus pada *price prediction* dengan optimasi fitur menggunakan QIM, bukan *Return prediction*, serta tidak membandingkan *Extremely Randomized Trees* dengan *Gradient Boosting* pada data IDX30 dengan variabel makroekonomi [11].

Analisis prediksi *Return* saham di pasar Vietnam menggunakan *Machine Learning* yang dikombinasikan dengan *data envelopment analysis* dan *automatic feature engineering* menemukan bahwa integrasi DEA dengan *automatic feature engineering* secara signifikan meningkatkan akurasi prediksi *Return* dibandingkan metode *Machine Learning* tradisional di *emerging market* Vietnam, sehingga menjadi landasan penting bahwa *Machine Learning* dengan *feature engineering* yang tepat dapat meningkatkan *predictability Return* saham di *emerging market*. Namun, penelitian ini menggunakan metode DEA + *auto feature engineering*, bukan *Extremely Randomized Trees* dan *Gradient Boosting*, serta tidak memasukkan variabel makroekonomi spesifik seperti *BI_Rate* atau *Inflation* [12].

Pengembangan sistem prediksi harga saham menggunakan *Machine Learning* (termasuk *Random Forest*, *Gradient Boosting*) dalam EMITI 2025 Conference menemukan bahwa *ensemble methods* (*Random Forest*, *Gradient Boosting*) menghasilkan akurasi prediksi harga yang lebih tinggi dibandingkan metode *single model* seperti regresi linear atau SVM, sehingga menjadi landasan penting bahwa *ensemble Tree-based* seperti *Random Forest* dan *Gradient Boosting* efektif untuk prediksi pasar saham. Namun, penelitian ini fokus pada *price prediction*, bukan *Return prediction*, serta tidak secara spesifik membandingkan *Extremely Randomized Trees* dengan *Gradient Boosting* pada data IDX30 dengan integrasi teknikal dan makroekonomi [13].

Pengembangan sistem prediksi pergerakan harga saham menggunakan *Quantum Machine Learning* berbasis *Variational Quantum Circuits* menemukan bahwa *Quantum Machine Learning* mampu mencapai akurasi klasifikasi arah harga yang kompetitif dibandingkan *classical Machine Learning*, sehingga menjadi landasan penting bahwa pendekatan inovatif seperti *quantum computing* dapat diterapkan untuk prediksi pasar saham. Namun, penelitian ini fokus pada *Quantum Machine Learning* untuk klasifikasi arah harga, bukan *classical ensemble Tree-based* untuk regresi nilai *Return*, serta tidak memasukkan variabel makroekonomi seperti *BI_Rate* atau *Inflation* [14].

Analisis dan *forecasting* pasar saham AS menggunakan *Random Forest Model* dalam konteks *smart finance* menemukan bahwa *Random Forest* mampu memprediksi *trend* pasar saham AS dengan akurasi yang tinggi, terutama ketika dikombinasikan dengan *feature engineering* yang tepat, sehingga menjadi landasan

penting bahwa Random Forest sebagai *ensemble Tree-based* efektif untuk prediksi pasar saham di *developed market*. Namun, penelitian ini menggunakan konteks pasar AS (*developed market*) yang sangat berbeda dengan *emerging market* seperti Indonesia, serta fokus pada *trend prediction*, bukan *Return prediction* dengan *Extremely Randomized Trees* dan *Gradient Boosting* [15].

Analisis prediksi *Return* saham perbankan India menggunakan *ensemble Machine Learning methods* (XGBoost, *Gradient Boosting*, Random Forest, AdaBoost) dengan indikator teknikal menemukan bahwa XGBoost sebagai varian *Gradient Boosting* mengungguli metode *ensemble* lainnya dengan MAE dan RMSE terendah untuk prediksi *Return* saham perbankan di *emerging market* India, sehingga menjadi landasan penting bahwa *ensemble Tree-based* (XGBoost, *Gradient Boosting*, Random Forest) efektif untuk *Return prediction* di *emerging market* dengan indikator teknikal. Namun, penelitian ini hanya menggunakan indikator teknikal tanpa variabel makroekonomi, serta tidak membandingkan *Extremely Randomized Trees* dengan *Gradient Boosting* pada data IDX30 [16].

Analisis *Systematic Design Choices* dalam *Machine Learning* untuk prediksi *Cross-section Stock Returns* dengan *fitting* lebih dari 1000 model menemukan bahwa *design choices* (*algorithm, target variable, Feature Set, hyperparameters*) secara signifikan memengaruhi performa prediksi, dengan *Tree-based methods* secara konsisten menunjukkan hasil yang *robust*, sehingga menjadi landasan penting bahwa *systematic comparison Machine Learning models* dapat mengidentifikasi konfigurasi optimal untuk *Return prediction*. Namun, penelitian ini *fitting* lebih dari 1000 model tanpa fokus spesifik pada perbandingan *Extremely*

Randomized Trees vs *Gradient Boosting*, serta tidak memasukkan variabel makroekonomi spesifik Indonesia seperti *BI_Rate* atau *Inflation* [17].

Analisis perbandingan *Machine Learning models* (Random Forest, SVR, KNN) untuk prediksi harga saham di pasar Indonesia menemukan bahwa Random Forest sebagai *ensemble Tree-based* mengungguli SVR dan KNN dalam prediksi harga saham di pasar Indonesia, sehingga menjadi landasan penting bahwa Random Forest efektif untuk prediksi pasar saham di konteks Indonesia (*emerging market*). Namun, penelitian ini fokus pada *price prediction* dengan Random Forest, SVR, KNN, bukan *Return prediction* dengan *Extremely Randomized Trees* dan *Gradient Boosting*, serta tidak memasukkan variabel makroekonomi [18].

Analisis performa berbagai varian *Gradient Boosting* (XGBoost, XGBoost Random Forest, CatBoost, *Gradient Boosting* Scikit-Learn) untuk memprediksi arah pergerakan harga saham di Bursa Efek Indonesia menggunakan 37 fitur teknikal, fundamental, dan sentimen menemukan bahwa XGBoost dan XGBoost Random Forest secara konsisten mengungguli varian *Gradient Boosting* lainnya dalam memprediksi arah harga saham di Indonesia, sehingga menjadi landasan penting bahwa varian *Gradient Boosting* (XGBoost, CatBoost) efektif untuk prediksi pasar saham Indonesia dengan indikator teknikal, fundamental, dan sentimen. Namun, penelitian ini fokus pada klasifikasi arah harga (*sideways*, *uptrend*, *downtrend*), bukan regresi nilai *Return*, serta tidak membandingkan *Extremely Randomized Trees* dengan *Gradient Boosting* [19].

Analisis prediksi *Return* saham menggunakan LGBM (*LightGBM*, varian *Gradient Boosting*) dan Random Forest untuk *portfolio construction* dengan metrik R^2 , MAE, dan *explained Variance* menemukan bahwa LGBM menunjukkan akurasi superior dengan $R^2 = 0,7377$ untuk prediksi *Return* harian, mengungguli Random Forest dalam konteks *portfolio construction*, sehingga menjadi landasan penting bahwa varian *Gradient Boosting* (LGBM) dan Random Forest efektif untuk *Return prediction* dan *portfolio construction*. Namun, penelitian ini menggunakan LGBM (bukan *Extremely Randomized Trees*), serta tidak memasukkan variabel makroekonomi spesifik Indonesia seperti *BI_Rate* atau *Inflation* [20].

Pengembangan sistem *trading* berbasis *Machine Learning* untuk saham menggunakan *feature engineering* dari indikator teknikal dengan perbandingan *Decision tree*, Random Forest, dan *Gradient Boosting* menemukan bahwa *Gradient Boosting* menghasilkan *Return* finansial tertinggi (37,443%), sementara Random Forest mencapai akurasi klasifikasi terbaik untuk sistem *trading*, sehingga menjadi landasan penting bahwa *ensemble Tree-based* (Random Forest, *Gradient Boosting*) dengan *feature engineering* efektif untuk sistem *trading* di pasar saham. Namun, penelitian ini fokus pada sistem *trading* (klasifikasi beli/jual), bukan prediksi nilai *Return* IDX30 secara regresi, serta tidak memasukkan variabel makroekonomi seperti *BI_Rate* atau *Inflation* [21].

Berdasarkan kajian terhadap penelitian-penelitian terdahulu tersebut, dapat disimpulkan bahwa berbagai metode *Ensemble learning* telah terbukti efektif dalam pemodelan data pasar saham, namun sebagian besar penelitian masih berfokus pada prediksi harga saham, klasifikasi arah pasar, atau hanya memanfaatkan satu jenis

variabel *input*. Penelitian yang secara spesifik mengintegrasikan indikator teknikal, variabel makroekonomi, dan data fundamental secara simultan untuk memprediksi *Return* saham pada indeks IDX30 menggunakan *Extremely Randomized Trees* dan *Gradient Boosting* masih sangat terbatas. Oleh karena itu, penelitian ini dirancang untuk mengisi celah tersebut dengan membangun sistem prediksi *Return* saham IDX30 menggunakan kedua algoritma tersebut berbasis kombinasi tiga jenis variabel, sekaligus membandingkan performa keduanya menggunakan metrik *MAE*, *RMSE*, dan R^2 sebagai dasar pengambilan keputusan investasi yang lebih objektif dan berbasis data.

2.2 Tinjauan Teoritis

2.2.1 Pasar Saham dan Investasi Saham

Pasar saham merupakan tempat terjadinya aktivitas jual beli saham antara investor dan perusahaan yang membutuhkan dana untuk pengembangan usaha. Pasar modal menjadi salah satu pilar penting dalam perekonomian, termasuk di Indonesia, karena memfasilitasi pertemuan antara pihak yang memiliki kelebihan dana dengan pihak yang membutuhkan modal untuk ekspansi bisnis. Di Indonesia, perdagangan saham dilakukan melalui Bursa Efek Indonesia (BEI) sebagai lembaga resmi yang memfasilitasi transaksi saham sehingga proses perdagangan berlangsung secara teratur dan transparan. BEI merupakan satu-satunya bursa efek yang resmi dan terorganisir di Indonesia, yang telah memainkan peran krusial dalam pembangunan ekonomi nasional sejak didirikan pada tahun 1977 [22].

Saham merupakan bukti kepemilikan seseorang terhadap suatu perusahaan yang memberikan hak kepada pemiliknya untuk memperoleh keuntungan dari kinerja perusahaan tersebut. Saham dapat dipahami sebagai tanda penyertaan modal dalam suatu perseroan terbatas, yang memberikan hak atas bagian keuntungan perusahaan berupa dividen dan hak suara dalam rapat umum pemegang saham. Saham menjadi salah satu instrumen investasi yang banyak diminati karena dapat diperjualbelikan dengan mudah serta memiliki potensi keuntungan yang relatif tinggi dibandingkan instrumen investasi lainnya. Saham merupakan instrumen investasi yang populer di pasar modal karena menawarkan potensi imbal hasil yang kompetitif bagi investor yang menerapkan strategi investasi yang tepat [22].

Keuntungan dari investasi saham diperoleh dalam bentuk *return* saham dan dividen. *Return* saham berasal dari selisih antara harga beli dan harga jual saham dalam periode tertentu (*capital gain*), sedangkan dividen merupakan pembagian laba perusahaan kepada pemegang saham. Investasi saham dapat memberikan imbal hasil melalui *capital gain*, yaitu keuntungan dari selisih harga jual dan harga beli saham, serta dividen yang merupakan distribusi laba perusahaan kepada pemegang saham. Dengan adanya potensi keuntungan tersebut, pasar saham menjadi sarana investasi yang menarik meskipun memiliki risiko fluktuasi harga yang cukup tinggi. Namun, seperti halnya investasi lainnya, terdapat risiko yang harus dihadapi oleh investor, seperti fluktuasi harga yang tinggi dan kemungkinan kehilangan seluruh investasi, sehingga investor perlu mengantisipasi volatilitas pasar yang dipengaruhi oleh kondisi ekonomi domestik dan global [22].

2.2.2 Return Saham

Return saham merupakan keuntungan yang diperoleh investor sebagai hasil dari investasi saham yang dilakukan dalam suatu periode tertentu. *Return* saham merupakan hasil yang diperoleh dari investasi, yaitu kelebihan harga jual saham di atas harga belinya. *Return* ini mencerminkan perubahan harga saham yang terjadi di pasar, sehingga menjadi indikator utama dalam menilai keberhasilan suatu investasi saham. *Return* realisasi penting karena digunakan sebagai salah satu pengukur kinerja perusahaan dalam pasar modal [23].

Secara umum, *return* saham dihitung berdasarkan selisih antara harga saham pada akhir periode dengan harga saham pada awal periode, kemudian dibandingkan dengan harga awal saham tersebut. Perhitungan *return* saham dapat dirumuskan sebagai berikut:

$$R_t = \frac{p_{t+h} - P_t}{P_t} \quad h = 1 \quad (2.1)$$

Keterangan:

- R_t = *return* saham pada periode t
- P_{t+h} = harga penutupan saham pada periode $t + 1$
- P_t = harga penutupan saham pada periode t
- $h = 1$ untuk *return* harian

Rumus ini menunjukkan persentase keuntungan atau kerugian yang diperoleh investor dari perubahan harga saham dalam satu periode harian.

Return saham yang bernilai positif menunjukkan bahwa investor memperoleh keuntungan dari kenaikan harga saham, sedangkan *return* saham bernilai negatif menunjukkan kerugian akibat penurunan harga saham. Semakin besar nilai *return* saham, semakin besar pula tingkat keuntungan yang diperoleh investor, sehingga *return* saham sering dijadikan dasar dalam membandingkan kinerja beberapa saham di pasar modal [23].

2.2.3 Indeks IDX30

IDX30 adalah indeks saham yang mengukur kinerja harga 30 saham dengan kapitalisasi pasar yang relatif besar, likuiditas tinggi, dan fundamental perusahaan yang baik. Indeks IDX30 merupakan indeks yang mengukur kinerja harga dari 30 saham yang memiliki likuiditas tinggi dan kapitalisasi pasar *free float* besar serta didukung oleh fundamental dan kepatuhan perusahaan yang baik. Indeks ini diluncurkan pada 23 April 2012 dan konstituen IDX30 dipilih dari 45 saham konstituen LQ45 yang telah ditetapkan pada periode yang bersangkutan. Indeks ini diluncurkan pada 23 April 2012 dengan tanggal dasar 28 Desember 2004 dan nilai dasar 100, serta konstituen indeks IDX30 dipilih dari saham-saham konstituen indeks LQ45. IDX30 mengukur rata-rata kinerja harga 30 saham dengan fundamental perusahaan yang kuat, likuiditas tinggi, dan kapitalisasi pasar yang besar [24].

Seleksi konstituen dilakukan berdasarkan faktor likuiditas yang mencakup nilai transaksi, frekuensi transaksi, dan *free float market capitalization*, serta melalui proses tinjauan oleh Komite Indeks. Faktor-

faktor yang dipertimbangkan dalam pemilihan konstituen meliputi: (a) Likuiditas yang mencakup nilai transaksi, frekuensi transaksi, dan kapitalisasi pasar *free float*; (b) Fundamental yang mencakup kinerja keuangan, kepatuhan, dan lain-lain. Evaluasi konstituen dilakukan secara berkala setiap bulan Januari, April, Juli, dan Oktober dengan efektivitas pada hari perdagangan pertama bulan berikutnya. Jadwal evaluasi mayor dilakukan pada bulan Januari, April, Juli, dan Oktober, dengan hari efektif pada hari bursa pertama di bulan Februari, Mei, Agustus, dan November [24].

Terdapat 30 saham dalam indeks IDX30 dan komponennya bersumber dari indeks LQ45. Beberapa faktor yang memengaruhi perkembangan indeks saham IDX30 antara lain suku bunga acuan dan tingkat inflasi. IDX30 menggunakan metode pembobotan *Capped free float adjusted market capitalization*, di mana bobot tertinggi setiap konstituen dibatasi tidak melebihi 15% pada setiap tinjauan periodik. Indeks IDX30 menggunakan metodologi *Capped free float adjusted market capitalization Weighted*, di mana pada saat evaluasi, bobot tiap saham pada indeks dibatasi paling tinggi 15%. Dengan karakteristik tersebut, IDX30 merepresentasikan saham-saham paling likuid dan berkapitalisasi besar di Bursa Efek Indonesia, sehingga menjadi acuan yang relevan dan representatif dalam penelitian prediksi *return* saham berbasis data historis di pasar Indonesia [24].

2.2.4 Data dan Variabel dalam Prediksi Saham

Data historis saham merupakan data pergerakan harga saham yang dicatat secara periodik dan menjadi dasar utama dalam analisis pergerakan pasar modal. Dalam konteks prediksi *return* saham berbasis *Machine Learning*, data historis mencakup harga penutupan (close) dan volume transaksi yang mencerminkan aktivitas perdagangan harian. Pendekatan ini sejalan dengan penelitian Lie Jaya (2022) yang menggunakan data harga saham dan volume transaksi dari platform Stockbit sebagai bagian dari variabel *input* untuk memprediksi *return* saham perusahaan yang terdaftar di LQ45 [25].

Selain data harga saham, indikator teknikal digunakan untuk membantu mengidentifikasi tren dan momentum pergerakan pasar. Indikator teknikal dibentuk dari pengolahan data historis harga untuk menangkap pola tertentu yang sulit diamati secara langsung. Beberapa indikator teknikal yang digunakan dalam penelitian ini meliputi *Moving Average* (MA5, MA10, MA20), *Relative Strength Index* (RSI), dan *Moving Average Convergence/Divergence* (MACD). Penggunaan indikator teknikal terbukti mampu meningkatkan kemampuan model dalam memprediksi pergerakan harga saham karena dapat merepresentasikan sentimen pasar dan arah tren secara lebih jelas [26].

Selain faktor teknikal, kondisi makroekonomi turut memengaruhi pergerakan pasar saham secara keseluruhan. Variabel makroekonomi mencakup laju inflasi, jumlah uang beredar, nilai tukar riil rupiah terhadap dolar AS, dan suku bunga [6]. Perubahan variabel makroekonomi sering kali berdampak langsung terhadap sentimen pasar dan fluktuasi harga saham, sebagaimana ditunjukkan oleh

hasil penelitian yang menyatakan bahwa suku bunga BI Rate berpengaruh signifikan terhadap pergerakan pasar saham [27].

Berdasarkan uraian tersebut, kombinasi data historis saham, indikator teknikal, data fundamental perusahaan, dan variabel makroekonomi menjadi pendekatan yang relevan dalam membangun model prediksi *return* saham yang lebih akurat dan objektif. Integrasi berbagai jenis variabel ini memungkinkan model *Machine Learning* untuk menangkap pola pergerakan saham secara lebih menyeluruh, baik dari sisi teknis pergerakan harga maupun faktor ekonomi dan kinerja perusahaan [25].

2.2.5 Konsep *Machine Learning* dalam Prediksi Saham

Machine Learning merupakan metode komputasi yang memungkinkan sistem mempelajari pola dari data historis melalui proses pelatihan (*training*), sehingga model dapat mengenali hubungan antara variabel *input* dan *output* berdasarkan data yang tersedia. *Machine Learning* sendiri adalah bagian dari teknologi kecerdasan artifisial yang lebih menitikberatkan pada konstruksi dan pelatihan sistem sehingga sistem ini dapat 'belajar' dari data yang diberikan. Dalam prediksi saham, *Machine Learning* digunakan untuk menganalisis data harga saham seperti open, high, low, close, dan volume guna menemukan pola yang berkaitan dengan perubahan *return* saham. Penelitian menggunakan sepuluh indikator analisis teknikal saham sebagai masukan untuk kedua model yang dibangun, dengan data historis harga saham sebagai dasar pembelajaran [28].

Pendekatan *Machine Learning* banyak digunakan dalam prediksi saham karena mampu menangani data dalam jumlah besar serta hubungan yang tidak

selalu linier antarvariabel. Dua model yang digunakan untuk melakukan prediksi, yaitu *Artificial Neural Network* (ANN) dan *Support Vector Machine* (SVM) dikenal cukup akurat dalam memprediksi pergerakan indeks harga saham . Dengan memanfaatkan data historis sebagai dasar pembelajaran, model *Machine Learning* dapat menghasilkan prediksi yang lebih adaptif terhadap perubahan pola pergerakan saham dibandingkan metode konvensional. *Machine Learning* telah merepresentasikan keunggulan yang luar biasa dalam melakukan prediksi pasar saham karena kemampuannya dalam mengenali pola kompleks dari data historis dan menghasilkan prediksi yang lebih akurat [28].

2.2.6 Ensemble learning

Ensemble learning adalah teknik kombinasi algoritma *Machine Learning* yang bertujuan untuk memperoleh hasil akurasi prediksi yang lebih tinggi dibandingkan dengan algoritma *Machine Learning* yang digunakan secara tunggal . Pendekatan ini menggabungkan beberapa model prediksi untuk menghasilkan estimasi yang lebih stabil dan akurat dalam menghadapi ketidakpastian dan kompleksitas pasar modal . Selain meningkatkan akurasi dari sistem pengambilan keputusan, *Ensemble learning* juga telah berhasil digunakan untuk mengatasi berbagai masalah *Machine Learning* seperti pemilihan fitur, estimasi kepercayaan, fitur yang hilang, pembelajaran tambahan, koreksi kesalahan, dan kelas dengan data yang tidak seimbang [29].

Dalam konteks prediksi harga saham, *Ensemble learning* bekerja dengan melatih beberapa model dasar (*base learner*) secara independen, kemudian

menggabungkan hasil prediksi dari masing-masing model tersebut untuk menghasilkan prediksi akhir yang lebih baik . Teknik ini terbukti mampu meningkatkan akurasi karena menggabungkan beberapa model dasar untuk memperbaiki kesalahan klasifikasi yang mungkin terjadi pada model tunggal . Dengan demikian, *Ensemble learning* menjadi pendekatan yang sangat efektif dalam melakukan prediksi harga saham, terutama ketika menghadapi data yang kompleks dan fluktuatif seperti data pasar modal [29].

Keunggulan utama dari *Ensemble learning* adalah kemampuannya dalam menghasilkan akurasi prediksi yang lebih tinggi dibandingkan dengan penggunaan algoritma *Machine Learning* secara tunggal . Hal ini dikarenakan *Ensemble learning* memanfaatkan kekuatan dari berbagai model yang berbeda, sehingga dapat mengkompensasi kelemahan masing-masing model dan menghasilkan prediksi yang lebih robust . Dalam penelitian prediksi harga saham, metode *Ensemble learning* telah terbukti memberikan hasil yang signifikan dengan tingkat akurasi yang sangat baik, menjadikannya salah satu teknik yang paling direkomendasikan untuk digunakan dalam pengembangan model prediksi saham [29].

2.2.7 Algoritma *Extremely Randomized Trees*

Extremely Randomized Trees (Extra Trees) adalah metode *ensemble* berbasis pohon keputusan yang diperkenalkan oleh Geurts dkk. (2006). *Extra Trees* membangun metode *ensemble* berdasarkan prosedur top-down, di mana perbedaan mendasar dari metode *ensemble* lainnya terletak pada proses pemisahan *node*. Metode ini mengusulkan metode *ensemble* berbasis pohon baru untuk masalah

klasifikasi dan regresi supervised, yang pada dasarnya terdiri dari mengacak secara kuat baik pilihan atribut maupun titik potong (*cut-point*) saat memisahkan *node* pohon [30].

Algoritma ini merupakan pendekatan *ensemble tree* dengan konsep menggabungkan banyak pohon keputusan, di mana penggabungan dilakukan dengan *majority vote* untuk kasus klasifikasi dan rata-rata aritmatika untuk kasus regresi . Algoritma ini terdiri dari rata-rata prediksi dari *ensemble* pohon yang dibangun secara acak, yang menghasilkan peningkatan signifikan dalam presisi dan berbagai keunggulan algoritmik, khususnya kompleksitas komputasi yang berkurang dan skalabilitas . Dalam kasus ekstrem, metode ini membangun pohon yang sepenuhnya teracak yang strukturnya independen dari nilai *output* sampel pembelajaran [30].

Secara matematis, prediksi akhir dari model *Extra Trees* untuk kasus regresi diperoleh dengan merata-ratakan hasil prediksi dari seluruh pohon dalam *ensemble*, sebagaimana dirumuskan berikut:[31].

$$\hat{y} = \frac{1}{T} \sum_{t=1}^T f_t(x)$$

(2.3)

Keterangan:

- $\hat{y}$ = hasil prediksi akhir model
- T = jumlah total pohon keputusan yang dibangun

- $f_t(x)$ = prediksi dari pohon ke- t
- x = variabel *input* (fitur)

Beberapa parameter penting dalam algoritma ini adalah: (a) parameter M yaitu jumlah *ensemble tree* yang dibentuk menggunakan seluruh sampel pembelajaran — semakin besar nilai M , semakin baik akurasi prediksi namun berpengaruh pada performa komputasi; (b) parameter K yaitu jumlah atribut acak yang digunakan pada setiap *node*; dan (c) parameter n_min yaitu jumlah minimum sampel yang digunakan dalam proses pemisahan, semakin besar nilai n_min maka *ensemble tree* akan semakin kecil, dan sebaliknya.

2.2.8 Algoritma *Gradient Boosting*

Gradient Boosting adalah algoritma *ensemble* yang membangun model prediksi secara bertahap melalui serangkaian *weak learners*, dengan menggabungkan beberapa model lemah untuk menghasilkan prediksi yang lebih kuat. Prinsipnya adalah mengoptimalkan fungsi *error* secara iteratif, di mana model berukuran M merupakan kombinasi linear dari M model dasar yang masing-masing dibangun sebagai aproksimasi turunan fungsi *loss* dari *residual* model sebelumnya, sehingga setiap model baru memberikan kontribusi perbaikan atas kesalahan sebelumnya [32].

Secara matematis, model *Gradient Boosting* berukuran M merupakan kombinasi linear dari M model dasar, sebagaimana dirumuskan oleh Konstantinov dan Utkin (2020) sebagai berikut:

$$g_M(x) = \sum_{t=1}^M \gamma_t h_t(x) = g_{M-1}(x) + \gamma_M h_M(x).$$

(2.4)

Keterangan:

- $g_m(x)$ = model *ensemble* pada iterasi ke- M
- $g(x)$ = model *ensemble* pada iterasi sebelumnya
- $h_m(x)$ = *weak learner* baru yang dilatih pada *residual* saat ini
- γ_M = learning rate (laju pembelajaran)
- $\gamma_t, h_t(x)$ = koefisien dan *weak learner* pada iterasi ke- t , untuk $t = 1, \dots, M$

Setiap *weak learner* dilatih untuk meminimalkan fungsi *loss* dari model sebelumnya menggunakan *gradient descent*, sehingga algoritma ini dikenal mampu menghasilkan model yang sangat akurat dengan menggabungkan banyak model sederhana menjadi satu model kuat [32].

2.2.9 Evaluasi Model Prediksi (R^2 , $RMSE$, MAE)

Evaluasi model prediksi dilakukan untuk mengukur tingkat akurasi hasil prediksi *return* saham yang telah dihasilkan oleh algoritma. Salah satu metrik yang digunakan adalah koefisien determinasi (R^2), yang menunjukkan seberapa besar variasi data aktual dapat dijelaskan oleh model prediksi. Rumus R^2 dapat dituliskan sebagai berikut:

$$R^2 = 1 - \frac{\sum (y_i - \hat{y}_i)^2}{\sum (y_i - \bar{y})^2}$$

(2.5)

Keterangan:

y_i = nilai aktual

$\hat{y}_i$ = nilai prediksi

$\bar{y}$ = rata-rata nilai aktual

Selain R^2 , *Root mean squared error* (*RMSE*) digunakan untuk mengukur rata-rata besar kesalahan prediksi antara nilai aktual dan nilai prediksi. Rumus *RMSE* adalah sebagai berikut [33]:

$$RMSE = \sqrt{\frac{1}{n} \sum_{i=1}^n (y_i - \hat{y}_i)^2}, \quad (2.6)$$

Keterangan:

y_i = nilai aktual ke-i

$\hat{y}_i$ = nilai prediksi ke-i

n = jumlah data

RMSE yang kecil menunjukkan bahwa hasil prediksi semakin mendekati nilai sebenarnya. Metrik evaluasi lainnya adalah *Mean absolute error* (*MAE*) yang digunakan untuk mengukur rata-rata selisih absolut antara nilai aktual dan nilai prediksi. Rumus *MAE* dapat dituliskan sebagai berikut [33]:

$$MAE = \frac{1}{n} \sum_{i=1}^n |y_i - \hat{y}_i|$$

(2.7)

Keterangan:

y_i = nilai aktual ke-i

$\hat{y}_i$ = nilai prediksi ke-i

n = jumlah data

$|y_i - \hat{y}_i|$ = nilai mutlak (absolut) selisih antara nilai aktual dan nilai prediksi


Nilai *MAE* yang rendah menunjukkan bahwa model memiliki tingkat akurasi yang tinggi dalam memprediksi *return* saham.

BAB III

METODOLOGI PENELITIAN

3.1 Alur Penelitian

Penelitian ini menggunakan metode eksperimental dengan pendekatan kuantitatif untuk mengembangkan sistem prediksi *return* saham berbasis *Machine Learning* menggunakan algoritma *Extremely Randomized Trees* dan *Gradient Boosting* pada saham-saham konstituen indeks IDX30. Penelitian ini dirancang untuk mengatasi permasalahan keterbatasan investor pemula dalam menganalisis potensi *return* saham secara objektif dan berbasis data. Gambar 3.1 menunjukkan alur penelitian secara keseluruhan yang terdiri dari beberapa tahapan utama mulai dari identifikasi masalah hingga penerapan model pada aplikasi web.



Gambar 3. 1 Tahapan Alur Penelitian

Gambar 3.1 menunjukkan alur penelitian diawali dengan identifikasi masalah, dilanjutkan dengan pengumpulan data yang bersumber dari dua jenis data utama, yaitu data harga saham (saham konstituen IDX30, IHSG, dan USD/IDR) serta data makroekonomi (tingkat inflasi dan BI Rate). Data harga saham diperoleh melalui *Yahoo Finance API*, sedangkan data makroekonomi diperoleh dari Badan Pusat Statistik (BPS) dan Bank Indonesia.

Seluruh data tersebut kemudian diproses melalui tahap perhitungan indikator teknikal dan *return* pasar yang meliputi *Volume_Ratio*, *Lag1*, *Lag2*, *Close_to_MA5*, *Close_to_MA10*, *Close_to_MA20*, *RSI*, *MACD*, dan *USD_IDR_Return*. Hasil perhitungan tersebut digabungkan bersama data makroekonomi menjadi satu *dataset* terpadu dengan total 12 fitur *input*.

Dataset yang terbentuk selanjutnya melalui tahap *data cleaning* dan analisis eksplorasi data (EDA), kemudian dipisahkan menggunakan metode *time-series split* dengan rasio 80% data latih dan 20% data uji untuk menghindari kebocoran data (*data leakage*). Sebelum digunakan untuk melatih model, seluruh fitur *input* melalui tahap *preprocessing* data berupa normalisasi menggunakan *StandardScaler*.

Kedua algoritma, yaitu *Extremely Randomized Trees* dan *Gradient Boosting*, kemudian dilatih pada tahap pelatihan model dan dievaluasi menggunakan metrik *RMSE*, *MAE*, dan R^2 . Model dengan performa terbaik dipilih sebagai model final, yaitu *Extremely Randomized Trees*, dan disimpan dalam *format .pkl* untuk diintegrasikan ke dalam aplikasi web.

Langkah terakhir dari penelitian ini adalah pembuatan website menggunakan *FastAPI* sebagai *backend*, *HTML*, *CSS*, dan *JavaScript* sebagai *frontend*, serta *MySQL* sebagai basis data, yang memungkinkan pengguna untuk memperoleh prediksi *return* saham secara *real-time* melalui antarmuka yang interaktif.

3.2 Analisa Kebutuhan Sistem

Analisa kebutuhan sistem merupakan tahapan penting dalam proses pengembangan perangkat lunak yang bertujuan untuk mengidentifikasi serta merumuskan seluruh kebutuhan yang harus dipenuhi agar sistem yang dibangun dapat berjalan sesuai dengan tujuan yang telah ditetapkan. Tahapan ini dilakukan sebelum proses perancangan dan implementasi sistem, sehingga hasil analisa dapat dijadikan acuan dalam menentukan fitur, alur kerja, serta spesifikasi teknis yang diperlukan dalam pembangunan sistem prediksi saham SmartSaham.

Penelitian ini membagi analisa kebutuhan sistem menjadi dua kategori, yaitu kebutuhan fungsional dan kebutuhan nonfungsional. Kebutuhan fungsional menjelaskan mengenai proses-proses atau fungsi-fungsi yang harus disediakan oleh sistem berdasarkan peran pengguna yang terlibat, sedangkan kebutuhan nonfungsional menjelaskan mengenai spesifikasi perangkat lunak (*software*) dan perangkat keras (*hardware*) yang digunakan untuk mendukung pengembangan serta operasional sistem secara optimal. Kedua kategori kebutuhan tersebut akan dijabarkan lebih rinci pada sub-bab berikut.

3.2.1 Analisa Kebutuhan Sistem

Kebutuhan fungsional adalah kebutuhan yang menguraikan seluruh entitas yang berperan dalam sistem, beserta fungsi atau proses yang dijalankan oleh masing-masing entitas tersebut. Sistem prediksi saham SmartSaham yang dibangun hanya melibatkan dua jenis pengguna, yakni *User* dan *Admin*. Berikut dipaparkan kebutuhan fungsional dari sistem ini.

1. *Admin*

Admin merupakan peran yang bertanggung jawab dalam mengelola serta mengawasi keseluruhan sistem prediksi saham SmartSaham. Adapun fungsionalitas yang dapat diakses oleh *Admin* antara lain:

- a. *Login* ke sistem.
- b. Mengakses halaman beranda (*dashboard* ringkasan saham dan indeks IHSG).
- c. Melihat data dan analisis saham IDX30 secara *real-time*.
- d. Mendapatkan hasil prediksi *return* saham (7 hari, 30 hari, dan 90 hari) beserta tingkat kepercayaan prediksi.
- e. Manajemen *User* (melihat daftar pengguna, mengubah *role* pengguna, dan menghapus akun).
- f. Mengelola data makroekonomi (mengunggah dan memperbarui data Inflasi dan BI Rate melalui *file Excel*) sebagai variabel pendukung model prediksi.
- g. Mengelola *watchlist* saham pribadi.
- h. Mengelola alert (notifikasi) harga saham pribadi.
- i. Mengelola profil akun (mengubah data profil, foto profil, dan kata sandi).

2. *User*

User merupakan peran yang memanfaatkan fungsi-fungsi inti dari sistem prediksi saham SmartSaham. Adapun fungsionalitas yang dapat diakses oleh *User* antara lain:

- a. *Login* dan registrasi akun ke sistem.
- b. Mengakses halaman beranda (*dashboard* ringkasan saham dan indeks IHSG).
- c. Melihat data dan analisis saham IDX30 secara *real-time*, termasuk grafik harga historis.
- d. Mendapatkan hasil prediksi *return* saham (7 hari, 30 hari, dan 90 hari) beserta tingkat kepercayaan prediksi.
- e. Menambahkan dan menghapus saham pada *watchlist* pribadi.
- f. Membuat, mengubah, dan menghapus alert (notifikasi) harga saham sesuai *target* harga yang ditentukan.
- g. Mengelola profil akun pribadi (mengubah data profil, foto profil, dan kata sandi).

3.2.2 Analisa Kebutuhan Non Fungsional

Kebutuhan nonfungsional adalah kebutuhan yang mencakup dua aspek, yaitu perangkat lunak (*software*) dan perangkat keras (*hardware*). Perangkat lunak sendiri merupakan kumpulan instruksi yang diberikan kepada komputer guna menjalankan tugas tertentu, sedangkan perangkat keras adalah komponen fisik komputer yang dapat dilihat dan disentuh secara langsung. Pemenuhan kebutuhan nonfungsional ini sangat penting agar sistem dapat beroperasi secara optimal sesuai dengan rancangan yang telah ditetapkan. Di samping itu, spesifikasi perangkat

lunak dan perangkat keras yang memadai turut mendukung kelancaran proses pengolahan data serta pelaksanaan pelatihan data secara akurat. Berikut ini dijabarkan kebutuhan nonfungsional dari sistem prediksi saham SmartSaham yang memanfaatkan algoritma *Extra Trees* dalam penelitian ini.

1. Kebutuhan Perangkat Lunak (*Software*)

Tabel 3.1 mencantumkan spesifikasi perangkat lunak yang digunakan dalam proses pengembangan sistem prediksi saham SmartSaham. Perangkat lunak ini meliputi tools pemrograman, *framework* pendukung, serta sistem operasi yang digunakan dalam pembangunan dan pengujian website, baik pada sisi *backend* maupun *frontend*.

Tabel 3. 1 *Software* yang Digunakan

Nomor	Nama <i>Software</i>	Spesifikasi / Fungsi
1	<i>Visual Studio Code</i>	Sebagai <i>Text Editor</i> yang ringan dan kaya fitur untuk pengembangan kode sumber.
2	<i>JavaScript</i>	Bahasa pemrograman utama untuk pengembangan antarmuka pengguna pada sisi <i>frontend</i> sistem.
3	<i>HTML 5</i>	Bahasa markup standar untuk menyusun struktur halaman web sistem prediksi saham.
4	<i>CSS 3</i>	Bahasa styling yang digunakan untuk merancang tampilan dan tata letak antarmuka pengguna sistem.
5	Python 3.11	Bahasa pemrograman utama untuk mengimplementasikan algoritma <i>Extra Trees</i> dan proses pengolahan data <i>Machine Learning</i> .

Nomor	Nama <i>Software</i>	Spesifikasi / Fungsi
6	<i>FastAPI</i>	<i>Framework</i> Python yang digunakan untuk membangun <i>backend</i> dan <i>REST API</i> sistem prediksi saham.
7	<i>MySQL</i>	Sistem manajemen basis data relasional yang digunakan untuk menyimpan data pengguna, <i>watchlist</i> , alert harga, serta data makroekonomi (inflasi dan BI rate).
8	<i>SQLAlchemy</i>	<i>Library Object Relational Mapping (ORM)</i> Python yang digunakan untuk menghubungkan aplikasi <i>backend</i> dengan basis data <i>MySQL</i> .
9	Scikit-learn	<i>Library Machine Learning</i> Python yang digunakan untuk membangun dan melatih model prediksi <i>Extra Trees</i> .
10	<i>yfinance</i>	<i>Library</i> Python yang digunakan untuk mengambil data harga saham dan indeks pasar secara <i>real-time</i> dari <i>Yahoo Finance</i> .
12	<i>Google Chrome</i>	<i>Browser</i> yang digunakan untuk mengakses dan menguji halaman sistem prediksi saham.
13	<i>Postman</i>	Perangkat lunak yang digunakan untuk melakukan pengujian terhadap <i>endpoint API</i> pada sistem.

2. Kebutuhan Perangkat Keras

Tabel 3.2 mencantumkan secara rinci spesifikasi perangkat keras (*Hardware*) yang digunakan, mencakup seluruh komponen penting dalam proses pembuatan sistem prediksi saham SmartSaham serta penulisan skripsi.

Tabel 3. 2 *Hardware* yang digunakan

Nomor	Nama <i>Software</i>	Spesifikasi / Fungsi
1	Laptop	Digunakan sebagai perangkat utama untuk pengembangan sistem, penulisan kode, serta proses pelatihan model <i>Machine Learning</i> .
2	<i>Processor</i>	Digunakan untuk menangani komputasi data, <i>preprocessing</i> data saham, serta proses pelatihan model prediksi.
3	<i>RAM</i>	Digunakan untuk mendukung proses pengolahan data dan pelatihan model <i>Machine Learning</i> agar berjalan stabil.
4	<i>HDD</i>	Digunakan untuk penyimpanan <i>dataset</i> data saham historis, <i>file</i> proyek, dan <i>backup</i> data penelitian.
5	<i>SSD</i>	Digunakan untuk penyimpanan sistem operasi dan <i>file-file</i> yang memerlukan akses cepat.
6	Koneksi <i>Internet</i>	Digunakan untuk mengakses data saham secara <i>real-time</i> melalui <i>Yahoo Finance</i> serta layanan pendukung lainnya.


3.3 Rancangan Sistem

Perancangan sistem merupakan tahap awal dari perancangan perangkat lunak yang akan dibuat. Perancangan bertujuan untuk memberi gambaran mengenai alur proses dari perangkat lunak tersebut. Perancangan sistem antara *User* dan aplikasi menggunakan Unified Modeling Language (UML). Pada perancangan UML ini terdapat dua perancangan yaitu *use case diagram* dan *activity diagram*. Perancangan ini dilakukan agar hubungan antara pengguna dan sistem dapat

digambarkan secara jelas. Dengan adanya rancangan ini, pengembangan sistem dapat mengikuti alur yang terstruktur. Selain itu, rancangan yang baik akan meminimalisir terjadinya kesalahan pada tahap implementasi.

3.3.1 Ilustrasi Sistem

Ilustrasi sistem pada diagram menggambarkan alur utama dari sebuah aplikasi berbasis web prediksi saham yang dirancang untuk membantu pengguna dalam memperkirakan *return* saham IDX30 secara otomatis menggunakan teknologi *Machine Learning*. Diagram ini disusun dalam bentuk konteks sistem yang menunjukkan hubungan antara aktor eksternal dengan sistem prediksi saham, serta bagaimana data dan proses berpindah di dalam sistem saat digunakan. Untuk lebih detailnya dapat dilihat pada Gambar 3.2.



Gambar 3. 2 Ilustrasi Sistem Prediksi Saham

Alur kerja sistem secara keseluruhan berlangsung sebagai berikut. Pengguna website (*User/Admin*) melakukan *input* kode saham yang ingin diprediksi melalui antarmuka web. Kode saham tersebut diterima oleh Aplikasi Prediksi Saham yang dibangun menggunakan *FastAPI*. Selanjutnya, aplikasi melakukan fetch data harga

saham melalui *Yahoo Finance API*, sekaligus mengambil data makroekonomi berupa inflasi dan BI rate dari *Database*. Data harga saham yang diperoleh kemudian diolah untuk menghasilkan indikator teknikal. Seluruh data fitur yang telah terkumpul, baik data teknikal, makroekonomi, maupun fundamental, selanjutnya digabungkan dan dikirimkan ke model *Machine Learning* terbaik hasil perbandingan antara algoritma *Extra Trees* dan *Gradient Boosting* untuk diproses. Hasil prediksi *return* saham dari model dikembalikan ke aplikasi, kemudian ditampilkan kepada pengguna secara *real-time*.

3.3.2 Use case diagram

Use case diagram digunakan untuk menampilkan bentuk interaksi yang terjadi antara aktor dengan sistem yang dibangun, ditinjau dari perspektif pengguna. Diagram ini menggambarkan fungsionalitas apa saja yang disediakan oleh sistem serta aktor mana saja yang berhak mengakses fungsionalitas tersebut, tanpa perlu menjelaskan detail proses internal di dalamnya.

Sistem prediksi saham SmartSaham ini melibatkan dua jenis aktor, yakni *User* (pengguna umum) dan *Admin* (*Administrator*). Kedua aktor tersebut berinteraksi langsung dengan sistem melalui antarmuka website, namun memiliki cakupan hak akses yang berbeda. Peran *Admin* mencakup seluruh kewenangan yang dimiliki *User*, ditambah dengan sejumlah akses khusus untuk keperluan pengelolaan sistem, seperti pengelolaan akun pengguna yang terdaftar. Hubungan ini digambarkan melalui relasi generalization pada *use case diagram*, di mana aktor *Admin* merupakan bentuk generalisasi dari aktor *User*.


1. Deskripsi Aktor

Terdapat dua aktor dengan hak akses yang berbeda pada sistem ini, sebagaimana diuraikan berikut ini.

- a. *User* : Merupakan aktor inti yang memanfaatkan sistem guna melakukan analisis serta riset saham pada indeks IDX30. *User* dapat membuka halaman beranda, melakukan penyaringan saham (*screener*), melakukan riset emiten secara mendalam, mengatur *watchlist* pribadi, mengatur *price alert*, serta mengelola pengaturan akunnya.
- b. *Admin*: Merupakan aktor dengan kewenangan tertinggi pada sistem. Selain memperoleh seluruh akses yang dimiliki *User*, *Admin* juga diberikan kewenangan tambahan untuk mengelola akun pengguna yang terdaftar pada sistem (kelola *User*).

2. Use case diagram

Diagram use case pada bagian ini menguraikan seluruh aktivitas yang dapat dijalankan oleh aktor *User* dan *Admin* di dalam website SmartSaham. *Admin* memiliki seluruh use case yang dimiliki *User*, ditambah satu use case khusus yaitu Kelola *User*. Ilustrasi diagram dapat dilihat pada Gambar 3.3 berikut.



Gambar 3. 3 Use Case *User* dan *Admin*

Terdapat tujuh use case pada sistem ini. Enam use case (Beranda, *Screener Saham*, Riset Emiten, *Watchlist*, *Price alert*, Pengaturan) dapat diakses oleh *User* maupun *Admin*, sedangkan satu use case (Kelola *User*) hanya dapat diakses oleh *Admin*. Rincian penjelasan setiap use case dipaparkan pada Tabel 3.3 berikut.

Tabel 3. 3 Penjelasan *Use case diagram*

No	Use Case	Aktor	Deskripsi
1	Beranda	<i>User,</i> <i>Admin</i>	Membuka halaman utama yang menyajikan ringkasan kondisi saham IDX30 beserta pergerakan indeks IHSG secara <i>real-time</i> .
2	<i>Screener</i> Saham	<i>User,</i> <i>Admin</i>	Menyaring dan membandingkan saham-saham IDX30 berdasarkan indikator teknikal, fundamental, maupun hasil prediksi <i>return</i> .
3	Riset Emiten	<i>User,</i> <i>Admin</i>	Melihat riset dan analisis mendalam terhadap suatu emiten, mencakup grafik harga historis, indikator teknikal & makroekonomi, data statistik fundamental, serta hasil prediksi <i>return</i> saham 5 hari bursa ke depan.
4	<i>Watchlist</i>	<i>User,</i> <i>Admin</i>	Menambah maupun menghapus saham pada daftar pantauan.
5	<i>Price alert</i>	<i>User,</i> <i>Admin</i>	Mengatur, memperbarui, ataupun menghapus notifikasi harga saham berdasarkan <i>target</i> harga tertentu.
6	Pengaturan	<i>User,</i> <i>Admin</i>	Mengubah pengaturan akun pribadi, termasuk data profil dan kata sandi.
7	Kelola <i>User</i>	<i>Admin</i>	Mengelola seluruh akun pengguna terdaftar, mencakup penampilan daftar pengguna, perubahan <i>role</i> , hingga penghapusan akun.


3.3.3 Activity diagram

Activity diagram data yang dieksekusi oleh *backend* dan basis data. Diagram ini memberikan gambaran terstruktur mengenai urutan langkah interaksi aktor dengan sistem beserta respon balik yang diberikan oleh aplikasi pada setiap tahapan

prosesnya. Pada penelitian ini, *activity diagram* dirancang untuk memetakan lima proses bisnis utama, yaitu proses autentikasi pengguna (registrasi dan *login*), riset emiten dan analisis prediksi saham berbasis *Machine Learning*, pengelolaan *watchlist*, pengaturan *price alert* beserta pemicu notifikasi, serta pembaruan data makroekonomi oleh *Administrator* melalui unggahan berkas *Excel*.

1. *Activity diagram* Autentikasi Pengguna

Activity diagram pada proses autentikasi pengguna menggambarkan alur pendaftaran akun baru (registrasi) serta proses masuk ke dalam sistem (*login*) oleh pengguna, dapat dilihat pada Gambar 3.4 di bawah ini.




Gambar 3. 4 *Activity diagram* Autentikasi Pengguna

Proses dimulai ketika pengguna melakukan aktivitas Isi *form register/login*, sebagaimana ditunjukkan pada Gambar 3.4. Setelah data diinputkan, *Frontend* menjalankan aksi Kirim request ke *backend* yang kemudian diterima oleh *Backend* pada *node* keputusan Jenis request?. Apabila jenis request adalah *Register*, *Backend* akan melakukan pengecekan *Email/Username* sudah ada? pada *database*. Jika data tersebut Sudah ada, *Backend* memicu proses Kembalikan *error* yang kemudian dikirim ke *Frontend* untuk dieksekusi oleh *node* Tampil hasil (sukses/gagal) sebelum akhirnya mengembalikan pengguna ke proses awal (Isi *form register/login*). Sebaliknya, jika *email/Username* Belum ada, *Backend* akan memproses Hash *password* & simpan *User* baru ke *database* dan memicu Kembalikan *status* sukses, sehingga *Frontend* melalui Tampil hasil (sukses/gagal) dapat mengakhiri alur registrasi pada titik akhir (End). Apabila jenis request adalah *Login*, *Backend* langsung diarahkan untuk mengecek Cek *Password* cocok?. Jika verifikasi *password* dinyatakan Salah, *Backend* memicu Kembalikan *error*, yang diteruskan ke *Frontend* melalui Tampil hasil (sukses/gagal) untuk mengembalikan pengguna ke *form* Isi *form register/login*. Namun, jika *password* dinyatakan Benar, *Backend* akan memicu Kembalikan *status* sukses sehingga *Frontend* melalui Tampil hasil (sukses/gagal) dapat mengakhiri alur *login* pengguna menuju titik akhir (End).

2. Activity diagram Riset Emiten & Prediksi Saham

Activity diagram pada proses riset emiten dan prediksi saham menggambarkan alur bagaimana pengguna mencari Informasi detail dan hasil analisis prediksi kecerdasan buatan (AI) untuk emiten tertentu, dapat dilihat pada Gambar 3.5 di bawah ini.



Gambar 3. 5 Activity diagram Riset Emiten & Prediksi Saham


Proses dimulai saat pengguna melakukan aktivitas Masukkan kode ticker saham di halaman riset, sebagaimana ditunjukkan pada Gambar 3.5. Antarmuka *Frontend* langsung melakukan verifikasi melalui *node* keputusan Saham ditemukan? (untuk memastikan emiten termasuk dalam daftar IDX30). Jika bernilai Tidak, *Frontend* mengeksekusi *node* Tampil error: saham tidak ditemukan dan mengarahkan kembali pengguna ke

kolom pencarian (Masukkan kode ticker saham). Jika bernilai Ya, *Frontend* akan menjalankan proses Minta detail saham ke *backend*.

Backend akan memproses *node* Ambil data saham & hitung indikator teknikal dengan menarik data historis harga dari *Yahoo Finance* setelah menerima permintaan tersebut. Selanjutnya, *Backend* mengeksekusi proses Ambil data makro (inflasi & BI rate) dari *database* lokal, kemudian Jalankan model prediksi *return* menggunakan algoritma *Extra Trees*. Terakhir, *Backend* memicu proses Kembalikan data & hasil prediksi dalam bentuk *format JSON* ke *Frontend*, sehingga *Frontend* dapat mengeksekusi *node* Tampil *dashboard* detail emiten sebelum akhirnya alur proses selesai (End).

3. *Activity diagram* Manajemen *Watchlist*

Activity diagram pada manajemen *watchlist* menggambarkan alur proses bagaimana pengguna menambah atau menghapus emiten saham dari daftar pantau pribadi mereka, dapat dilihat pada Gambar 3.6 di bawah ini.




Gambar 3. 6 Activity diagram Manajemen Watchlist

Alur proses dimulai saat pengguna menentukan pilihan pada keputusan Tambah atau hapus saham?, sebagaimana ditunjukkan pada Gambar 3.6. Jika pengguna memilih opsi Tambah, *Frontend* akan menjalankan proses Kirim request tambah saham ke *Backend*. *Backend* kemudian melakukan pengecekan Saham sudah ada di *watchlist*? pada *database*. Jika data emiten tersebut Sudah ada, *Backend* mengeksekusi Kembalikan *error*: sudah ada yang kemudian dikirim ke *Frontend* untuk diproses melalui *node* Perbarui tampilan *watchlist* sebelum alur berakhir (End). Namun jika emiten Belum ada, *Backend* akan memproses Simpan record *watchlist* baru ke *database*, yang diteruskan ke *Frontend* melalui *node* Perbarui tampilan *watchlist* hingga alur selesai (End).

Frontend akan menjalankan proses Kirim request hapus saham ke *Backend* jika pengguna memilih opsi Hapus. *Backend* langsung memproses Hapus record *watchlist* pada *database MySQL*, yang kemudian mengirimkan sinyal sukses ke *Frontend* untuk memicu aksi Perbarui tampilan *watchlist* sebelum akhirnya alur proses diakhiri (End).

4. Activity diagram Price alert & Pemicu Notifikasi

Activity diagram pada *price alert* dan pemicu notifikasi menggambarkan alur pembuatan batas harga saham oleh pengguna serta bagaimana sistem memicu dan mengelola notifikasi tersebut, dapat dilihat pada Gambar 3.7 di bawah ini.



Gambar 3. 7 Activity diagram Price alert & Pemicu Notifikasi


Proses dimulai ketika pengguna berada pada menu keputusan Pilih Alur, sebagaimana ditunjukkan pada Gambar 3.7. Jika pengguna memilih

jalur Buat Alert (Riset), pengguna akan melakukan aktivitas Isi & Simpan Alert pada antarmuka. Aktivitas ini memicu *Frontend* untuk menjalankan aksi Kirim request alert baru ke *Backend*. *Backend & Database* akan memproses aksi dengan menjalankan *node* Simpan ke DB, dilanjutkan dengan pengecekan kondisi pada keputusan Cek Capai *target?*. Jika harganya Tidak mencapai *target*, *Backend* mengirimkan sinyal sukses ke *Frontend* untuk memicu *node* Tampilkan pesan sukses sebelum alur selesai (End). Namun, jika harganya Ya (mencapai *target*), *Backend* menjalankan proses Kirim notifikasi yang diterima oleh *Frontend* melalui *node* Tampilkan notifikasi di *Dashboard* sebelum alur selesai (End).

Pengguna melakukan aktivitas Klik Tandai Dibaca pada *dashboard* jika memilih jalur Baca Notif (*Dashboard*). Hal tersebut memicu *Frontend* untuk menjalankan aksi Kirim request baca notifikasi ke *Backend*. *Backend* akan memproses data tersebut melalui *node* Update *status* dibaca di DB, yang kemudian mengirimkan respon balik ke *Frontend* untuk memicu aksi Hapus notifikasi dari *dashboard* sebelum akhirnya alur kerja selesai (End).

5. Activity diagram Panel Admin & Pengunggahan Data Makro

Activity diagram pada panel *Admin* dan pengunggahan data makro menggambarkan alur proses pembaruan data inflasi dan BI Rate melalui unggahan berkas *Excel* oleh *Administrator*, dapat dilihat pada Gambar 3.8 di bawah ini.



Gambar 3. 8 Activity diagram Panel Admin & Pengunggahan Data Makro


Proses dimulai ketika *Administrator* melakukan aktivitas *Pilih file Excel data makro* pada panel pengaturan *Admin*, sebagaimana ditunjukkan pada Gambar 3.8. Setelah *file* dipilih, *Frontend* akan menjalankan aksi *Tampil preview data* untuk menampilkan lembar baris data *Excel* secara visual, kemudian *Admin* mengonfirmasinya dengan menekan tombol *Unggah file ke backend*.

Backend akan menjalankan keputusan *Validasi File valid?* untuk memeriksa kecocokan *format* kolom setelah berkas diterima. Jika bernilai *Tidak*, *Backend* memicu aksi *Kirim respon gagal* yang diteruskan ke *Frontend* melalui *node* *Tampilkan pesan error* hingga alur selesai (End). Sebaliknya, jika bernilai *Ya*, *Backend* mengeksekusi *node* *Simpan/update data ke database MySQL*, lalu mengirimkan *status* sukses yang kemudian

diterima oleh *Frontend* untuk memicu aksi Tampilkan pesan sukses sebelum alur proses berakhir (End).

3.3.4 Perancangan *Database*

Perancangan basis data pada sistem ini menggunakan model relasional dengan *MySQL* sebagai sistem manajemen basis data. Basis data dirancang untuk menyimpan seluruh data yang dibutuhkan oleh sistem, mencakup data pengguna, *watchlist* saham, alert harga, serta data makroekonomi (inflasi dan BI rate). Sistem basis data ini terdiri dari lima tabel utama, yaitu tabel *Users*, *watchlist*, *price_alerts*, *inflation_data*, dan *bi_rate_data*, dapat dilihat pada Gambar 3.9 di bawah ini.



Gambar 3. 9 Struktur *Database* Tabel *Users*

Tabel *Users* menyimpan data akun seluruh pengguna yang terdaftar dalam sistem, baik pengguna biasa maupun *Administrator*. Tabel ini merupakan tabel utama yang menjadi acuan bagi tabel *watchlist* dan

price_alerts melalui relasi *foreign key*. Struktur tabel *Users* ditunjukkan pada Tabel 3.4 berikut.

Tabel 3. 4 Struktur Tabel *Users*

No	Kolom	Tipe Data	Keterangan
1	id	INT(PK)	Identifikasi unik pengguna, bersifat primary key dan auto increment
2	name	VARCHAR(100)	Nama lengkap pengguna
3	<i>Username</i>	VARCHAR(50)	Nama pengguna, digunakan sebagai salah satu kredensial <i>login</i>
4	<i>email</i>	VARCHAR(100)	Alamat <i>email</i> pengguna
5	<i>password_hash</i>	VARCHAR(255)	Kata sandi pengguna yang disimpan dalam bentuk terenkripsi (bcrypt)
6	created_at	TIMESTAMP	Waktu pembuatan akun, diisi otomatis oleh sistem
7	profile_pic	MEDIUMTEXT	Data foto profil pengguna
8	<i>role</i>	VARCHAR(20)	Peran pengguna dalam sistem, bernilai ' <i>User</i> ' untuk pengguna biasa atau ' <i>Admin</i> ' untuk <i>Administrator</i>

1. Tabel *Watchlist*

Tabel *watchlist* menyimpan daftar saham favorit yang ditambahkan oleh masing-masing pengguna untuk dipantau secara berkala. Tabel ini memiliki relasi dengan tabel *Users* melalui *foreign key* *User_id*. Struktur tabel *watchlist* ditunjukkan pada Tabel 3.5 berikut.

Tabel 3. 5 Struktur Tabel *Watchlist*

No	Kolom	Tipe Data	Keterangan
1	id	INT(PK)	Identifikasi unik <i>watchlist</i> , bersifat primary key dan auto increment
2	<i>User_id</i>	INT(FK)	Referensi ke kolom id pada tabel <i>Users</i> , menunjukkan pemilik <i>watchlist</i>
3	ticker	VARCHAR(10)	Kode saham yang ditambahkan ke <i>watchlist</i> (mis. BBKA, TLKM)
4	created_at	TIMESTAMP	Waktu penambahan saham ke <i>watchlist</i>

2. Tabel Price_Alerts

Tabel *price_alerts* merupakan tabel yang mencatat setiap alert atau notifikasi harga saham yang dibuat oleh pengguna. Tabel ini memiliki relasi dengan tabel *Users* melalui *foreign key* *User_id*. Setiap record pada tabel ini merepresentasikan satu aturan notifikasi harga. Struktur tabel *price_alerts* ditunjukkan pada Tabel 3.6 berikut.

Tabel 3. 6 Struktur Tabel *Price_Alerts*

No	Kolom	Tipe Data	Keterangan
1	id	INT(PK)	Identifikasi unik alert, bersifat primary key dan auto increment

2	<i>User_id</i>	INT(FK)	Referensi ke kolom id pada tabel <i>Users</i> , menunjukkan pemilik alert
3	ticker	VARCHAR(10)	Kode saham yang dipantau
4	trigger_condition	VARCHAR(5)	Kondisi pemicu alert ('gte', 'lte', 'gt', 'lt')
5	<i>target_price</i>	DECIMAL(15,2)	Harga <i>target</i> yang menjadi acuan pemicu alert
6	description	TEXT	Catatan atau deskripsi opsional dari pengguna, dapat bernilai NULL
7	is_triggered	TINYINT(1)	<i>Status</i> apakah alert sudah terpicu (1) atau belum (0), default 0
8	created_at	TIMESTAMP	Waktu pembuatan alert
9	is_read	TINYINT(1)	<i>Status</i> apakah notifikasi alert sudah dibaca oleh pengguna, default 0

3. Tabel Inflation_Data

Tabel *inflation_data* menyimpan data historis tingkat inflasi Indonesia yang diunggah oleh *Admin* melalui *file Excel*. Data ini digunakan sebagai salah satu variabel fitur pada model prediksi. Struktur tabel *inflation_data* ditunjukkan pada Tabel 3.7 berikut.

Tabel 3. 7 Struktur Tabel Inflation_Data

No	Kolom	Tipe Data	Keterangan
1	id	INT(PK)	Identifikasi unik data inflasi, bersifat primary key dan auto increment

2	periode	VARCHAR(50)	Periode inflasi dalam <i>format</i> teks asli (mis. "Mei 2026")
3	tanggal	DATETIME	Tanggal periode yang telah dinormalisasi
4	value	DECIMAL(5,2)	Nilai tingkat inflasi pada periode tersebut (dalam persen)

4. Tabel BI_Rate_Data

Tabel *bi_rate_data* menyimpan data historis suku bunga acuan Bank Indonesia (BI Rate) yang diunggah oleh *Admin* melalui *file Excel*. Data ini digunakan sebagai variabel fitur makroekonomi pendukung pada proses prediksi. Struktur tabel *bi_rate_data* ditunjukkan pada Tabel 3.8 berikut.

Tabel 3. 8 Struktur Tabel BI_Rate_Data

No	Kolom	Tipe Data	Keterangan
1	id	INT(PK)	Identifikasi unik data BI Rate, bersifat primary key dan auto increment
2	tanggal_str	VARCHAR(50)	Tanggal rapat BI dalam <i>format</i> teks asli (mis. "9 Juni 2026")
3	tanggal	DATETIME	Tanggal yang telah dinormalisasi (mis. 2026-06-09)
4	value	DECIMAL(5,2)	Nilai suku bunga acuan BI pada tanggal tersebut (dalam persen)

5. Relasi Antar Tabel

Terdapat dua relasi antar tabel dalam basis data sistem ini yang membentuk integritas referensial sebagai berikut.

- a. Relasi antara tabel *Users* dan tabel *watchlist* bersifat *one-to-many*, artinya satu pengguna dapat memiliki banyak saham pada *watchlist*, namun setiap entri *watchlist* hanya dimiliki oleh satu pengguna. Relasi ini diimplementasikan melalui *foreign key* *User_id* pada tabel *watchlist* yang mereferensi kolom id pada tabel *Users*.
- b. Relasi antara tabel *Users* dan tabel *price_alerts* bersifat *one-to-many*, artinya satu pengguna dapat memiliki banyak alert harga, namun setiap alert hanya dimiliki oleh satu pengguna. Relasi ini diimplementasikan melalui *foreign key* *User_id* pada tabel *price_alerts* yang mereferensi kolom id pada tabel *Users*.

3.3.5 Rancangan *Wireframe*

Perancangan *wireframe* dilakukan untuk memberikan gambaran tampilan sistem yang akan digunakan oleh pengguna. *Wireframe* dibuat secara sederhana dan mudah dipahami, dengan fokus pada fungsi utama sistem yaitu *input* kode saham dan prediksi *return* saham menggunakan algoritma *Extremely Randomized Trees* dan *Gradient Boosting*. Berikut ini dipaparkan rancangan antarmuka pengguna dari sistem yang dibangun.

1. Rancangan Halaman *Login*

Rancangan halaman *login* dan registrasi dapat dilihat pada Gambar 3.10 dibawah ini.

Gambar 3. 10 Rancangan Halaman *Login*

Gambar 3.10 menunjukkan halaman *login* yang merupakan halaman awal berfungsi sebagai pintu masuk bagi pengguna untuk mengakses sistem analisis dan prediksi saham cerdas SmartSaham. Halaman ini terbagi menjadi dua bagian utama, yaitu bagian showcase (kiri) yang menampilkan logo aplikasi, tagline "Riset saham lebih tenang.", Informasi singkat keunggulan sistem, serta pratinjau kartu pergerakan harga saham BBCA lengkap dengan grafik mini. Bagian kanan memuat *formulir login* yang terdiri dari kolom *input* Nama Pengguna (*Username*) dan Kata Sandi dengan tombol tampil/sembunyikan sandi, serta tombol "Masuk Sekarang" untuk

memproses autentikasi pengguna. Terdapat juga tab switcher di bagian atas *formulir* untuk berpindah ke halaman pendaftaran (*Register*).

4. Rancangan Halaman *Register*

Rancangan halaman *register* dapat dilihat pada Gambar 3.11 dibawah ini.

Riset Saham Lebih tenang.
Pantau watchlist, price alert, prediksi, dan rencana posisi dalam satu ruang kerja yang ringkas.

BBCA
Rp 9.650

Alert aktif 4 Watchlist 12 Sinyal Buy

Analisis AI Price Alert Rencana Investasi

Buat akun SmartSaham
Mulai simpan watchlist dan price alert pribadi Anda.

Masuk Daftar

NAMA LENGKAP
Nama Anda

NAMA PENGGUNA (USERNAME)
Masukkan username

ALAMAT EMAIL
name@example.com

KATA SANDI
Minimal 8 karakter

Buat Akun

Data akun digunakan untuk menyimpan watchlist, alert, dan preferensi Anda.


Gambar 3. 11 Rancangan Halaman *Register*

Gambar 3.11 menunjukkan halaman *register* yang berfungsi bagi pengguna baru untuk mendaftarkan akun ke dalam *database* sistem SmartSaham. Halaman ini memiliki struktur visual yang seimbang dengan halaman *login*, dengan bagian showcase di sebelah kiri dan *formulir* registrasi di sebelah kanan. Formulir registrasi terdiri dari empat kolom *input* utama, yaitu Nama Lengkap, Nama Pengguna (*Username*), Alamat *Email*, dan Kata Sandi yang dilengkapi dengan bar pendeteksi kekuatan kata sandi untuk memastikan aspek keamanan. Di bagian bawah *formulir*

terdapat tombol "Buat Akun" untuk memproses penyimpanan data kredensial ke dalam *database*.

5. Rancangan Halaman Beranda

Rancangan halaman beranda dapat dilihat pada Gambar 3.12 dibawah ini.




Gambar 3. 12 Rancangan Halaman Beranda

Gambar 3.12 menunjukkan halaman beranda (*dashboard*) yang merupakan halaman utama pertama kali disajikan kepada pengguna setelah berhasil masuk ke sistem SmartSaham. Halaman ini menyajikan rangkuman kondisi pasar saham dan ringkasan aktivitas akun secara *real-time*. Elemen-elemen yang ditampilkan meliputi ucapan selamat datang yang personal beserta Informasi hari dan tanggal di bagian atas, diikuti dengan running ticker (teks berjalan) yang menampilkan pergerakan harga saham-saham konstituen IDX30 secara langsung. Di bawah ticker, terdapat tiga kartu ringkasan (*bento card*) yaitu indeks IHSG (beserta nilai indeks dan persentase perubahan harian), total saham yang sedang aktif dalam

Watchlist, dan *status Price alert* (jumlah alert yang menunggu dan terpenuhi). Bagian bawah halaman terbagi menjadi tabel daftar Saham Trending Teraktif lengkap dengan grafik tren mini di sisi kiri, serta Panel Notifikasi terbaru di sisi kanan.

6. Rancangan Halaman *Screener* Saham

Rancangan halaman *screener* saham dapat dilihat pada Gambar 3.13 dibawah ini.




Gambar 3. 13 Rancangan Halaman *Screener* Saham

Gambar 3.13 menunjukkan halaman *screener* saham yang dirancang untuk membantu pengguna menyaring dan menyortir saham-saham IDX30 secara cepat berdasarkan indikator tertentu. Halaman ini menampilkan judul halaman "*Screener* Saham", bilah pencarian interaktif untuk menyaring saham berdasarkan kode ticker atau nama emiten, serta menu seleksi (drop-down) untuk mengurutkan daftar berdasarkan kriteria seperti *Potensi Return* (5 hari), Alfabet, Harga Saham, Perubahan Harga, Rasio PE, Price to Book (PB), dan Dividend Yield. Di bawahnya, daftar saham disajikan dalam

bentuk grid kartu dinamis yang memuat Informasi harga terkini, persentase perubahan harian, *sparkline* grafik harga historis singkat, indikator rasio keuangan utama, persentase *return* proyeksi AI, serta tombol aksi "Detail" untuk analisis lebih mendalam.

7. Rancangan Halaman Riset Emiten


Rancangan halaman riset emiten dengan kelima tab detailnya dapat dilihat pada Gambar 3.14 hingga Gambar 3.18 dibawah ini.



Gambar 3. 14 Rancangan Halaman Riset Emiten

Gambar 3.14 menunjukkan rancangan halaman riset emiten yang merupakan halaman analisis utama bagi pengguna untuk meneliti pergerakan saham tertentu secara detail. Halaman ini menyajikan kolom pencarian emiten di bagian atas untuk memilih saham pilihan. Setelah saham dipilih, halaman menampilkan kartu Informasi utama emiten yang memuat kode ticker, nama lengkap perusahaan, harga terkini, persentase perubahan harian, serta tombol "+ Watchlist". Di bawahnya terdapat visualisasi Grafik Harga & Proyeksi Prediksi AI dengan *filter* rentang waktu (1D, 1W, 1M,


3M, YTD, 1Y, 3Y, 5Y) yang menggambarkan garis historis harga saham berdampingan dengan garis putus-putus proyeksi masa depan, serta Kartu *Target Harga Prediksi AI* 5 hari kedepan.



Gambar 3. 15 Rancangan Halaman Riset Emiten - Key Stats

Gambar 3.15 menunjukkan sub-halaman Riset Emiten bagian Key Stats yang menyajikan kompilasi data statistik dan metrik keuangan fundamental emiten secara komprehensif. Informasi yang ditampilkan terbagi ke dalam beberapa kategori utama, yaitu Valuasi (PE Ratio, Price to Sales, Price to Book, Market Cap, Enterprise Value), Profitabilitas (Gross, Operating, dan Net Profit Margin, ROA, ROE), Solvabilitas (Current Ratio, Quick Ratio, Debt to Equity, Total Debt/Cash, Free Cash Flow), Dividen


(Yield, Annual Dividend, Payout Ratio, EPS), Performa Harga (52-Week High/Low, 1M & YTD *Return*), Neraca Keuangan (Total Assets, Liabilities, Book Value), Laporan Laba Rugi (Revenue, Net Income, EBIT), dan Arus Kas (Cash from Operations, Capex). Semua data ini ditarik secara *real-time* dari *Yahoo Finance* untuk membantu keputusan investasi pengguna.



Gambar 3. 16 Rancangan Halaman Riset Emiten - Faktor Prediksi

Gambar 3.16 menunjukkan sub-halaman Riset Emiten bagian Faktor Prediksi yang menyajikan transparansi mengenai 12 fitur teknikal dan makroekonomi yang digunakan oleh model pembelajaran mesin (*Extra Trees*) untuk menghasilkan estimasi *return* saham dalam 5 hari bursa ke depan. Faktor-faktor tersebut dikelompokkan ke dalam tiga dimensi analisis, yaitu Tren & Momentum (mengukur kejenuhan pasar dan kekuatan momentum tren berdasarkan RSI dan *MACD*), Harga & Volatilitas

(mengukur pergerakan harga relatif terhadap rata-rata historis serta intensitas volume transaksi melalui Volume Ratio, Lag, dan rasio *Moving Average*), serta Kondisi Makroekonomi & Pasar (mengukur performa pasar saham domestik, nilai tukar, inflasi, dan suku bunga acuan melalui *IHSG Return*, *USD/IDR Return*, tingkat inflasi, dan BI Rate).



Gambar 3. 17 Rancangan Halaman Riset Emiten - Rencana Investasi

Gambar 3.17 menunjukkan sub-halaman Riset Emiten bagian Rencana Investasi (Simulasi DCA) yang berfungsi sebagai kalkulator investasi interaktif untuk membantu pengguna merencanakan akumulasi saham secara berkala (Dollar Cost Averaging). Panel kiri simulasi menyediakan *slider* untuk menyesuaikan jumlah nominal investasi per bulan, durasi jangka waktu investasi (3 hingga 60 bulan), dan kolom

input/tombol cepat asumsi *return* tahunan (5%, 10%, 15%). Panel kanan menyajikan hasil kalkulasi estimasi nilai aset akhir, persentase keuntungan, total modal disetor, estimasi keuntungan bersih, *return* tahunan, serta estimasi lot akumulasi yang terkumpul selama masa durasi investasi.




Gambar 3. 18 Rancangan Halaman Riset Emiten - Profil Perusahaan

Gambar 3.18 menunjukkan sub-halaman Riset Emiten bagian Profil Perusahaan yang menyajikan Informasi profil korporat dan latar belakang bisnis emiten. Halaman ini memuat deskripsi ringkas mengenai lini bisnis utama perusahaan, sejarah singkat operasional, serta sektor industri tempat emiten bernaung yang disajikan secara terperinci dalam Bahasa Indonesia. Terdapat juga tag kategori industri di bagian bawah untuk mempermudah identifikasi sektor bisnis emiten.

8. Rancangan Halaman *Watchlist*

Rancangan halaman *watchlist* dapat dilihat pada Gambar 3.19 dibawah ini.



Watchlist saya
6 saham dipantau

Tambah saham ... Alphabetical Kolom


Saham	Price	Changes	Value	Lot	Open	High	Low	P/E	P/B
ADRO Adaro Energy Indonesia	2.300	+1.24%	38.6 M	167.976	2.300	2.330	2.280	7.44x	13.53x
ASI Astra International Tbk.	4.780	+0.62%	147.9 M	311.394	4.810	4.810	4.690	6.09x	0.82x
BBCA Bank Central Asia	2.300	+1.24%	38.6 M	167.976	2.300	2.330	2.280	7.44x	13.53x
BBRI Bank Rakyat Indonesia	4.780	+0.62%	147.9 M	311.394	4.810	4.810	4.690	6.09x	0.82x
BMRI Bank Mandiri(Persero)	2.300	+1.24%	38.6 M	167.976	2.300	2.330	2.280	7.44x	13.53x
ICBP Indohold CBP Sukses	4.780	+0.62%	147.9 M	311.394	4.810	4.810	4.690	6.09x	0.82x

Gambar 3. 19 Rancangan Halaman *Watchlist*

Gambar 3.19 menunjukkan halaman *watchlist* yang merupakan antarmuka pemantauan khusus bagi pengguna untuk mengamati pergerakan harga dan kinerja keuangan saham-saham pilihan yang dimasukkan ke dalam daftar pantau. Halaman ini terdiri dari Informasi jumlah saham terpantau, kolom pencarian cepat untuk menambahkan saham baru ke daftar *watchlist*, menu drop-down pengurutan (*sorting*), serta menu *dropdown* "Kolom" untuk mempersonalisasi metrik tabel yang ingin ditampilkan. Saham yang dipantau ditampilkan dalam bentuk tabel dinamis yang mencakup kolom nama saham, harga terkini, perubahan harga, penawaran bid/ask, nilai transaksi, volume lot, frekuensi perdagangan, harga rata-rata, harga penutupan sebelumnya, harga pembukaan, harga tertinggi dan terendah harian, indikator ARA/ARB, metrik PE/PB, pembagian dividen, dan kolom aksi untuk menghapus saham dari daftar.

9. Rancangan Halaman *Price alert*

Rancangan halaman *price alert* dapat dilihat pada Gambar 3.20 dibawah ini.




Gambar 3. 20 Rancangan Halaman *Price alert*

Gambar 3.20 menunjukkan halaman *price alert* yang dirancang untuk membuat dan mengelola notifikasi harga otomatis. Halaman ini memuat tombol "Tambah Alert Baru" yang membuka modal *input* kondisi pemicu alert (memasukkan kode saham, memilih kondisi matematis seperti *gte/lte*, menetapkan nilai harga *target*, dan menambahkan deskripsi catatan). Di bawah bilah navigasi tersebut, terdapat tabel Alert Aktif yang menyajikan daftar peringatan yang sedang berjalan lengkap dengan kolom kondisi, harga *target*, harga saat ini, *status* keaktifan, deskripsi, tanggal pembuatan, dan tombol aksi hapus alert. Di bagian paling bawah terdapat log riwayat pemicu alert (Alert Log) yang mencatat log kejadian notifikasi ketika harga saham menyentuh *target* yang ditentukan.


10. Rancangan Halaman Pengaturan

Rancangan halaman pengaturan dengan kedua sub-halamannya dapat dilihat pada Gambar 3.21 dan Gambar 3.22 dibawah ini.



Gambar 3. 21 Rancangan Halaman Pengaturan - Profil Pengguna

Gambar 3.21 menunjukkan halaman pengaturan profil pengguna yang menyajikan antarmuka untuk memperbarui Informasi data diri pengguna. Kolom kiri halaman menampilkan visualisasi foto profil/inisial pengguna dengan tombol unggah foto, nama lengkap, *email*, serta ringkasan jumlah *watchlist* dan alert aktif. Kolom kanan memuat panel *formulir* "Informasi Profil" yang terdiri dari kolom *input* nama lengkap, nama pengguna (*Username*), alamat *email*, serta tombol "Simpan Perubahan Profil" untuk memperbarui data ke dalam *server database*.




Gambar 3. 22 Rancangan Halaman Pengaturan - Keamanan dan Sandi

Gambar 3.22 menunjukkan halaman pengaturan keamanan dan sandi yang menyajikan antarmuka bagi pengguna untuk mengganti kata sandi demi menjaga keamanan akun. Panel kiri memuat kolom *input Password* Saat Ini, *Password* Baru yang dilengkapi dengan bilah kekuatan kata sandi, Konfirmasi *Password* Baru, serta tombol "*Ubah Password*". Panel kanan memuat kartu petunjuk kriteria kata sandi yang aman yang secara dinamis menunjukkan kepatuhan kata sandi baru terhadap kriteria minimal (seperti panjang 8 karakter, huruf besar dan kecil, serta angka).


11. Rancangan Halaman Kelola *User*

Rancangan halaman kelola *User* dengan kedua sub-halamannya dapat dilihat pada Gambar 3.23 dan Gambar 3.24 dibawah ini.



Gambar 3. 23 Rancangan Halaman Kelola *User* - Manajemen Pengguna

Gambar 3.23 menunjukkan halaman kelola *User* bagian manajemen pengguna yang merupakan halaman *Administrasi* hanya dapat diakses oleh *Admin* untuk memantau dan mengelola hak akses seluruh pengguna aplikasi SmartSaham. Halaman ini menampilkan tab navigasi *Administratif* (Kelola *User* dan *Upload Data Makro*) serta tombol *refresh* untuk memperbarui data tabel. Konten utama menyajikan tabel daftar pengguna terdaftar lengkap dengan kolom *Nama*, *Username*, *Email*, pilihan pengubahan *Role* (*Admin/User*), *Tanggal Gabung*, serta kolom aksi berupa tombol hapus untuk menghapus akun pengguna dari *database*.



Gambar 3. 24 Rancangan Halaman Kelola *User* - *Upload* Data Makro

Gambar 3.24 menunjukkan halaman kelola *User* bagian *upload* data makro yang merupakan antarmuka khusus *Admin* untuk memperbarui data indikator makroekonomi (Inflasi dan BI Rate) yang digunakan dalam perhitungan prediksi harga saham oleh model *Machine Learning*. Halaman ini menyediakan tombol bantuan cara penggunaan yang memuat tata cara unduh data resmi Bank Indonesia, serta dua area kartu unggahan *file Excel* (.xlsx) untuk masing-masing tipe data (Data Inflasi dan Data BI Rate). Terdapat dropzone seret-dan-lepas *file Excel*, tombol *preview* untuk memverifikasi baris data sebelum disinkronkan, serta tombol "Simpan ke *Database*" untuk memproses penyimpanan data baru ke *database*.

3.4 Data dan Pengumpulan Data

Pengumpulan data merupakan tahapan penting dalam penelitian ini karena kualitas, kelengkapan, dan konsistensi *dataset* sangat memengaruhi performa model regresi yang dihasilkan. Model prediksi *return* saham pada saham-saham yang tergabung dalam indeks IDX30 memerlukan data yang beragam agar mampu

menangkap pola pergerakan harga secara komprehensif, sehingga data yang dikumpulkan mencakup data harga saham, data indeks pasar, data nilai tukar, serta data makroekonomi yang secara teoretis memengaruhi pergerakan harga saham.

3.4.1 Sumber Data

Dataset yang digunakan dalam penelitian ini merupakan kombinasi dari beberapa sumber data sekunder yang saling melengkapi, yaitu data harga saham historis, data indeks pasar, data nilai tukar mata uang, serta data makroekonomi. Penggabungan berbagai sumber data ini bertujuan agar model tidak hanya mempelajari pola pergerakan harga dari sisi teknikal saham itu sendiri, tetapi juga mempertimbangkan kondisi pasar secara keseluruhan dan faktor makroekonomi yang memengaruhi keputusan investor.

Data harga saham historis diperoleh melalui pustaka *yfinance* yang mengambil data secara langsung dari *Yahoo Finance*. Data yang diunduh berupa data harga Open, High, Low, Close, dan Volume (OHLCV) harian untuk 30 saham yang tergabung dalam indeks IDX30, dengan rentang waktu tiga tahun terakhir terhitung dari tanggal pengumpulan data. Daftar lengkap kode saham (ticker) yang digunakan dalam penelitian ini disajikan pada Tabel 3.9.

Tabel 3. 9 Daftar Saham IDX30 yang Digunakan

No	Kode Saham	Nama Emiten
1	BBCA.JK	Bank Central Asia
2	BBRI.JK	Bank Rakyat Indonesia

No	Kode Saham	Nama Emiten
3	BMRI.JK	Bank Mandiri
4	BBNI.JK	Bank Negara Indonesia
5	TLKM.JK	Telkom Indonesia
6	ASII.JK	Astra International
7	UNVR.JK	Unilever Indonesia
8	HMSP.JK	H.M. Sampoerna
9	ICBP.JK	Indofood CBP Sukses Makmur
10	INDF.JK	Indofood Sukses Makmur
11	KLBF.JK	Kalbe Farma
12	EXCL.JK	XL Axiata
13	JSMR.JK	Jasa Marga
14	PTBA.JK	Bukit Asam
15	ANTM.JK	Aneka Tambang
16	INCO.JK	Vale Indonesia
17	MEDC.JK	Medco Energi
18	PGAS.JK	Perusahaan Gas Negara
19	SMGR.JK	Semen Indonesia
20	SIDO.JK	Industri Jamu Sido Muncul
21	BTPS.JK	Bank BTPN Syariah
22	BRIS.JK	Bank Syariah Indonesia
23	ACES.JK	<i>Ace Hardware</i> Indonesia

No	Kode Saham	Nama Emiten
24	MAPI.JK	Mitra Adiperkasa
25	CPIN.JK	Charoen Pokphand Indonesia
26	JPFA.JK	Japfa Comfeed Indonesia
27	TOWR.JK	Sarana Menara Nusantara
28	ESSA.JK	Essa Industries Indonesia
29	BRPT.JK	Barito Pacific
30	EMTK.JK	Elang Mahkota Teknologi

Penelitian ini juga mengumpulkan data Indeks Harga Saham Gabungan (IHSG) dengan kode ticker `^JKSE` sebagai representasi pergerakan pasar saham secara keseluruhan, serta data kurs nilai tukar Rupiah terhadap Dolar Amerika Serikat (USD/IDR) dengan kode ticker `IDR=X`, selain data harga saham individual, mengingat nilai tukar mata uang memiliki pengaruh terhadap arus modal asing dan kinerja emiten yang berorientasi ekspor-impor.

Data makroekonomi berupa tingkat inflasi bulanan dan suku bunga acuan (BI Rate) turut dikumpulkan sebagai pelengkap, yang keduanya diperoleh dari situs resmi Bank Indonesia (BI). Kedua data ini diunduh dalam *format* `xlsx`, kemudian diparsing dan dikonversi ke dalam *format* tanggal standar, karena *format* asli dari kedua sumber tersebut menggunakan penulisan bulan dalam Bahasa Indonesia (contoh: "Mei 2026" untuk data inflasi dan "9 Juni 2026" untuk data BI Rate). Ringkasan sumber data yang digunakan dalam penelitian ini disajikan pada Tabel 3.10.

Tabel 3. 10 Ringkasan Sumber Data Penelitian

No	Jenis Data	Sumber	Frekuensi	Periode
1	Harga Saham (OHLCV) 30 Emiten IDX30	<i>Yahoo Finance</i> (<i>yfinance</i>)	Harian	3 tahun terakhir
2	Indeks Harga Saham Gabungan (IHSG)	<i>Yahoo Finance</i> (ticker ^JKSE)	Harian	3 tahun terakhir
3	Kurs USD/IDR	<i>Yahoo Finance</i> (ticker IDR=X)	Harian	3 tahun terakhir
4	Tingkat Inflasi	Bank Indonesia (BI)	Bulanan	3 tahun terakhir
5	BI Rate (Suku Bunga Acuan)	Bank Indonesia (BI)	Per Rapat Dewan Gubernur	3 tahun terakhir

Seluruh sumber data tersebut kemudian digabungkan (merge) berdasarkan kolom tanggal (Date) menjadi satu *dataset* terpadu. Penggabungan data makroekonomi bulanan (inflasi dan BI Rate) ke dalam data harian dilakukan dengan mencocokkan bulan observasi, kemudian nilai yang kosong pada bulan-bulan tertentu diisi menggunakan teknik forward-fill dan backward-fill agar tidak terdapat celah data pada deret waktu bulanan.

3.4.2 Rekayasa Fitur (*Feature engineering*)

Proses rekayasa fitur dilakukan untuk mengekstraksi indikator teknikal maupun indikator pasar yang relevan terhadap pergerakan *return* saham, sebelum data historis harga saham dapat digunakan sebagai *input* model. Fitur-fitur ini dihitung secara terpisah untuk setiap saham menggunakan fungsi

`compute_features()`, lalu digabungkan kembali menjadi satu *dataset*. Fitur-fitur teknikal yang dihasilkan meliputi Lag *Return* (*Return_t-1* dan *Return_t-2*), rasio harga penutupan terhadap *Moving Average* 5, 10, dan 20 hari (*Close_to_MA5*, *Close_to_MA10*, *Close_to_MA20*), rasio volume perdagangan terhadap rata-rata volume 20 hari (*Volume_Ratio*), indikator *Relative Strength Index* (RSI) periode 14 hari, serta indikator *Moving Average* Convergence Divergence (*MACD* Histogram).

Perlu ditekankan bahwa nilai harga penutupan (*Close*) dan volume perdagangan mentah tidak digunakan secara langsung sebagai fitur model, melainkan digantikan dengan fitur rasio (*Close_to_MA** dan *Volume_Ratio*) serta fitur *return*. Hal ini dilakukan karena nilai *Close* dan *Volume* bersifat non-stasioner, yaitu levelnya cenderung terus berubah seiring waktu sehingga model berbasis pohon keputusan (*tree-based*) sulit melakukan ekstrapolasi terhadap rentang nilai baru yang belum pernah ditemui pada data pelatihan. Sebaliknya, fitur rasio memiliki rentang nilai yang relatif stabil dari waktu ke waktu sehingga lebih sesuai digunakan sebagai *input* model prediktif berbasis pohon.

Kurs USD/IDR juga tidak digunakan dalam bentuk nilai level (*USD_IDR*), melainkan dikonversi menjadi fitur *return* harian (*USD_IDR_Return*), dengan alasan yang sama. Seluruh fitur yang digunakan sebagai *input* model beserta penjelasannya disajikan pada Tabel 3.11.

Tabel 3. 11 Fitur (Variabel Independen) yang Digunakan dalam Model

No	Nama Fitur	Deskripsi	Kategori
1	Volume_Ratio	Rasio volume perdagangan harian terhadap rata-rata volume 20 hari	Teknikal
2	Lag1	<i>Return</i> harian pada t-1 (satu hari bursa sebelumnya)	Teknikal
3	Lag2	<i>Return</i> harian pada t-2 (dua hari bursa sebelumnya)	Teknikal
4	Close_to_MA5	Rasio harga penutupan terhadap <i>Moving Average</i> 5 hari	Teknikal
5	Close_to_MA10	Rasio harga penutupan terhadap <i>Moving Average</i> 10 hari	Teknikal
6	Close_to_MA20	Rasio harga penutupan terhadap <i>Moving Average</i> 20 hari	Teknikal
7	RSI	<i>Relative Strength Index</i> periode 14 hari	Teknikal
8	MACD	MACD Histogram (EMA12, EMA26, sinyal 9)	Teknikal
9	USD_IDR_Return	<i>Return</i> harian kurs USD terhadap IDR	Makroekonomi/Pasar
10	Inflation	Tingkat inflasi bulanan (BI)	Makroekonomi
11	BI_Rate	Suku bunga acuan Bank Indonesia	Makroekonomi

Fitur-fitur di atas kemudian digabungkan dengan *target* penelitian, yaitu *Return_5d*, yang dihitung sebagai *return* kumulatif 5 hari bursa ke depan pada setiap saham. Nilai horizon 5 hari bursa dipilih karena merepresentasikan kurang lebih satu minggu perdagangan bursa efek.

3.4.3 Pembagian Data

Pembagian *dataset* menjadi data latih dan data uji dilakukan berdasarkan cutoff tanggal (*time-based split*), bukan berdasarkan pembagian acak (*random split*) seperti umum digunakan pada data non-deret waktu. Pendekatan ini dipilih karena data yang digunakan bersifat deret waktu (*time series*), sehingga pembagian acak berisiko menyebabkan kebocoran data (*data leakage*) akibat Informasi dari masa depan tercampur ke dalam data pelatihan.

Seluruh tanggal unik pada *dataset* diurutkan, kemudian ditentukan satu titik potong (*cutoff date*) pada persentil ke-80, sehingga 80% tanggal paling awal digunakan sebagai data latih dan 20% tanggal paling akhir digunakan sebagai data uji. Pendekatan cutoff berbasis tanggal ini juga memastikan tidak ada satu tanggal observasi yang datanya terpecah antara data latih dan data uji, mengingat fitur makroekonomi dan fitur pasar (*USD_IDR_Return*, *Inflation*, *BI_Rate*) bernilai identik untuk seluruh saham pada tanggal yang sama. Rincian pembagian data disajikan pada Tabel 3.12.

Tabel 3. 12 Pembagian Data (*Time-based split*)

No	Subset	Proporsi	Fungsi
1	<i>Training set</i>	80%	Melatih model ExtraTrees dan <i>Gradient Boosting</i>
2	<i>Testing set</i>	20%	Evaluasi akhir performa model pada data yang belum pernah dilihat

Nilai kosong (missing values) yang tersisa pada fitur makroekonomi setelah proses penggabungan diimputasi menggunakan nilai *median*, yang dihitung khusus dari data latih saja kemudian diterapkan pula pada data uji. Strategi ini bertujuan mencegah kebocoran Informasi statistik dari data uji ke dalam proses imputasi, sehingga evaluasi model tetap objektif dan merepresentasikan kondisi data yang belum pernah dilihat model.

3.5 Pra-pemrosesan Data

Tahap pra-pemrosesan data bertujuan untuk membersihkan, menstandarkan, dan menyiapkan data agar layak digunakan dalam proses pelatihan model regresi ExtraTrees dan *Gradient Boosting*. Subbab ini terbagi menjadi tiga bagian, yaitu pembersihan data (*data cleaning*), penanganan *outlier*, dan standarisasi fitur (*feature scaling*).

3.5.1 Pembersihan Data (*Data cleaning*)

Proses pembersihan data diawali dengan pemeriksaan nilai kosong (missing values) pada *dataset* gabungan. Baris data yang memiliki nilai kosong pada fitur-fitur teknikal (*Return*, *Lag1*, *Lag2*, *Close_to_MA5*, *Close_to_MA10*,

Close_to_MA20, RSI, *MACD*, Volume_Ratio) dihapus dari *dataset*, karena nilai kosong pada kolom-kolom tersebut wajar terjadi di awal deret waktu setiap saham akibat perhitungan indikator berbasis periode (misalnya RSI 14 hari memerlukan minimal 14 observasi sebelum dapat dihitung).

Selanjutnya dilakukan pemeriksaan dan penghapusan data duplikat berdasarkan kombinasi kolom tanggal (Date) dan kode saham (Stock), untuk memastikan tidak terdapat baris observasi ganda pada saham dan tanggal yang sama.

3.5.2 Penanganan *Outlier*

Nilai *return* harian yang ekstrem berpotensi menyebabkan model bias terhadap nilai-nilai pencilan (*outlier*) yang tidak merepresentasikan pola umum pergerakan *return* saham. Untuk mengatasi hal ini, diterapkan teknik *Winsorizing* pada kolom *Return*, yaitu dengan memotong (clipping) nilai *return* yang berada di bawah persentil ke-1 dan di atas persentil ke-99 ke batas persentil tersebut. Teknik ini dipilih dibandingkan penghapusan langsung (removal) karena tetap mempertahankan jumlah observasi sekaligus mengurangi pengaruh nilai ekstrem terhadap proses pelatihan model.

3.5.3 Standardisasi Fitur (*Feature scaling*)

Karena fitur-fitur *input* memiliki satuan dan rentang nilai yang berbeda-beda (misalnya RSI berkisar 0-100, sedangkan Close_to_MA5 berkisar mendekati 1), seluruh fitur *input* distandardisasi menggunakan *StandardScaler* dari pustaka *scikit-learn*, sehingga setiap fitur memiliki rata-rata (mean) 0 dan simpangan baku

(standard deviation) 1. Proses fit scaler hanya dilakukan pada data latih, kemudian parameter yang sama (mean dan standar deviasi) diterapkan untuk transformasi data latih maupun data uji, guna mencegah kebocoran Informasi statistik dari data uji ke dalam proses pelatihan model.

3.6 Pengembangan Model (*Model development*)

Tahap pengembangan model merupakan inti dari penelitian ini, di mana dua algoritma *ensemble learning* berbasis pohon keputusan, yaitu *Extremely Randomized Trees* (ExtraTrees) dan *Gradient Boosting*, dikembangkan dan dibandingkan performanya dalam memprediksi *return* kumulatif 5 hari bursa ke depan pada saham-saham IDX30. Kedua model dilatih menggunakan data fitur yang telah melalui tahap pra-pemrosesan pada subbab sebelumnya.

3.6.1 *Extremely Randomized Trees* (ExtraTrees)

ExtraTrees merupakan algoritma *ensemble learning* yang membangun sejumlah pohon keputusan (*decision trees*) secara acak, baik dari sisi pemilihan subset fitur maupun titik pemisahan (*split point*), sehingga menghasilkan model yang cenderung memiliki variansi lebih rendah dibandingkan *Random Forest* konvensional. Model ExtraTrees pada penelitian ini diimplementasikan menggunakan ExtraTreesRegressor dari pustaka scikit-learn.

Berbeda dengan pendekatan *hyperparameter* tetap (*fixed*), penelitian ini menerapkan *hyperparameter tuning*, yaitu proses pencarian kombinasi *hyperparameter* terbaik secara otomatis berdasarkan hasil validasi silang (*cross-validation*), alih-alih menentukan nilai *hyperparameter* secara manual. Dua metode

pencarian digunakan, yaitu *Grid search* (mencoba seluruh kombinasi dalam rentang parameter yang ditentukan) dan *Randomized Search* (mencoba sejumlah kombinasi secara acak dari rentang yang sama). Rentang *hyperparameter* yang dicari meliputi jumlah pohon (*n_estimators*), kedalaman maksimum pohon (*max_depth*), jumlah sampel minimum untuk membagi *node* (*min_samples_split*), jumlah sampel minimum pada leaf *node* (*min_samples_leaf*), serta jumlah fitur yang dipertimbangkan tiap split (*max_features*).

3.6.2 *Gradient Boosting*

Gradient Boosting merupakan algoritma *ensemble learning* yang membangun model secara sekuensial, di mana setiap pohon baru dilatih untuk memperbaiki kesalahan (*residual error*) dari pohon-pohon sebelumnya. Model *Gradient Boosting* pada penelitian ini diimplementasikan menggunakan *GradientBoostingRegressor* dari pustaka *scikit-learn*.

Sama seperti *ExtraTrees*, *hyperparameter Gradient Boosting* juga tidak ditentukan secara manual, melainkan dicari melalui proses *tuning* dengan metode *Grid search* dan *Randomized Search*. Rentang *hyperparameter* yang dicari meliputi jumlah tahap boosting (*n_estimators*), bobot kontribusi tiap pohon (*learning_rate*), kedalaman maksimum pohon (*max_depth*), proporsi sampel yang digunakan tiap iterasi boosting (*subsample*), serta jumlah sampel minimum untuk membagi *node* dan pada leaf *node* (*min_samples_split* dan *min_samples_leaf*).

3.6.3 Skenario Pengujian *Tuning Hyperparameter*

Penelitian ini membuat 4 skenario pengujian untuk melihat apakah rentang pencarian dan metode *tuning* yang berbeda memengaruhi hasil model. Skenario ini menggabungkan dua hal: lebar rentang parameter yang dicoba (sempit atau lebar) dan cara pencariannya (*Grid search* atau *Randomized Search*), seperti pada Tabel 3.13.

Tabel 3. 13 Skenario Pengujian *Tuning Hyperparameter*

No	Skenario	Rentang Parameter	Metode Search
1	A	Sempit (konservatif)	<i>Grid search</i>
2	B	Lebar	<i>Grid search</i>
3	C	Sempit (konservatif)	<i>Randomized Search</i>
4	D	Lebar	<i>Randomized Search</i>

Rentang sempit berisi sedikit pilihan nilai untuk tiap parameter, sedangkan rentang lebar berisi lebih banyak pilihan nilai sehingga area pencariannya lebih luas. Nilai-nilai yang dicoba untuk model ExtraTrees ada di Tabel 3.14, dan untuk *Gradient Boosting* ada di Tabel 3.15.

Tabel 3. 14 Rentang *Hyperparameter* Model ExtraTrees

No	<i>Hyperparameter</i>	Rentang Sempit	Rentang Lebar
1	n_estimators	100, 200	100, 300
2	max_depth	5, 7	3, 7, 10
3	min_samples_split	-	10, 40

No	<i>Hyperparameter</i>	Rentang Sempit	Rentang Lebar
4	min_samples_leaf	10, 20	5, 20
5	max_features	-	sqrt, log2

Tabel 3. 15 Rentang *Hyperparameter* Model *Gradient Boosting*

No	<i>Hyperparameter</i>	Rentang Sempit	Rentang Lebar
1	n_estimators	100, 150	100, 200
2	learning_rate	0.03, 0.05	0.01, 0.05, 0.1
3	max_depth	2, 3	2, 4
4	subsample	-	0.7, 1.0
5	min_samples_split	-	10, 40

Setiap skenario diuji dengan cara membagi data latih menjadi 3 bagian (CV_FOLDS = 3), lalu dicoba bergantian mana yang jadi data validasi. Kombinasi *hyperparameter* yang menghasilkan kesalahan (*RMSE*) paling kecil di validasi ini akan dipilih sebagai kombinasi terbaik untuk skenario tersebut. *Grid search* mencoba semua kombinasi yang mungkin dari tabel di atas, sedangkan *Randomized Search* hanya mencoba beberapa kombinasi secara acak, sehingga lebih cepat, terutama untuk rentang lebar yang jumlah kombinasinya banyak. Seluruh proses pencarian ini memakai `random_state = 42` supaya hasilnya bisa didapat ulang persis sama jika dijalankan lagi.

3.6.4 Proses Pelatihan Model

Kedua model dilatih menggunakan data fitur hasil standardisasi (X_{train_sc}) dan *target return* kumulatif 5 hari bursa (y_{train}) yang telah dipisahkan pada tahap pembagian data. Proses pelatihan dilakukan pada tiap skenario *tuning* (A, B, C, dan D) untuk masing-masing algoritma, sehingga menghasilkan satu model terbaik (*best_estimator_*) per skenario. Model terbaik akhir untuk tiap algoritma kemudian dipilih dengan membandingkan nilai R^2 pada data uji di antara seluruh skenario, sehingga ExtraTrees dan *Gradient Boosting* bisa saja terpilih dari skenario yang berbeda. Waktu pelatihan (*training time*) tiap skenario turut dicatat sebagai salah satu indikator efisiensi komputasi yang dibandingkan pada tahap evaluasi. Untuk memastikan hasil penelitian dapat direproduksi, seluruh proses pelatihan menggunakan nilai *random_state* yang tetap ($RANDOM_STATE = 42$).

3.7 Pengujian dan Evaluasi Model

Tahap pengujian dan evaluasi dilakukan untuk mengukur kemampuan generalisasi kedua model dalam memprediksi *return* kumulatif 5 hari bursa ke depan pada data yang belum pernah dilihat selama proses pelatihan. Subbab ini terbagi menjadi tiga bagian, yaitu pengujian model, metrik evaluasi, dan perbandingan performa antar model.

3.7.1 Pengujian Model

Pengujian dilakukan dengan memberikan data uji (X_{test_sc}) yang telah melalui tahapan pra-pemrosesan identik dengan data latih, yaitu standardisasi

menggunakan parameter scaler yang telah di-fit pada data latih. Kedua model, ExtraTrees dan *Gradient Boosting*, melakukan proses prediksi terhadap data uji untuk menghasilkan nilai estimasi *return* kumulatif 5 hari bursa ke depan pada setiap saham dan tanggal observasi. Prediksi dilakukan baik pada data latih maupun data uji, untuk memungkinkan analisis perbandingan performa model antara kondisi *training* dan *testing* sebagai indikasi ada atau tidaknya overfitting.

3.7.2 Metrik Evaluasi

Penelitian ini menggunakan metrik evaluasi yang berbeda dengan metrik pada permasalahan klasifikasi, karena merupakan permasalahan regresi (memprediksi nilai *return* yang bersifat kontinu). Metrik evaluasi yang digunakan dalam penelitian ini disajikan pada Tabel 3.16.

Tabel 3. 16 Metrik Evaluasi Model Regresi

No	Metrik	Deskripsi
1	<i>RMSE (Root mean squared error)</i>	Mengukur akar rata-rata kuadrat selisih antara nilai <i>return</i> aktual dan nilai <i>return</i> hasil prediksi. Semakin kecil nilai <i>RMSE</i> , semakin baik akurasi model.
2	<i>MAE (Mean absolute error)</i>	Mengukur rata-rata selisih absolut antara nilai aktual dan nilai prediksi, memberikan gambaran kesalahan prediksi dalam satuan yang sama dengan <i>return</i> .
3	R^2 (Koefisien Determinasi)	Mengukur seberapa besar proporsi variansi <i>return</i> yang mampu dijelaskan oleh model. Nilai R^2 mendekati 1 menunjukkan model menjelaskan variansi data dengan baik.

Evaluasi juga dilengkapi dengan analisis visual berupa *scatter plot Actual vs predicted* untuk melihat sebaran hasil prediksi terhadap nilai aktual, *residual plot* untuk memeriksa pola kesalahan prediksi, serta grafik *feature importance* untuk mengidentifikasi fitur-fitur yang paling berpengaruh terhadap prediksi *return* pada masing-masing model, selain ketiga metrik kuantitatif di atas.

3.7.3 Perbandingan Performa Model

Hasil evaluasi tiap skenario (A, B, C, dan D) dirangkum ke dalam tabel perbandingan untuk memudahkan analisis, setelah kedua model (ExtraTrees dan *Gradient Boosting*) dievaluasi menggunakan metrik *RMSE*, *MAE*, dan R^2 pada data uji di setiap skenario. Model dengan nilai *RMSE* dan *MAE* terendah serta nilai R^2 tertinggi pada data uji dianggap sebagai model dengan performa prediksi yang lebih baik. Selain metrik akurasi, waktu pelatihan (*training time*) tiap skenario turut dibandingkan sebagai pertimbangan efisiensi komputasi antara kedua algoritma maupun antar metode *tuning* yang digunakan.

Perbandingan *feature importance* pada kedua model di setiap skenario dilakukan untuk mengidentifikasi konsistensi fitur penting serta variabel teknikal dan makroekonomi yang paling berpengaruh terhadap *return* saham IDX30 dalam horizon 5 hari bursa. Hasil keempat skenario kemudian dirangkum dalam satu tabel untuk membandingkan performa ExtraTrees dan Gradient Boosting secara lintas skenario. Model terbaik dari masing-masing algoritma selanjutnya disimpan dalam format *.pkl* beserta *scaler* yang digunakan untuk implementasi pada tahap berikutnya.

BAB IV


HASIL DAN PEMBAHASAN

4.1 Hasil *User interface* Sistem Prediksi *Return* Saham

Hasil dari *wireframe* sistem prediksi *Return* saham (SmartSaham) menghasilkan sebuah aplikasi web yang dibangun menggunakan *HTML*, *CSS* kustom, dan *Vanilla JavaScript* pada sisi *frontend* serta *FastAPI* pada sisi *backend*. Hasil antarmuka dilakukan dengan mengacu pada rancangan yang telah disusun sebelumnya, dengan beberapa penyesuaian pada tahap pengembangan untuk meningkatkan kenyamanan dan kemudahan penggunaan (*usability*) sistem.

4.1.1 Hasil Halaman *Login*

Hasil Dari Tampilan halaman *login* dapat dilihat pada Gambar 4. 1 di bawah ini.




Gambar 4. 1 Hasil Halaman *Login*

Gambar 4.1 menunjukkan halaman *login* yang menampilkan antarmuka bertipe *split screen* dengan dua panel utama. Panel kiri menampilkan ikon SmartSaham, nama aplikasi, deskripsi singkat, kartu pratinjau grafik pergerakan

saham BBKA, *status* jumlah alert aktif dan *watchlist*, serta tiga *badge* Informasi ("Analisis AI", "Price alert", "Rencana Investasi"). Tampilan panel kiri ini bermanfaat untuk memberikan gambaran awal kepada pengguna baru mengenai fitur-fitur unggulan yang tersedia, sehingga meningkatkan kepercayaan dan minat sebelum masuk ke sistem. Panel kanan berisi *formulir login* dengan kolom *input* Nama Pengguna dan Kata Sandi yang dilengkapi ikon tampilkan/sembunyikan kata sandi, bermanfaat untuk menjaga privasi pengguna saat memasukkan kredensial di tempat umum. Tombol "Masuk Sekarang" serta tab navigasi menuju halaman pendaftaran tersedia untuk memudahkan pengguna baru yang belum memiliki akun agar dapat langsung dialihkan tanpa perlu mencari tautan secara manual.

4.1.2 Hasil Halaman *Register*

Hasil Dari Tampilan halaman *register* dapat dilihat pada Gambar 4. 2 di bawah ini.




Gambar 4. 2 Hasil Halaman *Register*

Gambar 4.2 menunjukkan halaman *register* yang menampilkan antarmuka pendaftaran akun yang terbagi menjadi bagian *showcase* di sebelah kiri dan *formulir* registrasi di sebelah kanan. Bagian *formulir* menampilkan empat kolom *input* utama yang terdiri dari Nama Lengkap, Nama Pengguna (*Username*), Alamat *Email*, dan Kata Sandi. Kolom Kata Sandi dilengkapi dengan bar pendeteksi kekuatan kata sandi yang bermanfaat untuk membantu pengguna membuat kata sandi yang lebih aman secara *real-time*, sehingga mengurangi risiko akun diretas akibat kata sandi yang lemah. Di bagian bawah *formulir* terdapat tombol "Buat Akun" untuk memproses penyimpanan data kredensial, serta tab *switcher* di bagian atas untuk kembali ke *formulir* masuk bagi pengguna yang sudah memiliki akun, sehingga navigasi antar halaman autentikasi menjadi lebih intuitif tanpa perlu menekan tombol kembali *browser*.

4.1.3 Hasil Halaman Beranda

Hasil Dari Tampilan halaman beranda dapat dilihat pada Gambar 4.3 di bawah ini.




Gambar 4. 3 Hasil Halaman Beranda

Gambar 4.3 menunjukkan halaman beranda (*dashboard*) yang menampilkan antarmuka ringkasan kondisi pasar saham dan aktivitas akun pengguna secara *real-time*. Bagian atas halaman menampilkan ucapan selamat datang yang personal beserta Informasi hari dan tanggal, yang bermanfaat untuk memberikan kesan aplikasi yang responsif dan ramah pengguna. Di bawahnya terdapat *running ticker* (teks berjalan) yang menyajikan pergerakan harga saham-saham konstituen IDX30 secara langsung, bermanfaat agar pengguna dapat memantau kondisi pasar secara sekilas tanpa harus masuk ke halaman detail masing-masing saham. Selanjutnya tiga *bento card* menampilkan indeks IHSG beserta nilai dan persentase perubahan harian, total saham dalam *Watchlist*, dan *status Price alert*, yang bermanfaat sebagai ringkasan cepat (*at-a-glance summary*) kondisi portofolio pemantauan pengguna. Bagian bawah menampilkan tabel Saham Trending Teraktif dengan grafik tren mini, serta Panel Notifikasi terbaru di sisi kanan yang bermanfaat agar pengguna tidak melewatkan pergerakan harga yang telah menyentuh *target alert* yang telah ditetapkan.

4.1.4 Hasil Halaman *Screener Saham*

Hasil Dari Tampilan halaman *screener* saham dapat dilihat pada Gambar 4.4 di bawah ini.




Gambar 4. 4 Hasil Halaman *Screener Saham*

Gambar 4.4 menunjukkan halaman *screener* saham yang menampilkan judul halaman "*Screener Saham*" beserta bilah pencarian interaktif yang bermanfaat untuk menyaring saham secara cepat berdasarkan kode ticker atau nama emiten tanpa harus menggulir seluruh daftar. Terdapat menu seleksi (*drop-down*) pengurutan berdasarkan kriteria seperti *Potensi Return* (30 hari), Alfabet, Harga Saham, Perubahan Harga, Rasio PE, Price to Book (PB), dan Dividend Yield yang bermanfaat agar pengguna dapat menyesuaikan tampilan daftar saham sesuai strategi investasi masing-masing. Di bawahnya daftar saham ditampilkan dalam bentuk *grid* kartu dinamis yang menyajikan harga terkini, persentase perubahan harian, *sparkline* grafik historis singkat, indikator rasio keuangan utama, persentase *return* proyeksi AI, serta tombol aksi "Detail". Tampilan kartu yang informatif ini bermanfaat agar pengguna dapat membandingkan performa dan potensi berbagai emiten sekaligus dalam satu tampilan sebelum memutuskan untuk mengkaji lebih dalam.

4.1.5 Hasil Halaman Riset Emiten


Hasil Dari Tampilan halaman riset emiten dapat dilihat pada Gambar 4. 5 di bawah ini.



Gambar 4. 5 Hasil Halaman Riset Emiten

Gambar 4.5 menunjukkan halaman riset emiten yang menampilkan kolom pencarian emiten di bagian atas yang bermanfaat untuk memungkinkan pengguna langsung menuju saham yang ingin dianalisis tanpa navigasi berlapis. Setelah saham dipilih, halaman menampilkan kartu Informasi utama emiten yang menyajikan kode ticker, nama lengkap perusahaan, harga terkini, persentase perubahan harian, serta tombol "+ Watchlist" yang bermanfaat agar pengguna dapat langsung menambahkan emiten ke daftar pemantauan tanpa harus berpindah halaman. Di bawahnya terdapat visualisasi Grafik Harga & Proyeksi Prediksi AI dengan *filter* rentang waktu (1D, 1W, 1M, 3M, YTD, 1Y, 3Y, 5Y) yang menggambarkan garis historis harga saham berdampingan dengan garis putus-putus proyeksi masa depan, bermanfaat agar pengguna dapat memahami tren historis


sekaligus memvisualisasikan estimasi pergerakan harga ke depan dalam satu grafik terpadu. Kartu *Target Harga Prediksi AI 5 hari* turut ditampilkan, bermanfaat memberikan acuan harga *target* jangka pendek yang dapat digunakan pengguna sebagai pertimbangan keputusan beli atau jual. Tampilan hasil sub-halaman Riset Emiten bagian Key Stats dapat dilihat pada Gambar 4.6 di bawah ini.



Gambar 4. 6 Hasil Halaman Riset Emiten - Key Stats


Gambar 4.6 menunjukkan sub-halaman Riset Emiten bagian Key Stats yang menampilkan kompilasi data statistik dan metrik keuangan fundamental emiten secara *real-time* yang ditarik dari *Yahoo Finance*. Data tersebut ditampilkan dalam delapan kategori terstruktur, yaitu Valuasi (PE Ratio, Price to Sales, Price to Book,

Market Cap, Enterprise Value), Profitabilitas (Gross, Operating, dan Net Profit Margin, ROA, ROE), Solvabilitas (Current Ratio, Quick Ratio, Debt to Equity, Total Debt/Cash, Free Cash Flow), Dividen (Yield, Annual Dividend, Payout Ratio, EPS), Performa Harga (52-Week High/Low, 1M & YTD *Return*), Neraca Keuangan (Total Assets, Liabilities, Book Value), Laporan Laba Rugi (Revenue, Net Income, EBIT), dan Arus Kas (Cash from Operations, Capex). Pengelompokan data ke dalam kategori ini bermanfaat agar pengguna dapat mengevaluasi kesehatan finansial emiten secara menyeluruh dan sistematis, mulai dari nilai pasar, kemampuan menghasilkan laba, kemampuan membayar utang, hingga arus kas operasional, dalam satu halaman tanpa harus mencari data dari berbagai sumber terpisah. Tampilan hasil sub-halaman Riset Emiten bagian Faktor Prediksi dapat dilihat pada Gambar 4.7 di bawah ini.




Gambar 4. 7 Hasil Halaman Riset Emiten - Faktor Prediksi

Gambar 4.7 menunjukkan sub-halaman Riset Emiten bagian Faktor Prediksi yang menampilkan transparansi mengenai 12 fitur teknikal dan makroekonomi yang digunakan oleh model *Extra Trees* untuk menghasilkan estimasi *return* saham dalam 5 hari bursa ke depan. Fitur-fitur tersebut ditampilkan dalam tiga dimensi analisis, yaitu Tren & Momentum (Teknikal), Harga & Volatilitas (Teknikal), serta Kondisi Makroekonomi & Pasar. Setiap dimensi menampilkan *status* analisis secara dinamis berdasarkan data *real-time* dari *Yahoo Finance API* dan data makroekonomi terkini dari basis data sistem. Fitur ini bermanfaat untuk meningkatkan kepercayaan pengguna terhadap hasil prediksi AI dengan cara membuka "kotak hitam" model, sehingga pengguna tidak hanya menerima angka prediksi secara buta, melainkan juga dapat memahami faktor-faktor apa saja yang mendorong atau menghambat estimasi *return* tersebut. Tampilan hasil sub-halaman Riset Emiten bagian Rencana Investasi dapat dilihat pada Gambar 4.8 di bawah ini.



Gambar 4. 8 Hasil Halaman Riset Emiten - Rencana Investasi

Gambar 4.8 menunjukkan sub-halaman Riset Emiten bagian Rencana Investasi (Simulasi DCA) yang menampilkan kalkulator investasi interaktif. Panel kiri menampilkan *slider* untuk menyesuaikan nominal investasi per bulan, durasi jangka waktu investasi (3 hingga 60 bulan), dan kolom *input* tombol *return* tahunan (5%, 10%, 15%), yang bermanfaat agar pengguna dapat dengan mudah mengeksplorasi berbagai skenario investasi tanpa perlu menghitung secara manual. Panel kanan menampilkan hasil kalkulasi berupa estimasi nilai aset akhir, persentase keuntungan, total modal disetor, estimasi keuntungan bersih, *return* tahunan, dan estimasi lot akumulasi yang terkumpul. Hasil kalkulasi yang terperinci ini bermanfaat untuk membantu pengguna merencanakan strategi akumulasi saham jangka panjang dengan metode Dollar-Cost Averaging (DCA) berdasarkan kemampuan finansial dan *target* imbal hasil yang realistis. Tampilan hasil sub-halaman Riset Emiten bagian Profil Perusahaan dapat dilihat pada Gambar 4.9 di bawah ini.




Gambar 4. 9 Hasil Halaman Riset Emiten - Profil Perusahaan

Gambar 4.9 menunjukkan sub-halaman Riset Emiten bagian Profil Perusahaan yang menampilkan profil korporat dan latar belakang bisnis emiten yang disajikan dalam bahasa Indonesia, lengkap dengan tag kategori industri di bagian bawah. Penyajian profil dalam bahasa Indonesia ini bermanfaat untuk menurunkan hambatan literasi bagi pengguna yang belum terbiasa membaca laporan keuangan dalam bahasa Inggris, sehingga pemahaman terhadap model bisnis emiten dapat dicapai lebih cepat. Tag kategori industri bermanfaat agar pengguna dapat langsung mengidentifikasi sektor usaha emiten sebagai konteks tambahan dalam proses analisis fundamental.

4.1.6 Hasil Halaman *Watchlist*

Hasil Dari Tampilan halaman *watchlist* dapat dilihat pada Gambar 4. 10 di bawah ini.



SAHAMIQ Cari saham... mis. BBKA, Astra, Perbankan Andrian Fakhruza

Watchlist Saya
6 saham dipantau

Tambah saham... Alphabetical Kolom

SAHAM	PRICE	CHANGES	VALUE	LOT	OPEN	HIGH	LOW	P/E	P/B	DIVIDEN
ADRO Adaro Energy Indonesia	2.300	▲ +0.00%	38.6M	167.976	2.300	2.330	2.280	7.44x	13.53x	10.28%
ASII Astra International Tbk.	4.780	▼ -0.62%	147.9M	311.394	4.810	4.810	4.690	6.09x	0.82x	8.11%
BBCA Bank Central Asia	6.125	▲ +1.24%	903.3M	1.486.849	6.050	6.175	5.975	13.00x	2.90x	5.88%
BBRI Bank Rakyat Indonesia	2.790	▲ +2.95%	705.5M	2.574.730	2.710	2.790	2.680	7.17x	1.24x	15.42%
BMRI Bank Mandiri (Persero)	4.030	▲ +0.50%	573.2M	1.436.663	4.020	4.040	3.940	6.43x	1.23x	11.89%
ICBP Indofood CBP Sukses	6.925	▼ -0.36%	18.8M	27.105	6.950	7.000	6.900	8.83x	1.48x	3.81%

AKUN PENGATURAN KELOLA USER KELUAR


Gambar 4. 10 Hasil Halaman *Watchlist*

Gambar 4.10 menunjukkan halaman *watchlist* yang menampilkan antarmuka pemantauan khusus yang menyajikan Informasi jumlah saham terpantau,

kolom pencarian cepat untuk menambahkan saham baru, menu *dropdown* pengurutan (*sorting*), serta menu *dropdown* "Kolom" untuk mempersonalisasi metrik tabel yang ditampilkan. Fitur personalisasi kolom ini bermanfaat agar setiap pengguna dapat menyesuaikan tampilan data sesuai kebutuhan analisisnya masing-masing, tanpa harus melihat Informasi yang tidak relevan. Daftar saham terpantau disajikan dalam bentuk tabel dinamis yang memuat kolom nama saham, harga terkini, perubahan harga, penawaran bid/ask, nilai transaksi, volume lot, frekuensi perdagangan, harga rata-rata, harga penutupan sebelumnya, harga pembukaan, harga tertinggi dan terendah harian, indikator ARA/ARB, metrik PE/PB, pembagian dividen, dan tombol aksi hapus dari daftar. Kelengkapan data dalam satu tabel ini bermanfaat agar pengguna dapat memantau kondisi seluruh portofolio pemantauan secara komprehensif dalam satu tampilan terpusat tanpa perlu berpindah-pindah halaman untuk setiap emiten.

4.1.7 Hasil Halaman *Price alert*


Hasil Dari Tampilan halaman *price alert* dapat dilihat pada Gambar 4. 11 di bawah ini.

Gambar 4. 11 Hasil Halaman *Price alert*

Gambar 4.11 menunjukkan halaman *price alert* yang menampilkan pengelolaan notifikasi harga otomatis. Halaman ini menampilkan tombol "Tambah Alert Baru" untuk membuka modal *input* kondisi pemicu alert yang terdiri dari pilihan kode saham, kondisi matematis (*gte/lte*), nilai harga *target*, dan deskripsi catatan. Fitur konfigurasi kondisi ini bermanfaat agar pengguna dapat menetapkan titik harga pemicu secara fleksibel baik untuk skenario beli (harga turun ke *target*) maupun jual (harga naik ke *target*), sehingga pengguna tidak perlu memantau pergerakan harga secara manual sepanjang waktu. Di bawahnya terdapat tabel Alert Aktif yang berisi daftar peringatan berjalan lengkap dengan kolom kondisi, harga *target*, harga saat ini, *status* keaktifan, deskripsi, tanggal pembuatan, dan tombol aksi hapus, yang bermanfaat agar pengguna dapat mengelola seluruh peringatan harga yang sedang aktif dalam satu tampilan. Bagian paling bawah menampilkan log riwayat pemicu alert (*Alert Log*) yang bermanfaat sebagai catatan historis untuk evaluasi apakah strategi harga *target* yang ditetapkan sebelumnya telah akurat dan tepat waktu.


4.1.8 Hasil Halaman Pengaturan

Tampilan hasil halaman Pengaturan - Profil Pengguna dapat dilihat pada Gambar 4. 12 di bawah ini.



Gambar 4. 12 Hasil Halaman Pengaturan - Profil Pengguna

Gambar 4.12 menunjukkan sub-halaman pengaturan profil pengguna yang menampilkan antarmuka pembaruan data diri. Kolom kiri menampilkan visualisasi foto profil atau inisial pengguna dengan tombol unggah foto, nama lengkap, *email*, serta ringkasan jumlah *watchlist* dan alert aktif yang bermanfaat sebagai tampilan identitas pengguna sekaligus ringkasan aktivitas akun secara sekilas. Kolom kanan menampilkan *formulir* "Informasi Profil" yang terdiri dari kolom *input* nama lengkap, nama pengguna (*Username*), alamat *email*, serta tombol "Simpan Perubahan Profil" yang bermanfaat agar pengguna dapat memperbarui data identitas akun kapan saja tanpa harus menghubungi *Administrator* sistem. Tampilan hasil halaman Pengaturan - Keamanan dan Sandi dapat dilihat pada Gambar 4.13 di bawah ini.




Gambar 4. 13 Hasil Halaman Pengaturan - Keamanan dan Sandi

Gambar 4.13 menunjukkan sub-halaman pengaturan keamanan dan sandi yang menampilkan antarmuka penggantian kata sandi. Panel kiri menampilkan kolom *input Password Saat Ini*, *Password Baru* yang dilengkapi bilah kekuatan kata sandi, *Konfirmasi Password Baru*, serta tombol "*Ubah Password*". Persyaratan verifikasi *password* lama bermanfaat untuk memastikan hanya pemilik sah akun yang dapat melakukan perubahan kata sandi, sehingga akun terlindungi dari perubahan tidak sah. Panel kanan menampilkan kartu petunjuk kriteria kata sandi aman yang secara dinamis menampilkan indikator kepatuhan kata sandi baru, bermanfaat untuk memandu pengguna membuat kata sandi yang memenuhi standar keamanan tanpa harus menebak-nebak persyaratan yang berlaku.


4.1.9 Hasil Halaman Kelola User

Tampilan hasil halaman Kelola User - Manajemen Pengguna dapat dilihat pada Gambar 4. 14 di bawah ini.



Gambar 4. 14 Hasil Halaman Kelola *User* - Manajemen Pengguna

Gambar 4.14 menunjukkan halaman kelola *User* bagian manajemen pengguna yang menampilkan antarmuka *Administrasi* khusus *Admin* untuk memantau dan mengelola hak akses seluruh pengguna terdaftar. Halaman ini menampilkan tab navigasi *Administratif* (*Kelola User* dan *Upload Data Makro*) yang bermanfaat untuk memisahkan fungsi *Administrasi* pengguna dan *Administrasi* data dalam satu area *Admin* yang terorganisir. Tombol *refresh* tersedia untuk memperbarui data secara manual, serta tabel daftar pengguna terdaftar yang dilengkapi kolom *Nama*, *Username*, *Email*, pilihan pengubahan *Role* (*Admin/User*), *Tanggal Gabung*, dan tombol aksi hapus akun. Fitur pengubahan *role* secara langsung dari tabel ini bermanfaat agar *Administrator* dapat memberikan atau mencabut hak akses *Administratif* kepada pengguna tertentu dengan cepat tanpa perlu masuk ke panel konfigurasi yang lebih kompleks. Tampilan hasil halaman *Kelola User - Upload Data Makro* dapat dilihat pada Gambar 4.15 di bawah ini.



Gambar 4. 15 Hasil Halaman Kelola *User* - *Upload* Data Makro

Gambar 4.15 menunjukkan sub-halaman kelola *User* bagian *upload* data makro yang menampilkan antarmuka khusus *Admin* untuk memperbarui data indikator makroekonomi yang digunakan sebagai fitur *input* model prediksi AI. Halaman ini menampilkan tombol bantuan penggunaan yang bermanfaat sebagai panduan *format file* yang harus diunggah agar proses impor data berjalan tanpa kesalahan. Tersedia area kartu unggahan *file Excel* (.xlsx) dengan *dropzone* seret-dan-lepas untuk Data Inflasi dan Data BI Rate, yang bermanfaat untuk mempermudah proses pembaruan data makroekonomi tanpa memerlukan akses langsung ke basis data. Tombol *preview* baris data *Excel* bermanfaat agar *Administrator* dapat memverifikasi kebenaran isi *file* sebelum disimpan, serta tombol "Simpan ke *Database*" untuk memproses penyimpanan secara permanen sehingga data inflasi dan BI Rate yang digunakan model prediksi selalu mutakhir sesuai kondisi ekonomi terkini.

4.2 Preprocessing Data

Proses *preprocessing* data bertujuan untuk mengubah data mentah hasil pengumpulan data pada Bab III menjadi bentuk yang siap digunakan oleh model ExtraTrees dan *Gradient Boosting*, mengingat data harga saham, indeks pasar, dan makroekonomi memiliki satuan, rentang nilai, serta frekuensi observasi yang berbeda-beda. Subbab ini menjelaskan hasil implementasi tahapan rekayasa fitur, penggabungan dan pembersihan data, penanganan *outlier*, hingga pembagian dan standardisasi data.

4.2.1 Rekayasa Fitur Teknikal (*Feature engineering*)

Langkah pertama, seluruh fitur teknikal dihitung untuk setiap saham secara terpisah menggunakan fungsi `compute_features()`, meliputi fitur *lag return*, rasio harga terhadap *Moving Average*, rasio volume, RSI, dan *MACD*. Kode implementasi rekayasa fitur dapat dilihat pada Gambar 4.16 di bawah ini.

```
def compute_features(df_stock):
    """Hitung semua fitur teknikal untuk satu saham."""
    df = df_stock.sort_values('Date').copy()
    close = df['Close'].astype(float)

    # Return & Lag
    df['Return'] = close.pct_change()
    df['Lag1']   = df['Return'].shift(1)
```

```

df['Lag2']    = df['Return'].shift(2)

# Moving Averages (dipakai untuk hitung RASIO, bukan
langsung jadi fitur)

df['MA5']     = close.rolling(5).mean()
df['MA10']    = close.rolling(10).mean()
df['MA20']    = close.rolling(20).mean()

# Fitur rasio harga terhadap MA (pengganti Close
mentah)

df['Close_to_MA5'] = close / df['MA5']
df['Close_to_MA10'] = close / df['MA10']
df['Close_to_MA20'] = close / df['MA20']
# Volume Ratio (pengganti Volume mentah)
vol = df['Volume'].astype(float)
df['Volume_MA20'] = vol.rolling(20).mean()
df['Volume_Ratio'] = vol / df['Volume_MA20']

# RSI (14)
rsi = RSIIndicator(close=close, window=14)
df['RSI'] = rsi.rsi()

# MACD
macd_ind = MACD(close=close, window_slow=26,
window_fast=12, window_sign=9)

df['MACD'] = macd_ind.macd_diff() # MACD Histogram

return df

```

Gambar 4. 16 Kode Rekayasa Fitur Teknikal

Kode pada Gambar 4.16 dijalankan secara berulang untuk setiap saham melalui pengelompokan berdasarkan kolom *Stock*, sehingga perhitungan indikator teknikal tidak tercampur antar saham. Fungsi ini menghasilkan fitur *Lag1* dan *Lag2* sebagai representasi *return* pada satu dan dua hari bursa sebelumnya, fitur *Close_to_MA5*, *Close_to_MA10*, dan *Close_to_MA20* sebagai rasio harga penutupan terhadap rata-rata bergerak 5, 10, dan 20 hari, serta fitur *Volume_Ratio* sebagai rasio volume perdagangan harian terhadap rata-rata volume 20 hari. Fitur rasio ini dipilih menggantikan nilai *Close* dan *Volume* mentah karena bersifat lebih stasioner, sehingga model berbasis pohon keputusan tidak perlu melakukan ekstrapolasi terhadap rentang nilai baru yang tidak pernah ditemui pada data latih. Selain itu, dihitung pula indikator *RSI* periode 14 hari menggunakan *RSIIndicator* dan indikator *MACD* Histogram menggunakan *MACD* dari pustaka *ta*, dengan parameter *window_slow*=26, *window_fast*=12, dan *window_sign*=9 sesuai konfigurasi standar.

4.2.2 Penggabungan dan Pembersihan Data (*Data cleaning*)

Dataset digabungkan dengan data IHSG, kurs USD/IDR, inflasi, dan BI Rate berdasarkan kolom tanggal, setelah fitur teknikal dihitung. Selanjutnya dilakukan pembersihan data untuk menghapus nilai kosong pada fitur teknikal, menghapus data duplikat, serta menangani *outlier* pada kolom *Return*. Kode implementasi pembersihan data dapat dilihat pada Gambar 4.17 di bawah ini.

```

FEATURE_COLS = ['Volume_Ratio', 'Return', 'Lag1', 'Lag2',
                'Close_to_MA5',          'Close_to_MA10',
                'Close_to_MA20',
                'RSI', 'MACD',
                'USD_IDR_Return',
                'Inflation', 'BI_Rate']

ALL_COLS = list(dict.fromkeys(META_COLS + FEATURE_COLS +
                              ['Close']))

df_clean = df_merged[ALL_COLS].copy()

# Drop baris dengan NaN di fitur teknikal (wajar di awal
# deret waktu tiap saham)

tech_cols = ['Return', 'Lag1', 'Lag2', 'Close_to_MA5',
             'Close_to_MA10',
             'Close_to_MA20',          'RSI',          'MACD',
             'Volume_Ratio']

df_clean.dropna(subset=tech_cols, inplace=True)

# Hapus duplikat

df_clean.drop_duplicates(subset=['Date',          'Stock'],
                        inplace=True)

# Outlier handling (winsorize 1% - 99% pada Return harian)
q_low  = df_clean['Return'].quantile(0.01)
q_high = df_clean['Return'].quantile(0.99)

df_clean['Return'] = df_clean['Return'].clip(lower=q_low,
                                             upper=q_high)

```

Gambar 4. 17 Kode Pembersihan Data (*Data cleaning*)

Kode pada Gambar 4.17 pertama-tama menyeleksi kolom fitur yang benar-benar digunakan sebagai *input* model (FEATURE_COLS), lalu menghapus seluruh baris yang memiliki nilai kosong pada fitur-fitur teknikal menggunakan `dropna()`. Nilai kosong ini wajar muncul pada awal deret waktu setiap saham karena indikator seperti RSI dan *MACD* membutuhkan sejumlah observasi historis sebelum dapat dihitung. Selanjutnya, fungsi `drop_duplicates()` digunakan untuk menghapus baris data ganda berdasarkan kombinasi tanggal dan kode saham. Pada bagian akhir kode, teknik *Winsorizing* diterapkan pada kolom *Return* dengan memotong nilai yang berada di bawah persentil ke-1 dan di atas persentil ke-99 ke batas persentil tersebut menggunakan fungsi `clip()`, sehingga pengaruh nilai *return* yang ekstrem terhadap pelatihan model dapat diminimalkan tanpa harus mengurangi jumlah data.

4.2.3 Rekayasa *Target*, Split Data, dan Standardisasi

Tahap berikutnya adalah menghitung *target* penelitian berupa *return* kumulatif 5 hari bursa ke depan, membagi *dataset* menjadi data latih dan data uji berdasarkan cutoff tanggal, mengimputasi nilai kosong pada fitur makroekonomi, serta melakukan standardisasi fitur menggunakan `StandardScaler`. Keempat langkah ini penting dilakukan secara berurutan dan hati-hati, karena kesalahan urutan — misalnya mengimputasi atau menstandarisasi sebelum data dibagi menjadi data latih dan data uji — dapat menyebabkan kebocoran Informasi (*data leakage*) dari data uji ke proses pelatihan, sehingga hasil evaluasi model menjadi tidak objektif dan tidak merepresentasikan kondisi data yang benar-benar belum pernah dilihat model. Kode implementasi tahap ini dapat dilihat pada Gambar 4.18 di bawah ini.

```

HORIZON = 5 # 5 hari bursa ke depan

def add_horizon_target(group, horizon=HORIZON):
    """Hitung return kumulatif h hari ke depan: (Close[t+h]
    / Close[t]) - 1."""
    group = group.sort_values('Date').copy()
    close = group['Close'].astype(float)
    group[f'Return_{horizon}d'] = close.shift(-horizon) /
    close - 1
    return group

df_ml = df_clean.groupby('Stock',
group_keys=False).apply(add_horizon_target)
TARGET_COL = f'Return_{HORIZON}d'

df_ml = df_ml.dropna(subset=[TARGET_COL]).sort_values('Date').reset_index(drop=True)

X_COLS = ['Volume_Ratio', 'Lag1', 'Lag2',
          'Close_to_MA5', 'Close_to_MA10',
          'Close_to_MA20',
          'RSI', 'MACD',
          'USD_IDR_Return',
          'Inflation', 'BI_Rate']

# Split berdasarkan cutoff TANGGAL (bukan jumlah baris)
unique_dates = np.sort(df_ml['Date'].unique())
cutoff_date = unique_dates[int(len(unique_dates) * (1 -
TEST_SIZE))]

```

```

df_train_raw = df_ml[df_ml['Date'] < cutoff_date].copy()
df_test_raw  = df_ml[df_ml['Date'] >= cutoff_date].copy()

# Imputasi fitur makro memakai median dari data TRAINING
saja
macro_cols = ['USD_IDR_Return', 'Inflation', 'BI_Rate']
for col in macro_cols:
    train_median = df_train_raw[col].median()
    df_train_raw[col] = df_train_raw[col].fillna(train_median)
    df_test_raw[col] = df_test_raw[col].fillna(train_median)

X_train = df_train_raw[X_COLS].values
X_test  = df_test_raw[X_COLS].values
y_train = df_train_raw[TARGET_COL].values
y_test  = df_test_raw[TARGET_COL].values

# Scaling – fit di train saja, transform ke train & test
scaler      = StandardScaler()
X_train_sc = scaler.fit_transform(X_train)
X_test_sc  = scaler.transform(X_test)

```

Gambar 4. 18 Kode Rekayasa *Target*, Split Data, dan Standardisasi Fitur

Kode pada Gambar 4.18 pertama-tama mendefinisikan fungsi `add_horizon_target()` untuk menghitung *target Return_5d*, yaitu *return* kumulatif 5 hari bursa ke depan pada setiap saham. Baris data yang tidak memiliki nilai *target* (karena berada di ujung akhir deret waktu tiap saham) dihapus menggunakan

`dropna()`. Selanjutnya, seluruh tanggal unik pada *dataset* diurutkan dan ditentukan satu titik potong (`cutoff_date`) berdasarkan proporsi `TEST_SIZE`, sehingga data dengan tanggal sebelum `cutoff` menjadi data latih (`df_train_raw`) dan data dengan tanggal setelah `cutoff` menjadi data uji (`df_test_raw`). Pendekatan pembagian berbasis tanggal ini dipilih agar tidak ada satu tanggal observasi yang datanya terpecah antara data latih dan data uji.

Nilai kosong pada fitur makroekonomi (`USD_IDR_Return`, `Inflation`, `BI_Rate`) kemudian diimputasi menggunakan nilai *median* yang dihitung khusus dari data latih, lalu nilai *median* yang sama diterapkan pula pada data uji melalui `fillna()`, untuk mencegah kebocoran Informasi statistik dari data uji. Pada bagian akhir kode, seluruh fitur *input* distandardisasi menggunakan `StandardScaler`, di mana proses `fit_transform()` hanya dilakukan pada data latih, sedangkan data uji hanya melalui proses `transform()` menggunakan parameter mean dan standar deviasi yang telah dipelajari dari data latih.

4.3 Pengujian Sistem

Pengujian Sistem dilakukan dengan 2 cara yaitu pengujian *black box* dan pengujian *white box*.

4.3.1 Pengujian *Black box*

Pengujian *black box* dilakukan untuk memverifikasi bahwa seluruh fungsionalitas sistem berjalan sesuai dengan spesifikasi yang telah dirancang. Pengujian berfokus pada keluaran sistem berdasarkan *input* yang diberikan tanpa memperhatikan detail Hasil internal.

1. Pengujian Autentikasi

Pengujian ini merupakan bagian dari pengujian fungsional sistem yang bertujuan untuk memverifikasi bahwa modul autentikasi, mencakup proses registrasi, *login*, dan *logout*, berjalan sesuai dengan spesifikasi kebutuhan perangkat lunak yang telah ditetapkan. Pengujian dilakukan secara manual dengan total 9 skenario uji yang terbagi ke dalam tiga kelompok fungsionalitas utama, yaitu: registrasi akun baru, proses *login*, dan *logout*. Hasil pengujian dapat dilihat pada Tabel 4.1 dibawah ini.

Tabel 4. 1 *Black box* Autentikasi

No	Skenario Uji	<i>Input</i>	Hasil yang Diharapkan	<i>Status</i>
1	Registrasi akun baru dengan data lengkap dan valid	Nama, <i>Username</i> baru, <i>email</i> baru, <i>password</i> $\geq$ 8 karakter	Akun berhasil dibuat, notifikasi sukses muncul, otomatis <i>login</i> dan dialihkan ke <i>dashboard</i>	Berhasil
2	Registrasi dengan <i>email</i> tidak valid (tanpa @)	<i>Email</i> tanpa karakter @	<i>Browser</i> memunculkan validasi, <i>form</i> tidak terkirim	Berhasil
3	Registrasi dengan <i>password</i> kurang dari 8 karakter	<i>Password</i> : abc (< 8 karakter)	Pesan <i>error</i> " <i>Password</i> minimal 8 karakter" ditampilkan, submit dicegah	Berhasil
4	Registrasi dengan <i>Username</i> yang sudah terdaftar di <i>database</i>	<i>Username</i> yang sudah terdaftar di <i>database</i>	<i>Server</i> mengembalikan pesan <i>error</i> " <i>Username</i> sudah digunakan"	Berhasil

No	Skenario Uji	<i>Input</i>	Hasil yang Diharapkan	<i>Status</i>
	sudah digunakan			
5	Registrasi dengan <i>email</i> yang sudah digunakan	<i>Email</i> yang sudah terdaftar di <i>database</i>	<i>Server</i> mengembalikan pesan <i>error</i> " <i>Email</i> sudah terdaftar"	Berhasil
6	<i>Login</i> dengan <i>Username</i> dan <i>password</i> yang benar	<i>Username</i> dan <i>password</i> valid	<i>Login</i> berhasil, data disimpan di <i>localStorage</i> , dialihkan ke halaman <i>dashboard</i>	Berhasil
7	<i>Login</i> dengan <i>password</i> yang salah	<i>Username</i> benar, <i>password</i> salah	Pesan <i>error</i> " <i>Username</i> atau <i>password</i> salah" ditampilkan, sesi tidak dibuat	Berhasil
8	<i>Login</i> dengan semua field kosong	Semua field kosong	Pesan validasi <i>browser</i> muncul, submit dicegah	Berhasil

2. Pengujian Halaman Beranda & *Screener* Saham

Pengujian ini bertujuan memverifikasi fungsionalitas halaman beranda (*dashboard*) dan halaman *screener* saham, meliputi penampilan grafik tren pasar *real-time*, ticker IDX30, kelola notifikasi alert, *filter* pencarian emiten, dan penyortiran saham berdasarkan metrik tertentu. Pengujian dilakukan secara manual dengan total 8 skenario uji. Hasil pengujian dapat dilihat pada Tabel 4.2 dibawah ini.

Tabel 4. 2 Pengujian Halaman Beranda & *Screener* Saham

No	Skenario Uji	<i>Input</i>	Hasil yang Diharapkan	<i>Status</i>
1	Menampilkan data beranda secara <i>real-time</i>	<i>Login</i> berhasil dan diarahkan ke beranda	Running ticker bergerak menampilkan harga saham IDX30, data bento <i>card</i> (IHSG, <i>Watchlist</i> , Alert) terisi dari <i>API</i>	Berhasil
2	Menampilkan notifikasi alert terpicu di panel beranda	Alert harga menyentuh <i>target</i> batas di <i>database</i>	Notifikasi muncul di panel notifikasi beranda sebelah kanan	Berhasil
3	Menandai semua notifikasi dibaca	Klik tombol "Tandai Semua Dibaca"	Notifikasi beranimasi keluar (fade out), <i>status</i> di <i>database</i> diperbarui menjadi dibaca	Berhasil
4	Pencarian saham di navigasi utama	Memasukkan kode saham "BBCA"	<i>Dropdown</i> hasil pencarian navigasi menampilkan BBCA dengan harga terkini	Berhasil
5	Pencarian saham di halaman <i>Screener</i>	Kata kunci "ASII" pada kolom pencarian <i>screener</i>	Daftar saham tersaring secara <i>real-time</i> hanya menampilkan kartu saham ASII	Berhasil
6	Menyortir saham berdasarkan kriteria <i>return</i> 30 hari	Memilih opsi "Potensi <i>Return</i> (30 hari)" pada <i>dropdown screener</i>	Grid kartu saham terurut dari potensi <i>return</i> terbesar berdasarkan proyeksi model AI	Berhasil

No	Skenario Uji	<i>Input</i>	Hasil yang Diharapkan	<i>Status</i>
7	Menyortir saham berdasarkan Dividend Yield	Memilih opsi "Dividend Yield" pada <i>dropdown screener</i>	Grid kartu saham terurut berdasarkan persentase yield dividen tertinggi	Berhasil
8	Menekan tombol "Detail" pada kartu saham	Klik tombol "Detail" pada kartu saham BMRI	Halaman berpindah ke menu Riset Emiten untuk BMRI secara dinamis	Berhasil

3. Pengujian Halaman Riset Emiten & Prediksi AI

Pengujian ini bertujuan memverifikasi fungsionalitas halaman riset emiten yang memuat profil emiten, grafik historis dengan visualisasi prediksi AI, *target* harga proyeksi, metrik statistik fundamental, dimensi fitur prediksi, dan kalkulator simulasi investasi (DCA). Pengujian dilakukan secara manual dengan total 8 skenario uji. Hasil pengujian dapat dilihat pada Tabel 4.3 dibawah ini.

Tabel 4. 3 Pengujian Halaman Riset Emiten & Prediksi AI

No	Skenario Uji	<i>Input</i>	Hasil yang Diharapkan	<i>Status</i>
1	Memuat profil dan grafik emiten terpilih	Memilih saham BBKA di halaman Riset Emiten	Dhero info terisi, grafik historis harga digambar menggunakan <i>library</i> grafik	Berhasil
2	Mengubah <i>filter</i> rentang waktu grafik	Klik <i>filter</i> rentang waktu "1Y"	Chart memuat loading <i>overlay</i> , mengambil data 1 tahun dari <i>Yahoo Finance</i> , dan	Berhasil

No	Skenario Uji	Input	Hasil yang Diharapkan	Status
			memperbarui grafik harga	
3	Menampilkan proyeksi <i>target</i> harga AI	Membuka halaman Riset Emiten	Estimasi <i>return</i> 5 hari bursa dari model <i>Extra Trees</i> beserta <i>target</i> harga proyeksi ditampilkan pada kartu prediksi	Berhasil
4	Menampilkan metrik fundamental di tab Key Stats	Klik tab "Key Stats"	Seluruh data valuasi, profitabilitas, solvabilitas, dividen, performa harga, neraca, laba rugi, dan arus kas termuat lengkap	Berhasil
5	Menampilkan metrik fitur pada tab Faktor Prediksi	Klik tab "Faktor Prediksi"	12 fitur <i>input</i> model <i>Extra Trees</i> terbagi dalam 3 dimensi analisis (Tren & Momentum, Harga & Volatilitas, Kondisi Makroekonomi & Pasar) ditampilkan dengan <i>status</i> analisis dinamis berbasis data <i>real-time</i>	Berhasil
6	Melakukan simulasi investasi (DCA)	Menggeser <i>slider</i> durasi (12 bulan) dan nominal investasi	Hasil kalkulasi estimasi nilai akhir, keuntungan bersih, dan lot akumulasi ter-update otomatis	Berhasil

No	Skenario Uji	<i>Input</i>	Hasil yang Diharapkan	<i>Status</i>
		(Rp2.000.000/bulan)		
7	Menampilkan profil deskripsi perusahaan	Klik tab "Profil Perusahaan"	Deskripsi profil emiten dalam Bahasa Indonesia dan tag sektor industri tampil dengan benar	Berhasil
8	Menambahkan saham ke <i>watchlist</i> via tombol dhero	Klik tombol "+ <i>Watchlist</i> " pada kartu dhero emiten	Saham ditambahkan ke <i>watchlist</i> di <i>database</i> , tombol berubah menjadi "✓ <i>Watchlist</i> "	Berhasil

4. Pengujian Halaman *Watchlist* & *Price alert*

Pengujian ini bertujuan memverifikasi fungsionalitas halaman pemantauan *watchlist* (tabel dinamis, *filter* kolom kustom, hapus *watchlist*) dan manajemen *price alert* (*form input* alert, tabel alert aktif, log kejadian alert terpicu). Pengujian dilakukan secara manual dengan total 8 skenario uji. Hasil pengujian dapat dilihat pada Tabel 4.4 dibawah ini.

Tabel 4. 4 Pengujian Halaman *Watchlist* & *Price alert*

No	Skenario Uji	<i>Input</i>	Hasil yang Diharapkan	<i>Status</i>
1	Menampilkan tabel <i>watchlist</i> dinamis	Membuka halaman <i>Watchlist</i>	Menampilkan tabel saham terpantau dengan metrik harga teraktif, ARA/ARB, PE/PB	Berhasil

No	Skenario Uji	<i>Input</i>	Hasil yang Diharapkan	<i>Status</i>
2	Kustomisasi tampilan kolom tabel <i>watchlist</i>	Memilih/menghilangkan centang metrik di <i>dropdown</i> "Kolom"	Kolom tabel bertambah atau berkurang secara instan sesuai preferensi	Berhasil
3	Menghapus saham dari <i>watchlist</i>	Klik tombol "Hapus" pada baris saham TLKM	Saham terhapus dari <i>watchlist</i> di <i>database</i> dan baris tabel hilang	Berhasil
4	Membuka modal tambah alert baru	Klik tombol "Tambah Alert Baru"	Modal terbuka menampilkan <i>form input</i> saham, kondisi pemicu, harga <i>target</i> , dan catatan	Berhasil
5	Membuat alert baru dengan kondisi Naik di atas (gte)	<i>Input</i> saham: BBRI, kondisi: Naik di atas, harga: 5500	Alert tersimpan ke <i>database</i> dan muncul di tabel Alert Aktif	Berhasil
6	Pengujian validasi harga <i>target</i> kosong pada <i>form</i> alert	Klik "Buat Alert" tanpa mengisi harga <i>target</i>	<i>Form</i> memvalidasi <i>input</i> wajib diisi, submit dicegah	Berhasil
7	Menghapus alert aktif	Klik tombol "Hapus" pada baris alert aktif	Alert dihapus dari <i>database</i> , baris pada tabel Alert Aktif hilang	Berhasil

No	Skenario Uji	<i>Input</i>	Hasil yang Diharapkan	<i>Status</i>
8	Pemicu alert mendeteksi pergeseran harga saham	Harga <i>real-time</i> saham menyentuh <i>target</i> alert	<i>Status</i> alert berubah menjadi terpicu (<i>is_triggered=True</i>) dan dikirim ke log riwayat alert	Berhasil

5. Pengujian Halaman Pengaturan (Profil & Keamanan)

Pengujian ini bertujuan memverifikasi fungsionalitas halaman pengaturan profil (ubah data diri, unggah foto profil) dan halaman pengaturan keamanan (ganti kata sandi dengan verifikasi kriteria keamanan). Pengujian dilakukan secara manual dengan total 6 skenario uji. Hasil pengujian dapat dilihat pada Tabel 4.5 dibawah ini.

Tabel 4. 5 Pengujian Halaman Pengaturan

No	Skenario Uji	<i>Input</i>	Hasil yang Diharapkan	<i>Status</i>
1	Mengubah nama lengkap pengguna	Mengganti nama lengkap di <i>input</i> profil dan klik "Simpan Perubahan"	Nama berhasil diperbarui di <i>database</i> dan nama di <i>navbar</i> langsung berubah	Berhasil
2	Mengunggah foto profil baru	Pilih <i>file</i> gambar .jpg (< 2MB) pada tombol unggah foto	Foto berhasil diunggah, disimpan di <i>database</i> , dan avatar profil diperbarui	Berhasil
3	Mengunggah <i>file</i> foto profil	Pilih <i>file</i> gambar ukuran 3MB	Pesan <i>error</i> "Ukuran foto maksimal 2MB"	Berhasil

No	Skenario Uji	<i>Input</i>	Hasil yang Diharapkan	<i>Status</i>
	melebihi batas 2MB		ditampilkan, unggahan ditolak	
4	Mengubah <i>password</i> dengan <i>input</i> valid	<i>Password</i> saat ini benar, <i>password</i> baru 8 karakter, konfirmasi cocok	<i>Password</i> berhasil diubah di <i>database</i> , kolom dikosongkan	Berhasil
5	Mengubah <i>password</i> dengan konfirmasi tidak cocok	<i>Password</i> baru berbeda dengan konfirmasi <i>password</i>	Pesan <i>error</i> "Konfirmasi <i>password</i> baru tidak cocok!" muncul, perubahan dibatalkan	Berhasil
6	Mengubah <i>password</i> dengan kriteria tidak terpenuhi	<i>Password</i> baru kurang dari 8 karakter atau tanpa angka	Pesan kriteria di sisi kanan mendeteksi tanda silang, tombol "Ubah <i>Password</i> " membatalkan aksi	Berhasil

6. Pengujian Halaman Kelola *User & Data* Makro (*Admin*)

Pengujian ini bertujuan memverifikasi fungsionalitas manajemen pengguna oleh *Administrator*, kendali akses berbasis hak akses (*role-based access control*), serta pembaruan data indikator makroekonomi melalui berkas *Excel*. Pengujian dilakukan secara manual dengan total 7 skenario uji. Hasil pengujian dapat dilihat pada Tabel 4.6 dibawah ini.

Tabel 4. 6 Pengujian Halaman Kelola *User* & Data Makro

No	Skenario Uji	<i>Input</i>	Hasil yang Diharapkan	<i>Status</i>
1	Pengendalian akses halaman <i>Admin</i> (RBAC Guard)	<i>Login</i> sebagai pengguna biasa, coba akses menu kelola <i>User</i>	Menu kelola <i>User</i> disembunyikan, akses dibatasi hanya untuk <i>Admin</i>	Berhasil
2	Mengubah peran pengguna (<i>Role</i>)	Klik tombol "Jadikan <i>Admin</i> " pada salah satu <i>User</i> di tabel	Peran pengguna diperbarui menjadi <i>Admin</i> secara <i>real-time</i> di <i>database</i>	Berhasil
3	Menghapus akun pengguna lain	Klik tombol "Hapus" pada <i>User</i> terpilih dan konfirmasi	Pengguna terhapus dari tabel dan data <i>database</i> dibersihkan	Berhasil
4	<i>Admin</i> mencoba menghapus akun sendiri	Melihat tombol aksi pada akun <i>Admin</i> aktif di tabel	Tombol hapus dinonaktifkan (hanya bertuliskan "Anda (Aktif)") sehingga mencegah aksi hapus diri sendiri	Berhasil
5	Mengunggah data inflasi makroekonomi	Drop <i>file Excel</i> inflasi valid, klik "Simpan ke <i>Database</i> "	Data berhasil diurai (parsed), <i>preview</i> tabel data muncul, <i>database</i> ter-update	Berhasil
6	Mengunggah <i>file Excel</i> makroekonomi kosong atau rusak	Drop <i>file</i> dokumen kosong	Sistem memunculkan pesan peringatan kegagalan membaca <i>file</i>	Berhasil

No	Skenario Uji	Input	Hasil yang Diharapkan	Status
7	Menampilkan <i>preview</i> baris data sebelum disimpan	Setelah drop <i>file Excel</i> data BI Rate	Menampilkan <i>preview</i> 10 baris pertama data di tabel <i>preview</i> beserta total data	Berhasil

4.3.2 Pengujian *White box*

Pengujian *white box* dilakukan dengan menganalisis alur logika dan struktur kode pada proses inti sistem SmartSaham. Proses inti tersebut meliputi sistem autentikasi masuk (*login*), pendaftaran akun baru (*register*), proses inferensi dan prediksi *return* saham menggunakan model pembelajaran mesin (*Machine Learning*), validasi pencarian ticker saham IDX30, pengunggahan berkas data makro (inflasi & *BI Rate*) berbasis *Excel*, serta penambahan emiten ke dalam daftar pantau (*watchlist*). Setiap proses dianalisis jalur instruksinya melalui tabel potongan kode beserta alurnya, kemudian diverifikasi menggunakan skenario *test case* untuk menjamin seluruh percabangan logika berjalan secara valid.


a. Pengujian Whitebox Proses Inferensi & Prediksi Model *Machine Learning*

Pengujian ini menganalisis alur logika pada proses prediksi *return* saham pada fungsi *prediction()* di berkas *backend main.py*. Fungsi ini memiliki 3 *node* predikat yang menangani kasus model tidak tersedia, data historis tidak cukup, dan kegagalan pemanggilan *API* eksternal, sebelum meneruskan ke proses inferensi model *Extra Trees*. Berikut pseudocode pada fungsi prediksi.

Tabel 4. 7 Potongan Kode Proses Prediksi

<i>Node</i>	Potongan Kode
1	<code>def prediction(ticker, info=None, hist=None, usd_idr_return=None):</code>
2	<code>if ml_model is None or scaler is None:</code>
3	<code> return {"predicted_return_5d": None}</code>
4	<code>db = SessionLocal()</code>
5	<code>latest_inflation = db.query(InflationData)...first() latest_bi_rate = db.query(BIRateData)...first()</code>
6	<code>inflation_val = float(latest_inflation.value) if latest_inflation else 3.08 bi_rate_val = float(latest_bi_rate.value) if latest_bi_rate else 5.50</code>
7	<code>finally: db.close()</code>
8	<code>if hist is None:</code>
9	<code> hist = yf.Ticker(f'{ticker}.JK').history(period="3mo")</code>
10	<code>if hist.empty or len(hist) < 20:</code>
11	<code> return {"predicted_return_5d": None}</code>
12	<code># Kalkulasi 12 Fitur: Volume_Ratio, Lag1, Lag2, # Close_to_MA5/10/20, RSI, MACD, # USD_IDR_Return, Inflation, BI_Rate</code>
13	<code># NaN Imputation: if math.isnan(x): x = default_value</code>
14	<code>features_scaled = scaler.transform([features])</code>
15	<code>pred_decimal = float(ml_model.predict(features_scaled)[0])</code>
16	<code>predicted_return_5d = round(pred_decimal * 100, 2)</code>
17	<code>return {"predicted_return_5d": predicted_return_5d, "inflation": inflation_val, "bi_rate": bi_rate_val}</code>
18	<code>except Exception as e:</code>
19	<code> return {"predicted_return_5d": None, "inflation": 3.08, "bi_rate": 5.50}</code>
20	<code># End</code>

Flowgraph dibentuk berdasarkan pseudocode pada tabel di atas, dapat dilihat pada gambar berikut.



Gambar 4. 19 *Flowgraph* Proses Prediksi

Flow graph tersebut menjadi dasar perhitungan *cyclomatic complexity* menggunakan rumus: $V(G) = E - N + 2$

Di mana:

E = jumlah edge (panah/busur)

N = jumlah *node* (lingkaran)

$E = 23, N = 20$

Maka:

$$V(G) = 23 - 20 + 2 = 5$$

$V(G) = 5$, artinya terdapat 4 jalur independen yang harus diuji.

Jalur Pengujian (Independent Paths)

Jalur 1: $1 \rightarrow 2 \rightarrow 3 \rightarrow 20$

Jalur 2: $1 \rightarrow 2 \rightarrow 4 \rightarrow 5 \rightarrow 6 \rightarrow 7 \rightarrow 8 \rightarrow 10 \rightarrow 11 \rightarrow 20$

Jalur 3: $1 \rightarrow 2 \rightarrow 4 \rightarrow 5 \rightarrow 6 \rightarrow 7 \rightarrow 8 \rightarrow 9 \rightarrow 10 \rightarrow 12 \rightarrow 13 \rightarrow 14 \rightarrow 15 \rightarrow 16$
 $\rightarrow 17 \rightarrow 20$

Jalur 4: 1 → 2 → 4 → 5 → 6 → 7 → 8 → 9 → 18 → 19 → 20

Tabel 4. 8 Test Case Skenario Proses Prediksi

Jalur	Input	Alur Jalur (Process)	Hasil (Output)	Status
1	Berkas extratrees_model_5d.p kl atau scaler_5d.pkl tidak ditemukan saat startup <i>server</i> , sehingga variabel ml_model atau scaler bernilai None.	1 → 2 → 3 → 20	{"predicted_return_ 5d": None}	Valid
2	Model dan scaler berhasil dimuat. Data makro tersedia di DB. Riwayat harga historis yang diterima fungsi kosong atau kurang dari 20 baris (emiten baru IPO).	1 → 2 → 4 → 5 → 6 → 7 → 8 → 10 → 11 → 20	{"predicted_return_ 5d": None}	Valid
3	Model, scaler, dan data makro berhasil disiapkan. Riwayat harga ≥ 20 baris. Seluruh 12 fitur teknikal dan makroekonomi berhasil diekstraksi, diimputasi, dan	1 → 2 → 4 → 5 → 6 → 7 → 8 → 9 → 10 → 12 → 13 → 14 → 15 → 16 → 17 → 20	{"predicted_return_ 5d": 2.34, "inflation": 3.12, "bi_rate": 5.75}	Valid

Jalur	Input	Alur Jalur (Process)	Hasil (Output)	Status
	diskalakan. Model berhasil menghasilkan nilai prediksi.			
4	Model dan scaler tersedia. Terjadi masalah koneksi jaringan atau rate limiting saat memanggil <code>yf.Ticker().history()</code> . Exception ditangkap oleh blok <code>except</code> .	1 → 2 → 4 → 5 → 6 → 7 → 8 → 9 → 18 → 19 → 20	<code>{"predicted_return_5d": None, "inflation": 3.08, "bi_rate": 5.50}</code>	Valid

4.4 Hasil Skenario Pengujian *Tuning*

Bagian ini menampilkan hasil pengujian *hyperparameter tuning* yang dilakukan melalui empat skenario, yaitu kombinasi antara rentang parameter (sempit dan lebar) dengan metode pencarian (*Grid search* dan *Randomized Search*). Setiap skenario dievaluasi menggunakan data uji yang sama sekali belum pernah dilihat model selama proses pelatihan, dengan tiga visualisasi yang membandingkan ExtraTrees dan *Gradient Boosting* secara langsung, yaitu perbandingan metrik R^2 , *RMSE*, dan *MAE*, grafik *Actual vs predicted*, serta grafik *Feature importance*. Hasil keempat skenario tersebut dirangkum ke dalam satu tabel ringkasan gabungan setelah dibahas satu per satu, untuk melihat kombinasi model dan skenario mana yang memberikan performa terbaik, sekaligus menentukan model akhir yang akan disimpan untuk tahap implementasi selanjutnya.

4.4.1 Skenario A - *Grid search* (Sempit)

Skenario A menerapkan pencarian *hyperparameter* menggunakan *Grid search* dengan rentang parameter sempit (konservatif), sebagaimana telah dijelaskan pada Tabel 3.16 dan Tabel 3.17. Hasil pencarian menunjukkan kombinasi *hyperparameter* terbaik untuk model ExtraTrees disajikan pada Tabel 4.9, dan untuk model *Gradient Boosting* pada Tabel 4.10.

Tabel 4. 9 Kombinasi *Hyperparameter* Terbaik ExtraTrees


No	<i>Hyperparameter</i>	Rentang Parameter
1	max_depth	5
2	min_samples_leaf	20
3	n_estimators	200

Tabel 4. 10 Kombinasi *Hyperparameter* Terbaik *Gradient Boosting*

No	<i>Hyperparameter</i>	Rentang Parameter
1	<i>learning_rate</i>	0,03
2	max_depth	2
3	n_estimators	100

a. Perbandingan R^2 , *RMSE*, dan *MAE*

Grafik berikut membandingkan langsung nilai R^2 , *RMSE*, dan *MAE* kedua model pada data uji untuk Skenario A.




Gambar 4. 20 Perbandingan Metrik R^2 , $RMSE$, MAE

Hasil pengujian menunjukkan nilai $RMSE$ dan MAE kedua model relatif setara, dengan ExtraTrees sedikit lebih rendah ($RMSE=0,065754$; $MAE=0,046126$) dibanding *Gradient Boosting* ($RMSE=0,066349$; $MAE=0,046308$). Nilai R^2 kedua model sama-sama berada di bawah nol, yaitu -0,0073 untuk ExtraTrees dan -0,0256 untuk *Gradient Boosting*, yang berarti kedua model belum berhasil menjelaskan pergerakan *return* dengan baik pada skenario ini, meski ExtraTrees sedikit lebih baik.

b. *Actual vs predicted*

Grafik berikut membandingkan angka *return* sebenarnya (*Actual*) dengan hasil tebakan (*Predicted*) kedua model pada data uji, dengan garis putus-putus sebagai garis Perfect Fit.




Gambar 4. 21 *Actual vs predicted*

Titik-titik hasil tebakan kedua model terlihat mengumpul di sekitar angka nol dan belum mengikuti garis Perfect Fit dengan rapi, menunjukkan bahwa baik ExtraTrees maupun *Gradient Boosting* cenderung menebak angka yang aman di sekitar rata-rata, alih-alih menangkap arah pergerakan *return* yang sebenarnya.

c. Feature importance

Grafik berikut menampilkan fitur-fitur yang paling berpengaruh terhadap prediksi kedua model pada Skenario A.



Gambar 4. 22 *Feature importance*

Kedua model cenderung mengandalkan fitur teknikal yang sama, seperti rasio harga terhadap rata-rata bergerak dan RSI, sebagai fitur dengan kontribusi tertinggi, sementara fitur makroekonomi berperan lebih kecil dalam kedua model.

4.4.2 Skenario B - *Grid search* (Lebar)

Skenario B menerapkan pencarian *hyperparameter* menggunakan *Grid search* dengan rentang parameter lebar, sebagaimana telah dijelaskan pada Tabel

3.16 dan Tabel 3.17. Hasil pencarian menunjukkan kombinasi *hyperparameter* terbaik untuk model ExtraTrees disajikan pada Tabel 4.11, dan untuk model *Gradient Boosting* pada Tabel 4.12.

Tabel 4. 11 Kombinasi *Hyperparameter* Terbaik ExtraTrees


No	<i>Hyperparameter</i>	Rentang Parameter
1	max_depth	3
2	max_features	sqrt
3	min_samples_leaf	20
4	min_samples_split	10
5	n_estimators	300

Tabel 4. 12 Kombinasi *Hyperparameter* Terbaik *Gradient Boosting*

No	<i>Hyperparameter</i>	Rentang Parameter
1	<i>learning_rate</i>	0,01
2	max_depth	2
3	min_samples_split	10
4	n_estimators	100
5	<i>subsample</i>	0,7

a. Perbandingan R^2 , *RMSE*, dan *MAE*

Grafik berikut membandingkan langsung nilai R^2 , *RMSE*, dan *MAE* kedua model pada data uji untuk Skenario B.




Gambar 4. 23 Perbandingan Metrik R^2 , $RMSE$, MAE

Hasil pengujian menunjukkan nilai $RMSE$ dan MAE kedua model relatif setara, yaitu $RMSE=0,065851$ dan $MAE=0,046031$ untuk ExtraTrees, dibanding $RMSE=0,065932$ dan $MAE=0,046125$ untuk *Gradient Boosting*. Nilai R^2 kedua model sama-sama berada di bawah nol, yaitu -0,0103 untuk ExtraTrees dan -0,0128 untuk *Gradient Boosting*, sedikit lebih rendah dibanding Skenario A, yang berarti memperlebar rentang pencarian pada *Grid search* belum tentu menghasilkan performa yang lebih baik pada kasus ini.

b. *Actual vs predicted*

Grafik berikut membandingkan angka *return* sebenarnya (*Actual*) dengan hasil tebakan (*Predicted*) kedua model pada data uji, dengan garis putus-putus sebagai garis Perfect Fit.




Gambar 4. 24 *Actual vs predicted*

Pola yang muncul serupa dengan Skenario A, yaitu titik-titik tebakan kedua model masih mengumpul di sekitar angka nol dan belum mengikuti garis Perfect Fit dengan baik, menunjukkan bahwa perluasan rentang parameter tidak serta-merta memperbaiki kemampuan model dalam menangkap arah pergerakan *return* yang sebenarnya.

c. Feature importance

Grafik berikut menampilkan fitur-fitur yang paling berpengaruh terhadap prediksi kedua model pada Skenario B.



Gambar 4. 25 *Feature importance*

Kedua model masih konsisten mengandalkan fitur teknikal, seperti rasio harga terhadap rata-rata bergerak dan RSI, sebagai fitur dengan kontribusi tertinggi, dengan urutan tingkat kepentingan yang relatif mirip dengan Skenario A.

4.4.3 Skenario C - *Randomized Search* (Sempit)

Skenario C menerapkan pencarian *hyperparameter* menggunakan *Randomized Search* dengan rentang parameter sempit (konservatif), sebagaimana

telah dijelaskan pada Tabel 3.16 dan Tabel 3.17. Hasil pencarian menunjukkan kombinasi *hyperparameter* terbaik untuk model ExtraTrees disajikan pada Tabel 4.13, dan untuk model *Gradient Boosting* pada Tabel 4.14.

Tabel 4. 13 Kombinasi *Hyperparameter* Terbaik ExtraTrees


No	<i>Hyperparameter</i>	Rentang Parameter
1	n_estimators	200
2	min_samples_leaf	20
3	max_depth	5

Tabel 4. 14 Kombinasi *Hyperparameter* Terbaik *Gradient Boosting*

No	<i>Hyperparameter</i>	Rentang Parameter
1	n_estimators	100
2	max_depth	2
3	<i>learning_rate</i>	0,03

a. Perbandingan R^2 , *RMSE*, dan *MAE*

Grafik berikut membandingkan langsung nilai R^2 , *RMSE*, dan *MAE* kedua model pada data uji untuk Skenario C.




Gambar 4. 26 Perbandingan Metrik R^2 , $RMSE$, MAE

Hasil pengujian menunjukkan nilai $RMSE$, MAE , dan R^2 kedua model pada Skenario C identik dengan Skenario A ($RMSE=0,065754$ dan $R^2=-0,0073$ untuk ExtraTrees; $RMSE=0,066349$ dan $R^2=-0,0256$ untuk *Gradient Boosting*). Hal ini terjadi karena rentang parameter sempit hanya memiliki sedikit kombinasi yang mungkin, sehingga *Randomized Search* yang mencoba sejumlah kombinasi acak berhasil menemukan kombinasi terbaik yang sama persis dengan yang ditemukan *Grid search* pada Skenario A.

b. *Actual vs predicted*

Grafik berikut membandingkan angka *return* sebenarnya (*Actual*) dengan hasil tebakan (*Predicted*) kedua model pada data uji, dengan garis putus-putus sebagai garis Perfect Fit.




Gambar 4. 27 *Actual vs predicted*

Pola sebaran titik yang dihasilkan juga serupa dengan Skenario A karena kombinasi *hyperparameter* yang terpilih identik, yaitu tebakan kedua model masih mengumpul di sekitar angka nol dan belum mengikuti garis Perfect Fit dengan baik.

c. *Feature importance*

Grafik berikut menampilkan fitur-fitur yang paling berpengaruh terhadap prediksi kedua model pada Skenario C.



Gambar 4. 28 *Feature importance*

Urutan dan besar kontribusi fitur pada Skenario C juga sama dengan Skenario A, sejalan dengan hasil metrik yang identik, dengan fitur teknikal seperti rasio harga terhadap rata-rata bergerak dan RSI tetap menjadi fitur paling berpengaruh pada kedua model.

4.4.4 Skenario D - *Randomized Search* (Lebar)

Skenario D menerapkan pencarian *hyperparameter* menggunakan *Randomized Search* dengan rentang parameter lebar. Hasil pencarian menunjukkan kombinasi *hyperparameter* terbaik untuk model ExtraTrees disajikan pada Tabel 4.15, dan untuk model *Gradient Boosting* pada Tabel 4.16.

Tabel 4. 15 Kombinasi *Hyperparameter* Terbaik ExtraTrees


No	<i>Hyperparameter</i>	Rentang Parameter
1	max_depth	3
2	max_features	log2
3	min_samples_leaf	20
4	min_samples_split	10
5	n_estimators	300

Tabel 4. 16 Kombinasi *Hyperparameter* Terbaik Gradient Boosting

No	<i>Hyperparameter</i>	Rentang Parameter
1	<i>learning_rate</i>	0,01
2	max_depth	2
3	min_samples_split	10
4	n_estimators	100
5	<i>subsample</i>	0,7

a. Perbandingan R^2 , $RMSE$, dan MAE

Grafik berikut membandingkan langsung nilai R^2 , $RMSE$, dan MAE kedua model pada data uji untuk Skenario D.




Gambar 4. 29 Perbandingan Metrik R^2 , $RMSE$, MAE

Hasil pengujian menunjukkan nilai $RMSE$, MAE , dan R^2 kedua model pada Skenario D identik dengan Skenario B ($RMSE=0,065851$ dan $R^2=-0,0103$ untuk ExtraTrees; $RMSE=0,065932$ dan $R^2=-0,0128$ untuk *Gradient Boosting*). Hal ini menunjukkan bahwa *Randomized Search* dengan sejumlah kombinasi acak berhasil menemukan kombinasi *hyperparameter* terbaik yang sama persis dengan yang ditemukan *Grid search* pada rentang lebar, meskipun tidak mencoba seluruh kombinasi yang ada seperti *Grid search*.

b. *Actual vs predicted*

Grafik berikut membandingkan angka *return* sebenarnya (*Actual*) dengan hasil tebakan (*Predicted*) kedua model pada data uji, dengan garis putus-putus sebagai garis Perfect Fit.




Gambar 4. 30 *Actual vs predicted*

Pola sebaran titik yang dihasilkan juga serupa dengan Skenario B karena kombinasi *hyperparameter* yang terpilih identik, yaitu tebakan kedua model masih mengumpul di sekitar angka nol dan belum mengikuti garis Perfect Fit dengan baik.

c. Feature importance

Grafik berikut menampilkan fitur-fitur yang paling berpengaruh terhadap prediksi kedua model pada Skenario D.



Gambar 4. 31 *Feature importance*

Urutan dan besar kontribusi fitur pada Skenario D juga sama dengan Skenario B, sejalan dengan hasil metrik yang identik, dengan fitur teknikal seperti rasio harga terhadap rata-rata bergerak dan RSI tetap menjadi fitur paling berpengaruh pada kedua model.

4.4.5 Ringkasan Perbandingan Seluruh Skenario

Hasil evaluasi keempat skenario dirangkum ke dalam tabel ringkasan gabungan untuk memudahkan perbandingan performa lintas skenario, dipisahkan untuk model ExtraTrees pada Tabel 4.17 dan model *Gradient Boosting* pada Tabel 4.18.

Tabel 4. 17 Ringkasan Perbandingan Seluruh Skenario - ExtraTrees

No	Skenario	<i>RMSE</i>	<i>MAE</i>	R^2	Waktu (detik)
1	A - <i>Grid search</i> (Sempit)	0,065754	0,046126	-0,0073	6,9
2	C - <i>Randomized Search</i> (Sempit)	0,065754	0,046126	-0,0073	2,2
3	B - <i>Grid search</i> (Lebar)	0,065851	0,046031	-0,0103	9,4
4	D - <i>Randomized Search</i> (Lebar)	0,065851	0,046031	-0,0103	21,5

Tabel 4. 18 Ringkasan Perbandingan Seluruh Skenario - *Gradient Boosting*

No	Skenario	<i>RMSE</i>	<i>MAE</i>	R^2	Waktu (detik)
1	B - <i>Grid search</i> (Lebar)	0,065932	0,046125	-0,0128	60,7
2	D - <i>Randomized Search</i> (Lebar)	0,065932	0,046125	-0,0128	41,1

No	Skenario	<i>RMSE</i>	<i>MAE</i>	R^2	Waktu (detik)
3	A - <i>Grid search</i> (Sempit)	0,066349	0,046308	-0,0256	11,1
4	C - <i>Randomized</i> Search (Sempit)	0,066349	0,046308	-0,0256	29,4

Kedua tabel menunjukkan bahwa model *ExtraTrees* mencapai R^2 terbaik pada Skenario A dan C ($R^2=-0,0073$), sedangkan model *Gradient Boosting* mencapai R^2 terbaik pada Skenario B dan D ($R^2=-0,0128$), keduanya dengan kombinasi *hyperparameter* identik meski metode pencariannya berbeda. Pola ini menunjukkan bahwa ruang pencarian sempit sudah cukup mewakili kombinasi *hyperparameter* optimal untuk kasus penelitian ini.

Randomized Search menunjukkan waktu komputasi yang konsisten lebih cepat dibanding *Grid Search* pada rentang lebar (41,1 detik vs 60,7 detik untuk *Gradient Boosting*), sedangkan pada rentang sempit selisih waktu kedua metode tidak signifikan. Namun, seluruh nilai R^2 pada kedelapan kombinasi model dan skenario tetap berada di bawah nol, yang berarti baik *ExtraTrees* maupun *Gradient Boosting* belum mampu menjelaskan pergerakan *return* saham IDX30 dalam horizon 5 hari bursa ke depan dengan baik.

BAB V

PENUTUP

5.1 Simpulan

Beberapa simpulan dapat ditarik berdasarkan hasil implementasi, pengujian, dan evaluasi model prediksi *Return* saham IDX30 menggunakan algoritma *Extremely Randomized Trees (ExtraTrees)* dan *Gradient Boosting* yang telah dijabarkan pada Bab IV, sebagai berikut.

1. Algoritma *Extremely Randomized Trees* memprediksi *Return* kumulatif 5 hari bursa ke depan pada saham-saham IDX30 dengan hasil terbaik pada Skenario A dan C, yaitu *RMSE* sebesar 0,065754, *MAE* sebesar 0,046126, dan R^2 sebesar -0,0073 pada data uji. Nilai R^2 yang negatif menunjukkan bahwa model belum mampu menjelaskan variansi pergerakan *Return* dengan baik, bahkan performanya sedikit lebih buruk dibandingkan jika hanya menebak nilai rata-rata *Return* saja, meskipun telah melalui proses *hyperparameter tuning* dengan berbagai skenario rentang parameter dan metode pencarian. Hal ini menjawab rumusan masalah pertama, yaitu bahwa tingkat akurasi kedua algoritma dalam memprediksi *Return* saham IDX30 masih tergolong rendah apabila hanya mengandalkan indikator teknikal dan data makroekonomi.
2. Algoritma *Gradient Boosting* menghasilkan performa terbaik pada Skenario B dan D, yaitu *RMSE* sebesar 0,065932, *MAE* sebesar 0,046125, dan R^2 sebesar -0,0128 pada data uji. Ketika dibandingkan dengan model *ExtraTrees* terbaik, *Gradient Boosting* menunjukkan performa yang sedikit lebih rendah dari sisi R^2 , meski selisih *RMSE* dan *MAE* antara kedua model tergolong tipis. Dari sisi

efisiensi komputasi, *Randomized Search* juga terbukti lebih efisien dibandingkan *Grid search* pada rentang parameter yang lebar, tanpa kehilangan kualitas kombinasi *hyperparameter* yang ditemukan. Dengan demikian, menjawab rumusan masalah kedua, algoritma *ExtraTrees* terbukti sedikit lebih unggul dibandingkan *Gradient Boosting* dari segi akurasi prediksi, meskipun selisih performa antar kedua model relatif kecil di seluruh skenario yang diuji.

3. Nilai R^2 negatif yang diperoleh kedua model bukan disebabkan oleh kesalahan implementasi, melainkan mencerminkan karakteristik pasar saham yang sulit diprediksi dalam jangka pendek (*Short-term Market Efficiency*), terutama setelah metodologi penelitian ini dikoreksi untuk menghindari kebocoran data (*Data leakage*) melalui pembagian data berbasis waktu (*Time-based split*) dan penghapusan *Look-ahead Bias* pada proses imputasi data makroekonomi. Temuan ini konsisten dengan hasil penelitian Gu, Kelly, dan Xiu (2020) yang juga melaporkan R^2 *Out-of-sample* yang sangat rendah, bahkan mendekati nol, pada horizon prediksi *Return* saham jangka pendek menggunakan metode *Machine Learning*.
4. Analisis *feature importance* pada kedua model menunjukkan bahwa fitur-fitur teknikal, khususnya rasio harga terhadap *Moving Average* dan *Relative Strength Index* (RSI), memberikan kontribusi yang lebih besar terhadap prediksi dibandingkan fitur makroekonomi seperti inflasi dan BI Rate. Hal ini wajar terjadi karena fitur makroekonomi bernilai identik untuk seluruh saham pada tanggal yang sama, sehingga kurang mampu membedakan pergerakan

Return antar saham dibandingkan fitur teknikal yang bersifat spesifik untuk masing-masing saham.

5.2 Saran

Berdasarkan simpulan yang telah dipaparkan, terdapat beberapa keterbatasan dalam penelitian ini yang dapat menjadi bahan pertimbangan bagi penelitian selanjutnya, yaitu sebagai berikut.

1. Penelitian selanjutnya disarankan untuk menambahkan variasi fitur lain di luar indikator teknikal dan data makroekonomi yang digunakan pada penelitian ini, misalnya data fundamental emiten, sentimen berita, maupun data dari media sosial, guna menguji apakah penambahan jenis variabel tersebut dapat meningkatkan kemampuan model dalam menjelaskan pergerakan *return* saham.
2. Penelitian selanjutnya dapat mencoba horizon prediksi yang lebih panjang (misalnya 20 hari bursa), untuk melihat apakah tingkat akurasi model berubah signifikan seiring perubahan horizon waktu prediksi.
3. Penelitian selanjutnya disarankan untuk mengeksplorasi algoritma lain di luar ExtraTrees dan *Gradient Boosting*, seperti model deep learning berbasis deret waktu (misalnya *LSTM* atau Temporal Fusion Transformer), untuk dibandingkan performanya dengan kedua algoritma *ensemble learning* berbasis pohon yang digunakan pada penelitian ini.
4. Penelitian selanjutnya disarankan untuk menerapkan skema validasi silang berbasis deret waktu (*time series cross-validation*), alih-alih *k-fold cross-validation* konvensional yang digunakan pada penelitian ini, serta

mengeksplorasi metode *tuning* yang lebih canggih seperti Bayesian Optimization, agar pencarian *hyperparameter* dapat lebih merepresentasikan karakteristik data deret waktu dan berpotensi menemukan kombinasi yang lebih optimal.

5. Bagi pengembangan sistem SmartSaham selanjutnya, disarankan untuk menambahkan mekanisme pembaruan model (model *retraining*) secara berkala menggunakan data pasar terbaru, mengingat kondisi pasar saham yang terus berubah dari waktu ke waktu sehingga model yang bersifat statis berisiko mengalami penurunan akurasi (model drift) apabila tidak diperbarui secara berkala.

DAFTAR PUSTAKA

- [1] F. F. Rachman, “Masuk Saham Tak Cukup Modal, Investor Perlu Paham Proses dan Risiko,” *finance.detik.com*. Accessed: Aug. 05, 2026. [Online]. Available: <https://finance.detik.com/portofolio/d-8339417/masuk-saham-tak-cukup-modal-investor-perlu-paham-proses-dan-risiko>
- [2] A. I. Reni Susanti, “Praktisi Saham Ingatkan Investor Pemula Tak Tergoda Untung Instan,” *kompas.com*. Accessed: Aug. 05, 2026. [Online]. Available: <https://money.kompas.com/read/2026/02/03/090557126/praktisi-saham-ingatkan-investor-pemula-tak-tergoda-untung-instan>
- [3] P. Studi, M. Fakultas, U. Indo, and G. Mandiri, “Analisis Perilaku Investor dalam Pengambilan Keputusan Investasi di Pasar Modal Pada Era Vuca,” vol. 3, no. 3, pp. 40–52, 2024.
- [4] J. Budiman, R. Limgestu, and I. T. Sagianto, “Perilaku keputusan investasi investor pasar saham Indonesia,” vol. 5, no. 9, pp. 3518–3526, 2023.
- [5] R. Satria, “*BEHAVIORAL FINANCE FACTORS AND INVESTMENT DECISIONS IN*,” vol. 8, no. 1, pp. 2221–2241, 2025.
- [6] Z. A. Mohammad, “*How Ensemble learning Balances Accuracy and Overfitting : A Bias – Variance Perspective on Tabular Data*”.
- [7] N. Cakici and A. Zarembo, “Empirical Asset Pricing via Machine Learning : The Global Edition,” vol. 33, no. 0, pp. 1–79.
- [8] W. Drobetz and T. Otto, *Empirical Asset Pricing via Machine Learning : evidence from the European stock market*, vol. 22, no. 7. Palgrave Macmillan UK, 2021. doi: 10.1057/s41260-021-00237-x.
- [9] T. Informatika and U. Asahan, “Tinjauan Algoritma *Machine Learning* untuk Prediksi Harga Saham : Studi Literatur,” vol. 1, no. 7, pp. 608–613, 2024.
- [10] S. Gu and B. Kelly, “No Title,” 2019.
- [11] R. Wahyudi *et al.*, “Optimasi seleksi fitur prediksi saham menggunakan *quantum inspired metaheuristic* dan *lightgbm*,” vol. 13, no. 1, 2026.
- [12] H. T. Nhon, N. Do-thi, and T. Nguyen-trang, “*Predicting stock returns using machine analysis and automatic feature engineering : A case study on the*

- Vietnamese stock market,”* pp. 1–16, 2025, doi: 10.1371/journal.pone.0332154.
- [13] T. Xue, “*Research on Machine Learning Based Stock Price prediction Model,*” no. Emiti, pp. 209–215, 2025, doi: 10.5220/0014325100004718.
 - [14] S. H. Setiyani and Y. Rahma, “SAHAM MENGGUNAKAN *QUANTUM MACHINE LEARNING,*” vol. 13, no. 3, pp. 1705–1715.
 - [15] J. Zheng, “*The Random Forest Model for Analyzing and Forecasting the US Stock Market in the Context of Smart Finance,*” pp. 1–10.
 - [16] S. Mohapatra, R. Mukherjee, A. Roy, A. Sengupta, and A. Puniyani, “*Can ensemble Machine Learning methods predict stock returns for Indian banks using technical indicators ? Can Ensemble Machine Learning Methods Predict Stock Returns for Indian Banks Using Technical indicators ?,*” 2022.
 - [17] M. Chen and M. X. Hanauer, “*Design choices , Machine Learning , and the cross-section of stock returns,*” 2026.
 - [18] S. Anastassia *et al.*, “*Comparing Machine Learning models for Indonesia stock market prediction,*” vol. 38, no. 1, pp. 508–516, 2025, doi: 10.11591/ijeecs.v38.i1.pp508-516.
 - [19] D. C. Kho and H. D. Purnomo, “*PERFORMANCE ANALYSIS OF GRADIENT BOOSTING MODELS VARIANTS IN PREDICTING THE DIRECTION OF STOCK CLOSING PRICES ON THE INDONESIA STOCK EXCHANGE,*” vol. 19, no. 2, pp. 1393–1408, 2025.
 - [20] H. Zhu, “*LGBM on Stock Returns Prediction and Portfolio construction,*” no. Icdse, pp. 521–526, 2025, doi: 10.5220/0013701300004670.
 - [21] N. A. Haryono, Y. Lukito, and A. W. Mahastama, “*Feature engineering for Machine Learning-Based Trading Systems Using Decision tree , Random Forest , and Gradient Boosting,*” vol. 16, no. 12, pp. 736–746, 2025.
 - [22] J. O. Economis, “Saham Sebagai Instrumen Investasi: Peluang, Risiko, dan Strategi Investasi Di Tengah Dinamika Ekonomi Global 2024 – 2025 Fandi Febriansyah, Muhamad Aqim Adlan,” vol. 3, no. 2, pp. 207–220, 2025.
 - [23] B. A. B. Ii and T. Pustaka, “*No Title,*” 2013.
 - [24] A. Risiko *et al.*, “Analisis risiko sistematis dan expected return saham

sebagai dasar pengambilan keputusan investasi saham pada jakarta islamic index (jii) periode 2020-2022,” 2024.

- [25] *No Title*. 2022.
- [26] K. Valiant, Y. Lukito, and R. G. Santosa, “Sistem Prediksi Harga Saham LQ45 Dengan *Random Forest Classifier*,” no. 2, pp. 127–136, 2019, doi: 10.21460/jutei.2019.32.187.
- [27] M. Y. Urrochman and F. A. Hizham, “*PERFORMANCE COMPARISON OF RANDOM FOREST REGRESSION , SVR*,” vol. 21, no. 1, pp. 16–23, 2025, doi: 10.33480/pilar.v21i1.6072.
- [28] F. Nuraini, D. Jondri, M. Si, and T. A. B. W, “Prediksi Pergerakan Indeks Harga Saham Menggunakan *Artificial Neural Network* dan *Support Vector Machine Prediction of Stock Price Index Movement Using Artificial Neural Network and Support Vector Machine*”.
- [29] L. B. Masalah, “BAB I,” pp. 1–7, 2020.
- [30] P. Geurts, “*Learning to rank with Extremely Randomized Trees*,” vol. 14, pp. 49–61, 2011.
- [31] F. C. Onwuegbuche, A. Olaoluwa, A. D. Jurcut, and L. Pasquale, “*Graphical Abstract*”.
- [32] L. G. Oct, G. St, and P. Polytechnic, “*Ensembles of Gradient Boosting Machines ★*,” no. 19.
- [33] T. O. Hodson, “*Root-mean-square error (RMSE) or mean absolute error (MAE): when to use them or not*,” no. 2, pp. 5481–5487, 2022.

BIODATA PENULIS

Nama	: Andrian Fakhruza	
NIM	: 2022573010060	
Prodi	: Teknik Informatika	
Jurusan	: Teknologi Informasi dan Komputer	
Tempat/Tanggal Lahir	: Lhokseumawe, 25 September 2004	
Agama	: Islam	
No. HP	: 085321561342	
Email	: fakhruzaandrian561@gmail.com	
Alamat	: Jl. Cut Mutia, Panggoi, Muara Dua, Lhokseumawe	

Identitas Orang Tua

Nama Ayah	: Surya Darma
Pekerjaan	: Pensiunan
Nama Ibu	: Elyzar
Pekerjaan	: PNS

Riwayat Pendidikan

1. SD/Sederajat : SD Negeri Arun, Tahun 2010 - 2016
2. SMP/Sederajat : SMP Negeri Arun, Tahun 2016 - 2019
3. SMA/Sederajat : SMA Negeri Modal Bangsa Arun, Tahun 2019 - 2022
4. Perguruan Tinggi : Politeknik Negeri Lhokseumawe, Tahun 2022 - 2026

Judul Skripsi:

“Rancang Bangun Sistem Prediksi Return Saham Menggunakan Metode Extremely Randomized Trees dan Gradient Boosting”