

Penerapan Hybrid Recommendation System dengan Content-Based Filtering dan Euclidean Distance untuk Rekomendasi Warna Lipstik

Dinda Fitria Indriana^{1*}, Muhammad Rizka², Rahmad Hidayat³

^{1,2,3} Jurusan Teknologi Informasi dan Komputer, Politeknik Negeri Lhokseumawe, Jl. Banda Aceh–Medan Km. 280,3 Buketrata, Lhokseumawe 24301, Indonesia

*Corresponding Author: dindaindriana0911@gmail.com

Article info: Received August 15, 2026, Revised August 25, 2026, Accepted September 01, 2026

This is an open access article under the CC BY-SA license.



Abstrak

Pemilihan warna lipstik yang sesuai dengan karakteristik warna alami bibir umumnya masih dilakukan secara subjektif dan konvensional, sehingga diperlukan suatu sistem yang mampu memberikan rekomendasi secara otomatis, objektif, dan personal. Penelitian ini bertujuan untuk merancang dan membangun sistem rekomendasi warna lipstik berdasarkan citra bibir menggunakan pendekatan Deep Learning melalui model MobileNetV2 serta Hybrid Recommendation System. Alur penelitian mencakup deteksi landmark wajah menggunakan MediaPipe Face Mesh, segmentasi area bibir, ekstraksi fitur nilai rata-rata Red, Green, Blue (RGB), pelabelan otomatis berbasis K-Means Clustering ke dalam kategori Pinkish, Brownish, dan Dark, klasifikasi tipe bibir dengan MobileNetV2 melalui transfer learning, serta pemberian rekomendasi warna lipstik melalui perpaduan Rule-Based Filtering dan Content-Based Filtering berbasis Euclidean Distance. Hasil evaluasi pengujian menunjukkan bahwa model MobileNetV2 berhasil mengklasifikasikan tipe warna bibir dengan akurasi validasi sebesar 94,84%. Pada sistem rekomendasi, pengujian terhadap basis data shade lipstik komersial berhasil menghasilkan rekomendasi Top-3 dengan rata-rata tingkat kemiripan sebesar 93,62% pada rekomendasi pertama, 92,26% pada rekomendasi kedua, dan 91,41% pada rekomendasi ketiga. Dengan demikian, sistem yang dikembangkan terbukti akurat dan efektif dalam memberikan rekomendasi warna lipstik yang sesuai dengan karakteristik warna alami bibir pengguna.

Kata Kunci: Deep Learning, MobileNetV2, Hybrid Recommendation System, Content-Based Filtering, Euclidean Distance, K-Means Clustering, Rekomendasi Warna Lipstik.

1. PENDAHULUAN

Perkembangan industri kosmetik di Indonesia mengalami peningkatan yang sangat pesat seiring dengan tingginya kesadaran masyarakat terhadap penampilan diri dan perawatan kecantikan. Berdasarkan survei pasar konsumen di Indonesia, produk riasan bibir seperti lipstik, lip cream, dan lip tint menduduki kategori produk kosmetik yang paling banyak digunakan oleh wanita, dengan persentase penggunaan mencapai 80,4% [1]. Lipstik tidak hanya berfungsi sebagai pewarna bibir untuk meningkatkan estetika wajah, tetapi juga menjadi elemen penting dalam mengekspresikan karakter dan rasa percaya diri pemakainya.

Meskipun produk lipstik sangat populer, proses pemilihan warna (shade) lipstik yang tepat sering kali menjadi tantangan bagi konsumen. Karakteristik warna dasar bibir setiap individu bersifat unik dan sangat bervariasi. Penelitian ilmiah oleh Vergnaud dkk. menunjukkan bahwa warna alami bibir dipengaruhi oleh berbagai faktor fisiologis yang kompleks, seperti konsentrasi melanin, aliran hemoglobin, ketebalan stratum korneum, etnis, dan usia [2], [3]. Perbedaan pigmen dasar ini menyebabkan satu produk lipstik yang sama dapat menghasilkan tampilan warna akhir yang sangat berbeda ketika diaplikasikan pada bibir orang yang berbeda. Hal tersebut diperkuat oleh penelitian Charton dkk. yang berhasil menyusun bagan warna bibir (lip colour chart) multi-etnis dan membuktikan keragaman spektrum rona bibir manusia [4].

Sebagian besar konsumen masih memilih warna lipstik secara konvensional dan subjektif, misalnya dengan mencoba

produk langsung menggunakan tester di toko fisik atau hanya mengandalkan ulasan di media sosial. Metode konvensional ini memiliki risiko higienitas serta berpotensi menimbulkan ketidakcocokan warna saat bertransaksi daring. Sejumlah penelitian terdahulu telah mengkaji sistem rekomendasi produk kecantikan. Katariya dan Patel merancang model CNN untuk merekomendasikan produk kosmetik berdasarkan tipe dan rona warna kulit (skin tone) [5]. Selanjutnya, Gulati dkk. mengembangkan sistem BeautifAI yang memberikan rekomendasi riasan terpersonalisasi berdasarkan karakteristik wajah dan kebutuhan acara (occasion) pengguna [6]. Pada aspek komputasi rekomendasi, Pratama dkk. menerapkan metode Content-Based Filtering untuk sistem rekomendasi kosmetik berbasis kemiripan atribut produk [7]. Meskipun demikian, sebagian besar penelitian terdahulu tersebut masih menggunakan warna kulit wajah secara umum atau atribut teks katalog sebagai parameter acuan. Belum ditemukan penelitian yang secara spesifik mengekstraksi dan mengklasifikasikan karakteristik warna alami bibir pengguna sebagai basis utama rekomendasi warna lipstick.

Pemanfaatan teknologi Computer Vision dan Deep Learning berbasis Convolutional Neural Network (CNN) terbukti sangat andal dalam mengenali pola visual citra secara akurat [8]–[10]. Salah satu arsitektur CNN yang efisien untuk implementasi praktis adalah MobileNetV2, yang dirancang menggunakan inverted residuals dan linear bottlenecks sehingga berbobot komputasi ringan tanpa mengorbankan akurasi tinggi [11], [12]. Untuk mengelompokkan data warna bibir yang belum memiliki label acuan, algoritma unsupervised learning K-Means Clustering dapat digunakan untuk membentuk klasterisasi data berbasis kemiripan nilai warna RGB [13], [14].

Dalam sistem rekomendasi, pendekatan tunggal seperti Rule-Based Filtering efektif untuk menyaring kandidat berdasarkan batasan kategori tertentu, namun tidak fleksibel dalam mengukur derajat kedekatan gradasi warna [15]. Sebaliknya, Content-Based Filtering berbasis metrik jarak geometri Euclidean Distance mampu mengukur kedekatan fitur numerik secara kontinu dan presisi [16]. Oleh karena itu, penggabungan keduanya ke dalam Hybrid Recommendation System menjadi solusi ideal. Penelitian ini bertujuan merancang dan membangun sistem rekomendasi warna lipstick berbasis citra bibir dengan menerapkan MediaPipe Face Mesh [17] untuk segmentasi bibir otomatis, ekstraksi nilai rata-rata RGB, klasterisasi K-Means, klasifikasi MobileNetV2 dengan transfer learning, serta perpaduan Rule-Based dan Content-Based Filtering (Euclidean Distance) untuk menghasilkan Top-3 rekomendasi lipstick paling presisi.

2. METODE PENELITIAN

2.1 Alur Penelitian dan Arsitektur Sistem

Penelitian ini dilaksanakan melalui tahapan sistematis yang terbagi ke dalam fase pengolahan data, pelatihan model deep learning, perancangan sistem rekomendasi hybrid, dan evaluasi performa sistem. Alur umum sistem rekomendasi warna lipstick berbasis citra bibir diilustrasikan pada Gambar 1.




Figure 1: Diagram Alur Sistem Rekomendasi Warna Lipstick Menggunakan MobileNetV2 dan Hybrid Recommendation System

2.2 Pengumpulan dan Pembagian Dataset

Dataset yang digunakan dalam penelitian ini berjumlah total 18.100 citra wajah, yang terdiri atas:

1. Dataset Sekunder (CelebA): Sebanyak 18.000 citra wajah dari CelebFaces Attributes Dataset (CelebA) [18] dengan ekspresi netral tanpa riasan bibir tebal.
2. Dataset Primer: Sebanyak 100 citra wajah wanita Indonesia tanpa riasan bibir untuk meningkatkan representasi variasi pigmen bibir lokal.

Dataset dibagi menjadi data latih (training set) sebanyak 14.480 citra (80%) dan data validasi (validation set) sebanyak 3.620 citra (20%) untuk pelatihan dan evaluasi model.

2.3 Preprocessing dan Segmentasi Area Bibir

Tahap preprocessing bertujuan untuk mengekstraksi area bibir (Region of Interest / ROI) dan menyeragamkan format citra:

1. Resize Citra: Menyeragamkan ukuran citra masukan menjadi 224×224 piksel menggunakan OpenCV [19].
2. Deteksi Landmark Wajah: Menggunakan framework MediaPipe Face Mesh untuk mengekstrak 468 titik landmark wajah 3D [17]. Kontur bibir luar dan dalam diidentifikasi secara presisi (Gambar 2(a)).
3. Segmentasi dan Masking: Membentuk masker poligon biner berdasarkan prinsip segmentasi citra digital [20], [21] dari koordinat landmark bibir. Seluruh piksel di luar area bibir diatur bernilai nol (Gambar 2(b)).
4. Normalisasi dan Cropping ROI: Mengonversi intensitas piksel kanal RGB ke rentang $[0, 1]$ dan memotong citra terfokus pada batas area bibir ($x_{min}, y_{min}, x_{max}, y_{max}$).




Figure 2: Tahapan Deteksi Landmark Wajah dan Segmentasi Area Bibir Pengguna


2.4 Ekstraksi Fitur Warna dan K-Means Clustering

Karakteristik warna bibir diekstraksi berdasarkan nilai rata-rata pada kanal Red (R), Green (G), dan Blue (B) dari seluruh N piksel masker bibir menggunakan formula:

$$\bar{R} = \frac{1}{N} \sum_{i=1}^N R_i, \quad \bar{G} = \frac{1}{N} \sum_{i=1}^N G_i, \quad \bar{B} = \frac{1}{N} \sum_{i=1}^N B_i \quad (1)$$

Tiga nilai skalar ($\bar{R}, \bar{G}, \bar{B}$) ini menjadi masukan algoritma K-Means Clustering ($K = 3$, init k-means++, random state 42) untuk menghasilkan 3 kategori label tipe bibir alami (Gambar 3):

1. Pinkish: Rona cerah dengan rona kemerahan/merah muda dominan ($\bar{R} > 150, \bar{G} \approx 95-120, \bar{B} \approx 100-125$).
2. Brownish: Rona hangat kecokelatan ($\bar{R} \approx 125-155, \bar{G} \approx 75-100, \bar{B} \approx 65-90$).
3. Dark: Rona bibir dengan pigmentasi gelap/pekat ($\bar{R} < 110, \bar{G} < 65, \bar{B} < 60$).

Figure 3: Visualisasi Distribusi Hasil K-Means Clustering Warna Bibir ($K = 3$)

2.5 Pelatihan Model Klasifikasi MobileNetV2

MobileNetV2 dilatih menggunakan pendekatan Transfer Learning berbasis bobot ImageNet [22], [23] yang didukung teknik augmentasi citra untuk memperluas variasi fitur [24]. Lapisan kustom yang ditambahkan meliputi: Global Average Pooling 2D, Dropout (0.3), Dense (128 neuron, ReLU), Dropout (0.2), dan Dense Output (3 neuron, Softmax). Konfigurasi parameter hiper pelatihan disajikan pada Tabel 1.

Table 1: Parameter Hiper Pelatihan Model MobileNetV2

Parameter	Nilai / Konfigurasi
Arsitektur Dasar	MobileNetV2 (Pre-trained ImageNet)
Dimensi Masukan Citra	$224 \times 224 \times 3$ piksel
Jumlah Epoch	30
Batch Size	32
Optimizer	Adam ($\beta_1 = 0.9, \beta_2 = 0.999, lr = 0.0001$)
Fungsi Kerugian (Loss)	Categorical Crossentropy
Jumlah Kelas Output	3 (Pinkish, Brownish, Dark)

2.6 Hybrid Recommendation System

Setelah model MobileNetV2 memprediksi probabilitas kelas tipe bibir pengguna ($\hat{y}_{user} \in \{\text{Pinkish, Brownish, Dark}\}$), sistem merekomendasikan shade lipstick terbaik melalui mekanisme bertingkat:

2.6.1 Tahap 1: Rule-Based Filtering

Sistem menyaring 281 koleksi lipstick komersial pada knowledge base berdasarkan kesesuaian atribut `lip_type_tag` dengan kelas prediksi pengguna:

$$\mathcal{C}_{\text{kandidat}} = \{L_j \in \mathcal{D}_{\text{lipstik}} \mid \text{tag}(L_j) = \hat{y}_{\text{user}}\} \quad (2)$$

Jumlah kandidat tersaring adalah 147 produk untuk Pinkish, 127 produk untuk Brownish, dan 14 produk untuk Dark (Tabel 2).

Table 2: Aturan Rule-Based Recommendation Berdasarkan Tipe Warna Bibir

No	Tipe Warna Bibir Prediksi	Kriteria Filter Knowledge Base	Jumlah Kandidat Produk
1	Pinkish	<code>lip_type_tag = Pinkish</code>	147 produk
2	Brownish	<code>lip_type_tag = Brownish</code>	127 produk
3	Dark	<code>lip_type_tag = Dark</code>	14 produk
Total Basis Data Lipstik			281 produk

2.6.2 Tahap 2: Content-Based Filtering Menggunakan Euclidean Distance

Sistem menghitung jarak geometris ruang warna RGB (Euclidean Distance) antara vektor warna bibir pengguna $\mathbf{u} = (R_u, G_u, B_u)$ dan warna lipstick $\mathbf{v}_j = (R_j, G_j, B_j)$ pada seluruh kandidat $L_j \in \mathcal{C}_{\text{kandidat}}$:

$$d(\mathbf{u}, \mathbf{v}_j) = \sqrt{(R_u - R_j)^2 + (G_u - G_j)^2 + (B_u - B_j)^2} \quad (3)$$

Nilai jarak dikonversi menjadi persentase tingkat kemiripan (similarity score) terhadap jarak maksimum ruang warna $d_{\max} = \sqrt{3 \times 255^2} \approx 441.673$:

$$\text{Similarity}(u, v_j) = \left(1 - \frac{d(u, v_j)}{d_{\max}}\right) \times 100\% \quad (4)$$

Tiga produk dengan nilai similarity tertinggi ditetapkan sebagai Top-3 Lipstick Recommendation (Algoritma 1).

Algorithm 1 Algoritma Hybrid Recommendation System untuk Rekomendasi Lipstik

Require: Citra wajah pengguna I_{face} , Basis data produk lipstik $\mathcal{D}_{\text{lipstik}}$, Model klasifikasi MobileNetV2 $\mathcal{M}$.

Ensure: Tiga rekomendasi warna lipstik terbaik (Top-3) beserta nilai persentase kemiripan (similarity).

```

1:  $I_{\text{lip}} \leftarrow \text{SegmentLipRegion}(I_{\text{face}})$  ▷ Segmentasi MediaPipe Face Mesh
2:  $(R_u, G_u, B_u) \leftarrow \text{ExtractAverageRGB}(I_{\text{lip}})$ 
3:  $\hat{y}_{\text{user}} \leftarrow \mathcal{M}.\text{predict}(I_{\text{lip}})$  ▷ Klasifikasi: Pinkish, Brownish, atau Dark
4:  $\mathcal{C}_{\text{kandidat}} \leftarrow \emptyset$ 
5: for each  $L_j \in \mathcal{D}_{\text{lipstik}}$  do ▷ Tahap 1: Rule-Based Filtering
6:   if  $L_j.\text{tag} == \hat{y}_{\text{user}}$  then
7:      $\mathcal{C}_{\text{kandidat}} \leftarrow \mathcal{C}_{\text{kandidat}} \cup \{L_j\}$ 
8:   end if
9: end for
10:  $\mathcal{R} \leftarrow []$ 
11: for each  $L_j \in \mathcal{C}_{\text{kandidat}}$  do ▷ Tahap 2: Content-Based Filtering
12:    $(R_j, G_j, B_j) \leftarrow L_j.\text{rgb}$ 
13:    $d_j \leftarrow \sqrt{(R_u - R_j)^2 + (G_u - G_j)^2 + (B_u - B_j)^2}$ 
14:    $S_j \leftarrow (1 - d_j/441.673) \times 100\%$ 
15:   Append  $(L_j, d_j, S_j)$  to  $\mathcal{R}$ 
16: end for
17: Sort  $\mathcal{R}$  ascending by distance  $d_j$ 
18: return Top-3 elements of  $\mathcal{R}$ 

```

2.7 Metrik Evaluasi Performa

Performa klasifikasi dievaluasi menggunakan matriks konfusi (Confusion Matrix) serta metrik standar: Accuracy, Precision, Recall, dan F1-Score [25]:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (5)$$

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad \text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (6)$$

3. HASIL DAN PEMBAHASAN

3.1 Hasil Pelatihan dan Evaluasi Model MobileNetV2

Model MobileNetV2 dilatih selama 30 epoch menggunakan dataset berlabel hasil klusterisasi K-Means. Gambar 4(a) menyajikan grafik konvergensi akurasi dan kerugian (loss), sedangkan Gambar 4(b) menyajikan Confusion Matrix hasil pengujian pada data validasi (803 sampel).

Model mencapai konvergensi stabil pada epoch ke-15 ke atas tanpa gejala overfitting, dengan akurasi validasi akhir sebesar 94,84% dan validation loss sebesar 0,1612. Rincian nilai metrik evaluasi per kelas dirangkum dalam Classification Report pada Tabel 3.

Table 3: Classification Report Performa Model MobileNetV2

Kelas Tipe Bibir	Precision	Recall	F1-Score	Support (Sampel)
Pinkish	0.971 (97.1%)	0.981 (98.1%)	0.976 (97.6%)	746
Brownish	0.588 (58.8%)	0.426 (42.6%)	0.494 (49.4%)	47
Dark	0.200 (20.0%)	0.300 (30.0%)	0.240 (24.0%)	10
Overall Accuracy		0.940 (94.0%)		803
Macro Average	0.586	0.569	0.570	803
Weighted Average	0.939	0.940	0.938	803

Model menunjukkan performa klasifikasi sangat tinggi pada kelas Pinkish (F1-score 97,6%). Pada kelas Brownish dan Dark, nilai F1-score masing-masing tercatat 49,4% dan 24,0%. Karakteristik ini dipengaruhi oleh dominasi citra




Figure 4: Evaluasi Performa Model MobileNetV2: (a) Grafik Akurasi dan Loss, (b) Confusion Matrix pada Data Validasi

rona cerah pada dataset publik (class imbalance). Namun secara agregat weighted average, model mencapai F1-score 93,8% dan akurasi 94,0%, membuktikan efektivitas MobileNetV2 dalam mengenali karakteristik visual bibir.

3.2 Pengujian dan Evaluasi Hybrid Recommendation System

Pengujian sistem rekomendasi dilakukan terhadap 30 data uji pengguna dengan variasi nilai RGB bibir yang berbeda. Sampel hasil pengujian disajikan pada Tabel 4, dan rekapitulasi performa dirangkum pada Tabel 5.

Table 4: Sampel Hasil Pengujian Hybrid Recommendation System pada Data Uji Pengguna

No	RGB User	Tipe Bibir	Rekomendasi Shade	RGB Lipstik	Euclidean (d)	Similarity (%)
1	(164, 121, 108)	Pinkish	1. Glossy Berry	(167, 97, 101)	25.18	94.3%
			2. Dusty Rose	(185, 115, 125)	27.68	93.7%
			3. Cozy Cherry	(173, 98, 94)	28.39	93.6%
2	(128, 102, 99)	Brownish	1. Chilled Raspberry	(134, 85, 109)	20.62	95.3%
			2. Chilled Cranberry	(132, 68, 82)	38.22	91.3%
			3. Matte Berry	(162, 83, 86)	41.06	90.7%
3	(145, 98, 55)	Pinkish	1. Satin Vermillion	(173, 95, 86)	41.88	90.5%
			2. Bold Ruby	(176, 88, 86)	44.97	89.8%
			3. Cozy Cherry	(173, 98, 94)	48.01	89.1%
4	(195, 167, 153)	Brownish	1. Mauve Bliss	(170, 110, 130)	66.36	85.0%
			2. Warm Terracotta	(180, 105, 95)	74.35	83.2%
			3. Rose Brown	(160, 95, 110)	81.12	81.6%

Table 5: Rekapitulasi Skor Kemiripan (Similarity) Hybrid Recommendation System

Parameter Evaluasi	Nilai Kuantitatif
Jumlah Sampel Data Uji	30 data
Rata-rata Similarity Top-1 (Rekomendasi Pertama)	93.62%
Rata-rata Similarity Top-2 (Rekomendasi Kedua)	92.26%
Rata-rata Similarity Top-3 (Rekomendasi Ketiga)	91.41%
Nilai Similarity Tertinggi	97.60%
Nilai Similarity Terendah	73.60%
Total Basis Data Produk Lipstik Terdaftar	281 shade

Hasil rekapitulasi membuktikan bahwa sistem rekomendasi hibrida mampu menghasilkan rekomendasi warna lipstik dengan tingkat kecocokan yang sangat tinggi. Rata-rata kemiripan warna untuk rekomendasi utama (Top-1) mencapai 93,62%, dengan seluruh Top-3 rekomendasi konsisten berada di atas 91%. Pendekatan bertingkat (two-stage hybrid) terbukti efektif mengeliminasi ketidakcocokan kategori pada tahap Rule-Based dan mengoptimalkan presisi gradasi warna pada tahap Euclidean Distance.

3.3 Implementasi Antarmuka Sistem Berbasis Web

Sistem diimplementasikan ke dalam aplikasi web responsif. Pengguna dapat mengunggah foto wajah dan sistem secara otomatis menampilkan ROI bibir tersegmentasi, nilai RGB, kelas prediksi MobileNetV2, nilai kepercayaan (confidence), serta kartu Top-3 rekomendasi lipstick lengkap dengan swatch warna dan skor kemiripan (Gambar 5).




Figure 5: Implementasi Antarmuka Halaman Hasil Analisis dan Rekomendasi Lipstik

3.4 Pengujian Fungsional (Black Box Testing)

Pengujian fungsional sistem menggunakan metode Black Box Testing menunjukkan bahwa seluruh modul aplikasi berjalan sesuai rancangan kebutuhan fungsional dengan status 100% PASS (Tabel 6).

Table 6: Hasil Pengujian Black Box pada Modul Analisis dan Rekomendasi

No	Skenario Uji	Aktivitas / Masukan	Hasil yang Diharapkan	Status
1	Unggah Citra Valid	Foto wajah JPG/PNG	Sistem mendeteksi wajah dan menampilkan pre-view	PASS
2	Deteksi Landmark	Menjalankan analisis	MediaPipe mengekstrak 468 titik landmark wajah	PASS
3	Segmentasi Bibir	Ekstraksi batas bibir	Masker poligon bibir terbentuk dan area bibir terpotong	PASS
4	Klasifikasi Warna	Ekstraksi RGB & inferensi	MobileNetV2 memprediksi kelas (Pinkish/Brownish/Dark)	PASS
5	Rekomendasi Top-3	Filter aturan & jarak Euclidean	Menampilkan 3 produk lipstick dengan similarity tertinggi	PASS
6	Simpan Riwayat	Simpan ke basis data	Riwayat tersimpan dan dapat diakses pada menu History	PASS

4. KESIMPULAN DAN SARAN

4.1 Kesimpulan

Berdasarkan hasil perancangan, implementasi, dan pengujian yang telah dilaksanakan, penelitian ini telah berhasil membangun sistem rekomendasi warna lipstick terpersonalisasi berbasis citra bibir dengan mengintegrasikan MediaPipe Face Mesh, MobileNetV2 melalui transfer learning, serta Hybrid Recommendation System. Model MobileNetV2 terbukti andal dalam mengklasifikasikan tipe warna bibir pengguna ke dalam tiga kategori (Pinkish, Brownish, dan Dark) dengan perolehan akurasi validasi mencapai 94,84% dan nilai kerugian validasi sebesar 0,1612. Selain itu, integrasi metode Rule-Based Filtering dan Content-Based Filtering berbasis Euclidean Distance berhasil mengoptimalkan akurasi rekomendasi produk lipstick dari katalog komersial, menghasilkan rata-rata tingkat kemiripan sebesar 93,62% pada rekomendasi pertama, 92,26% pada rekomendasi kedua, dan 91,41% pada rekomendasi ketiga, dengan skor kecocokan tertinggi mencapai 97,60%. Pengujian fungsionalitas menggunakan

metode Black Box Testing juga membuktikan bahwa seluruh modul aplikasi web berjalan lancar dengan tingkat keberhasilan 100%.

4.2 Saran

Untuk pengembangan dan penyempurnaan penelitian di masa mendatang, disarankan untuk memperbanyak jumlah sampel data primer terutama pada kategori berpigmen gelap (Dark) dan kecokelatan (Brownish), serta menerapkan metode penanganan ketidakseimbangan kelas seperti class weighting atau SMOTE guna meningkatkan sensitivitas pada kelas minoritas. Di samping itu, penelitian lanjutan dapat memperluas kapabilitas sistem dengan menambahkan fitur simulasi riasan virtual (Virtual Try-On) berbasis Augmented Reality (AR) interaktif serta mempertimbangkan integrasi rona warna kulit (skin undertone) dan preferensi kebutuhan acara agar hasil rekomendasi kosmetik menjadi semakin komprehensif dan adaptif.

DAFTAR PUSTAKA

- [1] Jakpat Survey, "Makeup Product Categories Used by Indonesian Women in 2025," Databoks Katadata, 2025, [Online]. Available: <https://databoks.katadata.co.id/en/consumer-durables-apparel/statistics/692e89e11c6f5/makeup-product-categories-used-by-indonesian-women-in-2025>
- [2] H. Vergnaud et al., "Lip Color Diversity: An Intricate Study," *Skin Research and Technology*, vol. 30, no. 2, p. e13583, Feb. 2024, doi: 10.1111/srt.13583.
- [3] H. Vergnaud et al., "Lip Color Measurement: A New Hyperspectral Imaging Device," *Skin Research and Technology*, vol. 29, no. 8, p. e13418, Aug. 2023, doi: 10.1111/srt.13418.
- [4] Z. Charton et al., "Development of a Lip Colour Chart Across Four Ethnicities," *International Journal of Cosmetic Science*, vol. 48, no. 1, pp. 161–171, Feb. 2026, doi: 10.1111/ics.70004.
- [5] R. Katariya and S. Patel, "A Novel Strid CNN Model for Cosmetic Product Recommendation based on Skin Type and Tone," *SSRG International Journal of Electrical and Electronics Engineering*, vol. 12, no. 5, pp. 1–12, May 2025, doi: 10.14445/23488379/IJEE-V12I5P101.
- [6] K. Gulati, G. Verma, M. Mohania, and A. Kundu, "BeautifAI: Personalised Occasion-based Makeup Recommendation," in *Proc. 14th Asian Conf. Mach. Learn. (ACML)*, PMLR, vol. 189, pp. 407–419, Dec. 2023.
- [7] R. Pratama, M. Ikhsan, and A. Fitri, "Sistem Rekomendasi Produk Kosmetik Menggunakan Metode Content-Based Filtering Berbasis Website," *Jurnal Rabbit: Jurnal Teknologi dan Sistem Informasi Univ. Abdurrah*, vol. 10, no. 1, pp. 45–56, Jan. 2025, doi: 10.36341/rabit.v10i1.6371.
- [8] R. Szeliski, *Computer Vision: Algorithms and Applications*, 2nd ed. Cham, Switzerland: Springer Nature, 2022, doi: 10.1007/978-3-030-34372-9.
- [9] I. Goodfellow, Y. Bengio, and A. Courville, *Deep Learning*. Cambridge, MA, USA: MIT Press, 2016.
- [10] Y. LeCun, Y. Bengio, and G. Hinton, "Deep Learning," *Nature*, vol. 521, no. 7553, pp. 436–444, May 2015, doi: 10.1038/nature14539.
- [11] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," in *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, pp. 4510–4520, Jun. 2018, doi: 10.1109/CVPR.2018.00474.
- [12] A. G. Howard et al., "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications," *arXiv preprint arXiv:1704.04861*, Apr. 2017, [Online]. Available: <https://arxiv.org/abs/1704.04861>
- [13] J. MacQueen, "Some Methods for Classification and Analysis of Multivariate Observations," in *Proc. 5th Berkeley Symp. Math. Statist. Prob.*, vol. 1, pp. 281–297, 1967.
- [14] F. Pedregosa et al., "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, Nov. 2011.
- [15] F. Ricci, L. Rokach, and B. Shapira, *Recommender Systems Handbook*, 2nd ed. New York, NY, USA: Springer, 2015, doi: 10.1007/978-1-4899-7637-6.
- [16] C. C. Aggarwal, *Recommender Systems: The Textbook*. Cham, Switzerland: Springer Nature, 2016, doi: 10.1007/978-3-319-29659-3.
- [17] C. Lugaresi et al., "MediaPipe: A Framework for Building Perception Pipelines," *arXiv preprint arXiv:1906.08172*, Jun. 2019, [Online]. Available: <https://arxiv.org/abs/1906.08172>
- [18] Z. Liu, P. Luo, X. Wang, and X. Tang, "Deep Learning Face Attributes in the Wild," in *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, pp. 3730–3738, Dec. 2015, doi: 10.1109/ICCV.2015.425.
- [19] G. Bradski, "The OpenCV Library," *Dr. Dobb's Journal of Software Tools*, vol. 25, no. 11, pp. 120–125, Nov. 2000.
- [20] N. Otsu, "A Threshold Selection Method from Gray-Level Histograms," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 9, no. 1, pp. 62–66, Jan. 1979, doi: 10.1109/TSMC.1979.4310076.
- [21] R. C. Gonzalez and R. E. Woods, *Digital Image Processing*, 4th ed. New York, NY, USA: Pearson, 2018.
- [22] S. J. Pan and Q. Yang, "A Survey on Transfer Learning," *IEEE Transactions on Knowledge and Data Engineering*, vol. 22, no. 10, pp. 1345–1359, Oct. 2010, doi: 10.1109/TKDE.2009.191.
- [23] K. He, X. Zhang, S. Ren, and J. Sun, "Deep Residual Learning for Image Recognition," in *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, Jun. 2016, doi: 10.1109/CVPR.2016.90.
- [24] C. Shorten and T. M. Khoshgoftaar, "A Survey on Image Data Augmentation for Deep Learning," *Journal of Big Data*, vol. 6, no. 1, p. 60, Jul. 2019, doi: 10.1186/s40537-019-0197-0.
- [25] D. M. W. Powers, "Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness and Correlation," *Journal of Machine Learning Technologies*, vol. 2, no. 1, pp. 37–63, Dec. 2011.