

Penerapan Hybrid Recommendation System dengan Content-Based Filtering dan Euclidean Distance untuk Rekomendasi Warna Lipstik

Dinda Fitria Indriana^{1*}, Muhammad Rizka², Rahmad Hidayat³

^{1,2,3} Jurusan Teknologi Informasi dan Komputer, Politeknik Negeri Lhokseumawe, Jl. Banda Aceh–Medan Km. 280,3 Buketrata, Lhokseumawe 24301, Indonesia

*Corresponding Author: dindaindriana0911@gmail.com

Article info: Received August 15, 2026, Revised August 25, 2026, Accepted September 01, 2026

This is an open access article under the [CC BY-SA](https://creativecommons.org/licenses/by-sa/4.0/) license. 

Abstrak

Pemilihan warna lipstik yang sesuai dengan karakteristik warna alami bibir umumnya masih dilakukan secara subjektif dan konvensional, sehingga diperlukan suatu sistem yang mampu memberikan rekomendasi secara otomatis, objektif, dan personal. Penelitian ini bertujuan untuk merancang dan membangun sistem rekomendasi warna lipstik berdasarkan citra bibir menggunakan pendekatan Deep Learning melalui model MobileNetV2 serta Hybrid Recommendation System. Alur penelitian mencakup deteksi landmark wajah menggunakan MediaPipe Face Mesh, segmentasi area bibir, ekstraksi fitur nilai rata-rata Red, Green, Blue (RGB), pelabelan otomatis berbasis K-Means Clustering ke dalam kategori Pinkish, Brownish, dan Dark, klasifikasi tipe bibir dengan MobileNetV2 melalui transfer learning, serta pemberian rekomendasi warna lipstik melalui perpaduan Rule-Based Filtering dan Content-Based Filtering berbasis Euclidean Distance. Hasil evaluasi pengujian menunjukkan bahwa model MobileNetV2 berhasil mengklasifikasikan tipe warna bibir dengan akurasi validasi sebesar 94,84%. Pada sistem rekomendasi, pengujian terhadap basis data shade lipstik komersial berhasil menghasilkan rekomendasi Top-3 dengan rata-rata tingkat kemiripan sebesar 93,62% pada rekomendasi pertama, 92,26% pada rekomendasi kedua, dan 91,41% pada rekomendasi ketiga. Dengan demikian, sistem yang dikembangkan terbukti akurat dan efektif dalam memberikan rekomendasi warna lipstik yang sesuai dengan karakteristik warna alami bibir pengguna.

Kata Kunci: Deep Learning, MobileNetV2, Hybrid Recommendation System, Content-Based Filtering, Euclidean Distance, K-Means Clustering, Rekomendasi Warna Lipstik.

1. PENDAHULUAN

Perkembangan industri kosmetik di Indonesia mengalami peningkatan yang sangat pesat seiring dengan tingginya kesadaran masyarakat terhadap penampilan diri dan perawatan kecantikan. Berdasarkan survei pasar konsumen di Indonesia, produk riasan bibir seperti lipstik, *lip cream*, dan *lip tint* menduduki kategori produk kosmetik yang paling banyak digunakan oleh wanita, dengan persentase penggunaan mencapai 80,4% [1]. Lipstik tidak hanya berfungsi sebagai pewarna bibir untuk meningkatkan estetika wajah, tetapi juga menjadi elemen penting dalam mengekspresikan karakter dan rasa percaya diri pemakainya.

Meskipun produk lipstik sangat populer, proses pemilihan warna (*shade*) lipstik yang tepat sering kali menjadi tantangan bagi konsumen. Karakteristik warna dasar bibir setiap individu bersifat unik dan sangat bervariasi. Penelitian ilmiah oleh Vergnaud dkk. menunjukkan bahwa warna alami bibir dipengaruhi oleh berbagai faktor fisiologis yang kompleks, seperti konsentrasi melanin, aliran hemoglobin, ketebalan stratum korneum, etnis, dan usia [2, 3]. Perbedaan pigmen dasar ini menyebabkan satu produk lipstik yang sama dapat menghasilkan tampilan warna akhir yang sangat berbeda ketika diaplikasikan pada bibir orang yang berbeda. Hal tersebut diperkuat oleh penelitian Charton dkk. yang berhasil menyusun bagan warna bibir (*lip colour chart*) multi-etnis dan membuktikan keragaman spektrum rona bibir manusia [4].

Sebagian besar konsumen masih memilih warna lipstik secara konvensional dan subjektif, misalnya dengan mencoba produk langsung menggunakan *tester* di toko fisik atau hanya mengandalkan ulasan di media sosial.

Metode konvensional ini memiliki risiko higienitas serta berpotensi menimbulkan ketidakcocokan warna saat bertransaksi daring. Sejumlah penelitian terdahulu telah mengkaji sistem rekomendasi produk kecantikan. Katariya dan Patel merancang model CNN untuk merekomendasikan produk kosmetik berdasarkan tipe dan rona warna kulit (*skin tone*) [5]. Selanjutnya, Gulati dkk. mengembangkan sistem BeautifAI yang memberikan rekomendasi riasan terpersonalisasi berdasarkan karakteristik wajah dan kebutuhan acara (*occasion*) pengguna [6]. Pada aspek komputasi rekomendasi, Pratama dkk. menerapkan metode *Content-Based Filtering* untuk sistem rekomendasi kosmetik berbasis kemiripan atribut produk [7]. Meskipun demikian, sebagian besar penelitian terdahulu tersebut masih menggunakan warna kulit wajah secara umum atau atribut teks katalog sebagai parameter acuan. Belum ditemukan penelitian yang secara spesifik mengekstraksi dan mengklasifikasikan karakteristik warna alami bibir pengguna sebagai basis utama rekomendasi warna lipstick.

Pemanfaatan teknologi *Computer Vision* dan *Deep Learning* berbasis *Convolutional Neural Network* (CNN) terbukti sangat andal dalam mengenali pola visual citra secara akurat [8–10]. Salah satu arsitektur CNN yang efisien untuk implementasi praktis adalah MobileNetV2, yang dirancang menggunakan *inverted residuals* dan *linear bottlenecks* sehingga berbobot komputasi ringan tanpa mengorbankan akurasi tinggi [11, 12]. Untuk mengelompokkan data warna bibir yang belum memiliki label acuan, algoritma *unsupervised learning* K-Means Clustering dapat digunakan untuk membentuk klasterisasi data berbasis kemiripan nilai warna RGB [13, 14].

Dalam sistem rekomendasi, pendekatan tunggal seperti *Rule-Based Filtering* efektif untuk menyaring kandidat berdasarkan batasan kategori tertentu, namun tidak fleksibel dalam mengukur derajat kedekatan gradasi warna [15]. Sebaliknya, *Content-Based Filtering* berbasis metrik jarak geometri *Euclidean Distance* mampu mengukur kedekatan fitur numerik secara kontinu dan presisi [16]. Oleh karena itu, penggabungan keduanya ke dalam *Hybrid Recommendation System* menjadi solusi ideal. Penelitian ini bertujuan merancang dan membangun sistem rekomendasi warna lipstick berbasis citra bibir dengan menerapkan MediaPipe Face Mesh [17] untuk segmentasi bibir otomatis, ekstraksi nilai rata-rata RGB, klasterisasi K-Means, klasifikasi MobileNetV2 dengan *transfer learning*, serta perpaduan *Rule-Based* dan *Content-Based Filtering* (Euclidean Distance) untuk menghasilkan Top-3 rekomendasi lipstick paling presisi.

2. METODE PENELITIAN

2.1 Alur Penelitian dan Arsitektur Sistem

Penelitian ini dilaksanakan melalui tahapan sistematis yang terbagi ke dalam fase pengolahan data, pelatihan model *deep learning*, perancangan sistem rekomendasi hybrid, dan evaluasi performa sistem. Alur umum sistem rekomendasi warna lipstick berbasis citra bibir diilustrasikan pada Gambar 1.




Figure 1: Diagram Alur Sistem Rekomendasi Warna Lipstick Menggunakan MobileNetV2 dan Hybrid Recommendation System

2.2 Pengumpulan dan Pembagian Dataset

Dataset yang digunakan dalam penelitian ini berjumlah total 18.100 citra wajah, yang terdiri atas:

1. Dataset Sekunder (CelebA): Sebanyak 18.000 citra wajah dari *CelebFaces Attributes Dataset* (CelebA) [18] dengan ekspresi netral tanpa riasan bibir tebal.
2. Dataset Primer: Sebanyak 100 citra wajah wanita Indonesia tanpa riasan bibir untuk meningkatkan representasi variasi pigmen bibir lokal.

Dataset dibagi menjadi data latih (*training set*) sebanyak 14.480 citra (80%) dan data validasi (*validation set*) sebanyak 3.620 citra (20%) untuk pelatihan dan evaluasi model.

2.3 Preprocessing dan Segmentasi Area Bibir

Tahap *preprocessing* bertujuan untuk mengekstraksi area bibir (*Region of Interest* / ROI) dan menyeragamkan format citra:

1. Resize Citra: Menyeragamkan ukuran citra masukan menjadi 224×224 piksel menggunakan OpenCV [19].
2. Deteksi Landmark Wajah: Menggunakan framework MediaPipe Face Mesh untuk mengekstrak 468 titik landmark wajah 3D [17]. Kontur bibir luar dan dalam diidentifikasi secara presisi (Gambar 2(a)).
3. Segmentasi dan Masking: Membentuk masker poligon biner berdasarkan prinsip segmentasi citra digital [20, 21] dari koordinat landmark bibir. Seluruh piksel di luar area bibir diatur bernilai nol (Gambar 2(b)).
4. Normalisasi dan Cropping ROI: Mengonversi intensitas piksel kanal RGB ke rentang $[0, 1]$ dan memotong citra terfokus pada batas area bibir ($x_{\min}, y_{\min}, x_{\max}, y_{\max}$).




Figure 2: Tahapan Deteksi Landmark Wajah dan Segmentasi Area Bibir Pengguna

2.4 Ekstraksi Fitur Warna dan K-Means Clustering

Karakteristik warna bibir diekstraksi berdasarkan nilai rata-rata pada kanal Red (R), Green (G), dan Blue (B) dari seluruh N piksel masker bibir menggunakan formula:

$$\bar{R} = \frac{1}{N} \sum_{i=1}^N R_i, \quad \bar{G} = \frac{1}{N} \sum_{i=1}^N G_i, \quad \bar{B} = \frac{1}{N} \sum_{i=1}^N B_i \quad (1)$$

Tiga nilai skalar ($\bar{R}, \bar{G}, \bar{B}$) ini menjadi masukan algoritma K-Means Clustering ($K = 3$, init *k-means++*, random state 42) untuk menghasilkan 3 kategori label tipe bibir alami (Gambar 3):

1. Pinkish: Rona cerah dengan rona kemerahan/merah muda dominan ($\bar{R} > 150, \bar{G} \approx 95 - 120, \bar{B} \approx 100 - 125$).
2. Brownish: Rona hangat kecokelatan ($\bar{R} \approx 125 - 155, \bar{G} \approx 75 - 100, \bar{B} \approx 65 - 90$).
3. Dark: Rona bibir dengan pigmentasi gelap/pekat ($\bar{R} < 110, \bar{G} < 65, \bar{B} < 60$).




Figure 3: Visualisasi Distribusi Hasil K-Means Clustering Warna Bibir ($K = 3$)

2.5 Pelatihan Model Klasifikasi MobileNetV2

MobileNetV2 dilatih menggunakan pendekatan *Transfer Learning* berbasis bobot ImageNet [22, 23] yang didukung teknik augmentasi citra untuk memperluas variasi fitur [24]. Lapisan kustom yang ditambahkan meliputi: *Global Average Pooling 2D*, *Dropout* (0.3), *Dense* (128 neuron, ReLU), *Dropout* (0.2), dan *Dense Output* (3 neuron, Softmax). Konfigurasi parameter hiper pelatihan disajikan pada Tabel 1.

Table 1: Parameter Hiper Pelatihan Model MobileNetV2

Parameter	Nilai / Konfigurasi
Arsitektur Dasar	MobileNetV2 (Pre-trained ImageNet)
Dimensi Masukan Citra	$224 \times 224 \times 3$ piksel
Jumlah Epoch	30
Batch Size	32
Optimizer	Adam ($\beta_1 = 0.9, \beta_2 = 0.999, lr = 0.0001$)
Fungsi Kerugian (Loss)	Categorical Crossentropy
Jumlah Kelas Output	3 (Pinkish, Brownish, Dark)

2.6 Hybrid Recommendation System

Setelah model MobileNetV2 memprediksi probabilitas kelas tipe bibir pengguna ($\hat{y}_{\text{user}} \in \{\text{Pinkish, Brownish, Dark}\}$), sistem merekomendasikan shade lipstick terbaik melalui mekanisme bertingkat:

2.6.1 Tahap 1: Rule-Based Filtering

Sistem menyaring 281 koleksi lipstick komersial pada *knowledge base* berdasarkan kesesuaian atribut `lip_type_tag` dengan kelas prediksi pengguna:

$$\mathcal{C}_{\text{kandidat}} = \{L_j \in \mathcal{D}_{\text{lipstik}} \mid \text{tag}(L_j) = \hat{y}_{\text{user}}\} \quad (2)$$

Jumlah kandidat tersaring adalah 147 produk untuk Pinkish, 127 produk untuk Brownish, dan 14 produk untuk Dark (Tabel 2).

Table 2: Aturan Rule-Based Recommendation Berdasarkan Tipe Warna Bibir

No	Tipe Warna Bibir Prediksi	Kriteria Filter Knowledge Base	Jumlah Kandidat Produk
1	Pinkish	<code>lip_type_tag = Pinkish</code>	147 produk
2	Brownish	<code>lip_type_tag = Brownish</code>	127 produk
3	Dark	<code>lip_type_tag = Dark</code>	14 produk
Total Basis Data Lipstik			281 produk

2.6.2 Tahap 2: Content-Based Filtering Menggunakan Euclidean Distance

Sistem menghitung jarak geometris ruang warna RGB (*Euclidean Distance*) antara vektor warna bibir pengguna $\mathbf{u} = (R_u, G_u, B_u)$ dan warna lipstick $\mathbf{v}_j = (R_j, G_j, B_j)$ pada seluruh kandidat $L_j \in \mathcal{C}_{\text{kandidat}}$:

$$d(\mathbf{u}, \mathbf{v}_j) = \sqrt{(R_u - R_j)^2 + (G_u - G_j)^2 + (B_u - B_j)^2} \quad (3)$$

Nilai jarak dikonversi menjadi persentase tingkat kemiripan (*similarity score*) terhadap jarak maksimum ruang warna $d_{\max} = \sqrt{3} \times 255^2 \approx 441.673$:

$$\text{Similarity}(\mathbf{u}, \mathbf{v}_j) = \left(1 - \frac{d(\mathbf{u}, \mathbf{v}_j)}{d_{\max}}\right) \times 100\% \quad (4)$$

Tiga produk dengan nilai *similarity* tertinggi ditetapkan sebagai **Top-3 Lipstick Recommendation** (Algoritma 1).

Algorithm 1 Algoritma Hybrid Recommendation System untuk Rekomendasi Lipstik

Require: Citra wajah pengguna I_{face} , Basis data produk lipstik $\mathcal{D}_{\text{lipstik}}$, Model klasifikasi MobileNetV2 $\mathcal{M}$.

Ensure: Tiga rekomendasi warna lipstik terbaik (Top-3) beserta nilai persentase kemiripan (*similarity*).

```

1:  $I_{\text{lip}} \leftarrow \text{SegmentLipRegion}(I_{\text{face}})$  ▷ Segmentasi MediaPipe Face Mesh
2:  $(R_u, G_u, B_u) \leftarrow \text{ExtractAverageRGB}(I_{\text{lip}})$ 
3:  $\hat{y}_{\text{user}} \leftarrow \mathcal{M}.\text{predict}(I_{\text{lip}})$  ▷ Klasifikasi: Pinkish, Brownish, atau Dark
4:  $\mathcal{C}_{\text{kandidat}} \leftarrow \emptyset$ 
5: for each  $L_j \in \mathcal{D}_{\text{lipstik}}$  do ▷ Tahap 1: Rule-Based Filtering
6:   if  $L_j.\text{tag} == \hat{y}_{\text{user}}$  then
7:      $\mathcal{C}_{\text{kandidat}} \leftarrow \mathcal{C}_{\text{kandidat}} \cup \{L_j\}$ 
8:   end if
9: end for
10:  $\mathcal{R} \leftarrow []$ 
11: for each  $L_j \in \mathcal{C}_{\text{kandidat}}$  do ▷ Tahap 2: Content-Based Filtering
12:    $(R_j, G_j, B_j) \leftarrow L_j.\text{rgb}$ 
13:    $d_j \leftarrow \sqrt{(R_u - R_j)^2 + (G_u - G_j)^2 + (B_u - B_j)^2}$ 
14:    $S_j \leftarrow (1 - d_j/441.673) \times 100\%$ 
15:   Append  $(L_j, d_j, S_j)$  to  $\mathcal{R}$ 
16: end for
17: Sort  $\mathcal{R}$  ascending by distance  $d_j$ 
18: return Top-3 elements of  $\mathcal{R}$ 

```

2.7 Metrik Evaluasi Performa

Performa klasifikasi dievaluasi menggunakan matriks konfusi (*Confusion Matrix*) serta metrik standar: *Accuracy*, *Precision*, *Recall*, dan *F1-Score* [25]:

$$\text{Accuracy} = \frac{TP + TN}{TP + TN + FP + FN} \quad (5)$$

$$\text{Precision} = \frac{TP}{TP + FP}, \quad \text{Recall} = \frac{TP}{TP + FN}, \quad \text{F1-Score} = 2 \times \frac{\text{Precision} \times \text{Recall}}{\text{Precision} + \text{Recall}} \quad (6)$$

3. HASIL DAN PEMBAHASAN

3.1 Hasil Pelatihan dan Evaluasi Model MobileNetV2

Model MobileNetV2 dilatih selama 30 epoch menggunakan dataset berlabel hasil klusterisasi K-Means. Gambar 4(a) menyajikan grafik konvergensi akurasi dan kerugian (*loss*), sedangkan Gambar 4(b) menyajikan *Confusion Matrix* hasil pengujian pada data validasi (803 sampel).

Model mencapai konvergensi stabil pada epoch ke-15 ke atas tanpa gejala *overfitting*, dengan akurasi validasi akhir sebesar **94,84%** dan *validation loss* sebesar **0,1612**. Rincian nilai metrik evaluasi per kelas dirangkum dalam *Classification Report* pada Tabel 3.

Table 3: Classification Report Performa Model MobileNetV2

Kelas Tipe Bibir	Precision	Recall	F1-Score	Support (Sampel)
Pinkish	0.971 (97.1%)	0.981 (98.1%)	0.976 (97.6%)	746
Brownish	0.588 (58.8%)	0.426 (42.6%)	0.494 (49.4%)	47
Dark	0.200 (20.0%)	0.300 (30.0%)	0.240 (24.0%)	10
Overall Accuracy		0.940 (94.0%)		803
Macro Average	0.586	0.569	0.570	803
Weighted Average	0.939	0.940	0.938	803

Model menunjukkan performa klasifikasi sangat tinggi pada kelas **Pinkish** (F1-score 97,6%). Pada kelas **Brownish** dan **Dark**, nilai F1-score masing-masing tercatat 49,4% dan 24,0%. Karakteristik ini dipengaruhi oleh dominasi




Figure 4: Evaluasi Performa Model MobileNetV2: (a) Grafik Akurasi dan Loss, (b) Confusion Matrix pada Data Validasi

citra rona cerah pada dataset publik (*class imbalance*). Namun secara agregat *weighted average*, model mencapai F1-score 93,8% dan akurasi 94,0%, membuktikan efektivitas MobileNetV2 dalam mengenali karakteristik visual bibir.

3.2 Pengujian dan Evaluasi Hybrid Recommendation System

Pengujian sistem rekomendasi dilakukan terhadap 30 data uji pengguna dengan variasi nilai RGB bibir yang berbeda. Sampel hasil pengujian disajikan pada Tabel 4, dan rekapitulasi performa dirangkum pada Tabel 5.

Table 4: Sampel Hasil Pengujian Hybrid Recommendation System pada Data Uji Pengguna

No	RGB User	Tipe Bibir	Rekomendasi Shade	RGB Lipstik	Euclidean (d)	Similarity (%)
1	(164, 121, 108)	Pinkish	1. Glossy Berry	(167, 97, 101)	25.18	94.3%
			2. Dusty Rose	(185, 115, 125)	27.68	93.7%
			3. Cozy Cherry	(173, 98, 94)	28.39	93.6%
2	(128, 102, 99)	Brownish	1. Chilled Raspberry	(134, 85, 109)	20.62	95.3%
			2. Chilled Cranberry	(132, 68, 82)	38.22	91.3%
			3. Matte Berry	(162, 83, 86)	41.06	90.7%
3	(145, 98, 55)	Pinkish	1. Satin Vermillion	(173, 95, 86)	41.88	90.5%
			2. Bold Ruby	(176, 88, 86)	44.97	89.8%
			3. Cozy Cherry	(173, 98, 94)	48.01	89.1%
4	(195, 167, 153)	Brownish	1. Mauve Bliss	(170, 110, 130)	66.36	85.0%
			2. Warm Terracotta	(180, 105, 95)	74.35	83.2%
			3. Rose Brown	(160, 95, 110)	81.12	81.6%

Table 5: Rekapitulasi Skor Kemiripan (*Similarity*) Hybrid Recommendation System

Parameter Evaluasi	Nilai Kuantitatif
Jumlah Sampel Data Uji	30 data
Rata-rata Similarity Top-1 (Rekomendasi Pertama)	93.62%
Rata-rata Similarity Top-2 (Rekomendasi Kedua)	92.26%
Rata-rata Similarity Top-3 (Rekomendasi Ketiga)	91.41%
Nilai Similarity Tertinggi	97.60%
Nilai Similarity Terendah	73.60%
Total Basis Data Produk Lipstik Terdaftar	281 shade

Hasil rekapitulasi membuktikan bahwa sistem rekomendasi hibrida mampu menghasilkan rekomendasi warna lipstik dengan tingkat kecocokan yang sangat tinggi. Rata-rata kemiripan warna untuk rekomendasi utama (Top-1) mencapai **93,62%**, dengan seluruh Top-3 rekomendasi konsisten berada di atas 91%. Pendekatan bertingkat (*two-stage hybrid*) terbukti efektif mengeliminasi ketidakcocokan kategori pada tahap *Rule-Based* dan mengoptimalkan presisi gradasi warna pada tahap *Euclidean Distance*.

3.3 Implementasi Antarmuka Sistem Berbasis Web

Sistem diimplementasikan ke dalam aplikasi web responsif. Pengguna dapat mengunggah foto wajah dan sistem secara otomatis menampilkan ROI bibir tersegmentasi, nilai RGB, kelas prediksi MobileNetV2, nilai kepercayaan (*confidence*), serta kartu Top-3 rekomendasi lipstick lengkap dengan swatch warna dan skor kemiripan (Gambar 5).




Figure 5: Implementasi Antarmuka Halaman Hasil Analisis dan Rekomendasi Lipstik

3.4 Pengujian Fungsional (Black Box Testing)

Pengujian fungsional sistem menggunakan metode *Black Box Testing* menunjukkan bahwa seluruh modul aplikasi berjalan sesuai rancangan kebutuhan fungsional dengan status **100% PASS** (Tabel 6).

Table 6: Hasil Pengujian Black Box pada Modul Analisis dan Rekomendasi

No	Skenario Uji	Aktivitas / Masukan	Hasil yang Diharapkan	Status
1	Unggah Citra Valid	Foto wajah JPG/PNG	Sistem mendeteksi wajah dan menampilkan <i>preview</i>	PASS
2	Deteksi Landmark	Menjalankan analisis	MediaPipe mengekstrak 468 titik landmark wajah	PASS
3	Segmentasi Bibir	Ekstraksi batas bibir	Masker poligon bibir terbentuk dan area bibir terpotong	PASS
4	Klasifikasi Warna	Ekstraksi RGB & inferensi	MobileNetV2 memprediksi kelas (Pinkish/Brownish/Dark)	PASS
5	Rekomendasi Top-3	Filter aturan & jarak Euclidean	Menampilkan 3 produk lipstick dengan similarity tertinggi	PASS
6	Simpan Riwayat	Simpan ke basis data	Riwayat tersimpan dan dapat diakses pada menu <i>History</i>	PASS

4. KESIMPULAN DAN SARAN

4.1 Kesimpulan

Berdasarkan hasil perancangan, implementasi, dan pengujian yang telah dilaksanakan, penelitian ini telah berhasil membangun sistem rekomendasi warna lipstick terpersonalisasi berbasis citra bibir dengan mengintegrasikan MediaPipe Face Mesh, MobileNetV2 melalui *transfer learning*, serta *Hybrid Recommendation System*. Model MobileNetV2 terbukti andal dalam mengklasifikasikan tipe warna bibir pengguna ke dalam tiga kategori (Pinkish, Brownish, dan Dark) dengan perolehan akurasi validasi mencapai 94,84% dan nilai kerugian validasi sebesar 0,1612. Selain itu, integrasi metode *Rule-Based Filtering* dan *Content-Based Filtering* berbasis *Euclidean Distance* berhasil mengoptimalkan akurasi rekomendasi produk lipstick dari katalog komersial, menghasilkan rata-rata tingkat kemiripan sebesar 93,62% pada rekomendasi pertama, 92,26% pada rekomendasi kedua, dan 91,41% pada rekomendasi ketiga, dengan skor kecocokan tertinggi mencapai 97,60%. Pengujian fungsionalitas menggunakan

metode *Black Box Testing* juga membuktikan bahwa seluruh modul aplikasi web berjalan lancar dengan tingkat keberhasilan 100%.

4.2 Saran

Untuk pengembangan dan penyempurnaan penelitian di masa mendatang, disarankan untuk memperbanyak jumlah sampel data primer terutama pada kategori berpigmen gelap (Dark) dan kecokelatan (Brownish), serta menerapkan metode penanganan ketidakseimbangan kelas seperti *class weighting* atau SMOTE guna meningkatkan sensitivitas pada kelas minoritas. Di samping itu, penelitian lanjutan dapat memperluas kapabilitas sistem dengan menambahkan fitur simulasi riasan virtual (*Virtual Try-On*) berbasis *Augmented Reality* (AR) interaktif serta mempertimbangkan integrasi rona warna kulit (*skin undertone*) dan preferensi kebutuhan acara agar hasil rekomendasi kosmetik menjadi semakin komprehensif dan adaptif.

DAFTAR PUSTAKA

- [1] Jakpat Survey, 2025, "Makeup Product Categories Used by Indonesian Women in 2025," *Databoks Katadata*, Kata-data Indonesia, URL: <https://databoks.katadata.co.id/en/consumer-durables-apparel/statistics/692e89e11c6f5/makeup-product-categories-used-by-indonesian-women-in-2025>, Abstract: Survey on cosmetic usage showing lip products as the most popular category used by Indonesian women (80.4%)., Keywords: Makeup categories, Indonesian women, Cosmetics market, Lip products, Document Type: Online Report, Language: English, Database/Indexing: Katadata Databoks, Citation Key: jakpat2025.
- [2] H. Vergnaud, Z. Charton, D. Blumenthal, V. Couturaud, M. Le Fur, E. Loescher, et al., 2024, "Lip Color Diversity: An Intricate Study," *Skin Research and Technology*, vol. 30, no. 2, p. e13583, John Wiley & Sons, Inc., doi: 10.1111/srt.13583, ISSN: 1600-0846, URL: <https://doi.org/10.1111/srt.13583>, Abstract: Analysis of multi-ethnic lip pigmentation variations and underlying anatomical and physiological factors., Keywords: Lip color diversity, Melanin, Hemoglobin, Ethnicity, Skin colorimetry, Document Type: Journal Article, Language: English, Database/Indexing: Scopus / PubMed, Citation Key: vergnaud2024lip.
- [3] H. Vergnaud, M. Cherel, G. François, Z. Charton, E. Loescher, L. Caisey, et al., 2023, "Lip Color Measurement: A New Hyperspectral Imaging Device," *Skin Research and Technology*, vol. 29, no. 8, p. e13418, John Wiley & Sons, Inc., doi: 10.1111/srt.13418, ISSN: 1600-0846, URL: <https://doi.org/10.1111/srt.13418>, Abstract: Introduction of a hyperspectral imaging methodology for high-fidelity non-contact measurement of human lip color., Keywords: Lip color measurement, Hyperspectral imaging, Colorimetry, Spectroscopy, Document Type: Journal Article, Language: English, Database/Indexing: Scopus / PubMed, Citation Key: vergnaud2023measurement.
- [4] Z. Charton, H. Vergnaud, L. Caisey, D. Blumenthal, M. Ma, A. Shi, et al., 2026, "Development of a Lip Colour Chart Across Four Ethnicities," *International Journal of Cosmetic Science*, vol. 48, no. 1, pp. 161–171, John Wiley & Sons, Inc., doi: 10.1111/ics.70004, ISSN: 0142-5463, URL: <https://doi.org/10.1111/ics.70004>, Abstract: Construction of standardized multi-ethnic lip color chart aiding cosmetic product formulation and shade matching., Keywords: Lip colour chart, Multi-ethnic shade matching, Cosmetic science, Spectrophotometry, Document Type: Journal Article, Language: English, Database/Indexing: Scopus / Wiley Online Library, Citation Key: charton2026development.
- [5] R. Katarinya and S. Patel, 2025, "A Novel Strid CNN Model for Cosmetic Product Recommendation based on Skin Type and Tone," *SSRG International Journal of Electrical and Electronics Engineering*, vol. 12, no. 5, pp. 1–12, Seventh Sense Research Group, doi: 10.14445/23488379/IJEEE-V12I5P101, ISSN: 2348-8379, URL: <https://doi.org/10.14445/23488379/IJEEE-V12I5P101>, Abstract: Application of custom convolutional neural network for classifying skin types and predicting cosmetic products., Keywords: Cosmetic recommendation, Skin tone classification, Convolutional neural networks, Computer vision, Document Type: Journal Article, Language: English, Database/Indexing: SSRG / Google Scholar, Citation Key: katarinya2025novel.
- [6] K. Gulati, G. Verma, M. Mohania, and A. Kundu, 2023, "BeautifAI: Personalised Occasion-based Makeup Recommendation," *Proc. 14th Asian Conf. Mach. Learn. (ACML), PMLR*, vol. 189, pp. 407–419, PMLR, ISSN: 2640-3498, URL: <https://proceedings.mlr.press/v189/gulati23a.html>, Abstract: Machine learning framework recommending personalized makeup looks matching occasion and user facial traits., Keywords: Makeup recommendation, Facial cosmetics, Occasion-based styling, Deep learning, Document Type: Conference Paper, Language: English, Database/Indexing: PMLR / DBLP, Citation Key: gulati2023beautifai.
- [7] R. Pratama et al., 2025, "Sistem Rekomendasi Produk Kosmetik Menggunakan Metode Content-Based Filtering Berbasis Website," *Jurnal Rabit: Jurnal Teknologi dan Sistem Informasi Univ. Abdurrah*, vol. 10, no. 1, pp. 45–56, Universitas Abdurrah, ISSN: 2477-2062, URL: <https://jurnal.univrab.ac.id/index.php/rabit/article/view/6371>, Abstract: Web-based cosmetic recommendation system implementation applying Euclidean distance content-based filtering., Keywords: Content-based filtering, Euclidean distance, Cosmetics recommendation, Web system, Document Type: Journal Article, Language: Indonesian, Database/Indexing: SINTA / Garuda, Citation Key: pratama2025sistem.
- [8] R. Szeliski, 2022, "Computer Vision: Algorithms and Applications," *Springer Nature*, 2nd ed., Springer Cham, doi: 10.1007/978-3-030-34372-9, ISSN: 1868-0941, URL: <https://doi.org/10.1007/978-3-030-34372-9>, Abstract: Foundational textbook on fundamental computer vision algorithms, modern deep learning architectures, and applications., Keywords: Computer vision, Image classification, Recognition, Feature representation, Document Type: Book, Language: English, Database/Indexing: SpringerLink, Citation Key: szeliski2022computer.
- [9] I. Goodfellow, Y. Bengio, and A. Courville, 2016, "Deep Learning," *MIT Press*, MIT Press, ISSN: 978-0262035613, URL: <https://www.deeplearningbook.org/>, Abstract: Authoritative reference on deep feedforward networks, regularization, optimization, and convolutional networks., Keywords: Deep learning, Neural networks, Convolutional networks, Optimization, Document Type: Book, Language: English, Database/Indexing: MIT Press, Citation Key: goodfellow2016deep.
- [10] Y. LeCun, Y. Bengio, and G. Hinton, 2015, "Deep Learning," *Nature*, vol. 521, no. 7553, pp. 436–444, Nature Publishing Group, doi: 10.1038/nature14539, ISSN: 0028-0836, URL: <https://doi.org/10.1038/nature14539>, Abstract: Seminal review paper explaining

- foundations, capabilities, and future breakthroughs of deep learning in vision and speech., Keywords: Deep learning, Representation learning, Convolutional networks, Artificial intelligence, Document Type: Journal Article, Language: English, Database/Indexing: Scopus / Web of Science, Citation Key: lecun2015deep.
- [11] M. Sandler, A. Howard, M. Zhu, A. Zhmoginov, and L.-C. Chen, 2018, "MobileNetV2: Inverted Residuals and Linear Bottlenecks," *Proc. IEEE/CVF Conf. Comput. Vis. Pattern Recognit. (CVPR)*, pp. 4510–4520, IEEE, doi: 10.1109/CVPR.2018.00474, ISSN: 2575-7075, URL: <https://doi.org/10.1109/CVPR.2018.00474>, Abstract: Novel mobile neural network architecture utilizing inverted residual blocks with linear bottlenecks for efficient vision tasks., Keywords: MobileNetV2, Inverted residuals, Linear bottlenecks, Convolutional neural networks, Mobile vision, Document Type: Conference Paper, Language: English, Database/Indexing: IEEE Xplore / Scopus, Citation Key: sandler2018mobilenetv2.
 - [12] A. G. Howard, M. Zhu, B. Chen, D. Kalenichenko, W. Wang, T. Weyand, et al., 2017, "MobileNets: Efficient Convolutional Neural Networks for Mobile Vision Applications," *arXiv preprint arXiv:1704.04861*, arXiv, doi: 10.48550/arXiv.1704.04861, URL: <https://arxiv.org/abs/1704.04861>, Abstract: Introduction of depthwise separable convolutions to dramatically decrease parameter count and latency for mobile deep learning., Keywords: MobileNets, Depthwise separable convolution, Efficient CNN, Mobile vision, Document Type: Preprint, Language: English, Database/Indexing: arXiv, Citation Key: howard2017mobilenets.
 - [13] J. MacQueen, 1967, "Some Methods for Classification and Analysis of Multivariate Observations," *Proc. 5th Berkeley Symp. Math. Statist. Prob.*, vol. 1, pp. 281–297, University of California Press, URL: <https://projecteuclid.org/euclid.bsm/1200512992>, Abstract: Original formulation of the k-means clustering process for iterative partitioning and minimum variance multivariate analysis., Keywords: K-Means clustering, Multivariate analysis, Unsupervised classification, Centroid optimization, Document Type: Conference Paper, Language: English, Database/Indexing: Project Euclid, Citation Key: macqueen1967methods.
 - [14] F. Pedregosa, G. Varoquaux, A. Gramfort, V. Michel, B. Thirion, O. Grisel, et al., 2011, "Scikit-learn: Machine Learning in Python," *Journal of Machine Learning Research*, vol. 12, pp. 2825–2830, JMLR.org, ISSN: 1532-4435, URL: <https://jmlr.org/papers/v12/pedregosa11a.html>, Abstract: Python module integrating widely accessible, unified, and efficient machine learning algorithms for medium-scale problems., Keywords: Scikit-learn, Python, Machine learning, Data mining, Scientific computing, Document Type: Journal Article, Language: English, Database/Indexing: JMLR / Scopus, Citation Key: pedregosa2011scikit.
 - [15] F. Ricci, L. Rokach, and B. Shapira, 2015, "Recommender Systems Handbook," *Springer*, 2nd ed., Springer New York, doi: 10.1007/978-1-4899-7637-6, ISSN: 978-1-4899-7636-9, URL: <https://doi.org/10.1007/978-1-4899-7637-6>, Abstract: Exhaustive reference handbook on content-based filtering, collaborative filtering, hybrid techniques, and evaluation., Keywords: Recommender systems, Hybrid recommendation, Content-based filtering, Collaborative filtering, Document Type: Book, Language: English, Database/Indexing: SpringerLink, Citation Key: ricci2015recommender.
 - [16] C. C. Aggarwal, 2016, "Recommender Systems: The Textbook," *Springer Nature*, Springer Cham, doi: 10.1007/978-3-319-29659-3, ISSN: 978-3-319-29658-6, URL: <https://doi.org/10.1007/978-3-319-29659-3>, Abstract: Foundational textbook covering mathematical algorithms and applications of recommender systems and distance similarity metrics., Keywords: Recommender systems, Collaborative filtering, Content-based models, Similarity metrics, Document Type: Book, Language: English, Database/Indexing: SpringerLink, Citation Key: aggarwal2016recommender.
 - [17] C. Lugaresi, J. Tang, H. Nash, C. McClanahan, E. Uboweja, M. Hays, et al., 2019, "MediaPipe: A Framework for Building Perception Pipelines," *arXiv preprint arXiv:1906.08172*, arXiv, URL: <https://arxiv.org/abs/1906.08172>, Abstract: Open-source modular framework enabling cross-platform streaming perception pipelines including 3D face mesh estimation., Keywords: MediaPipe, Real-time perception, Face mesh, Streaming pipelines, Mobile computer vision, Document Type: Preprint, Language: English, Database/Indexing: arXiv, Citation Key: lugaresi2019mediapipe.
 - [18] Z. Liu, P. Luo, X. Wang, and X. Tang, 2015, "Deep Learning Face Attributes in the Wild," *Proc. IEEE Int. Conf. Comput. Vis. (ICCV)*, pp. 3730–3738, IEEE, doi: 10.1109/ICCV.2015.425, URL: <https://doi.org/10.1109/ICCV.2015.425>, Abstract: Establishment of CelebA large-scale benchmark dataset and deep cascaded neural networks for facial attribute prediction., Keywords: CelebA, Face attributes, Deep learning, Face localization, Facial representation, Document Type: Conference Paper, Language: English, Database/Indexing: IEEE Xplore / Scopus, Citation Key: liu2015deep.
 - [19] G. Bradski, 2000, "The OpenCV Library," *Dr. Dobbs' Journal of Software Tools*, vol. 25, no. 11, pp. 120–125, Miller Freeman Inc., ISSN: 1044-789X, Abstract: Design, capabilities, and computational architecture of OpenCV real-time computer vision library., Keywords: OpenCV, Computer vision library, Real-time image processing, C/C++, Document Type: Journal Article, Language: English, Database/Indexing: Scopus, Citation Key: bradski2000opencv.
 - [20] N. Otsu, 1979, "A Threshold Selection Method from Gray-Level Histograms," *IEEE Transactions on Systems, Man, and Cybernetics*, vol. 9, no. 1, pp. 62–66, IEEE, doi: 10.1109/TSMC.1979.4310076, ISSN: 0018-9472, URL: <https://doi.org/10.1109/TSMC.1979.4310076>, Abstract: Classic non-parametric threshold selection technique maximizing discriminant between-class variance in image histograms., Keywords: Otsu thresholding, Image binarization, Gray-level histogram, Image segmentation, Document Type: Journal Article, Language: English, Database/Indexing: IEEE Xplore / Scopus, Citation Key: otsu1979threshold.
 - [21] R. C. Gonzalez and R. E. Woods, 2018, "Digital Image Processing," *Pearson Education Limited*, 4th ed., Pearson Education Limited, ISSN: 978-0133356724, Abstract: Comprehensive textbook covering spatial filtering, image restoration, color processing, segmentation, and feature extraction., Keywords: Digital image processing, Color spaces, Image segmentation, Feature extraction, Document Type: Book, Language: English, Database/Indexing: Google Books, Citation Key: gonzalez2018digital.
 - [22] S. J. Pan and Q. Yang, 2010, "A Survey on Transfer Learning," *IEEE Transactions on Knowledge and Data Engineering*, vol. 22, no. 10, pp. 1345–1359, IEEE, doi: 10.1109/TKDE.2009.191, ISSN: 1041-4347, URL: <https://doi.org/10.1109/TKDE.2009.191>, Abstract: Comprehensive taxonomy, categorization, and review of transfer learning algorithms across heterogeneous domains., Keywords: Transfer learning, Inductive transfer, Transductive learning, Domain adaptation, Document Type: Journal Article, Language: English, Database/Indexing: IEEE Xplore / Scopus, Citation Key: pan2010survey.
 - [23] K. He, X. Zhang, S. Ren, and J. Sun, 2016, "Deep Residual Learning for Image Recognition," *Proc. IEEE Conf. Computer Vision and Pattern Recognition (CVPR)*, pp. 770–778, IEEE, doi: 10.1109/CVPR.2016.90, URL: <https://doi.org/10.1109/CVPR.2016.90>, Abstract: Residual learning framework reformulating deep layers as learning residual functions with reference to layer inputs (ResNet)., Keywords: Deep residual learning, ResNet, Image classification, Deep convolutional networks, Document Type: Conference Paper, Language: English, Database/Indexing: IEEE Xplore / Scopus, Citation Key: he2016deep.

- [24] C. Shorten and T. M. Khoshgoftaar, 2019, "A Survey on Image Data Augmentation for Deep Learning," *Journal of Big Data*, vol. 6, no. 1, p. 60, SpringerOpen, doi: 10.1186/s40537-019-0197-0, ISSN: 2196-1115, URL: <https://doi.org/10.1186/s40537-019-0197-0>, Abstract: Comprehensive review of image data augmentation methods covering geometric transformations, color spaces, GANs, and meta-learning., Keywords: Data augmentation, Deep learning, Image classification, Regularization, Overfitting, Document Type: Journal Article, Language: English, Database/Indexing: SpringerLink / Scopus, Citation Key: shorten2019survey.
- [25] D. M. W. Powers, 2011, "Evaluation: From Precision, Recall and F-Measure to ROC, Informedness, Markedness and Correlation," *Journal of Machine Learning Technologies*, vol. 2, no. 1, pp. 37–63, Bioinfo Publications, ISSN: 2229-3981, Abstract: Rigorous mathematical examination and unified analysis of machine learning evaluation metrics and trade-offs., Keywords: Evaluation metrics, Precision, Recall, F-measure, ROC, Informedness, Document Type: Journal Article, Language: English, Database/Indexing: Google Scholar, Citation Key: powers2011evaluation.