

Perbandingan Akurasi ChatGPT Menggunakan Chain-of-Thought dan Non-Chain-of-Thought pada IndoMMLU

Elvira Gladys Samsul¹, Muhammad Arhami^{2*}, Muhammad Rizka³

^{1,2,3} Jurusan Teknologi Informasi dan Komputer, Politeknik Negeri Lhokseumawe, Indonesia

*Penulis Korespondensi: mhselvira@gmail.com

This is an open access article under the [CC-BY-SA](#) license.



Abstrak

Pemanfaatan *Large Language Model* (LLM) seperti ChatGPT semakin meluas dalam pemrosesan bahasa alami, namun kinerjanya pada bahasa daerah di Indonesia masih menghadapi tantangan keterbatasan korpus data. Penelitian ini bertujuan untuk membandingkan akurasi dan kemiripan jawaban ChatGPT menggunakan model GPT-4o mini melalui dua metode *prompting*, yaitu *Chain-of-Thought* (CoT) dan *Non-Chain-of-Thought* (Non-CoT). Evaluasi dilakukan menggunakan dataset *Indonesian Massive Multitask Language Understanding* (IndoMMLU) yang mencakup 9 domain bahasa: Bahasa Lampung, Bali, Makassar, Banjar, Madura, Indonesia, Dayak Ngaju, Sunda, dan Jawa. Pengujian dilakukan melalui empat skenario komprehensif, meliputi pengujian per domain bahasa (900 butir soal) serta tiga skenario *multi-domain* gabungan 9 bahasa daerah (225, 450, dan 900 butir soal). Pengukuran derajat kemiripan teks jawaban model terhadap jawaban referensi dihitung menggunakan algoritma *Levenshtein Distance*, yang kemudian dikonversi menjadi persentase *similarity* dan akurasi *exact match*. Hasil penelitian menunjukkan bahwa pada Skenario 1 (pengujian per domain), metode CoT menghasilkan rata-rata akurasi sebesar 53,67% (483/900 soal benar) dan *similarity* 67,66%, lebih unggul dibandingkan Non-CoT yang mencatat akurasi 50,44% (454/900 soal benar) dan *similarity* 66,65%. Peningkatan performa oleh CoT terjadi pada 5 domain, dengan kenaikan tertinggi pada Bahasa Bali (+11 soal) dan Bahasa Lampung (+10 soal). Namun, pada pengujian *multi-domain* skala besar (Skenario 4 dengan 900 butir soal), Non-CoT justru mencatat akurasi lebih tinggi (52,11% vs 50,67%) dan *similarity* lebih stabil (67,30% vs 65,55%). Dari aspek komputasi, CoT membutuhkan konsumsi token 5,18× hingga 5,44× lipat lebih banyak dan waktu latensi respons 3,5× hingga 3,8× lebih lama dibanding Non-CoT. Dengan demikian, penerapan CoT efektif memberikan penguatan penalaran pada domain bahasa tertentu dengan tingkat kesulitan tinggi, namun metode Non-CoT terbukti lebih efisien dan stabil untuk tugas klasifikasi pemahaman bahasa daerah berskala besar.

Kata kunci: ChatGPT, Chain-of-Thought, Non-Chain-of-Thought, IndoMMLU, Levenshtein Distance, Large Language Model, Bahasa Daerah.

1. Pendahuluan

Perkembangan teknologi *Artificial Intelligence* (AI) khususnya pada bidang *Natural Language Processing* (NLP) telah mengalami lompatan besar dengan diperkenalkannya *Large Language Model* (LLM) [1,2]. Salah satu implementasi LLM yang paling populer dan banyak digunakan di berbagai sektor adalah ChatGPT yang dikembangkan oleh OpenAI. ChatGPT memiliki kemampuan memahami instruksi pengguna, menggenerasi teks alami, serta melakukan penalaran logis dalam menjawab berbagai pertanyaan yang kompleks [3].

Meskipun menunjukkan kinerja yang sangat baik dalam bahasa beresumber daya tinggi (*high-resource language*) seperti Bahasa Inggris dan Bahasa Indonesia formal, performa LLM dalam memahami ragam bahasa daerah di Indonesia masih menjadi tantangan yang terbuka [4,5]. Indonesia memiliki lebih dari 700 bahasa daerah dengan struktur sintaksis, kosakata, dan konteks sosio-kultural yang unik. Keterbatasan ketersediaan korpus digital untuk bahasa daerah (*low-resource regional languages*) menyebabkan LLM sering kali mengalami kesalahan pemahaman semantik maupun halusinasi ketika merespons pertanyaan

berbasis bahasa daerah [6, 7].

Untuk mengoptimalkan kemampuan penalaran LLM tanpa melakukan proses pelatihan ulang model (*fine-tuning*) yang memakan biaya komputasi tinggi, teknik rekayasa *prompt* (*prompt engineering*) menjadi solusi yang sangat efektif [8, 9]. Dua pendekatan *prompting* utama yang sering digunakan adalah *Non-Chain-of-Thought* (Non-CoT) dan *Chain-of-Thought* (CoT). Non-CoT merupakan pendekatan konvensional yang meminta model memberikan jawaban akhir secara langsung (*direct answer*). Sebaliknya, pendekatan CoT mengarahkan model untuk menguraikan langkah-langkah pemikiran dan penalaran secara bertahap (*step-by-step reasoning*) sebelum sampai pada kesimpulan jawaban akhir [10, 11].

Penelitian terkini mengenai efektivitas CoT pada berbagai tugas penalaran multi-bahasa menunjukkan hasil yang bervariasi. Sejumlah studi membuktikan bahwa CoT mampu meningkatkan akurasi model pada tugas penalaran matematika, logika, dan sains secara signifikan [8, 12]. Namun, efektivitas CoT pada domain bahasa daerah di Indonesia yang memiliki keragaman dialek dan struktur morfologi kompleks belum banyak dievaluasi secara komprehensif dan kuantitatif [4]. Selain itu, pendekatan CoT menghasilkan teks penalaran yang panjang sehingga berdampak langsung pada lonjakan konsumsi token dan latensi komputasi API [13, 14].

Oleh karena itu, penelitian ini bertujuan untuk menganalisis dan membandingkan akurasi jawaban ChatGPT (menggunakan model GPT-4o mini) dengan metode *Chain-of-Thought* dan *Non-Chain-of-Thought* pada *benchmark* dataset IndoMMLU [4]. Evaluasi dilakukan pada 9 domain bahasa (Bahasa Lampung, Bali, Makassar, Banjar, Madura, Indonesia, Dayak Ngaju, Sunda, dan Jawa) yang mencakup 4 skenario pengujian. Tingkat akurasi dan derajat kemiripan teks jawaban model terhadap kunci jawaban referensi diukur secara objektif menggunakan algoritma *Levenshtein Distance* [15, 16], serta dilengkapi dengan analisis efisiensi komputasi terhadap jumlah token dan waktu respons.

2. Metode

2.1 Arsitektur Sistem Evaluasi

Sistem evaluasi dirancang untuk menguji performa model GPT-4o mini secara otomatis dan terukur. Arsitektur sistem terdiri atas dua subsistem utama, yaitu tahap *preprocessing* dataset IndoMMLU dan tahap evaluasi akurasi jawaban menggunakan OpenAI API yang terintegrasi dengan algoritma pengukuran kemiripan teks *Levenshtein Distance*. Alur kerja sistem disajikan pada Gambar 1.




Figure 1: Arsitektur Sistem Evaluasi

2.2 Dataset Penelitian dan Tahapan Preprocessing

Dataset yang digunakan dalam penelitian ini bersumber dari *Indonesian Massive Multitask Language Understanding* (IndoMMLU) [4]. Penelitian ini memfokuskan pada 9 domain bahasa, yaitu Bahasa Lampung, Bahasa Bali, Bahasa Makassar, Bahasa Banjar, Bahasa Madura, Bahasa Indonesia, Bahasa Dayak Ngaju, Bahasa Sunda, dan Bahasa Jawa. Masing-masing domain bahasa terdiri atas 100 butir soal pilihan ganda (*multiple-choice questions*), sehingga total sampel data primer berjumlah 900 butir soal.

Sebelum pengujian, dataset IndoMMLU mentah melalui empat tahapan *preprocessing*: (1) **Filtering Domain Bahasa**, yaitu menyaring data soal agar hanya memuat 9 domain bahasa yang diteliti; (2) **Seleksi dan Penataan Kolom Data**, yaitu memilih atribut penting (*nomor*, *subject*, *soal*, *jawaban*, dan *kunci*); (3) **Pembentukan Narasi Jawaban Referensi** (*jawaban_benar_teks*), yaitu mengekstrak teks murni pilihan jawaban benar secara otomatis berdasarkan kolom kunci tanpa huruf opsi (A/B/C/D/E) untuk evaluasi kemiripan teks; serta (4) **Normalisasi Format Teks**, yaitu menyeragamkan format UTF-8 dan membersihkan karakter spasi berlebih. Struktur master dataset hasil *preprocessing* disajikan pada Tabel 1.

Table 1: Struktur Kolom Dataset IndoMMLU Hasil Preprocessing

No	Nama Data	Sumber	Keterangan
1	nomor	IndoMMLU	Penanda urutan nomor soal
2	subject	IndoMMLU	Penanda domain bahasa soal
3	soal	IndoMMLU	Teks pertanyaan pilihan ganda
4	jawaban	IndoMMLU	Opsi pilihan jawaban pilihan ganda (A, B, C, D, E)
5	kunci	IndoMMLU	Penanda huruf jawaban benar dalam format A/B/C/D/E
6	jawaban_benar_teks	Preprocessing	Teks narasi jawaban benar hasil ekstraksi otomatis dari kolom kunci

2.3 Perancangan Prompt Pengujian (Non-CoT vs CoT)

Perancangan *prompt* bertujuan mengarahkan model menghasilkan format keluaran yang konsisten. Perbandingan struktur *prompt* Non-CoT dan CoT disajikan pada Gambar 2.

Prompt Non-CoT	Prompt Chain-of-Thought (CoT)
Instruksi: "Jawablah pertanyaan berikut. Berikan hanya jawaban akhir teks tanpa opsi (A/B/C/D/E)." Struktur Input: Soal: {soal} Pilihan: {pilihan jawaban} Karakteristik Output: • Memberikan jawaban teks langsung • Tanpa penalaran berbelit • Efisiensi token & latensi tinggi	Instruksi: "Jawablah pertanyaan berikut dengan berpikir langkah demi langkah untuk menyelesaikan soal ini secara logis." Struktur Input: Soal: {soal} Pilihan: {pilihan jawaban} Format Jawaban Akhir: "Setelah menjelaskan langkah penyelesaiannya, lalu di baris terakhir tulis format eksak: Jawaban akhir: [Teks jawaban tanpa huruf opsi]"

Figure 2: Perancangan dan Perbandingan Format Prompt Non-Chain-of-Thought (Non-CoT) dan Chain-of-Thought (CoT)

Penjelasan kedua format *prompt* adalah sebagai berikut:

1. **Prompt Non-Chain-of-Thought (Non-CoT):** Model diinstruksikan memberikan jawaban akhir secara langsung tanpa uraian langkah penalaran: "*Jawablah pertanyaan berikut. Berikan hanya jawaban akhir teks tanpa opsi (A/B/C/D/E)*". Format ini menghasilkan respons singkat dengan konsumsi token minimal.
2. **Prompt Chain-of-Thought (CoT):** Model diinstruksikan melakukan penalaran bertahap sebelum menyimpulkan jawaban: "*Jawablah pertanyaan berikut dengan berpikir langkah demi langkah... lalu di baris terakhir tulis format eksak: Jawaban akhir: [Teks jawaban tanpa huruf opsi]*". Sistem mengekstrak baris jawaban akhir tersebut untuk dievaluasi.

2.4 Model LLM dan Konfigurasi Pengujian

Model LLM yang digunakan adalah **GPT-4o mini** (gpt-4o-mini-2024-07-18) yang diakses melalui OpenAI REST API. Model ini dipilih karena memiliki efisiensi komputasi tinggi, latensi rendah, serta kapabilitas penalaran yang unggul [14]. Seluruh pengujian dijalankan dengan parameter suhu (*temperature*) $T = 0,0$ guna memastikan determinisme keluaran respons model [1].

2.5 Skenario Pengujian

Evaluasi disusun ke dalam 4 skenario komprehensif:

- **Skenario 1 (Baseline Per Domain):** Pengujian dilakukan pada masing-masing dari 9 domain bahasa secara terpisah dengan 100 butir soal per domain (total 900 butir soal).
- **Skenario 2 (Multi-Domain 225 Soal):** Pengujian acak gabungan dari seluruh 9 domain bahasa dengan proporsi 25 soal per domain (total 225 butir soal).
- **Skenario 3 (Multi-Domain 450 Soal):** Pengujian acak gabungan dari seluruh 9 domain bahasa dengan proporsi 50 soal per domain (total 450 butir soal).
- **Skenario 4 (Multi-Domain Skala Penuh 900 Soal):** Pengujian acak gabungan seluruh 9 domain bahasa dengan proporsi 100 soal per domain (total 900 butir soal).

2.6 Rumus Matematis dan Metrik Pengukuran

Untuk mengukur derajat kemiripan teks jawaban model terhadap jawaban referensi secara kuantitatif, digunakan algoritma *Levenshtein Distance* [15].

2.6.1 Perhitungan Jarak Levenshtein

Diberikan dua string teks, yaitu string jawaban model s dengan panjang $m = \text{len}(s)$ dan string referensi t dengan panjang $n = \text{len}(t)$. Matriks jarak Levenshtein $\text{lev}(i, j)$ berukuran $(m + 1) \times (n + 1)$ dihitung melalui Persamaan (1):

$$\text{lev}_{s,t}(i, j) = \begin{cases} i, & \text{jika } j = 0 \\ j, & \text{jika } i = 0 \\ \text{lev}_{s,t}(i - 1, j - 1), & \text{jika } s[i] = t[j] \\ 1 + \min \begin{cases} \text{lev}_{s,t}(i - 1, j) & (\text{deletion}) \\ \text{lev}_{s,t}(i, j - 1) & (\text{insertion}) \\ \text{lev}_{s,t}(i - 1, j - 1) & (\text{substitution}) \end{cases}, & \text{jika } s[i] \neq t[j] \end{cases} \quad (1)$$

di mana $\text{lev}(m, n)$ menyatakan jumlah operasi edit minimum untuk mengubah string s menjadi string t .

2.6.2 Persentase Kemiripan Teks (*Similarity Score*)

Berdasarkan jarak Levenshtein $\text{lev}(m, n)$, persentase kemiripan dihitung menggunakan Persamaan (2):

$$\text{Similarity}(s, t) = \left(1 - \frac{\text{lev}_{s,t}(m, n)}{\max(m, n)}\right) \times 100\% \quad (2)$$

2.6.3 Rata-rata Kemiripan Teks (*Average Similarity*)

Rata-rata persentase kemiripan untuk suatu skenario pengujian dengan N butir soal dihitung dengan Persamaan (3):

$$\text{Similarity}_{\text{avg}} = \frac{1}{N} \sum_{k=1}^N \text{Similarity}_k \quad (3)$$

2.6.4 Akurasi Pencocokan Eksak (*Exact Match Accuracy*)

Butir soal bernilai benar (*Exact Match*) jika teks jawaban model identik dengan jawaban referensi ($\text{Similarity}_k = 100\%$). Akurasi keseluruhan dihitung melalui Persamaan (4) dan (5):

$$\text{Accuracy} = \frac{\sum_{k=1}^N \text{Correct}_k}{N} \times 100\% \quad (4)$$

$$\text{Correct}_k = \begin{cases} 1, & \text{jika } \text{Similarity}_k = 100\% \\ 0, & \text{jika } \text{Similarity}_k < 100\% \end{cases} \quad (5)$$

Proses evaluasi sistematis dirangkum pada Algoritma 1.

Algorithm 1 Prosedur Evaluasi Akurasi ChatGPT Menggunakan Levenshtein Distance

Require: Dataset IndoMMLU $\mathcal{D} = \{(Q_k, O_k, R_k)\}_{k=1}^N$, Model GPT-4o mini $\mathcal{M}$, Mode $\in \{\text{Non-CoT}, \text{CoT}\}$

Ensure: Metrik Akurasi (%) dan Rata-rata Similarity (%)

```

1:  $total\_correct \leftarrow 0$ ,  $sum\_similarity \leftarrow 0$ 
2: for each  $(Q_k, O_k, R_k) \in \mathcal{D}$  do
3:    $prompt_k \leftarrow \text{GeneratePrompt}(\text{Mode}, Q_k, O_k)$ 
4:    $response_k \leftarrow \text{CallOpenAI\_API}(\mathcal{M}, prompt_k, \text{temp} = 0.0)$ 
5:    $ans_k \leftarrow \text{ExtractAnswer}(\text{Mode}, response_k)$ 
6:    $m \leftarrow \text{len}(ans_k)$ ,  $n \leftarrow \text{len}(R_k)$ 
7:    $dist_k \leftarrow \text{ComputeLevenshtein}(ans_k, R_k, m, n)$  ▷ Persamaan (1)
8:    $sim_k \leftarrow (1 - dist_k / \max(m, n)) \times 100\%$  ▷ Persamaan (2)
9:    $sum\_similarity \leftarrow sum\_similarity + sim_k$ 
10:  if  $sim_k == 100\%$  then
11:     $total\_correct \leftarrow total\_correct + 1$ 
12:  end if
13: end for
14:  $\text{Accuracy} \leftarrow (total\_correct / N) \times 100\%$ 
15:  $\text{Similarity}_{\text{avg}} \leftarrow sum\_similarity / N$ 
16: return  $\text{Accuracy}, \text{Similarity}_{\text{avg}}$ 

```

3. Hasil dan Pembahasan

3.1 Hasil Pengujian Per Domain Bahasa (Skenario 1)

Pengujian Skenario 1 dilakukan secara independen terhadap 9 domain bahasa IndoMMLU dengan 100 butir soal per domain (total 900 butir soal). Hasil perbandingan skor kemiripan (*similarity*) dan akurasi jumlah soal benar disajikan pada Tabel 2.

Table 2: Perbandingan Hasil Pengujian Skenario 1 Per Domain Bahasa

Domain Bahasa	Similarity Non-CoT	Similarity CoT	Soal Benar Non-CoT	Soal Benar CoT	Metode Unggul
Bahasa Lampung	61,60%	66,92%	46/100 (46%)	56/100 (56%)	CoT (+10)
Bahasa Bali	55,49%	62,14%	38/100 (38%)	49/100 (49%)	CoT (+11)
Bahasa Makassar	59,88%	59,39%	37/100 (37%)	37/100 (37%)	Setara
Bahasa Banjar	62,77%	61,03%	45/100 (45%)	45/100 (45%)	Setara
Bahasa Madura	59,36%	55,06%	40/100 (40%)	37/100 (37%)	Non-CoT (+3)
Bahasa Indonesia	93,86%	95,92%	90/100 (90%)	94/100 (94%)	CoT (+4)
Bahasa Dayak Ngaju	61,02%	57,88%	33/100 (33%)	33/100 (33%)	Setara
Bahasa Sunda	69,70%	73,39%	62/100 (62%)	66/100 (66%)	CoT (+4)
Bahasa Jawa	76,18%	77,23%	63/100 (63%)	66/100 (66%)	CoT (+3)
Rata-rata / Total	66,65%	67,66%	454/900 (50,44%)	483/900 (53,67%)	CoT Unggul (+29)

Berdasarkan Tabel 2, **Bahasa Indonesia** mencapai performa tertinggi dengan skor *similarity* 95,92% dan akurasi 94%, mengonfirmasi representasi korpus bahasa nasional yang sangat kuat pada model. Pada rumpun bahasa daerah, **Bahasa Jawa** (77,23%, 66 benar) dan **Bahasa Sunda** (73,39%, 66 benar) menempati posisi tertinggi. Sebaliknya, bahasa daerah dengan sumber daya rendah seperti **Bahasa Dayak Ngaju** dan **Bahasa Makassar** hanya mencapai akurasi 33% dan 37%.

Metode CoT berhasil meningkatkan jumlah jawaban benar pada 5 domain (Lampung, Bali, Indonesia, Sunda, Jawa) dengan peningkatan terbesar pada Bahasa Bali (+11 soal) dan Bahasa Lampung (+10 soal). Pada 3 domain (Makassar, Banjar, Dayak Ngaju), kedua metode menghasilkan akurasi identik. Namun, pada **Bahasa Madura**, Non-CoT justru lebih unggul (40 vs 37 soal), menunjukkan bahwa penalaran buatan model pada kosakata Madura tertentu rentan mengalami halusinasi leksikal (*reasoning error*). Rincian distribusi klasifikasi jawaban per butir soal disajikan pada Tabel 3.

Table 3: Rincian Distribusi Kebenaran Jawaban Per Butir Soal pada Skenario 1

Domain Bahasa	Kedua Metode Benar	Hanya Non-CoT Benar	Hanya CoT Benar	Kedua Metode Salah
Bahasa Lampung	36	10	20	34
Bahasa Bali	27	11	22	40
Bahasa Makassar	24	13	13	50
Bahasa Banjar	31	14	14	41
Bahasa Madura	20	20	17	43
Bahasa Indonesia	88	2	6	4
Bahasa Dayak Ngaju	20	13	13	54
Bahasa Sunda	54	8	12	26
Bahasa Jawa	55	8	11	26
Total Butir	355	99	128	318

3.2 Hasil Pengujian Multi-Domain (Skenario 2, 3, dan 4)

Evaluasi gabungan domain dilakukan untuk menguji stabilitas performa penalaran model saat menghadapi perpindahan konteks bahasa daerah secara acak dan simultan. Hasil pengujian multi-domain dirangkum pada Tabel 4.

Table 4: Perbandingan Performa Pengujian Multi-Domain (Skenario 2, 3, dan 4)

Skenario Pengujian	Metode	Similarity (%)	Soal Benar / Akurasi	Total Token	Rata-rata Latensi (s)
Skenario 2 (Multi-Domain)	Non-CoT	68,60%	121 / 225 (53,78%)	16.307	1,77 s
(9 Bahasa × 25 Soal = 225)	CoT	68,27%	123 / 225 (54,67%)	88.819	5,16 s
Skenario 3 (Multi-Domain)	Non-CoT	70,18%	247 / 450 (54,89%)	34.068	1,42 s
(9 Bahasa × 50 Soal = 450)	CoT	69,37%	249 / 450 (55,33%)	180.602	5,00 s
Skenario 4 (Multi-Domain)	Non-CoT	67,30%	469 / 900 (52,11%)	71.908	1,46 s
(9 Bahasa × 100 Soal = 900)	CoT	65,55%	456 / 900 (50,67%)	372.965	5,48 s

3.3 Analisis Komparatif Gabungan 4 Skenario

Untuk memberikan pemahaman visual mengenai dinamika performa pada seluruh skenario, perbandingan akurasi *exact match* dan skor kemiripan disajikan pada Gambar 3.




Figure 3: Grafik Perbandingan Komparatif Performa Metode Non-CoT dan CoT pada Seluruh Skenario Pengujian (Skenario 1–4): (a) Akurasi Exact Match (%), (b) Skor Kemiripan Levenshtein (%)

Berdasarkan Tabel 4 dan Gambar 3, terdapat beberapa temuan empiris utama:

1. Pada Skenario 1–3, metode CoT menunjukkan keunggulan pada akurasi *exact match* (+3,23% pada Skenario 1, +0,89% pada Skenario 2, dan +0,44% pada Skenario 3). Namun, margin keunggulan tersebut semakin menyempit seiring bertambahnya variasi domain dan jumlah data.
2. Pada skor kemiripan *similarity* Skenario 2 dan 3, Non-CoT mencatat skor lebih tinggi dibanding CoT (68,60% vs 68,27% dan 70,18% vs 69,37%). Hal ini disebabkan respons CoT yang menyertakan narasi penalaran tambahan sehingga memperbesar jarak Levenshtein ketika teks jawaban akhir tidak terisolasi secara sempurna.
3. Pada **Skenario 4 (skala penuh 900 butir soal)**, metode Non-CoT berbalik unggul mutlak atas CoT baik dari segi akurasi (52,11% vs 50,67%) maupun skor kemiripan (67,30% vs 65,55%). Pada volume data besar dengan pergantian bahasa daerah secara acak, model rentan mengalami disorientasi konteks semantik (*context drift*) selama proses penalaran langkah demi langkah.

3.4 Analisis Trade-Off Efisiensi Komputasi (Token dan Latensi)

Evaluasi aspek efisiensi komputasi menunjukkan bahwa metode *Chain-of-Thought* membutuhkan konsumsi sumber daya yang jauh lebih besar:

- **Penggunaan Token:** Metode CoT mengonsumsi rata-rata 5,18× **hingga** 5,44× **lipat** lebih banyak token dibandingkan Non-CoT (contoh pada Skenario 4: 372.965 token CoT berbanding 71.908 token Non-CoT).
- **Waktu Respons (Latensi):** Rata-rata waktu inferensi CoT berkisar antara **5,00–5,48 detik per soal**, atau 3,5× **hingga** 3,8× **lebih lambat** dibandingkan Non-CoT yang hanya memerlukan **1,42–1,77 detik per soal**.

Dengan margin peningkatan akurasi CoT yang sangat tipis pada pengujian per domain (+3,23%) dan

penurunan akurasi pada pengujian multi-domain skala besar (-1,44%), penggunaan CoT untuk soal pilihan ganda bahasa daerah dinilai **kurang efisien dari segi biaya operasional (*cost-inefficient*)**.

4. Kesimpulan

Berdasarkan hasil evaluasi dan pembahasan yang telah dilakukan, dapat ditarik kesimpulan sebagai berikut:

1. Metode *Chain-of-Thought* (CoT) terbukti efektif meningkatkan akurasi jawaban ChatGPT (GPT-4o mini) pada pengujian per domain bahasa (Skenario 1) dengan akurasi 53,67% (483/900 soal benar) dan *similarity* 67,66%, mengungguli Non-CoT yang mencatat akurasi 50,44% (454/900 soal benar) dan *similarity* 66,65%. Peningkatan signifikan terjadi pada Bahasa Bali (+11 soal) dan Bahasa Lampung (+10 soal).
2. Bahasa Indonesia mencatat performa tertinggi (akurasi 94%, *similarity* 95,92%), diikuti oleh Bahasa Jawa (77,23%) dan Bahasa Sunda (73,39%). Sementara itu, bahasa daerah beresumber daya rendah seperti Bahasa Dayak Ngaju (33%) dan Bahasa Makassar (37%) memiliki akurasi terendah karena keterbatasan data latih korpus bahasa daerah pada LLM.
3. Pada pengujian *multi-domain* skala penuh (Skenario 4), metode Non-CoT mencatat performa yang lebih unggul dibandingkan CoT, baik dari segi akurasi (52,11% vs 50,67%) maupun *similarity* (67,30% vs 65,55%) akibat kerentanan CoT terhadap disorientasi penalaran pada perpindahan bahasa yang dinamis.
4. Metode CoT membutuhkan konsumsi token $5,18 \times - 5,44 \times$ lebih besar dan latensi waktu $3,5 \times - 3,8 \times$ lebih lambat dibandingkan Non-CoT. Untuk tugas klasifikasi pemahaman bahasa daerah berbasis pilihan ganda, metode Non-CoT direkomendasikan sebagai pilihan yang jauh lebih efisien dan stabil.

Saran untuk pengembangan penelitian selanjutnya antara lain:

1. Menerapkan teknik *Few-Shot CoT* dengan menyertakan contoh penalaran dalam bahasa daerah yang relevan untuk meminimalkan halusinasi semantik.
2. Melakukan pengujian perbandingan pada model LLM multibahasa sumber terbuka (*open-source*) seperti Llama 3 atau Mistral guna membandingkan ketahanan pemahaman bahasa daerah di luar ekosistem OpenAI.
3. Mengintegrasikan korpus kamus bahasa daerah melalui pendekatan *Retrieval-Augmented Generation* (RAG) guna memperkaya pengetahuan leksikal model secara dinamis.

REFERENSI

- [1] T. B. Brown, B. Mann, N. Ryder, M. Subbiah, J. Kaplan, P. Dhariwal *et al.*, "Language Models are Few-Shot Learners," in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 33, 2020, pp. 1877–1901.
- [2] J. Achiam, S. Adler, S. Agarwal, L. Ahmad, I. Akkaya, F. L. Aleman *et al.*, "GPT-4 Technical Report," *arXiv preprint arXiv:2303.08774*, 2023.
- [3] S. Bubeck, V. Chandrasekaran, R. Eldan, J. Gehrke, E. Horvitz, E. Kamar *et al.*, "Sparks of Artificial General Intelligence: Early experiments with GPT-4," *arXiv preprint arXiv:2303.12712*, 2023.
- [4] F. Koto, N. H. Prasjo, and E. A. Rachman, "IndoMMLU: A Multi-Task Language Understanding Benchmark for Indonesian and Local Languages," in *Proc. 2023 Conf. Empir. Methods Nat. Lang. Process. (EMNLP)*, 2023, pp. 11210–11225.
- [5] A. F. Aji, G. I. Winata, R. F. Sari, E. Bradshaw, Z. Liu, P. Fung *et al.*, "One Country, 700+ Languages: NLP Challenges for Underrepresented Languages and Dialects in Indonesia," in *Proc. 60th Annu. Meet. Assoc. Comput. Linguist. (ACL)*, 2022, pp. 7226–7249.
- [6] S. Cahyawijaya, G. I. Winata, B. Wilie, K. Vincent, X. Li, J. D. Kuncoro *et al.*, "IndoNLP: Benchmark and Resources for Evaluating Indonesian Natural Language Generation," in *Proc. 2021 Conf. Empir. Methods Nat. Lang. Process. (EMNLP)*, 2021, pp. 8875–8898.
- [7] G. I. Winata, A. F. Aji, Z. Zheng, S. Cahyawijaya, D. I. Adelani, Z. Liu *et al.*, "NusaX: Multilingual Parallel Sentiment Dataset for 10 Indonesian Local Languages," in *Proc. 17th Conf. Eur. Chapter Assoc. Comput. Linguist. (EACL)*, 2023, pp. 2420–2434.
- [8] J. Wei, X. Wang, D. Schuurmans, M. Bosma, F. Xia, E. Chi, Q. V. Le, and D. Zhou, "Chain-of-Thought Prompting Elicits Reasoning in Large Language Models," in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 35, 2022, pp. 24824–24837.
- [9] T. Kojima, S. S. Gu, M. Reid, Y. Matsuo, and Y. Iwasawa, "Large Language Models are Zero-Shot Reasoners," in *Proc. Adv. Neural Inf. Process. Syst. (NeurIPS)*, vol. 35, 2022, pp. 22199–22213.
- [10] X. Wang, J. Wei, D. Schuurmans, Q. Le, E. Chi, S. Narang, A. Chowdhery, and D. Zhou, "Self-Consistency Improves Chain of Thought Reasoning in Language Models," in *Proc. 11th Int. Conf. Learn. Represent. (ICLR)*, 2023.
- [11] Z. Zhang, A. Zhang, M. Li, and A. Smola, "Automatic Chain of Thought Prompting in Large Language Models," in *Proc. 11th Int. Conf. Learn. Represent. (ICLR)*, 2023.

- [12] D. Zhou, N. Schärli, L. Hou, J. Wei, N. Scales, X. Wang *et al.*, “Least-to-Most Prompting Enables Complex Reasoning in Large Language Models,” in *Proc. 11th Int. Conf. Learn. Represent. (ICLR)*, 2023.
- [13] L. Chen, M. Zaharia, and J. Zou, “FrugalGPT: How to Use Large Language Models While Reducing Cost and Improving Accuracy,” *arXiv preprint arXiv:2305.05176*, 2023.
- [14] OpenAI, “GPT-4o mini: Advancing Cost-Efficient Intelligence,” OpenAI Blog, 2024. [Daring]. Tersedia: <https://openai.com/index/gpt-4o-mini-advancing-cost-efficient-intelligence/>.
- [15] V. I. Levenshtein, “Binary Codes Capable of Correcting Deletions, Insertions, and Reversals,” *Soviet Physics Doklady*, vol. 10, no. 8, pp. 707–710, 1966.
- [16] G. Navarro, “A Guided Tour to Approximate String Matching,” *ACM Comput. Surv.*, vol. 33, no. 1, pp. 31–88, 2001, doi: 10.1145/398738.398744.
- [17] D. Jurafsky and J. H. Martin, *Speech and Language Processing: An Introduction to Natural Language Processing, Computational Linguistics, and Speech Recognition*, 3rd ed. draft. Stanford, CA, USA, 2024.
- [18] C. D. Manning, P. Raghavan, and H. Schütze, *Introduction to Information Retrieval*. Cambridge, UK: Cambridge University Press, 2008, doi: 10.1017/CBO9780511809071.
- [19] D. Hendrycks, C. Burns, S. Basart, A. Zou, M. Mazeika, D. Song, and J. Steinhardt, “Measuring Massive Multitask Language Understanding,” in *Proc. 9th Int. Conf. Learn. Represent. (ICLR)*, 2021.
- [20] K. Papineni, S. Roukos, T. Ward, and W.-J. Zhu, “BLEU: A Method for Automatic Evaluation of Machine Translation,” in *Proc. 40th Annu. Meet. Assoc. Comput. Linguist. (ACL)*, 2002, pp. 311–318.
- [21] C.-Y. Lin, “ROUGE: A Package for Automatic Evaluation of Summaries,” in *Text Summarization Branches Out: Proc. ACL-04 Workshop*, 2004, pp. 74–81.
- [22] S. Banerjee and A. Lavie, “METEOR: An Automatic Metric for MT Evaluation with Improved Correlation with Human Judgments,” in *Proc. ACL Workshop Intrinsic Extrinsic Eval. Meas. MT/Summarization*, 2005, pp. 65–72.
- [23] S. Cahyawijaya, H. Lovenia, A. F. Aji, G. I. Winata, B. Wilie, K. Vincent *et al.*, “NusaCrowd: Open Source Initiative for Indonesian NLP Resources,” in *Proc. 61st Annu. Meet. Assoc. Comput. Linguist. (ACL)*, 2023, pp. 13745–13818.
- [24] H. Touvron, L. Martin, K. Stone, P. Albert, A. Almahairi, Y. Babaei *et al.*, “Llama 2: Open Foundation and Fine-Tuned Chat Models,” *arXiv preprint arXiv:2307.09288*, 2023.
- [25] A. Q. Jiang, A. Sablayrolles, A. Mensch, C. Bamford, D. S. Chaplot, D. d. l. Casas *et al.*, “Mistral 7B,” *arXiv preprint arXiv:2310.06825*, 2023.