

Perbandingan Akurasi ChatGPT Menggunakan Chain-of-Thought dan Non-Chain-of-Thought pada IndoMMLU

Elvira Gladys Samsul¹, Muhammad Arhami^{2*}, Muhammad Rizka³

^{1,2,3} Jurusan Teknologi Informasi dan Komputer, Politeknik Negeri Lhokseumawe, Indonesia

*Penulis Korespondensi: muhammad.arhami@pnl.ac.id

This is an open access article under the [CC-BY-SA](https://creativecommons.org/licenses/by-sa/4.0/) license.



Abstrak

Perkembangan Large Language Model (LLM) seperti ChatGPT meningkatkan kemampuan pemahaman bahasa alami, namun kemampuannya dalam konteks bahasa dan budaya lokal Indonesia masih perlu dievaluasi karena sebagian besar pengujian dilakukan menggunakan dataset berbahasa Inggris. Penelitian ini mengukur akurasi jawaban GPT-4o mini pada soal Multiple Choice Question (MCQ) dataset IndoMMLU domain bahasa menggunakan algoritma Levenshtein Distance, serta membandingkan efektivitas metode Chain-of-Thought (CoT) dan Non-Chain-of-Thought (Non-CoT). Pengujian dilakukan melalui empat skenario terhadap sembilan domain bahasa daerah dengan total hingga 900 soal, mengukur nilai similarity, akurasi exact match, penggunaan token, dan waktu respons. Hasil menunjukkan pengujian per domain menghasilkan similarity rata-rata 65,42% (CoT) dan 63,81% (Non-CoT), dengan 483 dan 454 jawaban benar dari 900 soal. Pada pengujian gabungan skala besar, Non-CoT justru lebih stabil dengan similarity tertinggi 70,18% dibanding CoT 69,37%. Bahasa Indonesia mencapai similarity tertinggi (95,92%), sedangkan bahasa daerah lain berkisar 55,49%–77,23%. CoT membutuhkan token sekitar 5,2 kali lebih besar dan waktu respons empat hingga enam kali lebih lama dibanding Non-CoT. Temuan ini menunjukkan bahwa efektivitas Chain-of-Thought tidak konsisten meningkatkan kualitas jawaban GPT-4o mini, melainkan bergantung pada karakteristik domain bahasa dan skala pengujian.

Kata kunci: ChatGPT, Chain-of-Thought, Non-Chain-of-Thought, IndoMMLU, Levenshtein Distance, Large Language Model, Bahasa Daerah.

1. Pendahuluan

Perkembangan teknologi *Artificial Intelligence* (AI) khususnya pada bidang *Natural Language Processing* (NLP) telah mengalami kemajuan pesat berkat arsitektur model transformator (*Transformers*) [25]. Implementasi *Large Language Model* (LLM) seperti ChatGPT yang berbasis *Generative Pre-trained Transformer* (GPT) memiliki kemampuan generasi teks alami, merespons instruksi multibahasa, serta menyelesaikan penalaran kompleks pada berbagai disiplin ilmu [3, 5]. Diperkenalkannya model mutakhir seperti GPT-4o mini menghadirkan kemampuan pemrosesan bahasa yang berkecepatan tinggi dengan biaya komputasi yang jauh lebih terjangkau, sehingga banyak diadaptasi untuk evaluasi akademik maupun otomatisasi penalaran bahasa [4].

Meskipun menunjukkan kinerja luar biasa pada bahasa beresumber daya tinggi (*high-resource languages*) seperti Bahasa Inggris dan evaluasi penalaran terstandarisasi [8], kapabilitas LLM dalam memahami ragam bahasa lokal di Indonesia masih menghadapi tantangan mendasar [1]. Indonesia memiliki ratusan bahasa daerah dengan keunikan struktur sintaksis, tingkatan tutur, dan morfologi yang kompleks. Keterbatasan ketersediaan korpus data digital lokal menyebabkan LLM kerap mengalami kegagalan inferensi makna, ambiguitas leksikal, maupun kesalahan faktual (*hallucination*) pada saat merespons pertanyaan berbasis bahasa daerah [1, 19]. Evaluasi empiris menggunakan format *Multiple Choice Question* (MCQ) menjadi tolok ukur standar dalam menguji pemahaman faktual model bahasa, meskipun format tersebut memiliki karakteristik sensitivitas posisi opsi dan membutuhkan analisis kemiripan yang ketat [9].

Guna mengoptimalkan akurasi dan penalaran LLM tanpa memerlukan proses pelatihan ulang (*fine-tuning*) yang mahal, rekayasa *prompt* (*prompt engineering*) menjadi instrumen utama [7, 22]. Dua pendekatan pengujian yang banyak dikaji adalah *Non-Chain-of-Thought* (Non-CoT) dan *Chain-of-Thought* (CoT). Non-CoT meminta model memberikan kesimpulan akhir secara instan (*direct answer*). Sebaliknya, CoT mengarahkan model untuk menguraikan tahapan

berpikir logis secara terstruktur (*step-by-step reasoning*) sebelum menarik kesimpulan jawaban akhir [6, 21, 23]. Berbagai studi membuktikan efektivitas CoT dalam meningkatkan akurasi inferensi pada berbagai domain spesifik seperti evaluasi medis, konsultasi terapi, hingga penilaian jawaban otomatis [4, 10–12]. Namun demikian, pengujian efektivitas CoT pada pemahaman ragam bahasa daerah di Indonesia yang bersumber dari *benchmark* IndoMMLU masih sangat terbatas dan memerlukan investigasi yang komprehensif [1].

Di sisi lain, evaluasi jawaban teks LLM terhadap kunci referensi memerlukan pendekatan kuantitatif yang objektif di luar pencocokan label biner sederhana. Pengukuran derajat kemiripan teks menggunakan algoritma *Levenshtein Distance* terbukti andal dalam menganalisis variasi string teks, mendeteksi penyimpangan leksikal, serta mengukur akurasi dan presisi pada perbandingan sekuens di berbagai domain ilmiah [2, 13–18, 24]. Pemanfaatan matriks jarak Levenshtein memungkinkan penghitungan persentase kemiripan (*similarity score*) dan akurasi pencocokan eksak (*exact match*) secara matematis dan terstruktur [15, 17].

Oleh karena itu, penelitian ini bertujuan untuk melakukan analisis komparatif performa ChatGPT (GPT-4o mini) menggunakan metode CoT dan Non-CoT pada 9 domain bahasa lokal dari dataset IndoMMLU (Bahasa Lampung, Bali, Makassar, Banjar, Madura, Indonesia, Dayak Ngaju, Sunda, dan Jawa) melalui metodologi tinjauan state-of-the-art yang sistematis [1, 20]. Evaluasi dilakukan secara komprehensif melalui 4 skenario pengujian dengan mengukur akurasi *exact match*, skor kemiripan berbasis *Levenshtein Distance* [15, 16], serta analisis *trade-off* terhadap efisiensi konsumsi token dan waktu respons komputasi.

2. Metode

2.1 Arsitektur Sistem Evaluasi

Sistem evaluasi dirancang untuk menguji performa model GPT-4o mini secara otomatis dan terukur. Arsitektur sistem terdiri atas dua subsistem utama, yaitu tahap *preprocessing* dataset IndoMMLU dan tahap evaluasi akurasi jawaban menggunakan OpenAI API yang terintegrasi dengan algoritma pengukuran kemiripan teks *Levenshtein Distance*. Alur kerja sistem disajikan pada Gambar 1.




Figure 1: Arsitektur Sistem Evaluasi

2.2 Dataset Penelitian dan Tahapan Preprocessing

Dataset yang digunakan dalam penelitian ini bersumber dari *Indonesian Massive Multitask Language Understanding* (IndoMMLU) [1]. Penelitian ini memfokuskan pada 9 domain bahasa, yaitu Bahasa Lampung, Bahasa Bali, Bahasa Makassar, Bahasa Banjar, Bahasa Madura, Bahasa Indonesia, Bahasa Dayak Ngaju, Bahasa Sunda, dan Bahasa Jawa. Masing-masing domain bahasa terdiri atas 100 butir soal pilihan ganda (*multiple-choice questions*), sehingga total sampel data primer berjumlah 900 butir soal.

Sebelum pengujian, dataset IndoMMLU mentah melalui empat tahapan *preprocessing*: (1) **Filtering Domain Bahasa**, yaitu menyaring data soal agar hanya memuat 9 domain bahasa yang diteliti; (2) **Seleksi dan Penataan Kolom Data**, yaitu memilih atribut penting (nomor, subject, soal, jawaban, dan kunci); (3) **Pembentukan Narasi Jawaban Referensi** (jawaban_benar_teks), yaitu mengekstrak teks murni pilihan jawaban benar secara otomatis berdasarkan kolom kunci tanpa huruf opsi (A/B/C/D/E) untuk evaluasi kemiripan teks; serta (4) **Normalisasi Format Teks**, yaitu menyeragamkan format UTF-8 dan pembersihan karakter spasi berlebih. Struktur master dataset hasil *preprocessing* disajikan pada Tabel 1.

Table 1: Struktur Kolom Dataset IndoMMLU Hasil Preprocessing

No	Nama Data	Sumber	Keterangan
1	nomor	IndoMMLU	Penanda urutan nomor soal
2	subject	IndoMMLU	Penanda domain bahasa soal
3	soal	IndoMMLU	Teks pertanyaan pilihan ganda
4	jawaban	IndoMMLU	Opsi pilihan jawaban pilihan ganda (A, B, C, D, E)
5	kunci	IndoMMLU	Penanda huruf jawaban benar dalam format A/B/C/D/E
6	jawaban_benar_teks	Preprocessing	Teks narasi jawaban benar hasil ekstraksi otomatis dari kolom kunci

2.3 Perancangan Prompt Pengujian (Non-CoT vs CoT)

Perancangan *prompt* bertujuan mengarahkan model menghasilkan format keluaran yang konsisten. Perbandingan struktur *prompt* Non-CoT dan CoT disajikan pada Gambar 2.




Figure 2: Perancangan dan Perbandingan Format Prompt Non-Chain-of-Thought (Non-CoT) dan Chain-of-Thought (CoT)

Penjelasan kedua format *prompt* adalah sebagai berikut:

1. **Prompt Non-Chain-of-Thought (Non-CoT):** Model diinstruksikan memberikan jawaban akhir secara langsung tanpa uraian langkah penalaran: *"Jawablah pertanyaan berikut. Berikan hanya jawaban akhir teks tanpa opsi (A/B/C/D/E)"*. Format ini menghasilkan respons singkat dengan konsumsi token minimal.
2. **Prompt Chain-of-Thought (CoT):** Model diinstruksikan melakukan penalaran bertahap sebelum menyimpulkan jawaban: *"Jawablah pertanyaan berikut dengan berpikir langkah demi langkah... lalu di baris terakhir tulis format eksak: Jawaban akhir: [Teks jawaban tanpa huruf opsi]"*. Sistem mengekstrak baris jawaban akhir tersebut untuk dievaluasi.

2.4 Model LLM dan Konfigurasi Pengujian

Model LLM yang digunakan adalah **GPT-4o mini** (gpt-4o-mini-2024-07-18) yang diakses melalui OpenAI REST API. Model ini dipilih karena memiliki efisiensi komputasi tinggi, latensi rendah, serta kapabilitas penalaran yang unggul pada tugas evaluasi bahasa dan penalaran terstruktur [4, 11]. Seluruh pengujian dijalankan dengan parameter suhu (*temperature*) $T = 0,0$ guna memastikan determinisme keluaran respons model secara konsisten [7].

2.5 Skenario Pengujian

Evaluasi disusun ke dalam 4 skenario komprehensif:

- **Skenario 1 (Baseline Per Domain):** Pengujian dilakukan pada masing-masing dari 9 domain bahasa secara terpisah dengan 100 butir soal per domain (total 900 butir soal).
- **Skenario 2 (Multi-Domain 225 Soal):** Pengujian acak gabungan dari seluruh 9 domain bahasa dengan proporsi 25 soal per domain (total 225 butir soal).
- **Skenario 3 (Multi-Domain 450 Soal):** Pengujian acak gabungan dari seluruh 9 domain bahasa dengan proporsi 50 soal per domain (total 450 butir soal).
- **Skenario 4 (Multi-Domain Skala Penuh 900 Soal):** Pengujian acak gabungan seluruh 9 domain bahasa dengan proporsi 100 soal per domain (total 900 butir soal).

2.6 Rumus Matematis dan Metrik Pengukuran

Untuk mengukur derajat kemiripan teks jawaban model terhadap jawaban referensi secara kuantitatif, digunakan algoritma *Levenshtein Distance* [2, 15–17].

2.6.1 Perhitungan Jarak Levenshtein

Diberikan dua string teks, yaitu string jawaban model s dengan panjang $m = \text{len}(s)$ dan string referensi t dengan panjang $n = \text{len}(t)$. Matriks jarak Levenshtein $\text{lev}(i, j)$ berukuran $(m + 1) \times (n + 1)$ dihitung melalui Persamaan (1):

$$\text{lev}_{s,t}(i, j) = \begin{cases} i, & \text{jika } j = 0 \\ j, & \text{jika } i = 0 \\ \text{lev}_{s,t}(i - 1, j - 1), & \text{jika } s[i] = t[j] \\ 1 + \min \begin{cases} \text{lev}_{s,t}(i - 1, j) & \text{(deletion)} \\ \text{lev}_{s,t}(i, j - 1) & \text{(insertion)} \\ \text{lev}_{s,t}(i - 1, j - 1) & \text{(substitution)} \end{cases}, & \text{jika } s[i] \neq t[j] \end{cases} \quad (1)$$

di mana $\text{lev}(m, n)$ menyatakan jumlah operasi edit minimum untuk mengubah string s menjadi string t .

2.6.2 Persentase Kemiripan Teks (Similarity Score)

Berdasarkan jarak Levenshtein $\text{lev}(m, n)$, persentase kemiripan dihitung menggunakan Persamaan (2):

$$\text{Similarity}(s, t) = \left(1 - \frac{\text{lev}_{s,t}(m, n)}{\max(m, n)} \right) \times 100\% \quad (2)$$

2.6.3 Rata-rata Kemiripan Teks (Average Similarity)

Rata-rata persentase kemiripan untuk suatu skenario pengujian dengan N butir soal dihitung dengan Persamaan (3):

$$\text{Similarity}_{\text{avg}} = \frac{1}{N} \sum_{k=1}^N \text{Similarity}_k \quad (3)$$

2.6.4 Akurasi Pencocokan Eksak (Exact Match Accuracy)

Butir soal bernilai benar (*Exact Match*) jika teks jawaban model identik dengan jawaban referensi ($\text{Similarity}_k = 100\%$). Akurasi keseluruhan dihitung melalui Persamaan (4) dan (5):

$$\text{Accuracy} = \frac{\sum_{k=1}^N \text{Correct}_k}{N} \times 100\% \quad (4)$$

$$\text{Correct}_k = \begin{cases} 1, & \text{jika } \text{Similarity}_k = 100\% \\ 0, & \text{jika } \text{Similarity}_k < 100\% \end{cases} \quad (5)$$

Proses evaluasi sistematis dirangkum pada Algoritma 1.

Algorithm 1 Prosedur Evaluasi Akurasi ChatGPT Menggunakan Levenshtein Distance

Require: Dataset IndoMMLU $\mathcal{D} = \{(Q_k, O_k, R_k)\}_{k=1}^N$, Model GPT-4o mini $\mathcal{M}$, Mode $\in \{\text{Non-CoT}, \text{CoT}\}$

Ensure: Metrik Akurasi (%) dan Rata-rata Similarity (%)

1: $\text{total_correct} \leftarrow 0, \text{sum_similarity} \leftarrow 0$

2: **for each** $(Q_k, O_k, R_k) \in \mathcal{D}$ **do**

3: $\text{prompt}_k \leftarrow \text{GeneratePrompt}(\text{Mode}, Q_k, O_k)$

4: $\text{response}_k \leftarrow \text{CallOpenAI_API}(\mathcal{M}, \text{prompt}_k, \text{temp} = 0.0)$

5: $\text{ans}_k \leftarrow \text{ExtractAnswer}(\text{Mode}, \text{response}_k)$

6: $m \leftarrow \text{len}(\text{ans}_k), n \leftarrow \text{len}(R_k)$

7: $\text{dist}_k \leftarrow \text{ComputeLevenshtein}(\text{ans}_k, R_k, m, n)$

8: $\text{sim}_k \leftarrow (1 - \text{dist}_k / \max(m, n)) \times 100\%$

9: $\text{sum_similarity} \leftarrow \text{sum_similarity} + \text{sim}_k$

10: **if** $\text{sim}_k == 100\%$ **then**

11: $\text{total_correct} \leftarrow \text{total_correct} + 1$

12: **end if**

13: **end for**

14: $\text{Accuracy} \leftarrow (\text{total_correct} / N) \times 100\%$

15: $\text{Similarity}_{\text{avg}} \leftarrow \text{sum_similarity} / N$

16: **return** Accuracy, $\text{Similarity}_{\text{avg}}$

▷ Persamaan (1)

▷ Persamaan (2)

3. Hasil dan Pembahasan

3.1 Hasil Pengujian Per Domain Bahasa (Skenario 1)

Pengujian Skenario 1 dilakukan secara independen terhadap 9 domain bahasa IndoMMLU dengan 100 butir soal per domain (total 900 butir soal). Hasil perbandingan skor kemiripan (*similarity*) dan akurasi jumlah soal benar disajikan pada Tabel 2.

Table 2: Perbandingan Hasil Pengujian Skenario 1 Per Domain Bahasa

Domain Bahasa	Similarity Non-CoT	Similarity CoT	Soal Benar Non-CoT	Soal Benar CoT	Metode Unggul
Bahasa Lampung	61,60%	66,92%	46/100 (46%)	56/100 (56%)	CoT (+10)
Bahasa Bali	55,49%	62,14%	38/100 (38%)	49/100 (49%)	CoT (+11)
Bahasa Makassar	59,88%	59,39%	37/100 (37%)	37/100 (37%)	Setara
Bahasa Banjar	62,77%	61,03%	45/100 (45%)	45/100 (45%)	Setara
Bahasa Madura	59,36%	55,06%	40/100 (40%)	37/100 (37%)	Non-CoT (+3)
Bahasa Indonesia	93,86%	95,92%	90/100 (90%)	94/100 (94%)	CoT (+4)
Bahasa Dayak Ngaju	61,02%	57,88%	33/100 (33%)	33/100 (33%)	Setara
Bahasa Sunda	69,70%	73,39%	62/100 (62%)	66/100 (66%)	CoT (+4)
Bahasa Jawa	76,18%	77,23%	63/100 (63%)	66/100 (66%)	CoT (+3)
Rata-rata / Total	66,65%	67,66%	454/900 (50,44%)	483/900 (53,67%)	CoT Unggul (+29)

Berdasarkan Tabel 2, **Bahasa Indonesia** mencapai performa tertinggi dengan skor *similarity* 95,92% dan akurasi 94%, mengonfirmasi representasi korpus bahasa nasional yang sangat kuat pada model. Pada rumpun bahasa daerah, **Bahasa Jawa** (77,23%, 66 benar) dan **Bahasa Sunda** (73,39%, 66 benar) menempati posisi tertinggi. Sebaliknya, bahasa daerah dengan sumber daya rendah seperti **Bahasa Dayak Ngaju** dan **Bahasa Makassar** hanya mencapai akurasi 33% dan 37%.

Metode CoT berhasil meningkatkan jumlah jawaban benar pada 5 domain (Lampung, Bali, Indonesia, Sunda, Jawa) dengan peningkatan terbesar pada Bahasa Bali (+11 soal) dan Bahasa Lampung (+10 soal). Pada 3 domain (Makassar, Banjar, Dayak Ngaju), kedua metode menghasilkan akurasi identik. Namun, pada **Bahasa Madura**, Non-CoT justru lebih unggul (40 vs 37 soal), menunjukkan bahwa penalaran buatan model pada kosakata Madura tertentu rentan mengalami halusinasi leksikal (*reasoning error*). Rincian distribusi klasifikasi jawaban per butir soal disajikan pada Tabel 3.

Table 3: Rincian Distribusi Kebenaran Jawaban Per Butir Soal pada Skenario 1

Domain Bahasa	Kedua Metode Benar	Hanya Non-CoT Benar	Hanya CoT Benar	Kedua Metode Salah
Bahasa Lampung	36	10	20	34
Bahasa Bali	27	11	22	40
Bahasa Makassar	24	13	13	50
Bahasa Banjar	31	14	14	41
Bahasa Madura	20	20	17	43
Bahasa Indonesia	88	2	6	4
Bahasa Dayak Ngaju	20	13	13	54
Bahasa Sunda	54	8	12	26
Bahasa Jawa	55	8	11	26
Total Butir	355	99	128	318

3.2 Hasil Pengujian Multi-Domain (Skenario 2, 3, dan 4)

Evaluasi gabungan domain dilakukan untuk menguji stabilitas performa penalaran model saat menghadapi perpindahan konteks bahasa daerah secara acak dan simultan. Pengujian dilakukan menggunakan sembilan domain bahasa dengan jumlah sampel yang berbeda, yaitu 25, 50, dan 100 soal untuk setiap domain. Variasi jumlah sampel tersebut digunakan untuk melihat konsistensi performa model ketika jumlah data pengujian meningkat. Selain membandingkan nilai *similarity* dan akurasi, pengujian juga memperhatikan penggunaan token dan rata-rata latensi untuk melihat efisiensi respons dari masing-masing metode. Hasil pengujian multi-domain dirangkum pada Tabel 4.

Table 4: Perbandingan Performa Pengujian Multi-Domain (Skenario 2, 3, dan 4)

Skenario Pengujian	Metode	Similarity (%)	Soal Benar / Akurasi	Total Token	Rata-rata Latensi (s)
Skenario 2 (Multi-Domain) (9 Bahasa × 25 Soal = 225)	Non-CoT	68,60%	121 / 225 (53,78%)	16.307	1,77 s
	CoT	68,27%	123 / 225 (54,67%)	88.819	5,16 s
Skenario 3 (Multi-Domain) (9 Bahasa × 50 Soal = 450)	Non-CoT	70,18%	247 / 450 (54,89%)	34.068	1,42 s
	CoT	69,37%	249 / 450 (55,33%)	180.602	5,00 s
Skenario 4 (Multi-Domain) (9 Bahasa × 100 Soal = 900)	Non-CoT	67,30%	469 / 900 (52,11%)	71.908	1,46 s
	CoT	65,55%	456 / 900 (50,67%)	372.965	5,48 s

3.3 Analisis Komparatif Gabungan 4 Skenario

Untuk memberikan pemahaman visual mengenai dinamika performa pada seluruh skenario, perbandingan akurasi *exact match* dan skor kemiripan disajikan pada Gambar 3.




Figure 3: Grafik Perbandingan Komparatif Performa Metode Non-CoT dan CoT pada Seluruh Skenario Pengujian (Skenario 1–4): (a) Akurasi Exact Match (%), (b) Skor Kemiripan Levenshtein (%)

Berdasarkan Tabel 4 dan Gambar 3, terdapat beberapa temuan empiris utama:

1. Pada Skenario 1–3, metode CoT menunjukkan keunggulan pada akurasi *exact match* (+3,23% pada Skenario 1, +0,89% pada Skenario 2, dan +0,44% pada Skenario 3). Namun, margin keunggulan tersebut semakin menyempit seiring bertambahnya variasi domain dan jumlah data.
2. Pada skor kemiripan *similarity* Skenario 2 dan 3, Non-CoT mencatat skor lebih tinggi dibanding CoT (68,60% vs 68,27% dan 70,18% vs 69,37%). Hal ini disebabkan respons CoT yang menyertakan narasi penalaran tambahan sehingga memperbesar jarak Levenshtein ketika teks jawaban akhir tidak terisolasi secara sempurna.
3. Pada **Skenario 4 (skala penuh 900 butir soal)**, metode Non-CoT berbalik unggul mutlak atas CoT baik dari segi akurasi (52,11% vs 50,67%) maupun skor kemiripan (67,30% vs 65,55%). Pada volume data besar dengan pergantian bahasa daerah secara acak, model rentan mengalami disorientasi konteks semantik (*context drift*) selama proses penalaran langkah demi langkah.

3.4 Analisis Trade-Off Efisiensi Komputasi (Token dan Latensi)

Evaluasi aspek efisiensi komputasi menunjukkan bahwa metode *Chain-of-Thought* membutuhkan konsumsi sumber daya yang jauh lebih besar:

- **Penggunaan Token:** Metode CoT mengonsumsi rata-rata $5,18\times$ hingga $5,44\times$ lipat lebih banyak token dibandingkan Non-CoT (contoh pada Skenario 4: 372.965 token CoT berbanding 71.908 token Non-CoT).
- **Waktu Respons (Latensi):** Rata-rata waktu inferensi CoT berkisar antara **5,00–5,48 detik per soal**, atau $3,5\times$ hingga $3,8\times$ lebih lambat dibandingkan Non-CoT yang hanya memerlukan **1,42–1,77 detik per soal**.

Dengan margin peningkatan akurasi CoT yang sangat tipis pada pengujian per domain (+3,23%) dan penurunan akurasi pada pengujian multi-domain skala besar (-1,44%), penggunaan CoT untuk soal pilihan ganda bahasa daerah dinilai **kurang efisien dari segi biaya operasional (*cost-inefficient*)**.

4. Kesimpulan

Berdasarkan hasil evaluasi dan pembahasan yang telah dilakukan, dapat ditarik kesimpulan sebagai berikut:

1. Metode *Chain-of-Thought* (CoT) terbukti efektif meningkatkan akurasi jawaban ChatGPT (GPT-4o mini) pada pengujian per domain bahasa (Skenario 1) dengan akurasi 53,67% (483/900 soal benar) dan *similarity* 67,66%, mengungguli Non-CoT yang mencatat akurasi 50,44% (454/900 soal benar) dan *similarity* 66,65%. Peningkatan signifikan terjadi pada Bahasa Bali (+11 soal) dan Bahasa Lampung (+10 soal).
2. Bahasa Indonesia mencatat performa tertinggi (akurasi 94%, *similarity* 95,92%), diikuti oleh Bahasa Jawa (77,23%) dan Bahasa Sunda (73,39%). Sementara itu, bahasa daerah beresumber daya rendah seperti Bahasa Dayak Ngaju (33%) dan Bahasa Makassar (37%) memiliki akurasi terendah karena keterbatasan data latih korpus bahasa daerah pada LLM.
3. Pada pengujian *multi-domain* skala penuh (Skenario 4), metode Non-CoT mencatat performa yang lebih unggul dibandingkan CoT, baik dari segi akurasi (52,11% vs 50,67%) maupun *similarity* (67,30% vs 65,55%) akibat kerentanan CoT terhadap disorientasi penalaran pada perpindahan bahasa yang dinamis.
4. Metode CoT membutuhkan konsumsi token $5,18\times$ – $5,44\times$ lebih besar dan latensi waktu $3,5\times$ – $3,8\times$ lebih lambat dibandingkan Non-CoT. Untuk tugas klasifikasi pemahaman bahasa daerah berbasis pilihan ganda, metode Non-CoT direkomendasikan sebagai pilihan yang jauh lebih efisien dan stabil.

Saran untuk pengembangan penelitian selanjutnya antara lain:

1. Menerapkan teknik *Few-Shot CoT* atau pendekatan *prompt fine-tuning* dengan menyertakan contoh penalaran dalam bahasa daerah yang relevan untuk meminimalkan halusinasi semantik [22, 23].
2. Melakukan pengujian perbandingan pada model LLM multibahasa sumber terbuka (*open-source*) berbasis arsitektur Transformers mutakhir guna membandingkan ketahanan pemahaman bahasa daerah di luar ekosistem OpenAI [25].
3. Mengembangkan metrik evaluasi hybrid yang memadukan edit distance dengan representasi embedding semantik teks untuk menangkap variasi jawaban berbahasa daerah secara lebih fleksibel [9, 19].

REFERENSI

- [1] F. Koto, N. Aisyah, H. Li, and T. Baldwin, "Large Language Models Only Pass Primary School Exams in Indonesia: A Comprehensive Test on IndoMMLU," in *Proc. 2023 Conf. Empir. Methods Nat. Lang. Process. (EMNLP)*, 2023, pp. 11210–11225.
- [2] J. Beernaerts, E. Debever, M. Lenoir, B. De Baets, and N. Van de Weghe, "A method based on the Levenshtein Distance metric for the comparison of multiple movement patterns described by matrix sequences of different length," *Expert Syst. Appl.*, vol. 115, pp. 373–385, Jan. 2019, doi: 10.1016/j.eswa.2018.07.076.
- [3] A. Maitland, R. Fowkes, and S. Maitland, "Can ChatGPT pass the MRCP (UK) written examinations? Analysis of performance and errors using a clinical decision-reasoning framework," *BMJ Open*, vol. 14, no. 3, Mar. 2024, doi: 10.1136/bmjopen-2023-080558.
- [4] Y. T. Ting *et al.*, "Performance of ChatGPT incorporated Chain-of-Thought method in bilingual nuclear medicine physician board examinations," *Digit. Health*, vol. 10, Jan. 2024, doi: 10.1177/20552076231224074.
- [5] J. W. A. Strachan *et al.*, "Testing theory of mind in large language models and humans," *Nat. Hum. Behav.*, vol. 8, no. 7, pp. 1285–1295, Jul. 2024, doi: 10.1038/s41562-024-01882-z.
- [6] G. G. Lee, E. Latif, X. Wu, N. Liu, and X. Zhai, "Applying large language models and Chain-of-Thought for automatic scoring," *Comput. Educ. Artif. Intell.*, vol. 6, Jun. 2024, doi: 10.1016/j.caeai.2024.100213.
- [7] J. Chen, L. Chen, H. Huang, and T. Zhou, "When do you need Chain-of-Thought Prompting for ChatGPT?," *arXiv preprint arXiv:2304.03262*, 2023.
- [8] D. Hendrycks *et al.*, "Measuring Massive Multitask Language Understanding," in *Proc. 9th Int. Conf. Learn. Represent. (ICLR)*, 2021.
- [9] W. Li, L. Li, T. Xiang, X. Liu, W. Deng, and N. Garcia, "Can multiple-choice questions really be useful in detecting the abilities of LLMs?," *arXiv preprint arXiv:2403.17752*, 2024.
- [10] G. Zhu, X. Zhang, and C. Chen, "Assessing and enhancing the reliability of Chinese large language models in dental implantology," *BMC Oral Health*, vol. 25, no. 1, Dec. 2025, doi: 10.1186/s12903-025-06648-1.
- [11] Z. W. Lim *et al.*, "Benchmarking large language models' performances for myopia care: a comparative analysis of ChatGPT-3.5, ChatGPT-4.0, and Google Bard," *eClinicalMedicine (The Lancet Discovery Science)*, 2023.
- [12] C. W. Tsai, Y. J. Lin, J. U. Hou, S. C. Tsai, P. C. Yeh, and C. H. Kao, "Optimizing patient education for radioactive iodine therapy and the role of ChatGPT incorporating Chain-of-Thought technique: ChatGPT questionnaire," *Digit. Health*, vol. 11, Jan. 2025, doi: 10.1177/20552076251357468.
- [13] H. C. Lind-Combs, T. Bent, R. F. Holt, C. G. Clopper, and E. Brown, "Comparing Levenshtein Distance and dynamic time warping in predicting listeners' judgments of accent distance," *Speech Commun.*, vol. 155, Nov. 2023, doi: 10.1016/j.specom.2023.102987.
- [14] J. Song, G. Qin, Y. Liang, J. Yan, and M. Sun, "SIDI LDNG: A similarity-based intrusion detection system using improved Levenshtein Distance and N-gram for CAN," *Comput. Secur.*, vol. 142, Jul. 2024, doi: 10.1016/j.cose.2024.103847.
- [15] B. Berger, M. S. Waterman, and Y. W. Yu, "Levenshtein Distance, Sequence Comparison and Biological Database Search," *IEEE Trans. Inf. Theory*, vol. 67, no. 6, pp. 3287–3294, Jun. 2021, doi: 10.1109/TIT.2020.2996543.
- [16] T. Petty, J. Hannig, T. I. Huszar, and H. Iyer, "A New String Edit Distance and Applications," *Algorithms*, vol. 15, no. 7, Jul. 2022, doi: 10.3390/a15070242.
- [17] P. Sanda Mette, E. Arriyanti, and S. Lailiyah, "Penerapan Algoritma Levenshtein Distance Untuk Pengecekan Kemiripan Judul Skripsi di STMIK Widya Cipta Dharma," *Jurnal Nasional Komputasi dan Teknologi Informasi (JNKTI)*, vol. 8, no. 3, 2025.
- [18] B. Young, T. Faris, and L. Armogida, "Levenshtein Distance as a measure of accuracy and precision in forensic PCR-MPS methods," *Forensic Sci. Int. Genet.*, vol. 55, Nov. 2021, doi: 10.1016/j.fsigen.2021.102594.
- [19] J. Mugaanyi, L. Cai, S. Cheng, C. Lu, and J. Huang, "Evaluation of Large Language Model Performance and Reliability for Citations and References in Scholarly Writing: Cross-Disciplinary Study," *J. Med. Internet Res.*, vol. 26, no. 1, Jan. 2024, doi: 10.2196/52935.
- [20] E. S. Barry, J. Merkebu, and L. Varpio, "State-of-the-art literature review methodology: A six-step approach for knowledge synthesis," *Perspect. Med. Educ.*, vol. 11, no. 5, pp. 281–288, Oct. 2022, doi: 10.1007/s40037-022-00725-9.
- [21] K. Ji, Z. Wu, J. Han, G. Zhai, and J. Liu, "Evaluating ChatGPT-4's performance on oral and maxillofacial queries: Chain-of-Thought and standard method," *Front. Oral Health*, vol. 6, 2025, doi: 10.3389/froh.2025.1541976.
- [22] S. Kim *et al.*, "The CoT Collection: Improving Zero-shot and Few-shot Learning of Language Models via Chain-of-Thought Fine-Tuning," in *Proc. 2023 Conf. Empir. Methods Nat. Lang. Process. (EMNLP)*, 2023.
- [23] B. Ji, H. Liu, M. Du, and S.-K. Ng, "Chain-of-Thought Improves Text Generation with Citations in Large Language Models," *arXiv preprint arXiv:2402.16438*, 2024.
- [24] R. N. Suharto, M. H. Z. Al Faroby, and Y. Setiawan, "Comparative Evaluation of YOLO-based Models for Indonesian License Plate Detection and Recognition with EASY OCR," in *Procedia Computer Science*, Elsevier B.V., vol. 260, 2025, pp. 943–952, doi: 10.1016/j.procs.2025.09.037.
- [25] T. Wolf *et al.*, "Transformers: State-of-the-Art Natural Language Processing," in *Proc. 2020 Conf. Empir. Methods Nat. Lang. Process.: System Demonstrations*, 2020, pp. 38–45.